

Sección 7.6 Hogg

1. La media de Y cuando $x = 0$ en el modelo de regresión lineal simple es $\alpha - \beta\bar{x} = \alpha_1$. El estimador de minimos cuadrados de α_1 es $\hat{\alpha} - \hat{\beta}\bar{x} = \hat{\alpha}_1$.

- a) Encuentre la distribución de $\hat{\alpha}_1$ bajo los supuestos habituales del modelo.

Sabemos que

$$\hat{\alpha} \sim N\left(\alpha, \frac{\sigma^2}{n}\right) \quad y \quad \hat{\beta} \sim N\left(\beta, \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right)$$

Dado que $\hat{\alpha}_1 = \hat{\alpha} - \hat{\beta}\bar{x}$ tenemos que $\hat{\alpha}_1$ viene dada por una distribución normal la cual es

$$\begin{aligned} \hat{\alpha}_1 &\sim N(\mu_1 - \mu_2, \sigma_1^2 + \sigma_2^2) \\ &\sim N\left(\alpha - \beta\bar{x}, \frac{\sigma^2}{n} + \frac{\sigma^2(\bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right) \\ &\sim N\left(\alpha_1, \sigma^2\left(\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right)\right) \end{aligned}$$

Por lo tanto $\hat{\alpha}_1$ tiene una distribución normal la cual es

$$\hat{\alpha}_1 \sim N\left(\alpha_1, \sigma^2\left(\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right)\right)$$

- b) Obtenga una expresión para un intervalo de confianza bilateral de $100(1 - \gamma) \%$ para α_1

Haciendo uso del inciso anterior tenemos que

$$Z = \frac{\hat{\alpha}_1 - \alpha_1}{\sigma \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}}$$

Ahora consideremos a

$$W = \frac{n\hat{\sigma}^2}{\sigma^2}$$

De esta manera definamos a

$$T^2 = \frac{Z}{\sqrt{\frac{W}{n-2}}} = \frac{\frac{\hat{\alpha}_1 - \alpha_1}{\sigma \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}}}{\sqrt{\frac{n\hat{\sigma}^2}{\sigma^2}}} = \frac{\frac{\hat{\alpha}_1 - \alpha_1}{\hat{\sigma} \sqrt{\frac{n}{n-2}}}}{\hat{\sigma} \sqrt{\frac{n}{n-2}} \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}} \sim t_{n-2}$$

De esta manera un intervalo con $100(1 - \gamma) \%$ de confianza para $\hat{\alpha}_1$ es

$$\hat{\alpha}_1 = t_{\frac{\gamma}{2}}(n-2) \hat{\sigma} \sqrt{\frac{n}{n-2}} \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}$$

3. Para los datos dados en el ejercicio 6,5 – 3, con las suposiciones usuales,

<i>Midterm</i>	<i>Final</i>	<i>Midterm</i>	<i>Final</i>
70	87	67	73
74	79	70	83
80	88	64	79
84	98	74	91
80	96	82	94

a) Encuentre un intervalo de confianza del 95 % para $\mu(x)$ cuando $x = 68, 75$ y 82 .

Recordemos que el intervalo de confianza para $\mu(x)$ viene dado por

$$\hat{\alpha} + \hat{\beta}(x - \bar{x}) \pm ct_{\frac{\gamma}{2}}(n - 2)$$

Donde

$$c = \sqrt{\frac{n\hat{\sigma}^2}{n-2}} \sqrt{\frac{1}{n} + \frac{(x - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}$$

Con esto los intervalos de confianza del 95 % son:

$$\begin{aligned} \mu(68) & \text{ es } [75,28068, 85,11132] \\ \mu(75) & \text{ es } [83,83858, 90,77742] \\ \mu(82) & \text{ es } [89,10949, 99,73051] \end{aligned}$$

El código utilizado para obtener los valores anteriores fue

```
x <- c(70, 74, 80, 84, 80, 67, 70, 64, 74, 82)
y <- c(87, 79, 88, 98, 96, 73, 83, 79, 91, 94)
n <- length(x)
```

```
intento <- data.frame(x,y)
```

```
regresion <- lm(y ~ x, intento)
summary(regresion)
anova(regresion)
```

```
xp <- mean(x)    #x promedio#
yp <- mean(y)    #y promedio#
```

```
w <- sum(x^2) - (xp^2)*n  #sum[(x_i - xp)^2]#
```

```
gama <- 0.05
t <- qt(1-(gama/2), 8)
```

```
xv <- c(68, 75, 82)
N <- length(xv)
ici <- c()
icd <- c()
```

```

D <- c()
I <-c()

sigma2 <- 180.0/n
B <- 1.016
A <- yp

for(i in 1:N){
  ici[i] = A + B*(xv[i]-xp)
  icd[i] <- sqrt( (n*sigma2)/(n-2) ) * sqrt( (1/n)+ ((xv[i]-xp)^2)/
D[i] <- ici[i]+icd[i]
I[i] <- ici[i]-icd[i]
cat("El intervalo de confianza para x=",xv[i],"es ","[",I[i],"",",",D[i])
}

```

Donde el código nos da

```

El intervalo de confianza para x= 68 es [ 75.28068 , 85.11132 ]
El intervalo de confianza para x= 75 es [ 83.83858 , 90.77742 ]
El intervalo de confianza para x= 82 es [ 89.10949 , 99.73051 ]

```

b) Encuentre un intervalo de predicción del 95 % para Y cuando $x = 68, 75$ y 82 .

Recordemos que el intervalo de confianza para Y_{n+1} viene dado por

$$\hat{\alpha} + \hat{\beta}(x - \bar{x}) \pm dt_{\frac{\gamma}{2}}(n-2)$$

Donde

$$d = \sqrt{\frac{n\hat{\sigma}^2}{n-2}} \sqrt{1 + \frac{1}{n} + \frac{(x - \bar{x})^2}{\sum_{i=1}^n [(x_i - \bar{x})^2]}}$$

Con esto los intervalos de confianza del 95 % para Y son:

```

x = 68  es  [68,20402 , 92,18798]
x = 75  es  [75,83263 , 98,78337]
x = 82  es  [82,26069 , 106,5793]

```

El código utilizado para obtener los valores anteriores fue

```

x <- c(70, 74, 80, 84, 80, 67, 70, 64, 74, 82)
y <- c(87, 79, 88, 98, 96, 73, 83, 79, 91, 94)
n <- length(x)

intento <- data.frame(x,y)

regresion <- lm(y ~ x, intento)
summary(regresion)
anova(regresion)

```

```

xp <- mean(x)      #x promedio#
yp <- mean(y)      #y estimador#

w <- sum(x^2) - (xp^2)*n  #sum[(x_i - xp)^2]#

gama <- 0.05
t <- qt(1-(gama/2),8)

xv <- c(68, 75, 82)
N <- length(xv)
ici <- c()
icd <- c()
D <- c()
I <-c()

sigma2 <- 180.0/n  #Manual es el residuo y suma sq entre n #
B <- 1.016        #Manual es estimate std, x #
A <- yp

for(i in 1:N){
  ici[i] = A + B*(xv[i]-xp)
  icd[i] <- sqrt( (n*sigma2)/(n-2) ) * sqrt(1 + (1/n)+ ((xv[i]-xp)^2)/v)
  D[i] <- ici[i]+icd[i]
  I[i] <- ici[i]-icd[i]
  cat("El intervalo de confianza para x=",xv[i],"es ","[",I[i],"-",D[i],"]")
}

```

Donde el código nos devuelve que

El intervalo de confianza para $x=68$ es [68.20402 , 92.18798]

El intervalo de confianza para $x=75$ es [75.83263 , 98.78337]

El intervalo de confianza para $x=82$ es [82.26069 , 106.5793]

5) Para los datos de cigarrillos del ejercicio 6,5 – 7, con las suposiciones usuales,

<i>Brand</i>	<i>x</i>	<i>y</i>	<i>Brand</i>	<i>x</i>	<i>y</i>
<i>Capri</i>	9	6	<i>Now</i>	3	4
<i>Carlton</i>	4	6	<i>Salem</i>	17	18
<i>Kent</i>	14	14	<i>Triumph</i>	6	8
<i>KoolMilds</i>	12	12	<i>True</i>	7	8
<i>MarlboroLights</i>	10	12	<i>Vantage</i>	8	13
<i>MeritUltras</i>	5	7	<i>VirginiaSlims</i>	15	13

a) Encuentre un intervalo de confianza del 95 % para $\mu(x)$ cuando $x = 5, 10$ y 15 .

Recordemos que el intervalo de confianza para $\mu(x)$ viene dado por

$$\hat{\alpha} + \hat{\beta}(x - \bar{x}) \pm ct_{\frac{\gamma}{2}}(n-2)$$

Donde

$$c = \sqrt{\frac{n\hat{\sigma}^2}{n-2}} \sqrt{\frac{1}{n} + \frac{(x - \bar{x})^2}{\sum_{i=1}^n [(x_i - \bar{x})^2]}}$$

Con esto los intervalos de confianza del 95 % son:

$$\begin{aligned} \mu(5) & \text{ es } [4,896982, 8,443851] \\ \mu(10) & \text{ es } [9,463715, 12,06812] \\ \mu(15) & \text{ es } [12,71796, 17,00487] \end{aligned}$$

El código utilizado para obtener los valores anteriores fue

```
x <- c(9, 4, 14, 12, 10, 5, 3, 17, 6, 7, 8, 15)
y <- c(6, 6, 14, 12, 12, 7, 4, 18, 8, 8, 13, 13)
n <- length(x)

intento <- data.frame(x,y)

regresion <- lm(y ~ x, intento)
summary(regresion)
anova(regresion)

xp <- mean(x)      #x promedio#
yp <- mean(y)      #y estimador#

w <- sum(x^2) - (xp^2)*n #sum[(x_i - xp)^2]#

gama <- 0.05
t <- qt(1-(gama/2),10)

xv <- c(5, 10, 15)
N <- length(xv)
ici <- c()
icd <- c()
D <- c()
I <-c()

sigma2 <- 39.528/n #Manual es el residuo y suma sq entre n #
B <- 0.8191      #Manual es estimate std, x #
A <- yp

for(i in 1:N){
  ici[i] = A + B*(xv[i]-xp)
  icd[i] <- sqrt( (n*sigma2)/(n-2) ) * sqrt( (1/n)+ ((xv[i]-xp)^2)/w )
  D[i] <- ici[i]+icd[i]
  I[i] <- ici[i]-icd[i]
  cat("El intervalo de confianza para x=",xv[i]," es ","[",I[i],",",D[i],"]")
}
```

Donde el código nos da

El intervalo de confianza para $x = 5$ es [4.896982 , 8.443851]

El intervalo de confianza para $x = 10$ es [9.463715 , 12.06812]

El intervalo de confianza para $x = 15$ es [12.71796 , 17.00487]

- b) Encuentre un intervalo de predicción del 95 % para Y cuando $x = 5, 10$ y 15 .

Recordemos que el intervalo de confianza para Y_{n+1} viene dado por

$$\hat{\alpha} + \hat{\beta}(x - \bar{x}) \pm dt_{\frac{\gamma}{2}}(n-2)$$

Donde

$$d = \sqrt{\frac{n\hat{\sigma}^2}{n-2}} \sqrt{1 + \frac{1}{n} + \frac{(x - \bar{x})^2}{\sum_{i=1}^n [(x_i - \bar{x})^2]}}$$

Con esto los intervalos de confianza del 95 % para Y son:

$x = 5$ es [1,898713 , 11,44212]

$x = 10$ es [6,148579 , 15,38325]

$x = 15$ es [9,940188 , 19,78265]

El código utilizado para obtener los valores anteriores fue

```
x <- c(9, 4, 14, 12, 10, 5, 3, 17, 6, 7, 8, 15)
y <- c(6, 6, 14, 12, 12, 7, 4, 18, 8, 8, 13, 13)
n <- length(x)
```

```
intento <- data.frame(x,y)
```

```
regresion <- lm(y ~ x, intento)
summary(regresion)
anova(regresion)
```

```
xp <- mean(x)      #x promedio#
yp <- mean(y)      #y estimador#
```

```
w <- sum(x^2) - (xp^2)*n  #sum[(x_i - xp)^2]#
```

```
gama <- 0.05
t <- qt(1-(gama/2),10)
```

```
xv <- c(5, 10, 15)
N <- length(xv)
ici <- c()
icd <- c()
D <- c()
I <-c()
```

```
sigma2 <- 39.528/n  #Manual es el residuo y suma sq entre n #
```

```

B <- 0.8191          #Manual es estimate std , x #
A <- yp

for(i in 1:N){
  ici[i] = A + B*(xv[i]-xp)
  icd[i] <- sqrt( (n*sigma2)/(n-2) ) * sqrt( 1 + (1/n)+ ((xv[i]-xp)
D[i] <- ici[i]+icd[i]
I[i] <- ici[i]-icd[i]
  cat("El intervalo de confianza para x=",xv[i],"es ","[",I[i],"",D[i]
}

```

El código nos devuelve

El intervalo de confianza para x= 5 es [1.898713 , 11.44212]

El intervalo de confianza para x= 10 es [6.148579 , 15.38325]

El intervalo de confianza para x= 15 es [9.940188 , 19.78265]

9. Por el método de mínimos cuadrados, ajuste la ecuación cúbica $y = \beta_1 + \beta_2 x + \beta_3 x^2 + \beta_4 x^3$ a los siguientes 10 puntos observados(x,y): (0,1), (-1,-3), (0,3), (1,3), (-1,-1), (2,10), (0,0), (-2,-9), (-1,-2), (2,8).

El método nos dice que resolver el siguiente sistema de ecuaciones

$$\beta_1 \sum_{j=1}^{10} x_{1j}^2 + \beta_2 \sum_{j=1}^{10} x_{1j}x_{2j} + \beta_3 \sum_{j=1}^{10} x_{1j}x_{3j} + \beta_4 \sum_{j=1}^{10} x_{1j}x_{4j} = \sum_{j=1}^{10} x_{1j}y_j$$

$$\beta_1 \sum_{j=1}^{10} x_{2j}x_{1j} + \beta_2 \sum_{j=1}^{10} x_{2j}^2 + \beta_3 \sum_{j=1}^{10} x_{2j}x_{3j} + \beta_4 \sum_{j=1}^{10} x_{2j}x_{4j} = \sum_{j=1}^{10} x_{2j}y_j$$

$$\beta_1 \sum_{j=1}^{10} x_{3j}x_{1j} + \beta_2 \sum_{j=1}^{10} x_{3j}x_{2j} + \beta_3 \sum_{j=1}^{10} x_{3j}^2 + \beta_4 \sum_{j=1}^{10} x_{3j}x_{4j} = \sum_{j=1}^{10} x_{3j}y_j$$

$$\beta_1 \sum_{j=1}^{10} x_{4j}x_{1j} + \beta_2 \sum_{j=1}^{10} x_{4j}x_{2j} + \beta_3 \sum_{j=1}^{10} x_{4j}x_{3j} + \beta_4 \sum_{j=1}^{10} x_{4j}^2 = \sum_{j=1}^{10} x_{4j}y_j$$

donde sea $x_1 = 1, x_2 = x, x_3 = x^2, x_4 = x^3$

$$\sum_{j=1}^{10} x_{1j}^2 = 1 + 1 + \dots + 1 = 10$$

$$\sum_{j=1}^{10} x_{1j}x_{2j} = 1(0) + 1(-1) + 1(0) + 1(1) + 1(-1) + 1(2) + 1(0) + 1(-2) + 1(-1) + 1(2) = 0$$

$$\sum_{j=1}^{10} x_{1j}x_{3j} = 1(0)^2 + 1(-1)^2 + 1(0)^2 + 1(1)^2 + 1(-1)^2 + 1(2)^2 + 1(0)^2 + 1(-2)^2 + 1(-1)^2 + 1(2)^2 = 16$$

$$\sum_{j=1}^{10} x_{1j}x_{4j} = 1(0)^3 + 1(-1)^3 + 1(0)^3 + 1(1)^3 + 1(-1)^3 + 1(2)^3 + 1(0)^3 + 1(-2)^3 + 1(-1)^3 + 1(2)^3 = 6$$

$$\sum_{j=1}^{10} x_{1j}y_j = 1(1) + 1(-3) + 1(3) + 1(3) + 1(-1) + 1(10) + 1(0) + 1(-9) + 1(-2) + 1(8) = 10$$

$$\sum_{j=1}^{10} x_{2j}x_{1j} = \sum_{j=1}^{10} x_{1j}x_{2j} = 0$$

$$\sum_{j=1}^{10} x_{2j}^2 = \sum_{j=1}^{10} x_{1j}x_{3j} = 16$$

$$\sum_{j=1}^{10} x_{2j}x_{3j} = \sum_{j=1}^{10} x_{1j}x_{4j} = 6$$

$$\begin{aligned}
\sum_{j=1}^{10} x_{2j}x_{4j} &= (0)^4 + (-1)^4 + (0)^4 + (1)^4 + (-1)^4 + (2)^4 + (0)^4 + (-2)^4 + (-1)^4 + (2)^4 = 52 \\
\sum_{j=1}^{10} x_{2j}y_j &= (0)(1) + (-1)(-3) + (0)(3) + (1)(3) + (-1)(-1) + 2(10) + 0(0) + (-2)(-9) + 1(-2) + 2(8) = 63 \\
\sum_{j=1}^{10} x_{3j}x_{1j} &= \sum_{j=1}^{10} x_{1j}x_{3j} = 16 \\
\sum_{j=1}^{10} x_{3j}x_{2j} &= \sum_{j=1}^{10} x_{2j}x_{3j} = 6 \\
\sum_{j=1}^{10} x_{3j}^2 &= \sum_{j=1}^{10} x_{2j}x_{4j} = 52 \\
\sum_{j=1}^{10} x_{3j}x_{4j} &= (0)^5 + (-1)^5 + (0)^5 + (1)^5 + (-1)^5 + (2)^5 + (0)^5 + (-2)^5 + (-1)^5 + (2)^5 = 30 \\
\sum_{j=1}^{10} x_{3j}y_j &= (0)^2(1) + (-1)^2(-3) + (0)^2(3) + (1)^2(3) + (-1)^2(-1) + 2^2(10) + 0^2(0) + (-2)^2(-9) + 1^2(-2) + 2^2(8) = 33 \\
\sum_{j=1}^{10} x_{4j}x_{1j} &= \sum_{j=1}^{10} x_{2j}x_{3j} = 6 \\
\sum_{j=1}^{10} x_{4j}x_{2j} &= \sum_{j=1}^{10} x_{3j}^2 = 52 \\
\sum_{j=1}^{10} x_{4j}x_{3j} &= \sum_{j=1}^{10} x_{3j}x_{4j} = 30 \\
\sum_{j=1}^{10} x_{4j}^2 &= (0)^6 + (-1)^6 + (0)^6 + (1)^6 + (-1)^6 + (2)^6 + (0)^6 + (-2)^6 + (-1)^6 + (2)^6 = 196 \\
\sum_{j=1}^{10} x_{4j}y_j &= (0)^3(1) + (-1)^3(-3) + (0)^3(3) + (1)^3(3) + (-1)^3(-1) + 2^3(10) + 0^3(0) + (-2)^3(-9) + 1^3(-2) + 2^3(8) = 225
\end{aligned}$$

De esta manera el sistema de ecuaciones es:

$$\begin{array}{rrrrrr}
10\beta_1 & + & 0\beta_2 & + & 16\beta_3 & + & 6\beta_4 & = & 10 \\
0\beta_1 & + & 16\beta_2 & + & 6\beta_3 & + & 52\beta_4 & = & 63 \\
16\beta_1 & + & 6\beta_2 & + & 52\beta_3 & + & 30\beta_4 & = & 33 \\
6\beta_1 & + & 52\beta_2 & + & 30\beta_3 & + & 196\beta_4 & = & 225
\end{array}$$

Resolviendo el sistema de ecuaciones con R y dado que $y = \beta_1 + \beta_2x + \beta_3x^2 + \beta_4x^3$ se tiene que

$$y = 1,103668 + 2,032695x - 0,2974482x^2 + 0,6204147x^3$$

El código para resolver el sistema de ecuaciones en R es

```

A <- matrix(c(10,0,16,6, 0,16,6,52, 16,6,52,30, 6,52,30,196 ), ncol = 4 )
b <- c(10, 63, 33, 225)
Solucion <- solve(A, b)
cat("La soluciones del sistema viene dado por" ,Solucion)

```

El código nos imprime

La soluciones del sistema viene dado por 1.103668 2.032695 -0.2974482 0.6204147

11. (La información presentada en este ejercicio proviene de Westview Blueberry Farm y National Oceanic e Informes de Administración Atmosférica [NOAA].) Para los siguientes datos emparejados, (x,y), x da la lluvia para junio para Holland, Michigan, y da la producción de arándano en miles de libras de Westview Granja de arándanos: (4.11,56.2) (5.49,45.3) (5.35,31.0) (6.53,30.1) (5.18,40.0) (4.89,38.5) (2.09,50.0) (1.40,45.8) (4.52,45.9) (1.11,32.4) (0.60,18.2) (3.80,56.1) Los datos son de 1971 a 1989 para aquellos años en los que la última helada ocurrió el 10 de mayo o antes.

a) Encuentre el coeficiente de correlación para estos datos.

Recordemos que el coeficiente de correlacion se define como

$$r = \frac{S_{xy}}{\sqrt{S_{xx}}\sqrt{S_{yy}}}$$

Del cual

$$S_{xx} = \sum_{i=1}^n x_i^2 - n\bar{x}^2 \quad S_{yy} = \sum_{i=1}^n y_i^2 - n\bar{y}^2 \quad S_{xy} = \sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}$$

Usando *R* obtuvimos

$$r = 0,1430206$$

El código utilizado fue

```
x=c(4.11,5.49,5.35,6.53,5.18,4.89,2.09,1.40,4.52,1.11,0.60,3.80)
y=c(56.2,45.3,31.0,30.1,40.0,38.5,50.0,45.8,45.9,32.4,18.2,56.1)
cor(x,y)
```

El código nos devuelve

```
[1] 0.1430206
```

b) Encuentre la línea de regresión de mínimos cuadrados


La línea de regresión de mínimos cuadrados es

$$y = 37,6843 + 0,8276x$$

La cual fue obtenida apartir del siguiente código en *R*

```
x=c(4.11,5.49,5.35,6.53,5.18,4.89,2.09,1.40,4.52,1.11,0.60,3.80)
y=c(56.2,45.3,31.0,30.1,40.0,38.5,50.0,45.8,45.9,32.4,18.2,56.1)
data=data.frame(x,y)
qreg=lm(y~x,data)
summary(qreg) # Observando lo que nos da el código #
```

c) Haz un diagrama de dispersión de los datos con los mínimos cuadrados



La grafica fue obtenida apartir del siguiente codigo


```
# Datos #
x=c(4.11,5.49,5.35,6.53,5.18,4.89,2.09,1.40,4.52,1.11,0.60,3.80)
y=c(56.2,45.3,31.0,30.1,40.0,38.5,50.0,45.8,45.9,32.4,18.2,56.1)

# Graficar la linea #
lin<-seq(0, 60, 0.1) # Crea una secuencia de valores de x #
plot(x,y)           # Grafica los datos, el cual es un diagrama de dispersio
lines(lin,37.6843 + 0.8276*lin ,col="red") # Grafica de la linea#
```

d) Calcule y represente gráficamente los residuos. ¿Parece apropiada la regresión lineal?

Dado que la linea de los mínimos cuadrados es $y = 37,6843 + 0,8276x$ esto implica que $\hat{y}_i = 37,6843 + 0,8276x$, por otro lado recordemos que el residuo se encuentra definido como $e_i = y_i - \hat{y}_i$

Con lo anterior, la gráfica es



Del cual podemos decir que no parece apropiada la regresión lineal debido a que una gran cantidad de valores no se encuentra cercana a la línea del eje x .

Lo grafica fue obtenida con el siguiente código

```
x=c(4.11,5.49,5.35,6.53,5.18,4.89,2.09,1.40,4.52,1.11,0.60,3.80)
y=c(56.2,45.3,31.0,30.1,40.0,38.5,50.0,45.8,45.9,32.4,18.2,56.1)
r=c()
re=c()
n=length(x)
for(i in 1:n){
  r[i]=0.8275959*x[i] + 37.68335
  re[i]=y[i]-r[i]
}
```


```
### Grafica de Residuos ###
xseq=seq(-300,300,0.01)
yseq = xseq -xseq
plot(x, re, main='Grafica de Residuos', xlab = 'x', ylab= 'e', col = 'cornflowerblue')
lines(xseq, yseq)
```

e) Encuentre la curva de regresión cuadrática de mínimos cuadrados.

La regresión cuadrática de mínimos cuadrados fue calculado con R la cual obtuvimos que

$$y = 12,845 + 22,566x + 3,218x^2$$

Y su gráfico es



Lo anterior fue obtenido con el siguiente código

```
x=c(4.11,5.49,5.35,6.53,5.18,4.89,2.09,1.40,4.52,1.11,0.60,3.80)
y=c(56.2,45.3,31.0,30.1,40.0,38.5,50.0,45.8,45.9,32.4,18.2,56.1)
x2=x^2
data=data.frame(x,y)
qreg=lm(y~x+x2,data)
summary(qreg)
```

Realizar Grafica

```
lin<-seq(0, 60, 0.1) # Crea una secuencia de valores de x #
```


```
plot(x,y) # Grafica los datos, el cual es un diagrama de dispersión
```

```
lines(lin, 12.845+22.566*lin-3.218*lin^2, col="red") # Grafica de la línea
```

f) Calcule y represente gráficamente los residuos. ¿La regresión cuadrática parece ser apropiada?

Dado que la línea de los mínimos cuadrados es $12,845 + 22,566x + 3,218x^2$ esto implica que $\hat{y}_i = 12,845 + 22,566x + 3,218x^2$, por otro lado recordemos que el residuo se encuentra definido como $e_i = y_i - \hat{y}_i$

Con lo anterior, la gráfica es



Del cual podemos decir que no parece apropiada la regresión cuadrática debido a que una gran cantidad de valores no se encuentra cercana a la línea del eje x .

Lo grafica fue obtenida con el siguiente codigo

```
x=c(4.11,5.49,5.35,6.53,5.18,4.89,2.09,1.40,4.52,1.11,0.60,3.80)
y=c(56.2,45.3,31.0,30.1,40.0,38.5,50.0,45.8,45.9,32.4,18.2,56.1)
x2=x^2
r=c()
re=c()
n=length(x)
for(i in 1:n){
  r[i]= -3.218*x2[i]+ 22.566*x[i] + 12.845
  re[i]=y[i]-r[i]
}
```

```
### Grafica de Residuos ###
xseq=seq(-300,300,0.01)
yseq = xseq -xseq
plot(x, re, main='Grafica de Residuos', xlab = 'x', ylab= 'e', col = 'cornflowerblue')
lines(xseq, yseq)
```

g) Dé una breve interpretación de sus resultados.

Observando ambas gráficas de la regresión cuadrática y la lineal podemos decir que la regresión cuadrática es un mejor modelo para los datos que la regresión lineal dado que los valores se encuentran menos dispersos.

13. Pruebe que:

$$\sum_{i=1}^n [Y_i - \alpha - \beta(x_i - \bar{x})]^2 = n(\hat{\alpha} - \alpha)^2 + (\hat{\beta} - \beta)^2 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x}_i)]^2.$$

Primero recordemos que

$$\hat{\alpha} = \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i \Leftrightarrow n\hat{\alpha} = \sum_{i=1}^n Y_i \quad y \quad \hat{\beta} = \frac{\sum_{i=1}^n Y_i(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \Leftrightarrow \hat{\beta} \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n Y_i(x_i - \bar{x})$$

Prueba

$$\begin{aligned} \sum_{i=1}^n [Y_i - \alpha - \beta(x_i - \bar{x})]^2 &= \sum_{i=1}^n [(\hat{\alpha} - \alpha) + (\hat{\beta} - \beta)(x_i - \bar{x}) + (Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x}))]^2 \\ &= \sum_{i=1}^n (\hat{\alpha} - \alpha)^2 + \sum_{i=1}^n (\hat{\beta} - \beta)^2 (x_i - \bar{x})^2 + \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2 \\ &\quad + 2 \sum_{i=1}^n (\hat{\alpha} - \alpha)(\hat{\beta} - \beta)(x_i - \bar{x}) + 2 \sum_{i=1}^n (\hat{\alpha} - \alpha)(Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})) \\ &\quad + 2 \sum_{i=1}^n (\hat{\beta} - \beta)(x_i - \bar{x})(Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})) \end{aligned} \quad (1)$$

Del cual observemos que

$$\begin{aligned} 2 \sum_{i=1}^n (\hat{\alpha} - \alpha)(\hat{\beta} - \beta)(x_i - \bar{x}) &= 2(\hat{\alpha} - \alpha)(\hat{\beta} - \beta) \sum_{i=1}^n (x_i - \bar{x}) = 2(\hat{\alpha} - \alpha)(\hat{\beta} - \beta)(n\bar{x} - n\bar{x}) = 2(\hat{\alpha} - \alpha)(\hat{\beta} - \beta)(0) \\ &= 0 \end{aligned}$$

$$\begin{aligned} 2 \sum_{i=1}^n (\hat{\alpha} - \alpha)(Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})) &= 2(\hat{\alpha} - \alpha) \sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})) = 2(\hat{\alpha} - \alpha) \left(\sum_{i=1}^n Y_i - \sum_{i=1}^n \hat{\alpha} - \sum_{i=1}^n \hat{\beta}(x_i - \bar{x}) \right) \\ &= 2(\hat{\alpha} - \alpha)(n\hat{\alpha} - n\hat{\alpha} - \hat{\beta} \sum_{i=1}^n (x_i - \bar{x})) = 2(\hat{\alpha} - \alpha) \left(-\hat{\beta} \sum_{i=1}^n (x_i - \bar{x}) \right) \\ &= 2(\hat{\alpha} - \alpha)(-\hat{\beta}(n\bar{x} - n\bar{x})) = 2(\hat{\alpha} - \alpha)(-\hat{\beta}(0)) \\ &= 0 \end{aligned}$$

$$\begin{aligned} 2 \sum_{i=1}^n (\hat{\beta} - \beta)(x_i - \bar{x})(Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})) &= 2(\hat{\beta} - \beta) \sum_{i=1}^n (x_i - \bar{x})(Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})) \\ &= 2(\hat{\beta} - \beta) \left(\sum_{i=1}^n (x_i - \bar{x})Y_i - \sum_{i=1}^n (x_i - \bar{x})\hat{\alpha} - \sum_{i=1}^n (x_i - \bar{x})\hat{\beta}(x_i - \bar{x}) \right) \\ &= 2(\hat{\beta} - \beta) \left(\hat{\beta} \sum_{i=1}^n (x_i - \bar{x})^2 - \hat{\alpha} \sum_{i=1}^n (x_i - \bar{x}) - \hat{\beta} \sum_{i=1}^n (x_i - \bar{x})^2 \right) \\ &= 2(\hat{\beta} - \beta) \left(-\hat{\alpha} \sum_{i=1}^n (x_i - \bar{x}) \right) \\ &= 2(\hat{\beta} - \beta)(-\hat{\alpha}(n\bar{x} - n\bar{x})) \\ &= 2(\hat{\beta} - \beta)(-\hat{\alpha}(0)) \\ &= 0 \end{aligned}$$

De esta manera regresando a (1) se concluye que

$$\begin{aligned}
 \sum_{i=1}^n [Y_i - \alpha - \beta(x_i - \bar{x})]^2 &= \sum_{i=1}^n (\hat{\alpha} - \alpha)^2 + \sum_{i=1}^n (\hat{\beta} - \beta)^2 (x_i - \bar{x})^2 + \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2 \\
 &\quad + 2 \sum_{i=1}^n (\hat{\alpha} - \alpha)(\hat{\beta} - \beta)(x_i - \bar{x}) + 2 \sum_{i=1}^n (\hat{\alpha} - \alpha)(Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})) \\
 &\quad + 2 \sum_{i=1}^n (\hat{\beta} - \beta)(x_i - \bar{x})(Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})) \\
 &= \sum_{i=1}^n (\hat{\alpha} - \alpha)^2 + \sum_{i=1}^n (\hat{\beta} - \beta)^2 (x_i - \bar{x})^2 + \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2 \\
 &= n(\hat{\alpha} - \alpha)^2 + (\hat{\beta} - \beta)^2 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2
 \end{aligned}$$

Q.E.D.

15. Pruebe que un intervalo del $100(1 - \gamma)\%$ para σ^2 es:

$$\left[\frac{n\hat{\sigma}^2}{\chi_{\gamma/2}(n-2)}, \frac{n\hat{\sigma}^2}{\chi_{1-\gamma/2}(n-2)} \right]$$

Prueba:

Dado que

$$\frac{\sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2}{\sigma^2} = \frac{n\hat{\sigma}^2}{\sigma^2} \geq 0$$

Tenemos que

$$\frac{n\hat{\sigma}^2}{\sigma^2} \sim \chi_{\gamma/2}(n-2)$$

Se sigue que

$$P\left(-\chi_{\gamma/2}(n-2) \leq \frac{n\hat{\sigma}^2}{\sigma^2} \leq \chi_{\gamma/2}(n-2)\right) = 1 - \gamma \quad \Leftrightarrow \quad P\left(\frac{1}{-\chi_{\gamma/2}(n-2)} \geq \frac{\sigma^2}{n\hat{\sigma}^2} \geq \frac{1}{\chi_{\gamma/2}(n-2)}\right) = 1 - \gamma$$

$$P\left(\frac{n\hat{\sigma}^2}{\chi_{\gamma/2}(n-2)} \leq \sigma^2 \leq \frac{n\hat{\sigma}^2}{-\chi_{\gamma/2}(n-2)}\right) = 1 - \gamma \quad \Leftrightarrow \quad P\left(\frac{n\hat{\sigma}^2}{\chi_{\gamma/2}(n-2)} \leq \sigma^2 \leq \frac{n\hat{\sigma}^2}{\chi_{1-\gamma/2}(n-2)}\right) = 1 - \gamma$$

Por lo tanto un intervalo de $(1 - \gamma)100\%$ de confianza para σ^2 esta dado por

$$\left[\frac{n\hat{\sigma}^2}{\chi_{\gamma/2}(n-2)}, \frac{n\hat{\sigma}^2}{\chi_{1-\gamma/2}(n-2)} \right]$$

Q.E.D.

17. Encuentre el intervalo de confianza del 95 % para α , β y σ^2 para la puntuación de las evaluaciones de medio y final del periodo en el **Ejercicio 6.5.3**.

<i>Midterm</i>	<i>Final</i>	<i>Midterm</i>	<i>Final</i>
70	87	67	73
74	79	70	83
80	88	64	79
84	98	74	91
80	96	82	94

- Intervalo del 95 % de confianza para α

Recordemos que un intervalo de confianza para α viene dado por

$$\hat{\alpha} \pm t_{\frac{\gamma}{2}}(n-2) \sqrt{\frac{\hat{\sigma}^2}{n-2}}$$

Haciendo uso de *R* el intervalo de confianza es

$$[83,34099 \quad , \quad 90,25901]$$

- Intervalo del 95 % de confianza para β

Recordemos que un intervalo de confianza para β viene dado por

$$\hat{\beta} \pm t_{\frac{\gamma}{2}}(n-2) \sqrt{\frac{\hat{\sigma}^2}{n-2}} \sqrt{\frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2}}$$

Haciendo uso de *R* el intervalo de confianza es

$$[0,4787344 \quad , \quad 1,553266]$$

- Intervalo del 95 % de confianza para σ^2

Recordemos que un intervalo de confianza para σ^2 viene dado por

$$\left[\frac{n\hat{\sigma}^2}{\chi_{\gamma/2}(n-2)}, \frac{n\hat{\sigma}^2}{\chi_{1-\gamma/2}(n-2)} \right]$$

Haciendo uso de *R* el intervalo de confianza es

$$[10,26545 \quad , \quad 82,57901]$$

Los intervalos de confianza anteriores se obtuvieron apartir del siguiente codigo

```

x <- c(70, 74, 80, 84, 80, 67, 70, 64, 74, 82)
y <- c(87, 79, 88, 98, 96, 73, 83, 79, 91, 94)
n <- length(x)

intento <- data.frame(x,y)

regresion <- lm(y ~ x, intento)
summary(regresion)
anova(regresion)

xp <- mean(x)      #x promedio#
yp <- mean(y)      #y promedio#

sigma2 <- 180.0/n   #sigma2#
B <- 1.016          #Beta#
A <- yp            #Alfa#

gamma <- 0.05
t <- qt(1-(gamma/2), n-2)

# Alfa #
w <- sqrt(sigma2/(n-2))
IA <- A - t*w
DA <- A + t*w

#Beta#
ww <- sqrt((n*sigma2)/(n-2))
www <- sum(x^2) - (xp^2)*n #sum[(x_i - xp)^2]#
IB <- B - t*ww*sqrt(1/www)
DB <- B + t*ww*sqrt(1/www)

#Sigma#
chi <- 0.05
c1 <- qchisq(1-(chi/2), n-2)
c2 <- qchisq(1-(1-chi/2), n-2)
IC <- (n*sigma2)/(c1)
DC <- (n*sigma2)/(c2)

cat("El intervalo de confianza para alfa=", "[", IA, ", ", DA, "]", "\n")
cat("El intervalo de confianza para beta=", "[", IB, ", ", DB, "]", "\n")
cat("El intervalo de confianza para sigma2=", "[", IC, ", ", DC, "]", "\n")

El codigo nos devuelve
El intervalo de confianza para alfa= [ 83.34099 , 90.25901 ]
El intervalo de confianza para beta= [ 0.4787344 , 1.553266 ]
El intervalo de confianza para sigma2= [ 10.26545 , 82.57901 ]

```

19. Usando los datos del **Ejercicio 6.5.8(a)**, encuentre el intervalo de confianza del 95 % para α , β y σ^2

<i>Tipo</i>	<i>mpg City</i>	<i>mpg HWy</i>	<i>Curb Weight</i>
<i>FordFusionV6SE</i>	20	28	3230
<i>ChevroletSebringSedanBase</i>	24	32	3287
<i>ToyotaCamrySolaraSE</i>	24	34	3240
<i>HondaAccordSedan</i>	20	29	3344
<i>AudiA63,2</i>	21	29	3825
<i>BMW5 – series525iSedan</i>	20	29	3450
<i>ChryslerPTCruiserBase</i>	22	29	3076
<i>MercedesE – ClassE350Sedan</i>	19	26	3740
<i>VolkswagenPassatSedan2,0T</i>	23	32	3305
<i>NissanAltima2,5</i>	26	35	3055
<i>KiaOptimaLX2,5</i>	24	34	3142

- Intervalo del 95 % de confianza para α

Recordemos que un intervalo de confianza para α viene dado por

$$\hat{\alpha} \pm t_{\frac{\gamma}{2}}(n-2) \sqrt{\frac{\hat{\sigma}^2}{n-2}}$$

Haciendo uso de R el intervalo de confianza es

$$[29,9873 \quad , \quad 31,28542]$$

- Intervalo del 95 % de confianza para β

Recordemos que un intervalo de confianza para β viene dado por

$$\hat{\beta} \pm t_{\frac{\gamma}{2}}(n-2) \sqrt{\frac{\hat{\sigma}^2}{n-2}} \sqrt{\frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2}}$$

Haciendo uso de R el intervalo de confianza es

$$[0,9232949 \quad , \quad 1,526705]$$

- Intervalo del 95 % de confianza para σ^2

Recordemos que un intervalo de confianza para σ^2 viene dado por

$$\left[\frac{n\hat{\sigma}^2}{\chi_{\gamma/2}(n-2)}, \frac{n\hat{\sigma}^2}{\chi_{1-\gamma/2}(n-2)} \right]$$

Haciendo uso de R el intervalo de confianza es

$$[0,428434 \quad , \quad 3,018083]$$

Los intervalos de confianza anteriores se obtuvieron apartir del siguiente codigo

```
x <- c(20, 24, 24, 20, 21, 20, 22, 19, 23, 26, 24)
y <- c(28, 32, 34, 29, 29, 29, 29, 26, 32, 35, 34)
n <- length(x)

intento <- data.frame(x,y)

regresion <- lm(y ~ x, intento)
summary(regresion)
anova(regresion)

xp <- mean(x)      #x promedio#
yp <- mean(y)      #y promedio#

sigma2 <- 8.150/n   #sigma2#
B <- 1.2250         #Beta#
A <- yp            #Alfa#

gamma <- 0.05
t <- qt(1-(gamma/2), n-2)

# Alfa #
w <- sqrt(sigma2/(n-2))
IA <- A - t*w
DA <- A + t*w

#Beta#
ww <- sqrt((n*sigma2)/(n-2))
www <- sum(x^2) - (xp^2)*n #sum[(x_i - xp)^2]#
IB <- B - t*ww*sqrt(1/www)
DB <- B + t*ww*sqrt(1/www)

#Sigma#
chi <- 0.05
c1 <- qchisq(1-(chi/2), n-2)
c2 <- qchisq(1-(1-chi/2), n-2)
IC <- (n*sigma2)/(c1)
DC <- (n*sigma2)/(c2)

cat("El intervalo de confianza para alfa=", "[", IA, ", ", DA, "]", "\n")
cat("El intervalo de confianza para beta=", "[", IB, ", ", DB, "]", "\n")
cat("El intervalo de confianza para sigma2=", "[", IC, ", ", DC, "]", "\n")
```

El codigo nos devuelve

El intervalo de confianza para alfa= [29.9873 , 31.28542]

El intervalo de confianza para beta= [0.9232949 , 1.526705]

El intervalo de confianza para $\sigma^2 = [0.428434, 3.018083]$

Seccion 12 Devore

33 El ejercicio 16 de la sección 12,2 incluyó la salida de *MINITAB* para una regresión de la altura de la hija sobre la altura del padre medio.

<i>Valordelpadremedio</i>	66,0	65,5	71,5	68,0	70,0	65,5	67,0	70,5	69,5	64,5	67,5
<i>Hija</i>	64,0	63,0	69,0	69,0	69,0	65,0	63,0	68,5	69,0	64,0	67,0

- a) Utilice el resultado para calcular un intervalo de confianza con un nivel de confianza del 95 % para la pendiente β_1 de la línea de regresión de población e interprete el intervalo resultante.

Tenemos que en el Devore y Hogg se modifica como se define la regresión pero en este caso para definir el intervalo de confianza no afecta.

Recordemos que un intervalo de confianza para β_1 viene dado por

$$\hat{\beta}_1 \pm t_{\frac{\gamma}{2}}(n-2) \sqrt{\frac{\hat{\sigma}^2}{n-2} \sqrt{\frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2}}}$$

Haciendo uso de *R* el intervalo de confianza es

[0,5096982 , 1,401302]

El intervalo de confianza se obtuvo apartir del siguiente código

```
x <- c(66.0,65.5,71.5,68.0,70.0,65.5,67.0,70.5,69.5,64.5,67.5)
y <- c(64.0,63.0,69.0,69.0,69.0,65.0,63.0,68.5,69.0,64.0,67.0)
n <- length(x)
```

```
data <- data.frame(x,y)
```

```
regresion <- lm(y ~ x, data)
summary(regresion)
anova(regresion)
```

```
xp <- mean(x)      #x promedio#
yp <- mean(y)      #y promedio#
```

```
sigma2 <- 18.938/n      #sigma2#
B <- 0.9555             #Beta#
A <- 1.6497             #Alfa#
```

```

gamma <- 0.05
t <- qt(1-(gamma/2), n-2)

ww <- sqrt((n*sigma2)/(n-2))
www <- sum(x^2) - (xp^2)*n #sum[(x_i - xp)^2]#

IB <- B - t*ww*sqrt(1/www)
DB <- B + t*ww*sqrt(1/www)

cat("El intervalo de confianza para beta=", "[", IB, ", ", DB, "]" , "\n")

```

El código nos da
El intervalo de confianza para beta= [0.5096982 , 1.401302]

- b) Suponga que anteriormente se había creído que cuando la altura de los padres medios aumentaba 1 pulgada, el cambio promedio verdadero asociado en la altura de la hija sería de al menos 1 pulgada. ¿Los datos de la muestra contradicen esta creencia? Enunciar y probar las hipótesis pertinentes.

Primero recordemos que el modelo de regresión lineal simple no debe usarse para más inferencias (estimaciones del valor medio o predicciones de valores futuros) a menos que la prueba de utilidad del modelo resulte en el rechazo de H_0 para un α adecuadamente pequeño. Apartir de esto tenemos si la hipótesis nula $H_0 : \beta_1 = \beta_{10}$ el valor estadístico de prueba $t = \frac{\hat{\beta}_1 - \beta_{10}}{s_{\hat{\beta}_1}}$ sucede que

Hipotesis alternativa	Región de rechazo para la prueba de nivel α
$H_a : \beta_1 > \beta_{10}$	$t \geq t_{\alpha}(n-2)$
$H_a : \beta_1 < \beta_{10}$	$t \leq -t_{\alpha}(n-2)$
$H_a : \beta_1 \neq \beta_{10}$	$t \geq t_{\alpha}(n-2)$ o $t \leq -t_{\alpha}(n-2)$

Sea $H_0 : \beta_1 = 1$ y $H_1 : \beta_1 < 1$, con los datos obtengamos los siguientes valores

$$t = -0,2258 \quad -t_{\alpha}(n-2) = -1,383$$

Del cual notemos que

$$-0,2258 > -1,383$$

Es decir, no hay motivo para rechazar la hipótesis nula, con $\alpha = 10\%$ donde no hay conflicto entre los datos con la afirmación de que la pendiente es al menos 1.

El código utilizado para obtener los valores anteriores fue:

37 Consulte los datos sobre x = valor de yodo e y = número de cetano dados en el *ejercicio*19.

x	132,0	129,0	120,0	113,2	105,0	92,0	84,0	83,2	88,4	59,0	80,0	81,5	71,0	69,2
y	46,0	48,0	51,0	52,1	54,0	52,0	59,0	58,7	61,6	64,0	61,4	54,6	58,8	58,0

- a) ¿El modelo de regresión lineal simple especifica una relación útil entre las dos variables? Use el procedimiento de prueba apropiado para obtener información sobre el P – *valor* y luego llegue a una conclusión con un nivel de significancia de ,01.

Sea $H_0 : \beta_1 = 0$ y $H_1 : \beta_1 \neq 0$, con los datos y usando R tenemos que

$$t = -6,734 \quad t_{\alpha}(n-2) = 3,05454 \quad p - \text{valor} = 0,00002091$$

Del cual por el p – *valor* podemos notar que es menor que el nivel de significancia, lo que implica que se rechaza la hipótesis nula. Del cual el nivel 0,01, concluye que existe una relación lineal útil.

El código utilizado para encontrar los valores fue:

```
x<-c(132.0,129.0,120.0,113.2,105.0,92.0,84.0,83.2,88.4,59.0,80.0,81.5,71.0,69.2)
y<-c(46.0,48.0,51.0,52.1,54.0,52.0,59.0,58.7,61.6,64.0,61.4,54.6,58.8,58.0)
n <- length(x)
```

```
data <- data.frame(x,y)
```

```
regresion <- lm(y ~ x, data)
summary(regresion)
```

```
gamma <- 0.01
t <- qt(1-(gamma/2), n-2)
```

- b) Calcule un IC del 95 % para el cambio esperado en el número de cetano asociado con un aumento de 10g en el valor de yodo.

Recordemos que un intervalo de confianza para β_1 viene dado por

$$\hat{\beta}_1 \pm t_{\frac{\gamma}{2}}(n-2) \sqrt{\frac{\hat{\sigma}^2}{n-2} \sqrt{\frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2}}}$$

Haciendo uso de R el intervalo de confianza es

$$[-0,2771354 \quad , \quad -0,1416446]$$

El intervalo de confianza se obtuvo apartir del siguiente código

```
x<-c(132.0,129.0,120.0,113.2,105.0,92.0,84.0,83.2,88.4,59.0,80.0,81.5,71.0,69.2)
y<-c(46.0,48.0,51.0,52.1,54.0,52.0,59.0,58.7,61.6,64.0,61.4,54.6,58.8,58.0)
n <- length(x)
```

```
data <- data.frame(x,y)
```

```
regresion <- lm(y ~ x, data)
summary(regresion)
anova(regresion)
```

```

xp <- mean(x)      #x promedio#
yp <- mean(y)      #y promedio#

sigma2 <- 78.92/n   #sigma2#
B <- -0.20939       #Beta#
A <- 75.21243       #Alfa#

gamma <- 0.05
t <- qt(1-(gamma/2), n-2)

ww <- sqrt((n*sigma2)/(n-2))
www <- sum(x^2) - (xp^2)*n #sum[(x_i - xp)^2]#

IB <- B - t*ww*sqrt(1/www)
DB <- B + t*ww*sqrt(1/www)

cat("El intervalo de confianza para beta=", "[", IB, ", ", DB, "]", "\n")

```

47. Astringencia es una característica del vino que hace que sea más áspero, seco y fuerte en la boca del catador del vino. El paper *Analysis of Tannins in Red Wine Using Multiple Methods: Correlation with Perceived Astringency* (Amer. J. Enol. Vitic., 2006: 481–485), reportó en una investigación sobre relación entre astringencia perceptible y la concentración de tanino, usando varios métodos analíticos. Aquí están los datos proporcionados por los autores en x = concentración de tanino y y = astringencia perceptible como fue determinado en el panel de los catadores.

x	0,718	0,808	0,924	1,000	0,667	0,529	0,514	0,559
y	0,428	0,480	0,493	0,978	0,318	0,298	-0,224	0,198
x	0,766	0,470	0,726	0,762	0,666	0,562	0,378	0,779
y	0,326	-0,336	0,765	0,190	0,066	-0,221	-0,898	0,836
x	0,674	0,858	0,406	0,927	0,311	0,319	0,518	0,687
y	0,126	0,305	-0,577	0,779	-0,707	-0,610	-0,648	-0,145
x	0,907	0,638	0,234	0,781	0,326	0,433	0,319	0,238
y	1,007	-0,090	-1,132	0,538	-1,098	-0,581	-0,862	-0,551

Los resultados de las sumas relevantes son:

$$\sum x_i = 19,404, \quad \sum y_i = -0,549, \quad \sum x_i^2 = 13,248032$$

$$\sum y_i^2 = 11,835795, \quad \sum x_i y_i = 3,497811$$

$$S_{xx} = 13,248032 - (19,404)^2/32 = 1,48193150$$

$$S_{yy} = 11,82637622$$

$$S_{xy} = 3,497811 - (19,404)(-0,549)/32 = 3,83071088$$

- a) Pruebe el siguiente modelo de regresión simple para estos datos. Después determine la proporción de astringencia observada que puede ser atribuida al modelo de relación entre la astringencia y la concentración de tanino.

El modelo de regresión lineal viene dado por:

$$y = \hat{\beta}_1 x + b$$

Donde

$$\hat{\beta}_1 = \frac{\sum(x_i - \bar{x})(Y_i - \bar{Y})}{\sum(x_i - \bar{x})^2} \quad y \quad b = \frac{\sum y \cdot \sum x^2 - \sum x \cdot \sum(x \cdot y)}{n \sum x^2 - (\sum x)^2}$$

Usando las sumas relevantes tenemos.

$$\hat{\beta}_1 = \frac{n \sum(x \cdot y) - \sum x \cdot \sum y}{n \sum x^2 - (\sum x)^2} = \frac{(3,497811) \cdot (32) - (19,404) \cdot (-0,549)}{(32) \cdot (13,248032) - (19,404)^2} = \frac{122,5827}{47,42181} = 2,584945$$

$$b = \frac{\sum y \cdot \sum x^2 - \sum x \cdot \sum(x \cdot y)}{n \sum x^2 - (\sum x)^2} = \frac{(-0,549) \cdot (13,248032) - (19,404) \cdot (3,497811)}{(32) \cdot (13,248032) - (19,404)^2} = \frac{-75,14469}{47,42181} = -1,584602$$

Entonces

$$y = -1,584602 + 2,584945x$$

El coeficiente de determinación está dado por

$$r^2 = \left(\frac{S_{XY}}{\sqrt{S_{XX}} \sqrt{S_{YY}}} \right)^2$$

De esta manera

$$r^2 = \left(\frac{3,83071088}{\sqrt{1,48193150} \sqrt{11,82637622}} \right)^2 = \left(\frac{3,83071088}{4,186392} \right)^2 = (0,9150387)^2 = 0,8372958$$

b) Calcule e interprete el intervalo de confianza para la pendiente de la verdadera regresión lineal.

El intervalo de confianza es

$$[2,268979 \quad , \quad 2,900821]$$

El cual fue obtenido apartir del siguiente codigo hecho en R

```
x=c(0.718,0.808,0.924,1.000,0.667,0.529,0.514,0.559,
0.766,0.470,0.726,0.762,0.666,0.562,0.378,0.779,
0.674,0.858,0.406,0.927,0.311,0.319,0.518,0.687,
0.907,0.638,0.234,0.781,0.326,0.433,0.319,0.238)
```

```
y=c(0.428,0.480,0.493,0.978,0.318,0.298,-0.224,0.198,
0.326,-0.336,0.765,0.190,0.066,-0.221,-0.898,0.836,
0.126,0.305,-0.577,0.779,-0.707,-0.610,-0.648,-0.145,
1.007,-0.090,-1.132,0.538,-1.098,-0.581,-0.862,-0.551)
```

```
n=length(x)
data=data.frame(x,y)
reg=lm(y~x,data)
```

```
summary(regr)
anova(regr)

sigma=1.9242
alpha=-1.5846
beta=2.5849

xvar=mean(x)
x1=.6
yg=alpha+beta*x1
s=sqrt((sum(y^2)-alpha*sum(y)-beta*3.83071088)*1/(n-2))

gamma <- 0.05
t <- qt(1-(gamma/2), n-2)

a=sqrt((n*sqrt(sigma))/(n-2))
b=1.48193150
sb=s/sqrt(b)

lib=beta-t*sb
lsb=beta+t*sb
```

- c) Estime el promedio de astringencia para una sola muestra de vino cuya concentración de tanino sea .6, hágalo de tal forma que sea fiable y preciso.

El intervalo de confianza es

$$[-0,101649 \quad , \quad 0,05432899]$$

Donde la media de astringencia es $\hat{y} = -0,03366$

El cual lo anterior fue obtenido con el siguiente código que es una continuación del anterior

```
li=yg-t*sy
ls=yg+t*sy
```

- d) Prediga la astringencia para una sola muestra de vino cuya concentración de tanino sea .6, hágalo de tal forma que sea fiable y preciso.

El intervalo de confianza es

$$[-0,4242084 \quad , \quad 0,3568884]$$

Donde la media de astringencia es $\hat{y} = -0,03366$

El cual lo anterior fue obtenido con el siguiente código que es una continuación del anterior

```
li=yg-t*sqrt(s^2+sy^2)
ls=yg+t*sqrt(s^2+sy^2)
```

- e) ¿Hay una evidencia convincente para concluir que la media de astringencia sea positiva cuando la concentración de tanino sea .7? Declare lo y pruebe la hipótesis adecuada.

Sea $H_0 : \beta = 0$ y $H_1 : \beta \neq 0$, dado que si la media era 0,6 el intervalo de confianza era muy cercano al 0 podemos concluir que si acepta la hipótesis para la concentración de tanino 0,7

57. La prueba de oxido de aceite de una turbina (TOST) y la prueba de rotación de la bomba (RBOT) son 2 diferentes procedimientos para evaluar la estabilidad del vapor de la oxidación de aceite en las turbinas. El artículo "*Dependence of Oxidation Stability of Steam Turbine Oil on Base Oil Composition*" (*J. Soc. Tribologists Lubricat. Engrs., Oct. 1997: 19–24*) reportó que las observaciones de la compañía con $x =$ TOST tiempo en horas y $y =$ RBOT tiempo en minutos para 12 especímenes de aceite.

TOST	4200	3600	3750	3675	4050	2770
RBOT	370	340	375	310	350	200
TOST	4870	4500	3450	2700	3750	3300
RBOT	400	375	285	225	345	285

- a) Calcule e interprete el valor de coeficiente de correlación de la muestra (como lo hicieron los autores del artículo).

El coeficiente de correlación es

$$r = 0,9231564$$

El cual fue obtenido en *R* con el siguiente código

```
x<-c(4200,3600,3750,3675,4050,2770,4870,4500,3450,2700,3750,3300)
y<-c(370,340,375,310,350,200,400,375,285,225,345,285)
cor(x,y)
```

- b) ¿Como afecta el valor r si $x =$ el tiempo de RBOT y $y =$ el tiempo de TOST?

Tenemos que $r = 0,9231564$ con esto podemos decir que no lo afecta dado que es el mismo valor que el inciso anterior. Este valor fue obtenido a partir del siguiente código en *R*.

```
y=c(4200,3600,3750,3675,4050,2770,4870,4500,3450,2700,3750,3300)
x=c(370,340,375,310,350,200,400,375,285,225,345,285)
cor(x,y)
```


- c) ¿Cómo afectaría el valor r si el tiempo de RBOT fuera expresado en horas?

Tenemos que $r = 0,9231564$ con esto podemos decir que no lo afecta al valor ya que obtuvimos el mismo que el inciso *a*. Este valor fue obtenido a partir del siguiente código en *R*


```
x=c(4200,3600,3750,3675,4050,2770,4870,4500,3450,2700,3750,3300)
y=c(370,340,375,310,350,200,400,375,285,225,345,285)*60
cor(x,y)
```


- d) Construya un diagrama de dispersión y diagramas de probabilidad normal y comente.

Diagrama de dispersión



Diagramas de probabilidad normal





Notemos que los gráficos normales si parecen seguir una distribución normal cada uno, pero el gráfico de dispersión se le observa muestra una ligera curvatura.

Los anteriores graficas se obtuvieron de los siguientes codigos realizados en R

Diagrama de dispersión

```
x=c(4200,3600,3750,3675,4050,2770,4870,4500,3450,2700,3750,3300)
y=c(370,340,375,310,350,200,400,375,285,225,345,285)*60
plot(x,y,xlab='TOST',ylab='RBOT',main='Diagrama de dispersion ',col='red')
```

Diagramas de probabilidad normal

```
x=c(4200,3600,3750,3675,4050,2770,4870,4500,3450,2700,3750,3300)
y=c(370,340,375,310,350,200,400,375,285,225,345,285)*60
qqnorm(x,main="Diagrama de probabilidad normal de x")
qqline(x,col="red")
qqnorm(y,main="Diagrama de probabilidad normal de y")
qqline(y,col="red")
```

- e) Realice una prueba de hipótesis para decidir si el tiempo de RBOT y TOST están linealmente relacionados. Recordemos que la hipótesis cuando $H_0 : \rho = 0$ es cierta tiene por valor estadístico de prueba $T = \frac{R\sqrt{n-2}}{\sqrt{1-R^2}}$ sucede que

Hipotesis alternativa	Región de rechazo para la prueba de nivel α
$H_a : \rho > 0$	$t \geq t_{\alpha}(n-2)$
$H_a : \rho < 0$	$t \leq -t_{\alpha}(n-2)$
$H_a : \rho \neq 0$	$t \leq -t_{\alpha/2}(n-2)$ o $t \geq t_{\alpha/2}(n-2)$

El donde se quiere hacer una prueba de hipótesis

$H_0 : \rho = 0$

$H_a : \rho \neq 0$

Se obtuve que el valor de $T = 7,593888$ y p -valor es aproximadamente 0,00002 donde podemos notar que es menor que el nivel de significancia, lo que implica que la hipótesis nula se rechaza en el nivel 0,001 teniendo una relación lineal útil.

Se usó el siguiente código en R

```
x=c(4200,3600,3750,3675,4050,2770,4870,4500,3450,2700,3750,3300)
y=c(370,340,375,310,350,200,400,375,285,225,345,285)*60
n=length(x)
data=data.frame(x,y)
regresion=lm(y ~ x, data)
summary(regresion)
yp=mean(y)
xp=mean(x)
a=(x-xp)^2
b=(y-yp)^2
R=sum((x-xp)*(y-yp))/(sqrt(sum(a))*sqrt(sum(b)))
T=R*sqrt(n-2)/sqrt(1-R^2)
```

71. La resistencia al desgaste de los componentes de cierto reactor nuclear hechos de Zircaloy-2 son parcialmente determinados por sus propiedades de la capa de óxido. Los siguientes datos que aparecen en el artículo que supone un nuevo método no destructivo para monitorear la capa de espesor (*"Monitoring of Oxide Layer Thickness on Zircaloy-2 by the Eddy Current Test Method," J. Test. Eval., 1987: 333–336*). Las variables son x = espesor de la capa de óxido (μm) y y = Respuesta de corriente de Foucault (unidades arbitrarias).

x	0	7	17	114	133
y	20,3	19,8	19,5	15,9	15,1

x	142	190	218	237	285
y	14,7	11,9	11,5	8,3	6,6


- a) Los autores resumieron la relación dada por la ecuación de la línea de los mínimos cuadrados como $y = 20,6 - 0,47x$. Calcule y grafique los residuales contra x y después comente en la adecuación del modelo de regresión lineal simple.

Dado que la línea de los mínimos cuadrados es $y = 20,6 - 0,47x$ esto implica que $\hat{y}_i = 20,6 - 0,47x_i$, por otro lado recordemos que el residuo se encuentra definido como $e_i = y_i - \hat{y}_i$ y de igual forma tenemos que los residuos de estandarización vienen dados por $e_i^* = \frac{e_i}{s_e \sqrt{1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{S_{xx}}}} = \frac{e_i}{s_e}$ donde

$s_e = 0,7921$ con esto calculemos dichos valores.

x	y	$\hat{y} = 20,6 - 0,47x$	$e = y - \hat{y}$	$e^* = \frac{e}{s_e}$
0	20.3	20.600	-0.300	-0.3787401
7	19.8	20.271	-0.471	-0.5946219
17	19.5	19.801	-0.301	-0.3800025
114	15.9	15.242	0.658	0.8307032
133	15.1	14.349	0.751	0.9481126
142	14.7	13.926	0.774	0.9771493
190	11.9	11.670	0.230	0.2903674
218	11.5	10.354	1.146	1.4467870
237	8.3	9.461	-1.161	-1.4657240
285	6.6	7.205	-0.605	-0.7637925

Con lo anterior realicemos la gráfica de residuos




Del cual podemos observar que la gráfica varios puntos se encuentran despegados de la recta $y = 0$ lo cual podemos decir que este modelo no es tan adecuado.

- b) Use $s = 0,7921$ para calcular los residuos de la estandarización de una muestra de regresión lineal simple. Construya un diagrama de residuos de estandarización y comente. También construya un diagrama de probabilidad normal y comente.

Tabla del inciso (a) ya incluye los residuos de la estandarización de la muestra de regresión lineal, mas precisamente es la columna 5 de la tabla. Ahora construyamos un diagrama



Ahora construyamos el diagrama de probabilidad normal



Del cual podemos observar que la grafica de residuos estandarizados casi no cambiar con la grafica de residuos, de igual manera observamos que los diagramas de probabilidad normal muestran que los datos de los residuos estandarizados no siguen una distribución normal.

Todo lo anterior se realizo con el siguiente código

```
x<-c(0,7,17,114,133,142,190,218,237,285)
y<-c(20.3,19.8,19.5,15.9,15.1,14.7,11.9,11.5,8.3,6.6)
s <- 0.7921
n <- length(x)

yi<-c()
```

```
for(i in 1:n){
  yi[i] <- 20.6-0.047*x[i]
}
e <- (y - yi)
es <- e/s

### Grafica de Residuos ###
xseq=seq(-300,300,0.01)
yseq = xseq -xseq
plot(x, e, main='Grafica de Residuos', xlab = 'x', ylab= 'e', col = 'cornflowerblue')
lines(xseq, yseq)

### Grafica de Residuos de Estandarizacion ###
plot(x, es, main='Grafica de Residuos de Estandarizacion', xlab = 'x', ylab= 'e')
lines(xseq, yseq)

### Grafica normal de Residuos de Estandarizacion ###
par(mfrow=c(1,2)) # Parte la pantalla en 2
qqnorm(es, main='Diagrama de normal de Residuos de Estandarizacion')
qqline(es)
hist(es, freq=F, main='Histograma normal de Residuos de Estandarizacion')
curve(dnorm(x, mean(es), sd(es)), add=TRUE)
```