

Sección 12 Devore

79. Sea y = ventas en un establecimiento de comida rápida (\$1000's), x_1 = número de puntos de venta de la competencia dentro de una milla radio, x_2 = población dentro de un radio de 1 milla (miles de personas), y x_3 sea una variable indicadora que es igual a 1 si la salida tiene una ventana de acceso y 0 en caso contrario. Supongamos que la verdadera regresión el modelo es

$$Y = 10.0 - 1.2x_1 + 6.8x_2 + 15.3x_3 + \varepsilon$$

- a) ¿Cuál es el valor medio de las ventas cuando el número de puntos de venta que compiten es 2, hay 8000 personas dentro de un radio de 1 milla, y el toma de corriente tiene una ventana de acceso?

Notemos que $x_1 = 2$, $x_2 = 8$ y $x_3 = 1$ de esta manera para calcular los valor medio de ventas reemplazamos los valores anteriores en la esperanza de Y así

$$\begin{aligned} E[Y] &= 10.0 - 1.2x_1 + 6.8x_2 + 15.3x_3 \\ &= 10.0 - 1.2(2) + 6.8(8) + 15.3(1) \\ &= 77.3 \end{aligned}$$

Por lo tanto, el valor medio de ventas es 77.3

- b) ¿Cuál es el valor medio de las ventas de un punto de venta sin ventanilla de autoservicio que tiene tres puntos de venta de la competencia y 5000 personas dentro de un radio de 1 milla?

Se resuelve análogamente el inciso anterior, en este caso tenemos que $x_1 = 3$, $x_2 = 5$ y $x_3 = 0$ entonces

$$\begin{aligned} E[Y] &= 10.0 - 1.2x_1 + 6.8x_2 + 15.3x_3 \\ &= 10.0 - 1.2(3) + 6.8(5) \\ &= 40.4 \end{aligned}$$

Por lo tanto, el valor medio de ventas es 40.4

Nota: $x_3 = 0$ debido a que tenemos el un punto de venta sin ventanilla de autoservicio, lo cual por como esta definido x_3 el valor que tomara es 0.

- c) Interprete β_3

Por como esta planteado el modelo del problema podemos decir que β_3 la diferencia en las ventas medias entre la ventanilla de autoservicio y la ventanilla sin autoservicio. Representando un factor muy relevante dado que influyen en el ingreso del establecimiento.

81. El artículo "Precios de venta/M2. Pie. de edificios de oficinas en el centro de Chicago: ¿cuánto vale ser un edificio antiguo pero de clase A?" (J. Real Estate Res., 2010 : 1–22) consideró un modelo de regresión

para relacionar $y = \ln(\$ft^2)$ con 16 predictores, incluyendo la edad, la edad al cuadrado, el número de pisos, la tasa de ocupación y las variables indicadoras para saber si un edificio tiene un restaurante y si tiene salas de conferencias. El modelo se ajustó a datos resultantes de 203 de ventas.

- a) El coeficiente de determinación múltiple fue de .711. ¿Cuál es el valor del coeficiente de determinación múltiple ajustado? ¿Sugiere que el valor R^2 relativamente alto fue el resultado de incluir demasiados predictores en el modelo en relación con la cantidad de datos disponibles?

Primero recordemos que el coeficiente de determinación múltiple es

$$R^2 = 1 - \frac{SSE}{SST}$$

De manera análoga el coeficiente ajustado de determinación múltiple se define por

$$R_a^2 = 1 - \frac{MSE}{MST} = 1 - \frac{\frac{SSE}{n-(k+1)}}{\frac{SST}{n-1}} = 1 - \frac{n-1}{n-(k+1)} \frac{SSE}{SST}$$

Con lo anterior sabemos que

$$R^2 = 0.711 = 1 - \frac{SSE}{SST} \Leftrightarrow \frac{SSE}{SST} = 1 - 0.711 = 0.289$$

Entonces

$$R_a^2 = 1 - \frac{n-1}{n-(k+1)} \frac{SSE}{SST} = 1 - \frac{203-1}{203-(16+1)} \cdot 0.289 = 0.68613$$

Es decir, el valor del coeficiente de determinación múltiple ajustado es 0.68613.

Tenemos que el valor de R^2 está más cercano a 1 y de la misma manera el valor R_a se encuentra bastante cercano al valor de R de lo que podemos decir que el modelo es bueno.

- b) Usando el valor R^2 de (a), realice una prueba de hipótesis para ver si existe una relación lineal útil entre la variable dependiente y al menos uno de los predictores.

Recordemos la prueba de utilidad del modelo.

Hipótesis nula: $H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$

Hipótesis alternativa: $H_a : \text{al menos uno } \beta_i \neq 0 \quad (i = 1, \dots, k)$

Valor de la estadística de prueba:

$$f = \frac{R^2/k}{(1-R^2)/[n-(k+1)]} = \frac{SSR/k}{SSE/[n-(k+1)]} = \frac{MSR}{MSE}$$

donde $SSR = SST - SSE$

Región de rechazo para una prueba de nivel α : $f \geq F_{\alpha, k, n-(k+1)}$

Por un lado tenemos que

$$f = \frac{R^2/k}{(1-R^2)/[n-(k+1)]} = \frac{0.711/16}{(1-0.711)/[203-(16+1)]} = 28.59991$$

Y por otro lado usando R considerando el nivel de significancia de 0.001 tenemos

$$F_{\alpha,k,n-(k+1)} = 2.624483$$

Del cual tenemos que

$$28.59991 > 2.624483$$

Lo cual significa que se rechaza H_0 , por lo tanto, existe una relación útil con al menos un β_i del modelo. Lo que implica que este β_i es estadísticamente significativo y que el modelo es útil para predecir la variable dependiente.

El código utilizado fue

```
alfa <- 0.001
k <- 16
n <- 203

f <- qf(1-alfa, k, n-(k+1))
```

- c) El coeficiente estimado de la variable indicadora de si un edificio era o no clase A fue de .364. Interprete este coeficiente estimado, primero en términos de y y luego en términos de $\$/ft^2$.

En términos en términos de y solo indica que con todos los demás predictores constantes, la diferencia para ser de la clase A.

En términos de $\$/ft^2$ representa el efecto es multiplicativo. Se estima que los edificios de clase A valen un porcentaje de dólares más con todos los demás predictores constantes.

- d) La relación t para el coeficiente estimado de (c) fue de 5.49. ¿Qué te dice esto?

Recordando

Hipotesis nula: $H_0 : \beta_1 = 0$

<i>Hipotesis alternativa</i>	<i>Region de rechazo</i>
$H_a : \beta_1 \neq 0$	$ t \geq t_{\frac{\alpha}{2}, n-(k+1)}$

Tenemos que si consideramos a $\alpha = 0.001$ se sigue que

$$t_{\frac{\alpha}{2}, n-(k+1)} = 3.343601$$

Del cual notemos que

$$5.49 > 3.343601$$

Lo cual implica que se rechaza la hipótesis nula, es decir, el coeficiente estimado del inciso anterior es estadísticamente significativo.

El código utilizado fue

```

n <- 203
k <- 16
alpha <- 0.001
t <- qt(1-(alpha/2), n-(k+1))

```

83. Un experimento llevado a cabo para estudiar el efecto de el contenido molar de cobalto (x_1) y la temperatura de calcinación (x_2) en el área superficial de un catalizador de hidróxido de hierro-cobalto (y) dieron como resultado los datos adjuntos (“Structural Changes and Surface Properties of $\text{Co}_x\text{Fe}_{3-x}\text{O}_4$ Spinel,” J. Chem.Tech. Biotech., 1994: 161–170).

x_1	.6	.6	.6	.6	.6	1.0	1.0
x_2	200	250	400	500	600	200	250
y	90.6	82.7	58.7	43.2	25.0	127.1	112.3

x_1	1.0	1.0	1.0	2.6	2.6	2.6	2.6
x_2	400	500	600	200	250	400	500
y	19.6	17.8	9.1	53.1	52.0	43.4	42.4

x_1	2.6	2.8	2.8	2.8	2.8	2.8
x_2	600	200	250	400	500	600
y	31.6	40.9	37.9	27.5	27.3	19.0

Una solicitud al paquete SAS para ajustar la función de regresión $\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3$ donde $x_3 = x_1 x_2$ (un predictor de interacción) produjo el resultado adjunto.

Dependent Variable: SURFAREA

Analysis of Variance

Source	DF	Sum of Squares	Mean Square	F Value	Prob > F
Model	3	15223.52829	5074.50943	18.924	0.0001
Error	16	4290.53971	268.15873		
C Total	19	19514.06800			

Root MSE	16.37555	R-square	0.7801
Dep Mean	48.06000	Adj R-sq	0.7389
C.V.	34.07314		

Parameter Estimates

Variable	DF	Parameter Estimate	Standard Error	T for H0: Parameter=0	Prob > T
INTERCEP	1	185.485740	21.19747682	8.750	0.0001
COBCON	1	-45.969466	10.61201173	-4.332	0.0005
TEMP	1	-0.301503	0.05074421	-5.942	0.0001
CONTEMP	1	0.088801	0.02540388	3.496	0.0030

- a) Prediga el valor del área superficial cuando el cobalto el contenido es 2.6 y la temperatura es 250, y calcule el valor del residual correspondiente.

Notemos que $x_1 = 2.6$, $x_2 = 250$ y $x_3 = 650$, además usando la tabla de análisis de varianza que nos da el problema tenemos la regresión lineal y con esta obtendremos el área superficial

$$\begin{aligned}\hat{y} &= 185.48574 - 45.969466x_1 - 0.301503x_2 + 0.088801x_1x_2 \\ &= 185.48574 - 45.969466(2.6) - 0.301503(250) + 0.088801(650) \\ &= 48.3100284\end{aligned}$$

Por lo tanto el valor del área superficial con los valores dados es 48.3100284

Ahora calculemos el valor del residual correspondiente, de aquí observando los datos cuando $x_1 = 2.6$ y $x_2 = 250$ se sigue que $y = 52$, de esta manera

$$e = y - \hat{y} = 52 - 48.3100284 = 3.6899716$$

Por lo tanto el valor de residual correspondiente es 3.6899716.

- b) Como $\hat{\beta}_1 = -46$ ¿Es legítimo concluir que si el contenido de cobalto aumenta en 1 unidad mientras los valores de los otros predictores permanecen fijos, se puede esperar que el área superficial disminuya en aproximadamente 46 unidades? Explique su razonamiento.

Sí, es podemos concluir que si el contenido de cobalto aumenta en 1 unidad mientras los valores de los otros predictores permanecen fijos, de esta manera se puede esperar que el área superficial disminuya en aproximadamente 46 unidades porque al observar los p -valores de la interacción de x_1 y x_2 son menores que 0.01 en el modelo, es decir, se rechazaría la hipótesis nula de que $H_0 : \beta_i = 0$ teniendo que los predictores en la interacción son significativos a la variable dependiente.

- c) ¿Parece haber una relación útil entre y y los predictores?

Recordemos la prueba de utilidad del modelo.

Hipótesis nula: $H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$

Hipótesis alternativa: $H_a : \text{al menos uno } \beta_i \neq 0 \quad (i = 1, \dots, k)$

Valor de la estadística de prueba:

$$f = \frac{R^2/k}{(1 - R^2)/[n - (k + 1)]} = \frac{SSR/k}{SSE/[n - (k + 1)]} = \frac{MSR}{MSE}$$

donde $SSR = SST - SSE$

Región de rechazo para una prueba de nivel α : $f \geq F_{\alpha, k, n - (k + 1)}$

De manera analoga recordemos el siguiente criterio.

- Si $p\text{valor} < 0.01$ se rechaza H_0

Y haciendo uso de la tabla que nos da el enunciado tenemos que

$$F = 18.924 \quad P_{valor} = 0.0001$$

Entonces por el criterio dado tendríamos que se rechaza H_0 , debido a que $0.0001 < 0.01$, por lo tanto, si existe una relación útil con al menos un β_i del modelo. Lo que implica que este β_i es estadísticamente significativo y que el modelo es útil para predecir la variable dependiente, siento en este caso y.

- d) Dado que el contenido molar y la temperatura de calcinación permanece en el modelo, ¿el predictor de interacción x_3 proporciona información útil sobre y? Enuncie y pruebe las hipótesis apropiadas usando un nivel de significancia de .01.

Recordando

Hipotesis nula: $H_0 : \beta_i = 0$

$$\begin{array}{ll} \text{Hipotesis alternativa} & \text{Region de rechazo} \\ H_a : \beta_i \neq 0 & |t| \geq t_{\frac{\alpha}{2}, n-(k+1)} \end{array}$$

Observando la tabla dada que nos da el enunciado tenemos que

$$t = 3.496$$

Considerando la significancia de 0.01 se tiene que

$$t_{\frac{\alpha}{2}, n-(k+1)} = 2.898231$$

Teniendo así que

$$3.496 > 2.898231$$

Implicando que la hipótesis nula se rechaza, es decir, el predictor de interacción x_3 proporciona información útil sobre y.

- e) La desviación estándar estimada de $\hat{Y}$ cuando el contenido molar es 2.0 y la temperatura de calcinación es 500 es $S_{\hat{y}} = 4.69$ Calcule un intervalo de confianza del 95 % para el valor medio del área superficial en estas circunstancias.

Recordemos que el intervalo de confianza para el valor medio viene dado por

$$\hat{y} \pm t_{\frac{\alpha}{2}, n-k-1} S_{\hat{y}}$$

Donde el inciso nos pide que el intervalo de confianza del 95 % donde $x_1 = 2.0$, $x_2 = 500$ y $S_{\hat{y}} = 4.69$ del cual se sigue que

$$\begin{aligned} \hat{y} &= 185.48574 - 45.969466x_1 - 0.301503x_2 + 0.088801x_1x_2 \\ &= 185.48574 - 45.969466(2.0) - 0.301503(500) + 0.088801(1000) \\ &= 31.596308 \end{aligned}$$

Asi utilizando R tenemos que el intervalo de confianza es

$$[21.65395, 41.53866]$$

El código utilizado para calcular el intervalo es


```
yg <- 31.596308
alfa <- 0.05
n <- 20
k <- 3
t <- qt(1-(alfa)/2, n-k-1)
S <- 4.69
```

```
I <- yg - t*S
D <- yg + t*S
```

```
cat("El intervalo de confianza es","[",I,"",D,""]", "\n")
```

- f) Con base en gráficos de diagnóstico apropiados, ¿hay alguna razón para cuestionar el modelo de regresión de suposiciones?

Observando la siguiente gráfica



No existe una razón para cuestionar el modelo de regresión dado que al graficar los residuos estandarizados observamos que sus valores sí siguen una distribución normal.

El código utilizado para obtener la gráfica fue

```
X1<-c(.6,.6,.6,.6,.6,1.0,1.0,1.0,1.0,1.0,2.6,2.6,2.6,2.6,2.6,2.8,2.8,2.8,2.8,2.8)
X2<-c(200,250,400,500,600,200,250,400,500,600,200,250,400,500,600,200,250,400,500,600)
Y<-c(90.6,82.7,58.7,43.2,25.0,127.1,112.3,19.6,17.8,9.1,53.1,52.0,43.4,42.4,31.5,45.6,44.5,43.4,42.4,31.5)
X12 <- X1*X2
```

```

n<-length(x1)

datos <- data.frame(X1,X2,X12,Y)

modelo <- lm(Y ~ X1+X2+X12, datos)
summary(modelo)

residuos<-rstandard(modelo)
qqnorm(residuos)
qqline(residuos)

```

85. El artículo "*The Undrained Strength of Some Thawed Permafrost Soils*" (*Canad. Geotech. J.*, 1979: 420–427) contiene los siguientes datos sobre la resistencia al corte no drenado del suelo arenoso, (y en kPa), profundidad (x_1 , en m) y el contenido de agua (x_2 , in %)



Obs	y	x_1	x_2	$\hat{y}$	$y - \hat{y}$	e^*
1	14.7	8.9	31.5	23.35	-8.65	-1.50
2	48.0	36.6	27.0	46.38	1.62	.54
3	25.6	36.8	25.9	27.13	-1.53	-.53
4	10.0	6.1	39.1	10.99	-.99	-.17
5	16.0	6.9	39.2	14.10	1.90	.33
6	16.8	6.9	38.3	16.54	.26	.04
7	20.7	7.3	33.9	23.34	-2.64	-.42
8	38.8	8.4	33.8	25.43	13.37	2.17
9	16.9	6.5	27.9	15.63	1.27	.23
10	27.0	8.0	33.1	24.29	2.71	.44
11	16.0	4.5	26.3	15.36	.64	.20
12	24.9	9.9	37.8	29.61	-4.71	-.91
13	7.3	2.9	34.6	15.38	-8.08	-1.53
14	12.8	2.0	36.4	7.96	4.84	1.02


Los valores predecidos y residuales fueron calculados por un modelo de regresión cuadrática, el cual resulto en la estimación de la siguiente función de regresión

$$y = -151.36 - 16.22x_1 + 13.48x_2 + 0.094x_1^2 - 0.253x_2^2 + 0.492x_1x_2$$

- (a) Realice los gráficos de e^* contra x_1 , e^* contra x_2 y e^* contra $\hat{y}$ ¿Sugiere que el modelo cuadrático completo debería ser modificado? Explique su respuesta.

Grafico de e^* contra x_1

Grafico de e^* contra x_2 Grafico de e^* contra $\hat{y}$



No, dado que al realizar los residuos contra los demás podemos observar que la mayoría de los valores se encuentran cercanos al eje x lo que implica que es un buen modelo.

El código para hacer las graficas fue

```
x1 <- c(8.9, 36.6, 36.8, 6.1, 6.9, 6.9, 7.3, 8.4, 6.5, 8.0, 4.5, 9.9, 2.9, 2.0)
x2 <- c(31.5, 27.0, 25.9, 39.1, 39.2, 38.3, 33.9, 33.8, 27.9, 33.1, 26.3, 37.8,
yg <- c(23.35, 46.38, 27.13, 10.99, 14.10, 16.54, 23.34, 25.43, 15.63, 24.29, 1
ea <- c(-1.50, .54, -.53, -.17, .33, .04, -.42, 2.17, .23, .44, .20, -.91, -1.5
```

```
### Grafica de Residuos ###
```

```
#x1 contra e*#
```

```
xseq=seq(-300,300,0.01)
```

```
yseq = xseq - xseq
```

```
plot(x1, ea, main='Grafica de  $e^*$  contra x_1', xlab = 'x_1', ylab= 'e*', col =
```

```
)
```

```
lines(xseq, yseq)
```

```
#x2 contra e*#
```

```
plot(x2, ea, main='Grafica de  $e^*$  contra x_2', xlab = 'x_2', ylab= 'e*', col =
```

```
)
```

```
lines(xseq, yseq)
```

```
#y gorro contra e*#
```

```
plot(yg, ea, main='Grafica de  $e^*$  contra y gorrito', xlab = 'yg', ylab= 'e*', c
```

```
)
```

```
lines(xseq, yseq)
```

```
qqnorm(ea)
```

```
qqline(ea)
```

- (b) El valor de R^2 para el modelo completo es 0.759. Pruebe el nivel .05 para la hipótesis nula declarando que no hay una relación lineal entre la variable dependiente y cualquiera de los 5 predictores.

Recordemos lo siguiente

Hipotesis nula: $H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$

Hipotesis alternativa: $H_a : \text{al menos uno } \beta_i \neq 0 \quad (i = 1, \dots, k)$

Valor de la estadística de prueba:

$$f = \frac{R^2/k}{(1-R^2)/[n-(k+1)]} = \frac{SSR/k}{SSE/[n-(k+1)]} = \frac{MSR}{MSE}$$

donde $SSR = SST - SSE$

Región de rechazo para una prueba de nivel α : $f \geq F_{a,k,n-(k+1)}$

Por un lado tenemos que

$$f = \frac{R^2/k}{(1-R^2)/[n-(k+1)]} = \frac{0.759/5}{(1-0.759)/[14-(5+1)]} = 5.03900$$

Y por otro lado usando R considerando el nivel de significancia de 0.05 tenemos

$$F_{a,k,n-(k+1)} = 3.687499$$

Del cual tenemos que

$$5.03900 > 3.687499$$

Lo cual significa que se rechaza H_0 , por lo tanto, existe una relación útil utilizando significativa en el nivel .05. Existiendo una relación lineal entre la variable dependiente y cualquiera de los 5 predictivos.

- (c) Cada uno de las hipótesis nula $H_0 : \beta_i = 0$, contra $H_a : \beta_i \neq 0$, $i = 1, 2, 3, 4, 5$ la cual no es rechazada en el nivel de 5%. ¿Tiene sentido en vista del resultado en (b)? Explique.

Usando R obtenemos la regresión lineal, el cual nos regresa

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-151.35551	134.06915	-1.129	0.2916
X1	-16.21614	8.83147	-1.836	0.1037
X2	13.47558	8.18686	1.646	0.1384
X11	0.09353	0.07093	1.319	0.2238
X22	-0.25282	0.12706	-1.990	0.0818 .
X12	0.49224	0.22813	2.158	0.0630 .

Del cual apartir del P – valor podemos observar que es cierto que algunos no se rechazan en el nivel del 5 %, con esto podemos decir que si tiene sentido el resultado del inciso anterior.

Dado que cuando trabajamos las hipotesis individuales podemos decir que cuando no se rechaza la hipotesis nula implica que se puede eliminar solo este predictor, mientras que cuando hacemos la eficacia del modelo vemos que al menos un predictor tenga ralización con la variable dependiente.

- (d) Se mostró en la Sección 12.8 que $V(Y) = \sigma^2 = V(\hat{Y}) + V(Y - \hat{Y})$. El estimador de σ es $\hat{\sigma} = s = 6.99$ (para el modelo cuadrático completo). Primero obtenga la desviación estándar de $Y - \hat{Y}$, y después estime la desviación estándar de $\hat{Y}$ (i.e., $\hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_1^2 + \hat{\beta}_4 x_2^2 + \hat{\beta}_5 x_1 x_2$ cuando $x_1 = 8$ y $x_2 = 33.1$). Finalmente, calcule el intervalo de confianza del 95 % para la media de la fuerza [Hint: ¿Qué es $(y - \hat{y})/e^*$?]

Primero obtengamos la desviación estándar de $Y - \hat{Y}$ cuando $x_1 = 8$ y $x_2 = 33.1$.

Del cual recordemos que $Var(Y_i - \hat{Y}_i) = S^2[1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{S_{xx}}]$ donde la desviación estándar de los residuos viene dado por la raíz de la ecuación anterior y la ecuación de los residuos estandarizados viene dada por $e_i^* = \frac{y_i - \hat{y}_i}{s\sqrt{1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{S_{xx}}}}$

Del cual haciendo uso del hint notemos que la desviación estándar del valor predicho es el residual dividido por el residual estandarizado, de esta manera

$$\frac{27 - 24.29}{0.44} = \frac{2.71}{0.44} = 6.15909$$

Así la desviación estándar de $Y - \hat{Y}$ cuando $x_1 = 8$ y $x_2 = 33.1$ es 6.15909

Posteriormente obtengamos la desviación estándar de $\hat{Y}$ cuando $x_1 = 8$ y $x_2 = 33.1$.

Partiendo de $\hat{\sigma} = 6.99$ y de que $V(Y) = \sigma^2 = V(\hat{Y}) + V(Y - \hat{Y})$ tenemos que $S = \sqrt{V(\hat{Y}) + V(Y - \hat{Y})}$, es decir

$$6.99 = \sqrt{V(\hat{Y}) + (6.15909)^2} \Leftrightarrow (6.99)^2 - (6.15909)^2 = V(\hat{Y})$$

$$V(\hat{Y}) = 10.92571 \Leftrightarrow S_{\hat{Y}} = 3.30540$$

Así la desviación estándar de $\hat{Y}$ cuando $x_1 = 8$ y $x_2 = 33.1$ es 3.30540

Finalmente obtengamos el intervalo de confianza del 95 % para la media de la fuerza.

Recordemos que el intervalo de confianza para el valor medio viene dado por

$$\hat{y} \pm t_{\frac{\alpha}{2}, n-k-1} S_{\hat{y}}$$

Dado que nos pide que el intervalo de confianza del 95 % donde $x_1 = 8$, $x_2 = 33.1$ y $S_{\hat{y}} = 3.30540$ del cual se sigue que

$$[16.66773, 31.91227]$$

El código con el que se obtuvo el intervalo fue

```

yg <- 24.29
Sy <- 3.30540
n <- 14
k <- 5
alpha <- 0.05
t <- qt(1-(alpha/2), n-(k+1))

```

```

I <- yg - t*Sy
D <- yg + t*Sy

```

```
cat("El intervalo de confianza es=", "[", I, ", ", D, "]", "\n")
```

- (e) En ciertas ocasiones un investigador quiere decidir si un grupo de m predictores ($m < 1$) puede ser eliminado simultáneamente del modelo. La hipótesis nula dice que todos los β 's asociados con la interpretación de que los m predictores son 0, lo cual es interpretado en la media tanto como $k - m$ predictores estén retenidos en el modelo, los m predictores bajo consideración colectivamente provee información inútil sobre y . Entonces la prueba es llevada a cabo por el modelo completo, con todos los k predictores para obtener $SSE(\text{completo})$ y después el modelo de regresión "reducido" consiste solo en los $k - m$ predictores no siendo considerados para la eliminación de la obtención de $SSE(\text{rojo})$. La prueba del estadístico es

$$F = \frac{[SSE(\text{rojo}) - SSE(\text{completo})]/m}{SSE(\text{completo})/[n - (k + 1)]}$$

La prueba es la cola superior y basada en el numerador m df y $n - (k + 1)$. El modelo de regresión de primer orden con los predictores x_1 y x_2 resulta en $SSE = 894.5$. Enuncie y pruebe al nivel de significación .05 el valor nulo hipótesis de que ninguno de los tres de segundo orden predictores (una interacción y dos cuadráticas) predictores) proporciona información útil sobre y siempre que los dos predictores de primer orden se mantienen en el modelo.

Tenemos que $SSE(\text{completo}) = s^2(n - (k + 1))$ donde $s^2 = \frac{SSE(\text{rojo})}{n - (k + 1)}$ entonces

$$s = \sqrt{\frac{SSE}{n - (k + 1)}} \Rightarrow SSE(\text{completo}) = s^2(n - (k + 1)) = 6.99^2(14 - 6) = 390.8808$$

Entonces

$$F = \frac{[SSE(\text{rojo}) - SSE(\text{completo})]/m}{SSE(\text{completo})/[n - (k + 1)]} = \frac{(894.95 - 390.8808)/(5 - 2)}{390.8808/(14 - (6))} = 3.43886$$

Y por otro lado usando R considerando el nivel de significancia de 0.05 tenemos

$$F_{\alpha, k, n - (k + 1)} = 3.687499$$

Del cual tenemos que

$$3.43886 < 3.687499$$

Lo cual significa que no se rechaza H_0 lo que implica que los términos cuadráticos pueden ser borrado.

El código utilizado fue

```
alfa <- 0.05
k <- 5
n <- 14

f <- qf(1-alfa, k, n-(k+1))
```

91 Ajuste el modelo $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$ para los datos

x_1	x_2	y
-1	-1	1
-1	1	1
1	-1	0
1	1	4

a) Determine X y y y exprese las ecuaciones normales en términos de matrices.

Recordemos lo siguiente

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \quad b = \begin{pmatrix} b_0 \\ b_1 \\ \vdots \\ b_k \end{pmatrix} \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix} \quad \varepsilon = \begin{pmatrix} \varepsilon_0 \\ \varepsilon_1 \\ \vdots \\ \varepsilon_k \end{pmatrix} \quad X = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1k} \\ 1 & x_{21} & x_{22} & \cdots & x_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{nk} \end{pmatrix}$$

Donde trabajando con el modelo $y = X\beta + \varepsilon$ el sistema de ecuaciones a resolver es $X^T y = X^T X b$ del cual

$$X^T X b = \begin{pmatrix} \sum_{i=1}^n 1 & \sum_{i=1}^n x_{i1} & \cdots & \sum_{i=1}^n x_{ik} \\ \sum_{i=1}^n x_{i1} & \sum_{i=1}^n x_{i1}x_{i1} & \cdots & \sum_{i=1}^n x_{i1}x_{ik} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n x_{ik} & \sum_{i=1}^n x_{ik} & \cdots & \sum_{i=1}^n x_{ik}x_{ik} \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n x_{i1}y_i \\ \vdots \\ \sum_{i=1}^n x_{ik}y_i \end{pmatrix}$$

de manera análoga el estimador $\hat{\beta} = b = [X^T X]^{-1} X^T y$ si existe la inversa de $X^T X$ además $\hat{y} = X\hat{\beta}$

Con lo anterior en mente tenemos que

$$X = \begin{pmatrix} 1 & -1 & -1 \\ 1 & -1 & 1 \\ 1 & 1 & -1 \\ 1 & 1 & 1 \end{pmatrix} \quad y = \begin{pmatrix} 1 \\ 1 \\ 0 \\ 4 \end{pmatrix}$$

La ecuación normales es

$$X^T X b = X^T y \Leftrightarrow \begin{pmatrix} 1 & 1 & 1 & 1 \\ -1 & -1 & 1 & 1 \\ -1 & 1 & -1 & 1 \end{pmatrix} \begin{pmatrix} 1 & -1 & -1 \\ 1 & -1 & 1 \\ 1 & 1 & -1 \\ 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} b_0 \\ b_1 \\ b_2 \end{pmatrix} = \begin{pmatrix} 1 & 1 & 1 & 1 \\ -1 & -1 & 1 & 1 \\ -1 & 1 & -1 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 0 \\ 4 \end{pmatrix} \Leftrightarrow$$

$$\begin{pmatrix} 4 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 4 \end{pmatrix} \begin{pmatrix} b_0 \\ b_1 \\ b_2 \end{pmatrix} = \begin{pmatrix} 6 \\ 2 \\ 4 \end{pmatrix}$$

b) Determine el vector $\hat{\beta}$, que contiene las estimaciones de los tres coeficientes del modelo.

Tenemos

$$\begin{aligned} \hat{\beta} = b = [X^T X]^{-1} X^T y &= \left[\begin{pmatrix} 1 & 1 & 1 & 1 \\ -1 & -1 & 1 & 1 \\ -1 & 1 & -1 & 1 \end{pmatrix} \begin{pmatrix} 1 & -1 & -1 \\ 1 & -1 & 1 \\ 1 & 1 & -1 \\ 1 & 1 & 1 \end{pmatrix} \right]^{-1} \begin{pmatrix} 1 & 1 & 1 & 1 \\ -1 & -1 & 1 & 1 \\ -1 & 1 & -1 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 0 \\ 4 \end{pmatrix} \\ &= \begin{pmatrix} \frac{1}{4} & 0 & 0 \\ 0 & \frac{1}{4} & 0 \\ 0 & 0 & \frac{1}{4} \end{pmatrix} \begin{pmatrix} 6 \\ 2 \\ 4 \end{pmatrix} \\ &= \begin{pmatrix} 1.5 \\ 0.5 \\ 1 \end{pmatrix} \end{aligned}$$

c) Determine $\hat{y}$, las predicciones para las cuatro observaciones y también los cuatro residuales. Encuentre SSE sumando los cuatro residuos al cuadrado. Use esto para obtener la varianza estimada MSE .

Determinemos a

$$\hat{y} = X\hat{B} = \begin{pmatrix} 1 & -1 & -1 \\ 1 & -1 & 1 \\ 1 & 1 & -1 \\ 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1.5 \\ 0.5 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 2 \\ 1 \\ 3 \end{pmatrix}$$

Ahora calculemos los 4 residuales así

$$y - \hat{y} = \begin{pmatrix} 1 \\ 1 \\ 0 \\ 4 \end{pmatrix} - \begin{pmatrix} 0 \\ 2 \\ 1 \\ 3 \end{pmatrix} = \begin{pmatrix} 1 \\ -1 \\ -1 \\ 1 \end{pmatrix}$$

Ahora calculemos a SSE así

$$SSE = ||y - \hat{y}||^2 = (1)^2 + (-1)^2 + (-1)^2 + (1)^2 = 4$$

Por otro lado recordemos que $MSE = S^2$ de esta manera

$$MSE = \frac{SSE}{n - (k + 1)} = \frac{4}{4 - (2 + 1)} = \frac{4}{1} = 4$$

d) Utilice MSE y c_{11} para obtener un intervalo de confianza de 95 % para β_1 .

Recordemos que el $100(1 - \alpha)\%$ intervalo de confianza para β_i es

$$\beta_i \pm t_{\frac{\alpha}{2}, n-(k+1)} S_{\hat{\beta}_i}$$

Donde $S_{\hat{\beta}_i} = S\sqrt{C_{ii}}$ del cual $C = [X^T X]^{-1}$

De esta manera tenemos que

$$C = \begin{pmatrix} \frac{1}{4} & 0 & 0 \\ 0 & \frac{1}{4} & 0 \\ 0 & 0 & \frac{1}{4} \end{pmatrix} \Rightarrow C_{11} = \frac{1}{4} \Rightarrow \sqrt{C_{11}} = \frac{1}{2} \quad S = \sqrt{MSE} = \sqrt{4} = 2 \quad \beta_1 = 0.5$$

Se sigue

$$S_{\hat{\beta}_1} = 2 \cdot \frac{1}{2} = 1$$

Así utilizando R tenemos que el intervalo de confianza es

$$[-12.2062, 13.2062]$$

El código con el que se obtuvo el intervalo fue

```
B1 <- 0.5
sc <- 1
n <- 4
k <- 2
alpha <- 0.05
t <- qt(1-(alpha/2), n-(k+1))

I <- B1 - t*sc
D <- B1 + t*sc

cat("El intervalo de confianza es=", "[", I, ", ", D, "]", "\n")
```

- e) Realice una prueba t para la hipótesis $H_0 : \beta_1 = 0$ contra la alternativa de *dos - colas* e interprete el resultado.

Recordemos lo siguiente

Hipotesis nula: $H_0 : \beta_i = 0$

Valor de la estadística de prueba:

$$T = \frac{\hat{\beta}_i}{S_{\hat{\beta}_i}}$$

Hipotesis alternativa	Región de rechazo para una prueba de nivel α
$H_a : \beta_1 \geq 0$	$T \geq t_{\alpha, n-(k+1)}$
$H_a : \beta_1 \leq 0$	$T \leq -t_{\alpha, n-(k+1)}$
$H_a : \beta_1 \neq 0$	$ T \geq t_{\frac{\alpha}{2}, n-(k+1)}$

Con lo anterior obtengamos el intervalo de confianza cuando $H_a : \beta \neq 0$ de esta manera consideremos el intervalo de confianza del 95 % del cual tenemos que

$$T = \frac{0.5}{1} = 0.5 \quad t_{\frac{\alpha}{2}, n-(k+1)} = 12.7062$$

Del cual se sigue que

$$|T| < t_{\frac{\alpha}{2}, n-(k+1)}$$

Lo cual significa que no se rechaza H_0 con el 0.05 nivel, lo que implica que x_1 no es un valor significativo.

- f) Forme la tabla de análisis de varianza y realice la prueba F para la hipótesis $H_0 : \beta_1 = \beta_2 = 0$. Encuentra R^2 e interpreta.

Recordemos la prueba F

Hipotesis nula: $H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$

Hipotesis alternativa: $H_a : \text{al menos uno } \beta_i \neq 0 \quad (i = 1, \dots, k)$

Valor de la estadística de prueba:

$$f = \frac{R^2/k}{(1-R^2)/[n-(k+1)]} = \frac{SSR/k}{SSE/[n-(k+1)]} = \frac{MSR}{MSE}$$

donde $SSR = SST - SSE$

Región de rechazo para una prueba de nivel α : $f \geq F_{\alpha, k, n-(k+1)}$

De manera análoga recordemos que la tabla ANOVA viene dada por

Source	Suma de Cuadrados(SS)	Grados de Libertad	Media de Cuadrados(MS)	F-razon
Regresion	SS(T)	m-1	$MS(T) = \frac{SS(T)}{m-1}$	$\frac{MS(T)}{MS(E)}$
Error	SS(E)	n-m	$MS(E) = \frac{SS(E)}{n-m}$	
Total	SS(TO)	n-1		

Del cual observemos que nos hace falta calcular SST , $SS(TO)$ y MST de esta manera tenemos que $\bar{y} = 1.5$ así

$$y - \bar{y} = \begin{pmatrix} 1 \\ 1 \\ 0 \\ 4 \end{pmatrix} - \begin{pmatrix} 1.5 \\ 1.5 \\ 1.5 \\ 1.5 \end{pmatrix} = \begin{pmatrix} -0.5 \\ -0.5 \\ -1.5 \\ 2.5 \end{pmatrix} \Rightarrow SST = \|y - \bar{y}\|^2 = (-0.5)^2 + (-0.5)^2 + (-1.5)^2 + (2.25)^2 =$$

De esta manera nuestra tabla ANOVA es

Source	SS	Grados de Libertad	Media de Cuadrados(MS)	F-razon
Regresion	5	2	2.5	0.625
Error	4	1	4.0	
Total	9	3		

Del cual tenemos que

$$f = 0.625$$

Por otro lado usando R tenemos que

$$F_{a,k,n-(k+1)} = 199.5$$

De lo que se sigue que

$$f < F_{a,k,n-(k+1)}$$

Es decir, no se rechaza la región en el nivel de 0.05 lo que implica que no existe una relación significativa.

Por otro lado tenemos que

$$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{4}{5} = 0.2$$

Del cual vemos que el valor de R^2 se encuentra mas cercano a cero, lo que podemos decir que no es un buen modelo.

- 93 Supongamos que el modelo consta de solo $Y = \beta_0 + \varepsilon$ entonces $k = 0$. Estime β_0 a partir de $[X^T X]^{-1} X^T y$. Encuentre expresiones simples para s y c_{00} , y utilícelas junto con la Ecuación (12.25) para expresar simplemente el intervalo de confianza de 95 % para β_0 . Su resultado debe ser equivalente al intervalo de confianza t de una muestra en la Sección 8.3.

Recordemos lo siguiente

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \quad b = \begin{pmatrix} b_0 \\ b_1 \\ \vdots \\ b_k \end{pmatrix} \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix} \quad \varepsilon = \begin{pmatrix} \varepsilon_0 \\ \varepsilon_1 \\ \vdots \\ \varepsilon_k \end{pmatrix} \quad X = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1k} \\ 1 & x_{21} & x_{22} & \cdots & x_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{nk} \end{pmatrix}$$

Donde trabajando con el modelo $y = X\beta + \varepsilon$ el sistema de ecuaciones a resolver es $X^T y = X^T X b$ del cual

$$X^T X b = \begin{pmatrix} \sum_{i=1}^n 1 & \sum_{i=1}^n x_{i1} & \cdots & \sum_{i=1}^n x_{ik} \\ \sum_{i=1}^n x_{i1} & \sum_{i=1}^n x_{i1}x_{i1} & \cdots & \sum_{i=1}^n x_{i1}x_{ik} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n x_{ik} & \sum_{i=1}^n x_{ik} & \cdots & \sum_{i=1}^n x_{ik}x_{ik} \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n x_{i1}y_i \\ \vdots \\ \sum_{i=1}^n x_{ik}y_i \end{pmatrix}$$

de manera análoga el estimador $\hat{\beta} = b = [X^T X]^{-1} X^T y$ si existe la inversa de $X^T X$ además $\hat{y} = X\hat{\beta}$

Dado que $k = 0$ se sigue que

$$\hat{\beta} = (\hat{\beta}_0) \quad \epsilon = (\epsilon_0) \quad X = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix}$$

Entonces

$$\begin{aligned} \beta_0 &= [X^T X]^{-1} X^T y = [|X|^2]^{-1} (1 \ 1 \ \dots \ 1) \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \\ &= [n]^{-1} \left(\sum_{i=1}^n y_i \right) \\ &= \left[\frac{\sum_{i=1}^n y_i}{n} \right] \\ &= \bar{y} \end{aligned}$$

De esta manera tenemos que $B_0 = \bar{y}$, ahora encontremos las expresiones simples de S y c_{00} del cual recordemos que $S^2 = \frac{SSE}{n-(k+1)}$ donde $SSE = \|y - \hat{y}\|^2$ y tenemos que $C = [X^T X]^{-1}$ así con lo calculado anteriormente tenemos que

$$C_{00} = \frac{1}{n}$$

Ahora calculemos SSE así

$$\hat{y} = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} \cdot \bar{y} = \begin{pmatrix} \bar{y} \\ \bar{y} \\ \vdots \\ \bar{y} \end{pmatrix} \Rightarrow SSE = \left\| \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} - \begin{pmatrix} \bar{y} \\ \bar{y} \\ \vdots \\ \bar{y} \end{pmatrix} \right\|^2 = \sum_{i=1}^n (y_i - \bar{y})^2$$

De esta manera tenemos que

$$S^2 = \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - (0 + 1)} = \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - 1} \Rightarrow S = \sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - 1}}$$

Finalmente usemos la ecuación (12.25) para expresar simplemente el intervalo de confianza de 95 % para β_0 .

Ecuación 12.25

$$\beta_i \pm t_{\frac{\alpha}{2}, n-(k+1)} S_{\hat{\beta}_i}$$

Donde $S_{\hat{\beta}_i} = S\sqrt{C_{ii}}$

De esta manera sustituyendo los valores obtenidos tenemos

$$\bar{y} \pm t_{\frac{0.05}{2}, n-(0+1)} \frac{S}{\sqrt{n}} \Leftrightarrow \bar{y} \pm t_{0.25, n-1} \sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n(n-1)}}$$

- 103 Las medidas aquí son similares a las de *Ejemplo 12.36*, excepto que aquí los estudiantes tomaron las medidas en casa y los resultados sufrieron en precisión. Estas son medidas de una muestra de diez estudiantes:

<i>Envergadura</i>	<i>Pie</i>	<i>Altura</i>
74	13.0	75
56	8.5	66
65	10.0	69
66	9.5	66
62	9.0	54
69	11.0	72
75	12.0	75
66	9.0	63
66	9.0	66
63	8.5	63

- a) Regresión de la envergadura en las otras dos variables. Realice la prueba de utilidad del modelo y las pruebas para los dos coeficientes de regresión individuales de los predictores.

Primero recordemos lo siguiente

Hipotesis nula: $H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$

Hipotesis alternativa: $H_a : \text{al menos uno } \beta_i \neq 0 \quad (i = 1, \dots, k)$

Valor de la estadística de prueba:

$$f = \frac{R^2/k}{(1 - R^2)/[n - (k + 1)]} = \frac{SSR/k}{SSE/[n - (k + 1)]} = \frac{MSR}{MSE}$$

donde $SSR = SST - SSE$

Región de rechazo para una prueba de nivel α : $f \geq F_{\alpha, k, n-(k+1)}$

De manera analoga

Hipotesis nula: $H_0 : \beta_1 = 0$

Hipotesis alternativa *Región de rechazo*
 $H_a : \beta_1 \neq 0 \quad |t| \geq t_{\frac{\alpha}{2}, n-(k+1)}$

Haciendo uso de R obtenemos lo siguiente

Call:

```
lm(formula = Y ~ X1 + X2, data = datos)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-5.5966	-1.3249	0.3599	2.0979	2.8140

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	35.003848	11.150624	3.139	0.0164 *
X1	3.178772	1.075599	2.955	0.0212 *
X2	-0.006467	0.263898	-0.025	0.9811

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3 on 7 degrees of freedom

Multiple R-squared: 0.7748, Adjusted R-squared: 0.7104

F-statistic: 12.04 on 2 and 7 DF, p-value: 0.005424

Del cual utilizando lo anterior veamos la prueba de utilidad del modelo consideran el nivel de significancia de 0.01 % tenemos que

$$f = 12.04 \quad F_{0.1,2,7} = 9.55 \quad \Rightarrow \quad f > F_{0.1,2,7}$$

Lo que significa que el modelo si es útil con significancia 0.01 % dado que se rechaza la hipótesis nula.

Ahora realicemos las pruebas de los dos coeficientes de la regresión, en ambos consideremos el nivel de significancia de 0.05 % de esta manera tenemos

- Considerando a $H_0 : \beta_1 = 0$ y $H_a : \beta_1 \neq 0$ observando lo obtenido con R se tiene que $|t| = 2.96$ y por otro lado $t_{0.25,7}$ lo cual implica que $|t| > t_{0.25,7}$ así se rechaza la hipótesis nula, es decir, el predictor que tiene se le asigna al *pie* es necesario dado que tiene una relación con la variable dependiente.
- Considerando a $H_0 : \beta_1 = 0$ y $H_a : \beta_1 \neq 0$ observando lo obtenido con R se tiene que $|t| = 0.02$ y por otro lado $t_{0.25,7}$ lo cual implica que $|t| < t_{0.25,7}$ así no se rechaza la hipótesis nula, es decir, el predictor que tiene se le asigna a la *altura* no es necesario..

El código utilizado para obtener la regresión fue

```
datos <- c(74,13.0,75,56,8.5,66,65,10.0,69,66,9.5,66,62,9.0,54,69,11.0,72,75,12.0)
intento <- matrix(datos, ncol=10, nrow=3)
buena <- t(intento)
```

```
X1 <- buena[,2]
```

```
X2 <- buena[,3]
```

```
Y <- buena[,1]
```

```
# Crear un data frame con los datos
```

```
datos <- data.frame(X1, X2, Y)
```

```
modelo <- lm(Y ~ X1+X2, datos)
summary(modelo)
```

- b) Obtenga los elementos diagonales de la matriz del sombrero (palancas). Identifique el punto con el mayor apalancamiento. ¿Qué tiene de inusual el punto? Dada la afirmación del instructor de que no había estudiantes en la clase que midieran menos de cinco pies, ¿diría que hubo un error? Da otra razón por la que las medidas de este estudiante parecen incorrectas.

Notemos que

$$X = \begin{pmatrix} 1 & 13.0 & 75 \\ 1 & 8.5 & 66 \\ 1 & 10.0 & 69 \\ 1 & 9.5 & 66 \\ 1 & 9.0 & 54 \\ 1 & 11.0 & 72 \\ 1 & 12.0 & 75 \\ 1 & 9.0 & 63 \\ 1 & 9.0 & 66 \\ 1 & 8.5 & 63 \end{pmatrix}$$

Con lo anterior en mente, recordemos lo siguiente los elementos diagonales de H a veces se denominan apalancamientos para indicar su influencia sobre la regresión.

Los apalancamientos fueron obtenidos usando R así tenemos la siguiente tabla

<i>Observaciones</i>	<i>Pie</i>	<i>Altura</i>	<i>Envergadura</i>	<i>Apalancamiento</i>
1	13.0	75	74	0.5549944
2	8.5	66	56	0.3106461
3	10.0	69	65	0.1291486
4	9.5	66	66	0.1118326
5	9.0	54	62	0.8845599
6	11.0	72	69	0.1723585
7	12.0	75	75	0.3087221
8	9.0	63	66	0.1464646
9	9.0	66	66	0.1790925
10	8.5	63	63	0.2021805

El punto con mayor apalancamiento es la observación 5 la cual tiene 0.88 de apalancamiento, así centrándonos en los datos de esta observación, se puede observar que el estudiante en cuestión presenta la estatura más baja de todos los estudiantes, a pesar de que su tamaño de pie es similar al de otros compañeros y de manera análoga su envergadura. Pero por tener un apalancamiento demasiado alto en comparación con los demás, se da la posibilidad de un error al obtener dichas medidas.

El código de R utilizado es

```
datos <- c(74, 13.0, 75, 56, 8.5, 66, 65, 10.0, 69, 66, 9.5, 66, 62, 9.0, 54, 69, 11.0, 72, 75, 12.0)
intento <- matrix(datos, ncol=10, nrow=3)
```

```

buena <- t(intento)

primera <- buena[,2]
segunda <- buena[,3]
n <- length(primera)

uno <-c()

for(i in 1:n){
    uno[i] = 1
}

X <- cbind(uno, primera, segunda)
Xt <-t(X)

H <- X %*%solve(Xt%*%X) %*%t(X)

L <-c()

for(i in 1:n){
    L[i] = H[i,i]
}

```

- c) Para los otros puntos con alto apalancamiento, ¿qué los distingue de los puntos con valores de apalancamiento ordinarios?

La observación 1 tiene un apalancamiento de 0.554999 lo cual analizando los datos de la observación tienen sentido dicho valor, debido a que tiene los parametros mas altos en todas las medidas que se realizaron.

La observacion 2 tiene apancamiento 0.3106461 lo cual analizando los datos de la observación tienen sentido dicho valor, debido a que tiene los parametros mas bajos en las medidas de pie y envergadura, pero en altura igual tiene un valor muy bajo comparado con los demas, cabe destacar que la envergadura con relacion a su altura si difieren bastante dado que dichos parametros deben tener valores muy similares.

La observacion 7 tiene apancamiento 0.3087 lo cual analizando los datos de la observación tienen sentido dicho valor, debido a que tiene parametros altos en todas medidas.

- d) Examinando los residuos, encuentre a otro estudiante cuyos datos puedan estar equivocados.

Usando *R* tenemos que

<i>Observaciones</i>	<i>Residuos</i>
1	-1.8428732
2	-5.5966009
3	-1.3453583
4	1.2246272
5	-1.2635883
6	-0.5047298
7	2.3358987
8	2.7946128
9	2.8140131
10	1.3839987

La observación 2 tiene el residuo mayor a comparación de todos los demás, y esto puede ser debido a lo dicho en el inciso anterior dado que la envergadura y su altura tiene una diferencia de 10 pies y sabemos que la envergadura tiende a ser casi igual a la altura. Por lo tanto, este dato seguramente se encuentra equivocado.

El código utilizado para el obtener los residuos fue

```
datos <- c(74, 13.0, 75, 56, 8.5, 66, 65, 10.0, 69, 66, 9.5, 66, 62, 9.0, 54, 69, 11.0, 72, 75, 12.0)
intento <- matrix(datos, ncol=10, nrow=3)
buena <- t(intento)

primera <- buena[,2]
segunda <- buena[,3]
n <- length(primera)

uno <- c()

for(i in 1:n){
  uno[i] = 1
}

X <- cbind(uno, primera, segunda)
Xt <- t(X)

H <- X %*% solve(Xt %*% X) %*% Xt(X)

L <- c()

for(i in 1:n){
  L[i] = H[i, i]
}

y <- buena[,1]
r <- y - H%*%y
```

e) Discutir la eliminación de puntos cuestionables para obtener resultados de regresión válidos.

Las observaciones cuestionables es la numero 5 por lo dicho en el inciso *b* y la observación numero 2 por lo dicho en el inciso anterior.