

## Sección 8.3 Hogg

3. Sea  $Y \sim b(192, p)$ . Rechazamos  $H_0 : p = 0,75$  y aceptamos  $H_1 : p > 0,75$  si y solo si  $Y \geq 152$ . Use la aproximación de la distribución normal para determinar

(a)  $\alpha = P(Y \geq 152; p = 0,75)$ .

Recordemos

$$Z = \frac{Y/n - p_0}{\sqrt{p_0(1-p_0)/n}}$$

Con esto en mente usando el siguiente código tenemos

```
n=192
yn= ((151.5)/n ) #restamos el error#
p0 = 0.75
var = (p0*(1-p0)/n)
z= (yn-p0)/ sqrt( var )
alpha = 1- pnorm(z)
> alpha
[1] 0.1056498
```

Por lo tanto  $\alpha = 0,1056498$

(b)  $\beta = P(Y > 152)$  cuando  $p = 0,80$ .

Recordemos que

$$H_1 : p < p_0 \quad \beta(p') = 1 - \Phi \left( \frac{p_0 - p' - Z_\alpha \sqrt{p_0(1-p_0)/n}}{p'(1-p'/n)} \right)$$

Usando algunas de las variables definidas en el inciso anterior y utilizando realizamos el siguiente código

```
zal = qnorm(1-alpha)
pprime = 0.80
valor = (p0-pprime+zal*sqrt((p0)*(1-p0)/n))/sqrt(pprime*(1-pprime)/n)
beta = pnorm(valor)
> beta
[1] 0.3523862
```

Obteniendo que  $\beta = 0,3523862$

5. Si el peso de un bebe recién nacido es menor que 2500 gramos (5.5 libras), decimos que el bebé tiene un bajo peso de nacimiento. La proporción de bebés con un peso de nacimiento al indicador de desnutrición para las madres. Para los estados unidos, aproximadamente 7% de los bebés tiene un bajo peso de nacimiento. Sea  $p$  igual a la proporción de bebés nacidos en Sudán quienes tienen un peso menor de 1500 gramos. Probaremos la hipótesis nula  $H_0 : p = 0,07$ , contra la hipótesis alternativa  $H_1 : p > 0,07$ . En una muestra aleatoria de  $n = 209$  bebes,  $y = 23$  cuyo peso es menor a los 2500 gramos.

- (a) ¿Cuál es la conclusión del nivel de significancia de  $\alpha = 0,05$ ?

Para obtener el valor de significancia debemos de calcular el valor de  $Z$  y  $z_\alpha$ , donde por un lado recordemos

$$Z = \frac{Y/n - p_0}{\sqrt{p_0(1 - p_0)/n}}$$

Con esto en mente usando el siguiente código tenemos

```
y = 23
n = 209
p0 = 0.07
Z = (y/n - p0) / sqrt((p0*(1-p0))/n)
> Z
[1] 2.269143
```

Obteniendo que el valor de  $Z = 2,269143$ , por otro lado obtengamos el valor de  $z_\alpha$  así utilizamos el siguiente código

```
alfa = 0.05
zalfa = 1 - alfa
qnorm(zalfa)
> qnorm(zalfa)
[1] 1.644854
```

Con lo anterior tenemos que  $z_\alpha = 1,644854$ , de lo que podemos notar que  $Z > z_\alpha$ , por lo tanto, se rechaza la hipótesis nula.

- (b) ¿Cuál es la conclusión del nivel de significancia de  $\alpha = 0,01$ ?

Por el inciso anterior sabemos que  $Z = 2,269143$  entonces solo falta calcular el valor de  $z_\alpha$  así utilizando el siguiente código

```
alfa = 0.01
zalfa = 1 - alfa
qnorm(zalfa)
> qnorm(zalfa)
[1] 2.326348
```

De esta manera tenemos que  $z_\alpha = 2,326348$ , de lo que podemos notar que dado que  $z < z_\alpha$  entonces no se rechaza la hipótesis nula.

- (c) Encuentre el  $p$ -valor para esta prueba.

Tenemos que el  $p$ -valor viene a dado por  $1 - pnorm(Z) = 0,01162982$ , así el  $p$ -valor  $= 0,01162982$

12. Sea  $p$  igual a la proporción de caramelos amarillos en un paquete de colores mezclados. Se afirma que  $p = 0,20$ .

- (a) Se define el estadístico de orden y una región crítica y un nivel de significancia de  $\alpha = 0,05$  para la prueba  $H_0 : p = 0,20$  contra una hipótesis alternativa bilateral.

Definamos nuestra región crítica

$$|Z| = \frac{Y/n - 0,20}{\sqrt{(0,20)(1 - 0,20)/n}} \geq z_{\frac{\alpha}{2}}$$

Donde nuestro  $z_{\frac{\alpha}{2}} = 1,959964$

- (b) Para mejorar la prueba, 20 estudiantes contaron los dulces amarillos,  $y$ , y el total de número de dulces,  $n$ , en una paquete de 48.1 gramos, de los cuales se obtuvieron los siguientes promedios,  $y/n$ : 8/56, 13/55, 12/58, 13/56, 14/57, 5/54, 14/56, 15/57, 11/54, 13/55, 10/57, 8/59, 10/54, 11/55, 12/56, 11/57, 6/54, 7/58, 12/58, 14/58. Si cada prueba tiene  $H_0 : p = 0,20$ , ¿Qué proporción de estudiantes rechazaron la hipótesis nula?

Primero recordemos que

$$z = \frac{y/n - p_0}{\sqrt{p_0(1 - p_0)/n}}$$

Así utilizemos el siguiente código para obtener los valores de  $z$

```
p0=0.20
Y <- c(8,13,12,13,14,5,14,15,11,13,10,8,10,11,12,11,6,7,12,14)
n <- c(56,55,58,56,57,54,56,57,54,55,57,59,54,55,56,57,54,58,58,58)
d <- c(0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0)
N <- length(n)
for (i in 1:N){
  d[i] = Y[i]/n[i]
  z = (d[i]-p0)/sqrt((p0*(1-p0))/n[i])
  print(paste("El valor de z es", z))
}
```

El código nos devuelve

```
[1] "El valor de z es -1.0690449676497"
[2] "El valor de z es 0.674199862463242"
[3] "El valor de z es 0.131306432859722"
[4] "El valor de z es 0.601337794302955"
[5] "El valor de z es 0.860946032092278"
[6] "El valor de z es -1.97320007057534"
[7] "El valor de z es 0.935414346693485"
[8] "El valor de z es 1.19207912135854"
[9] "El valor de z es 0.0680413817439768"
[10] "El valor de z es 0.674199862463242"
[11] "El valor de z es -0.463586324972766"
[12] "El valor de z es -1.23679465431783"
[13] "El valor de z es -0.272165526975909"
[14] "El valor de z es 0"
[15] "El valor de z es 0.267261241912424"
[16] "El valor de z es -0.132453235706505"
[17] "El valor de z es -1.63299316185545"
[18] "El valor de z es -1.51002397788681"
```

[19] "El valor de z es 0.131306432859722"

[20] "El valor de z es 0.787838597158335"

Con los valores de z obtenidos veamos cuales rechazan la hipótesis nula utilizando el siguiente código

```
p0=0.20
za=qnorm(1-0.025)
y=c(8,13,12,13,14,5,14,15,11,13,10,8,10,11,12,11,6,7,12,14)
n=c(56,55,58,56,57,54,56,57,54,55,57,59,54,55,56,57,54,58,58,58)
d <- c(0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0)
N <- length(n)
for (i in 1:N){
  d[i]=y[i]/n[i]
  z[i]=(d[i]-p0)/sqrt((p0*(1-p0))/n[i]) #calculando alpha

  if(abs(z[i])>za){
    print(paste("Se rechaza H0 en el promedio", i))
  } else {
    print(paste("No se rechaza H0 en el promedio",i))
  }
}
```

Donde el código nos devuelve

```
[1] "No se rechaza H0 en el promedio 1"
[1] "No se rechaza H0 en el promedio 2"
[1] "No se rechaza H0 en el promedio 3"
[1] "No se rechaza H0 en el promedio 4"
[1] "No se rechaza H0 en el promedio 5"
[1] "Se rechaza H0 en el promedio 6"
[1] "No se rechaza H0 en el promedio 7"
[1] "No se rechaza H0 en el promedio 8"
[1] "No se rechaza H0 en el promedio 9"
[1] "No se rechaza H0 en el promedio 10"
[1] "No se rechaza H0 en el promedio 11"
[1] "No se rechaza H0 en el promedio 12"
[1] "No se rechaza H0 en el promedio 13"
[1] "No se rechaza H0 en el promedio 14"
[1] "No se rechaza H0 en el promedio 15"
[1] "No se rechaza H0 en el promedio 16"
[1] "No se rechaza H0 en el promedio 17"
[1] "No se rechaza H0 en el promedio 18"
[1] "No se rechaza H0 en el promedio 19"
[1] "No se rechaza H0 en el promedio 20"
```

De lo anterior se concluye que de los 20 estudiantes que realizaron el conteo de los dulces amarillos, se concluye que la proporción de estudiantes rechazaron la hipótesis nula es  $\frac{1}{20} = 0,05 = 5\%$ .

- (c) Si asumimos que la hipótesis nula es verdadera, ¿Qué proporción de estudiantes esperarían rechazar la hipótesis nula?

Tendríamos la misma cantidad de personas que rechazan la hipótesis, es decir, 5 % de la población.

- (d) Para cada uno de los 20 promedios en la parte (b), un intervalo del 95 % de confianza para  $p$  puede ser calculado. ¿Qué proporción de ese 95 % de intervalos de confianza contienen a  $p = 0,20$ ?

Recordando que

$$\frac{y}{n} \pm z_{\frac{\alpha}{2}} \sqrt{\left(\frac{y}{n}\right) \left(1 - \frac{y}{n}\right) / n}$$

De esta manera usando el siguiente código para obtener los intervalos de confianza del 95 % para  $p = 0,20$  son:

```
al = 0.05
zal = qnorm(1-al/2)
y <- c(8,13,12,13,14,5,14,15,11,13,10,8,10,11,12,11,6,7,12,14)
n <- c(56,55,58,56,57,54,56,57,54,55,57,59,54,55,56,57,54,58,58,58)
LI <- c(0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0)
LD <- c(0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0)
N <- length(n)
for (i in 1:N){
  LI[i] = y[i]/n[i] - zal*sqrt( (y[i]/n[i])*(1-y[i]/n[i])/n[i] )
  LD[i] = y[i]/n[i] + zal*sqrt( (y[i]/n[i])*(1-y[i]/n[i])/n[i] )
  cat("El intervalo", LI[i], "< p <", LD[i] )
  print(paste("para el promedio", i))
}
```

Donde el código nos da

```
El intervalo 0.05120731 < p < 0.234507[1] "para el promedio 1"
El intervalo 0.1240842 < p < 0.3486431[1] "para el promedio 2"
El intervalo 0.1026467 < p < 0.3111464[1] "para el promedio 3"
El intervalo 0.121564 < p < 0.3427217[1] "para el promedio 4"
El intervalo 0.1338675 < p < 0.3573606[1] "para el promedio 5"
El intervalo 0.01528173 < p < 0.1699035[1] "para el promedio 6"
El intervalo 0.1365891 < p < 0.3634109[1] "para el promedio 7"
El intervalo 0.1488421 < p < 0.3774736[1] "para el promedio 8"
El intervalo 0.09628299 < p < 0.3111244[1] "para el promedio 9"
El intervalo 0.1240842 < p < 0.3486431[1] "para el promedio 10"
El intervalo 0.0767005 < p < 0.2741767[1] "para el promedio 11"
El intervalo 0.04823573 < p < 0.2229507[1] "para el promedio 12"
El intervalo 0.08157945 < p < 0.2887909[1] "para el promedio 13"
El intervalo 0.0942874 < p < 0.3057126[1] "para el promedio 14"
El intervalo 0.1068168 < p < 0.3217547[1] "para el promedio 15"
El intervalo 0.09053267 < p < 0.2954322[1] "para el promedio 16"
El intervalo 0.02728995 < p < 0.1949323[1] "para el promedio 17"
El intervalo 0.03685179 < p < 0.2045275[1] "para el promedio 18"
El intervalo 0.1026467 < p < 0.3111464[1] "para el promedio 19"
El intervalo 0.1312516 < p < 0.351507[1] "para el promedio 20"
```

Con lo obtenido con anterioridad observamos que la proporción es de  $\frac{18}{20} = 0,90 = 90\%$ .

- (e) Si 20 resultados son acumulados tal que  $\sum_{i=1}^{20} y_i$  igual al número total de números amarillos y  $\sum_{i=1}^{20} n_i$  igual al tamaño de la muestra, ¿Se rechaza  $H_0 : p = 0,20$ ?

Los resultados al acumular son

$$y = \sum_{i=1}^{20} y_i = 219 \quad n = \sum_{i=1}^{20} n_i = 1124$$

Consideremos el siguiente estimador  $\hat{p} = \frac{y}{n} = \frac{219}{1124} \approx 0,19484$ . En el cual para ver si rechazara debes usar a  $z = \frac{y/n - p_0}{\sqrt{p_0(1-p_0)/n}}$  que en nuestro caso es  $z = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}$  entonces

$$z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} = \frac{0,19484 - 0,20}{\sqrt{\frac{0,20(1-0,20)}{1124}}} \approx -0,432487$$

Y por el inciso (a) sabemos que  $z_{\frac{\alpha}{2}} = 1,959964$ , así notemos que  $|z| < z_{\frac{\alpha}{2}}$  lo que implica que no se rechaza  $H_0$ .

13. Sea  $p_m$  y  $p_f$  las proporciones de las hembras y machos de corona blanca que regresan a su lugar de nacimiento. De el final del intervalo de 95 % de confianza para  $p_m - p_f$  si 124 de 894 machos y 70 de 700 hembras regresan (*The Condor*, 1992, pp. 117–133) ¿Su resultado concuerda con la conclusión de la prueba de  $H_0 : p_1 = p_2$  contra  $H_1 : p_1 \neq p_2$  con  $\alpha = 0,05$ ?

Definamos a  $\hat{p}_m = \frac{124}{894} \approx 0,138702$ ,  $\hat{p}_f = \frac{70}{700} = 0,1$ , dado que nos piden el intervalo de 95 % de confianza de  $p_m - p_f$  tenemos que nuestro  $\alpha = 0,05$  y recordemos que para calcular el intervalo viene definido por

$$\hat{p}_m - \hat{p}_f \pm z_{\frac{\alpha}{2}} \sqrt{\frac{\hat{p}_m(1-\hat{p}_m)}{n_1} + \frac{\hat{p}_f(1-\hat{p}_f)}{n_2}}$$

Así utilizando el siguiente código

```
alfa <- 0.05
zal <- qnorm(1-alfa/2)
n1 <- 894
n2 <- 700
p1 <- 124/894
p2 <- 70/700
LI <- p1-p2-zal*sqrt((p1*(1-p1)/n1) + (p2*(1-p2)/n2))
LD <- p1-p2+zal*sqrt((p1*(1-p1)/n1) + (p2*(1-p2)/n2))
cat("El intervalo", LI, "< p1-p2 <", LD)
```

Donde el código nos da

El intervalo  $0.006965556 < p_1 - p_2 < 0.07043937$

Con lo anterior tenemos que el intervalo de confianza del 95 % para  $p_m - p_f$  es

$$[0,006965556, 0,07043937]$$

Dado que  $H_1 : p_1 \neq p_2$  con  $\alpha = 0,05$  usaremos la siguiente región crítica

$$|z| = \frac{|\hat{p}_1 - \hat{p}_2|}{\hat{p}(1 - \hat{p})(\frac{1}{n_1} + \frac{1}{n_2})} \geq z_{\frac{\alpha}{2}}$$

Pero como el intervalo no contiene al 0 tenemos que

$$|z| = \frac{|\frac{y_1}{n_1} - \frac{y_2}{n_2}|}{\sqrt{\frac{(y_1/n_1)(1-y_1/n_1)}{n_1} + \frac{(y_2/n_2)(1-y_2/n_2)}{n_2}}}$$

Asi utilizando el siguiente código tenemos

```
y1 <- 124
n1 <- 894
```

```
y2 <- 70
n2 <- 700
```

```
p1 <- y1 / n1
p2 <- y2 / n2
```

```
z <- (p1-p2) / sqrt( (p1*(1-p1)) / n1 + (p2*(1-p2)) / n2 )
```

El cual nos da que  $|z| = 2,390133$  y por otro lado sabemos que  $z_{\frac{\alpha}{2}} = 1,96$  entonces  $|z| > z_{\frac{\alpha}{2}}$ , por lo tanto, se rechaza  $H_0$ .

## Sección 10 Devore

81. Dos estudiantes, Miguel Melo y Cody Watson, hicieron un estudio de precios de libros de texto. Compararon los precios en la librería del campus y Amazon.com. Para ser justos, incluyeron el impuesto sobre las ventas para la tienda local y agregaron el envío para Amazon. Estos son los precios de una muestra de 27 libros.

| Campus | Amazon |
|--------|--------|
| 100.41 | 106.94 |
| 99.34  | 113.94 |
| 51.53  | 61.44  |
| 20.45  | 31.59  |
| 28.69  | 29.89  |
| 70.66  | 83.94  |
| 98.81  | 107.74 |
| 111.56 | 115.99 |
| 97.22  | 108.29 |
| 61.89  | 78.44  |
| 70.39  | 82.94  |
| 58.17  | 65.74  |
| 108.38 | 122.09 |
| 61.63  | 63.49  |
| 59.50  | 69.24  |
| 87.66  | 73.84  |
| 26.56  | 33.98  |
| 44.63  | 40.39  |
| 96.69  | 117.99 |
| 18.06  | 27.94  |
| 103.06 | 115.74 |
| 14.61  | 24.69  |
| 77.03  | 88.04  |
| 99.34  | 113.94 |
| 81.81  | 90.74  |
| 48.88  | 58.94  |
| 76.50  | 91.94  |

- (a) Determine el intervalo de 95 % de confianza para la diferencia de la media de poblaciones, usando el método  $t$  de la sección 10.3. Verifique si los datos son normales, explique por que el método  $t$  (o el método  $z$  de la sección 10.1) puede seguir aproximándose.

Primero recordemos el metodo  $t$  de la seccion 10,3.

Cuando  $D = X - Y$  donde  $X - Y$  son variable aleatorias dependientes tenemos que el intervalo de

confianza viene dado

$$\bar{d} \pm t_{\frac{\alpha}{2}}(n-1) \frac{s_d}{\sqrt{n}}$$

Con lo anterior en mente usemos el siguiente código

```
x <- c(100.41,99.34,51.53,20.45,28.69,70.66,98.81,111.56,97.22,61.89,70.39,58.1
y <- c(106.94,113.94,61.44,31.59,29.89,83.94,107.74,115.99,108.29,78.44,82.94,6
n <- 27
z <- x-y
```


```
alfa=(1-0.95)/2
d <- mean(z)
desviacion <- sd(z)
ta <- qt(1-alfa,26)
```


```
LI = d-ta*(desviacion/sqrt(n))
LD = d+ta*(desviacion/sqrt(n))
```

```
# Realiza grafica#
qqnorm(z)
qqline(z)
```

```
# Realiza el Histograma#
hist(z, freq=F, main = "Histograma de los datos")
curve(dnorm(x, mean(z), sd(z)), add=TRUE)
```

Con el código anterior tenemos el que intervalo de 95 % de confianza para la diferencia de medias el cual es  $[-11,85319, -6,399401]$ . Ahora a partir de las siguiente vamos a verificar si los datos son normales





Podemos observar que la mayoría de los datos en ambas imágenes se encuentran distribuidos de manera de la distribución normal, pero aproximadamente como 6 de ellos si no suelen seguir esto. Así podemos decir que si los datos son normales.

- (b) Basándose en las 27 diferencias, emplee el método **bootstrap** de 999 medias. Verifique si la distribución **bootstrap** hace normales a las muestras.

El siguiente código realiza el Bootstrap.

```
x <- c(100.41,99.34,51.53,20.45,28.69,70.66,98.81,111.56,97.22,61.89,70.39,58.1
y <- c(106.94,113.94,61.44,31.59,29.89,83.94,107.74,115.99,108.29,78.44,82.94,6
n <- 27
z <- x-y
```



```
b <-999
theta <- mean(z)
thetastar <- rep(0,b)
N<- length(z)
for(i in 1:b)
{
  xstar <-sample(z, N, replace = TRUE)
  thetastar[i] <- mean(xstar)
}
thetastar
```

```
# Realiza grafica#
qqnorm(thetastar)
qqline(thetastar)
```

```
# Realiza el Histograma#
```

```
hist(thetastar, freq=F, main = "Histograma de la thetastar")
curve(dnorm(x, mean(thetastar), sd(thetastar)), add=TRUE)
```

Del que obtenemos las siguientes graficas



Del que podemos observar **bootstrap** hace normales a las muestras.

- (c) Use la desviación estándar de la **bootstrap** de las medias y obtenga el intervalo de 95 % de confianza para la diferencia de medias.

Recordemos que el intervalo de medias con *bootstrap* viene dado por

$$\bar{x} \pm z_{\frac{\alpha}{2}} \bar{s}_{boot}$$

Así consideremos el siguiente código

```
zalfa <- qnorm(0.975)
```

```
SB <- sd( thetastar )
LIB <- d - z alfa *(SB)
LDB <- d + z alfa *(SB)
```

Del cual tenemos que el intervalo de confianza viene dado por

$$[-11,62048, -6,632115]$$

- (d) Use el método **bootstrap** y el método percentil para obtener el intervalo de 95 % de confianza para la diferencia de medias. Usemos el siguiente código

```
ordenar <- order( thetastar )
ordenar[25] # Nos dice la posion del elemento 25#
[1] 908

ordenar[975] # Nos dice la posion del elemento 975#
[1] 896

#En cada caso nos dara un elemento distinto#
# Para el caso que estamos realizando en este momento es#

thetastar[896]
[1] -11.4837

thetastar[908]
[1] -6.472593
```

Obtenemos que el intervalo dado es

$$[-11,4837, -6,472593]$$

- (e) Compare los 3 intervalos de confianza. En vista de los resultados obtenidos en (d) ¿La normalidad de los datos invalida los resultados de (a) y (c)? Explique.

No los invalida dado que al ver los 3 intervalos de confianza podemos notar que todos se encuentran en los mismos números de unidades y los decimales o centésimas (cambian de forma poco notaria).

- (f) Interprete los resultados. ¿Hay una diferencia substancial entre las 2 formas de adquirir los libros? Asuma que las poblaciones aún no adquieren los libros y tiene estás 2 opciones, ¿En dónde lo compraría?

Tenemos que los intervalos no incluyen al 0, es decir, si han incrementado con esto en mente conviene en su gran mayoría adquirir los libros en librería Campus,

## Sección 9.3 Hogg

5. La hembra del cuco pone sus huevos en los nidos de otras aves. Los “padres adoptivos” suelen ser engañados, probablemente por la similitud en el tamaño de sus propios huevos y los huevos de cuco. Latter (ver Referencias) investigó esta posible explicación y midió la longitud de los huevos de cuco (en mm) que se encontraron en los nidos de tres especies. Los siguientes son sus resultados:

Gorrión de cobertura: 22.0 23.9 20.9 23.8 25.0  
 24.0 21.7 23.8 22.8 23.1  
 23.1 23.5 23.0 23.0

Robin: 21.8 23.0 23.3 22.4 23.0  
 23.0 23.0 22.4 23.9 22.3  
 22.0 22.6 22.0 22.1 21.1  
 23.0

Wren: 19.8 22.1 21.5 20.9 22.0  
 21.0 22.3 21.0 20.3 20.9  
 22.0 20.0 20.8 21.2 21.0

- (a) Construya una tabla ANOVA para probar la igualdad de las tres medias.

Con el siguiente código realizamos los cálculos para la tabla **Anova**.

```
m <- 3 # Numero de filas #
```

```
HS <- c(22.0, 23.9, 20.9, 23.8, 25.0, 24.0, 21.7, 23.8, 22.8, 23.1, 23.1, 23.5, 23.0, 23.0)
```

```
m1 <- mean(HS)
```

```
L1 <- length(HS)
```

```
R <- c(21.8, 23.0, 23.3, 22.4, 23.0, 23.0, 23.0, 22.4, 23.9, 22.3, 22.0, 22.6, 22.0, 22.1, 23.0)
```

```
m2 <- mean(R)
```

```
L2 <- length(R)
```

```
W <- c(19.8, 22.1, 21.5, 20.9, 22.0, 21.0, 22.3, 21.0, 20.3, 20.9, 22.0, 20.0, 20.8, 21.2, 21.0)
```

```
m3 <- mean(W)
```

```
L3 <- length(W)
```

```
GM <- c(m1, m2, m3)
```

```
mg <- mean(GM) # X.. barra#
```

```
LG <- c(L1, L2, L3)
```

```
n <- sum(LG)
```

```
## SS(T)##

SSTT <- c()
for(i in 1:m){
  SSTT[i] = LG[i]*(GM[i] - mg)^2
}
SST <- sum(SSTT)
```

```
## SS(E) ##

f1 <- (HS-m1)^2
f2 <- (R-m2)^2
f3 <- (W -m3)^2
SSE <- sum(f1) + sum(f2) + sum(f3)
```

```
## SS(TO) ##

s1 <- (HS-mg)^2
s2 <- (R-mg)^2
s3 <- (W -mg)^2

SSTO <- sum(s1) + sum(s2) + sum(s3)
```

```
## Media de cuadrados ##
```

```
MST <- SST/(m-1)
MSE <- SSE/(n-m)
```

```
## F-razon ##
Fratio <- MST/MSE
```

```
# P-valor #
pre <- pf(Fratio,3,8)
pvalor <- 1-pre
```

```
#P-valor#
prep <-pf(Fratio,m-1,n-m)
```

```
pvalor <- (1 - prep)
```

Entonces la tabla **Anova** es

| Fuente de Variación | SS       | Grados de Libertad | Media de Cuadrados(MS) | F-razon  | p-valor |
|---------------------|----------|--------------------|------------------------|----------|---------|
| Tratamiento         | 31.11885 | 2                  | 15.55942               | 22.33371 | 0.000   |
| Error               | 29.26052 | 42                 | 0.696679               |          |         |
| Total               | 60.37936 | 44                 |                        |          |         |

Apartir del  $p$  – *valor* ponemos decir que se rechaza  $H_0$ , debido a que  $p$  – *valor*  $< 0,0,1$  lo cual implica que las medias no son iguales


(b) Para cada conjunto de datos, construya diagramas de caja y bigotes en la misma figura.

Se utilizara el siguiente código para realizar el diagrama de caja y bigotes

```
HS <- c(22.0, 23.9, 20.9, 23.8, 25.0, 24.0, 21.7, 23.8, 22.8, 23.1, 23.1, 23.5, 23.0, 23.0)
R <- c(21.8, 23.0, 23.3, 22.4, 23.0, 23.0, 23.0, 22.4, 23.9, 22.3, 22.0, 22.6, 22.0, 22.1, 22.1)
W <- c(19.8, 22.1, 21.5, 20.9, 22.0, 21.0, 22.3, 21.0, 20.3, 20.9, 22.0, 20.0, 20.8, 21.2, 21.2)
```

```
par(mfrow=c(1,3))
boxplot(HS, main= "Gorrion de cobertura")
boxplot(R, main= "Robin")
boxplot(W, main= "Wren")
```

Del cual tenemos



(c) Interpreta tus resultados.

Como podemos observar en las figuras la raya de en medio de cada caja representa la media, donde en todos los casos podemos observar que es distinta.

9. Sea  $X_i$ ,  $i = 1, 2, 3, 4$ , igual a la distancia (en yardas) que recorre una pelota de golf cuando se golpea desde un tee, donde  $i$  denota el índice del  $i$  – *esimo* fabricante. Suponga que la distribución de  $X_i$  es  $N(\mu_i, \sigma^2)$ ,

$i = 1, 2, 3, 4$ , cuando cierto golfista golpea una pelota. Probaremos la hipótesis nula  $H_0 : \mu_1 = \mu_2 = \mu_3 = \mu_4$ , usando tres observaciones de cada variable aleatoria.

(a) Dé una región crítica para un nivel de significancia  $\alpha = 0,05$ .

Recordemos que la región prueba a nivel de significancia  $\alpha$ . rechaza  $H_0$  si  $F \geq F_\alpha(m-1, n-m)$ . De esta manera usando el siguiente código.

```
alfa <- 0.05
qf(1-alfa, 3, 8)
```

Tenemos que

$$F \geq 4,066181$$

(b) Construya una tabla ANOVA y establezca su conclusión, usando los siguientes datos:

|       |     |     |     |
|-------|-----|-----|-----|
| $x_1$ | 240 | 221 | 265 |
| $x_2$ | 286 | 256 | 272 |
| $x_3$ | 259 | 245 | 232 |
| $x_4$ | 239 | 215 | 223 |

Con el siguiente código construyamos la tabla

```
m <- 4 # Numero de filas #

x1 <- c(240, 221, 265)
m1 <- mean(x1)
L1 <- length(x1)

x2 <- c(286, 256, 272)
m2 <- mean(x2)
L2 <- length(x2)

x3 <- c(259, 245, 232)
m3 <- mean(x3)
L3 <- length(x3)

x4 <- c(239, 215, 223)
m4 <- mean(x4)
L4 <- length(x4)

GM <- c(m1, m2, m3, m4)
mg <- mean(GM) # X.. barra#

LG <- c(L1, L2, L3, L4)

n <- sum(LG)

## SS(T)##
```

```

SSTT <- c()
for(i in 1:m){
  SSTT[i] = LG[i]*(GM[i] - mg)^2
}
SST <- sum(SSTT)

```

```
## SS(E) ##
```

```

f1 <- (x1-m1)^2
f2 <- (x2-m2)^2
f3 <- (x3 -m3)^2
f4 <- (x4 -m4)^2
SSE <- sum(f1) + sum(f2) + sum(f3) + sum(f4)

```

```
## SS(TO) ##
```

```

s1 <- (x1-mg)^2
s2 <- (x2-mg)^2
s3 <- (x3 -mg)^2
s4 <- (x4 -mg)^2

SSTO <- sum(s1) + sum(s2) + sum(s3) + sum(s4)

```

```
## Media de cuadrados ##
```

```

MST <- SST/(m-1)
MSE <- SSE/(n-m)

```

```

## F-razon ##
F <- MST/MSE

```

Así la tabla es

| Fuente de Variación | SS       | Grados de Libertad | Media de Cuadrados(MS) | F-razon  |
|---------------------|----------|--------------------|------------------------|----------|
| Tratamiento         | 3214.917 | 3                  | 1071.639               | 4.105896 |
| Error               | 2088     | 8                  | 261                    |          |
| Total               | 5302.917 | 11                 |                        |          |

Del lo anterior y del inciso *a* se tiene que

$$4,105896 > 4,066181$$

Por lo tanto, se rechaza a  $H_0$

(c) ¿Cuál sería su conclusión si  $\alpha = 0,025$ ?

Usemos el siguiente código para calcular  $F \geq F_\alpha(m-1, n-m)$

```
alfa <- 0.025
qf(1-alfa, 3, 8)
```

De lo que notemos que

$$4,105896 < 5,415962$$

Lo que implica que no se rechaza a  $H_0$ .

(d) ¿Cuál es el *p*-valor aproximado de esta prueba?

El *p*-valor es la probabilidad, bajo  $H_0$ , de obtener un  $F$  que sea al menos tan grande como este valor calculado de  $F$ , con esto en mente sabemos que  $F = 4,105896$ , usando el siguiente comando tenemos

```
pf(4.105896, 3, 8)
[1] 0.9510953
```

De esta manera

$$p\text{-valor} = 1 - 0,9510953 = 0,0489047$$

13. Para un producto en aerosol, hay tres pesos: el peso de la tara (peso del contenedor), el peso del concentrado y el peso del propulsor. Sea  $X_1, X_2, X_3$  los pesos propulsores en tres días diferentes. Suponga que cada una de estas variables aleatorias independientes tiene una distribución normal con varianza común y medias respectivas  $\mu_1, \mu_2$ , y  $\mu_3$ . Probaremos la hipótesis nula  $H_0 : \mu_1 = \mu_2 = \mu_3$ , usando nueve observaciones de cada una de las variables aleatorias.

(a) Dé una región crítica para un nivel de significancia  $\alpha = 0,01$ .

Recordemos que la región prueba a nivel de significancia  $\alpha$ . rechaza  $H_0$  si  $F \geq F_\alpha(m-1, n-m)$ . De esta manera usando el siguiente código.

```
alfa <- 0.01
qf(1-alfa, 2, 24)
```

Tenemos que

$$F \geq 5,613591$$

(b) Construya una tabla ANOVA y establezca su conclusión, usando los siguientes datos:

```

x1:  43.06  43.32  42.63  42.86  43.05
     42.87  42.94  42.80  42.36

x2:  42.33  42.81  42.13  42.41  42.39
     42.10  42.42  41.42  42.52

x3:  42.83  42.57  42.96  43.16  42.25
     42.24  42.20  41.97  42.61

```

Con el siguiente código obtengamos los valores de la tabla

```

m <- 3 # Numero de filas #

x1<- c(43.06,43.32,42.63,42.86,43.05,42.87,42.94,42.80,42.36)
m1 <- mean(x1)
L1 <- length(x1)

x2 <- c(42.33,42.81,42.13,42.41,42.39,42.10,42.42,41.42,42.52)
m2 <- mean(x2)
L2 <- length(x2)

x3 <- c(42.83,42.57,42.96,43.16,42.25,42.24,42.20,41.97,42.61)
m3 <- mean(x3)
L3 <- length(x3)

GM <- c(m1,m2, m3)
mg <- mean(GM) # X.. barra#

LG <- c(L1,L2,L3)

n <- sum(LG)

## SS(T)##

SSTT <- c()
for(i in 1:m){
    SSTT[i] = LG[i]*(GM[i] - mg)^2
}
SST <- sum(SSTT)

## SS(E) ##

f1 <- (x1-m1)^2
f2 <- (x2-m2)^2
f3 <- (x3 -m3)^2
SSE <- sum(f1) + sum(f2) + sum(f3)

```

```
## SS(TO) ##

s1 <- (x1-mg)^2
s2 <- (x2-mg)^2
s3 <- (x3 -mg)^2

SSTO <- sum(s1) + sum(s2) + sum(s3)

## Media de cuadrados ##

MST <- SST/(m-1)
MSE <- SSE/(n-m)

## F-razon ##
F <- MST/MSE
```

Así la tabla es


| Fuente de Variación | SS       | Grados de Libertad | Media de Cuadrados(MS) | F-razon  |
|---------------------|----------|--------------------|------------------------|----------|
| Tratamiento         | 1.609156 | 2                  | 0.8045778              | 6.337245 |
| Error               | 3.047044 | 24                 | 0.1269602              |          |
| Total               | 4.6562   | 26                 |                        |          |

Del lo anterior y del inciso *a* se tiene que

$$6,337245 > 5,613591$$

Por lo tanto, se rechaza a  $H_0$

- (c) Para cada conjunto de datos, construya diagramas de caja y bigotes en la misma figura y dé una interpretación de sus diagramas.



Como podemos notar tenemos las medias son distintas, lo cual coincide con lo obtenido en la tabla anterior. De manera análoga notamos que los pesos en cada día varían un poco pero todos en general se encuentran entre el rango de 42 – 44.

El código para realizar el diagrama fue el siguiente

```
x_1 <- c(43.06, 43.32, 42.63, 42.86, 43.05, 42.87, 42.94, 42.80, 42.36)
x_2 <- c(42.33, 42.81, 42.13, 42.41, 42.39, 42.10, 42.42, 41.42, 42.52)
x_3 <- c(42.83, 42.57, 42.96, 43.16, 42.25, 42.24, 42.20, 41.97, 42.61)

matriz <- cbind(x_1, x_2, x_3)
boxplot(matriz)
```

15. Ledolter y Hogg (*ver Referencias*) reportan que un ganadero de un cebadero quiere comparar la efectividad de tres tipos de alimento para de ganado. El seleccionó una muestra aleatoria de 15 pequeñas vacas de un un año, de su lote de cerca de 1000 vacas y las dividió en 3 grupos aleatoria mente. Cada grupo lo alimenta con un tipo de alimento diferente, al notar que una pequeña vaca del grupo A se perdió en un accidente, el operador registró el peso de su ganado (en libras) por un periodo de 6 meses

Grupo A: 500 650 530 680

Grupo B: 700 620 780 830 860

Grupo C: 500 520 400 580 410

- (a) Pruebe si hay diferencia en la media de los pesos de los 3 suplementos o no.

Notemos que

| Fuente de Variación | SS     | Grados de Libertad | Media de Cuadrados(MS) | F-razon  | p-valor |
|---------------------|--------|--------------------|------------------------|----------|---------|
| Tratamiento         | 193040 | 2                  | 96520                  | 12.46736 | 0.00148 |
| Error               | 85160  | 11                 | 7741.818               |          |         |
| Total               | 278200 | 13                 |                        |          |         |

Consideremos la hipótesis nula  $H_0 : \mu_1 = \mu_2 = \mu_3$ . En la cual notemos que el  $p$ -valor  $= 0,0062 < 0,01$  lo cual implica que se rechaza la hipótesis nula, es decir, que si hay una diferencia en la media de los pesos.

El código usado para obtener los valores de la tabla *Anova* es el siguiente

```
m <- 3 # Numero de filas #

x1<- c(500, 650, 530, 680)
m1 <- mean(x1)
L1 <- length(x1)

x2 <- c(700, 620, 780, 830, 860)
m2 <- mean(x2)
L2 <- length(x2)

x3 <- c(500, 520, 400, 580, 410)
m3 <- mean(x3)
L3 <- length(x3)

GM <- c(m1,m2, m3)
mg <- mean(GM) # X.. barra#

LG <- c(L1,L2,L3)

n <- sum(LG)

## SS(T)##

SSTT <- c()
for(i in 1:m){
  SSTT[i] = LG[i]*(GM[i] - mg)^2
}
SST <- sum(SSTT)

## SS(E) ##

f1 <- (x1-m1)^2
f2 <- (x2-m2)^2
f3 <- (x3 -m3)^2
SSE <- sum(f1) + sum(f2) + sum(f3)

## SS(TO) ##
```

```

s1 <- (x1-mg)^2
s2 <- (x2-mg)^2
s3 <- (x3 -mg)^2

SSTO <- sum(s1) + sum(s2) + sum(s3)

## Media de cuadrados ##


MST <- SST/(m-1)
MSE <- SSE/(n-m)

## F-razon ##
F <- MST/MSE

#P-valor#
prep <- pf(F,m-1,n-m)
pvalor <- 1-prep

```

**(b)** ¿Los datos de los diagramas box plot confirman su respuesta en la parte **(a)**?



Si, dado que podemos observar principalmente que las medias no coinciden además notemos que los datos en este caso si se encuentran variando, por ejemplo, tenemos que el grupo A toma valores entre 500 – 700 mientras que el grupo B toma valores desde 700 – 900.

El código para realizar el boxplot fue el siguiente:

```

x1<- c(500, 650, 530, 680)
x2 <- c(700, 620, 780, 830, 860)
x3 <- c(500, 520, 400, 580, 410)

```

```
# Intentar despues con esto ylim=range(350,950)#  
par(mfrow=c(1,3))  
boxplot(x1, main = "Grupo A")  
boxplot(x2, main = "Grupo B")  
boxplot(x3, main = "Grupo C")
```

## Sección 9.4 Hogg

3. Queremos comparar la fuerza de compresión del concreto correspondiente a  $a = 3$  diferencia del método de colado. El concreto es mezclado en lotes que son tan largos que pueden cubrir 3 cilindros. Aunque se le toma importancia a la uniformidad, esperamos algo de cambio entre el lote  $b = 5$  usado para obtener la siguiente fuerza de compresión (hay una pequeña razón para sospechar de la interacción; por lo tanto, solo se toma una observación en cada celda):

| Tratamiento | Lote |    |    |    |    |
|-------------|------|----|----|----|----|
|             | B1   | B2 | B3 | B4 | B5 |
| A1          | 52   | 47 | 44 | 51 | 42 |
| A2          | 60   | 55 | 49 | 52 | 43 |
| A3          | 56   | 48 | 45 | 44 | 38 |

- (a) Use el 5 % de nivel de significancia y pruebe  $H_A : \alpha_1 = \alpha_2 = \alpha_3 = 0$  contra toda las demás alternativas.

Antes de resolverlo usemos el siguiente código para construir la *TablaANOVA2*

```
a <- 3      # Numero de filas #
b <- 5      # Numero de columnas #

x1 <- c(52, 47, 44, 51, 42)
x2 <- c(60, 55, 49, 52, 43)
x3 <- c(56, 48, 45, 44, 38)
matriz <- rbind(x1, x2, x3)

row <- rowSums(matriz) #suma filas#
col <- colSums(matriz) #suma columnas#

xdpunto <- sum(matriz)/(a*b)

pf <-c()
for(i in 1:a){
    pf[i] = row[i]/b
}
pf

pc <-c()
for(j in 1:b){
    pc[j] = col[j]/a
}
pc

SSA <- b*sum((pf-xdpunto)^2)
```

```
SSB <- a*sum((pc-xdpunto)^2)

# SSE #
p1 <-c()
p2 <-c()
p3 <-c()
for(i in 1:b){
  p1[i]<-(x1[i] - pc[i]-pf[1] + xdpunto)^2
  p2[i]<-(x2[i] - pc[i]-pf[2] + xdpunto)^2
  p3[i]<-(x3[i] - pc[i]-pf[3] + xdpunto)^2
}
SSE <- sum(p1) + sum(p2) + sum(p3)

SSTO <- SSA + SSB + SSE

a-1
b-1
(a-1)*(b-1)
a*b-1

MSA <- SSA/(a-1)
MSB <- SSB/(b-1)

MSE <- SSE/((a-1)*(b-1))

FA <- MSA/MSE
FB <- MSB/MSE
```

Obteniendo así

| Fuente de Variación | SS    | Grados de Libertad | Media de Cuadrados(MS) | F-razon  |
|---------------------|-------|--------------------|------------------------|----------|
| Factor A renglón    | 89.2  | 2                  | 44.6                   | 7.623932 |
| Factor B columna    | 363.6 | 4                  | 90.9                   | 15.53846 |
| Error               | 46.8  | 8                  | 5.85                   |          |
| Total               | 499.6 | 14                 |                        |          |

Del cual sabemos que para encontrar el 5% de significancia, se rechaza  $H_A : \alpha_1 = \alpha_2 = \alpha_3 = 0$  si  $F_A \geq F_{\alpha}[a-1, (a-1)(b-1)]$  así utilizando el siguiente código

```
a <- 3
b <- 5
alfa <- 0.05
qf(1-alfa, a-1, (a-1)*(b-1))
```

Tenemos que

$$F_A \geq F_{\alpha}[a-1, (a-1)(b-1)] = 4,45897 \approx 4,46$$

Con lo anterior y observando la tabla tenemos que

$$7,623932 > 4,46$$

Lo que implica que  $H_A$  se rechaza.

- (b) Use el 5 % de nivel de significancia y pruebe  $H_B : \beta_1 = \beta_2 = \beta_3 = 0$  contra toda las demás alternativas. (Ver las referencias de Ledolter y Hogg en Referencias.)

Del forma análoga sabemos que para encontrar el 5 % de significancia, se rechaza  $H_B : \beta_1 = \beta_2 = \beta_3 = 0$  si  $F_B \geq F_\alpha[b-1, (a-1)(b-1)]$  así utilizando el siguiente código

```
a <- 3
b <- 5
alfa <- 0.05
qf(1-alfa, b-1, (a-1)*(b-1))
```

Obtenemos que

$$F_B \geq F_\alpha[b-1, (a-1)(b-1)] = 3,837853 \approx 3,84$$

Con lo anterior y observando la tabla tenemos que

$$15,53846 > 3,84$$

Lo que implica que  $H_B$  se rechaza.

5. Un estudiante de psicología se interesó en probar como el consumo de comida de las ratas podría ser afectado por una droga particular. Ella suele usar aspectos para el primer atributo droga y placebo, y 4 aspectos para el segundo atributo, macho(M), castrado (C), hembra (F) y ovariectomizado (O). Para cada celda, ella colocó 5 ratas. La cantidad de comida consumida en gramos por 24 horas se en listó en la siguiente tabla .

|         | M     | C     | F     | O     |
|---------|-------|-------|-------|-------|
| Droga   | 22.56 | 16.54 | 18.58 | 18.20 |
|         | 25.02 | 24.64 | 15.44 | 14.56 |
|         | 23.66 | 24.62 | 16.12 | 15.54 |
|         | 17.22 | 19.06 | 16.88 | 16.82 |
|         | 22.58 | 20.12 | 17.58 | 14.56 |
| Placebo | 25.64 | 22.50 | 17.82 | 19.74 |
|         | 28.84 | 24.48 | 15.76 | 17.48 |
|         | 26.00 | 25.52 | 12.96 | 16.46 |
|         | 26.02 | 24.76 | 15.00 | 16.44 |
|         | 23.24 | 20.62 | 19.54 | 15.70 |

- (a) Use el nivel del 5 % de significancia y pruebe  $H_{AB} : \gamma_{ij} = 0, i = 1, 2, j = 1, 2, 3, 4$ .

Antes realicemos nuestro tabla ANOVA, para obtener los valores de la tabla usemos el siguiente código

```
a<-2
b<-4
c<-5
```

```
x1<-c(22.56, 25.02, 23.66, 17.22, 22.58, 16.54, 24.64, 24.62, 19.06, 20.12, 18.20, 25.64, 28.84, 26.00, 26.02, 23.24, 22.50, 24.48, 25.52, 24.76, 20.62, 17.82, 15.76, 12.96, 15.00, 19.54, 19.74, 17.48, 16.46, 16.44, 15.70)
sum(x1)
```

```

m1<-mean(x1)
x2<-c(25.64, 28.84, 26.00, 26.02, 23.24, 22.50, 24.48, 25.52, 24.76, 20.62, 17.
sum(x2)
m2<-mean(x2)

x11<-c()
x22<-c()
for(i in 1:b){ #Idea usar el 3*i - (c-i)#
  x11[i] <-x1[5*i-4]+x1[5*i-3]+x1[5*i-2]+x1[5*i-1]+x1[5*i]
  x22[i] <-x2[5*i-4]+x2[5*i-3]+x2[5*i-2]+x2[5*i-1]+x2[5*i]
}

#Matriz#
matriz1 <- rbind(x1, x2)
matriz2 <- rbind(x11, x22)

#Obtener el x_{pjp}#

colsuma <-colSums(matriz1)
vecxpjp <-c()
for(i in 1:b){
  vecxpjp[i] <-colsuma[5*i-4]+colsuma[5*i-3]+colsuma[5*i-2]+ colsuma[5*i-1]
}
vecxpjp

suma<-c(sum(x1),sum(x2)) # Vector de x_{ipp}#
medias<-c(m1,m2) # Vector de x_{ipp} media#
xppp <- sum(suma) # x_{ppp}#
xpppm <- mean(medias) # x_{ppp} media#
xppp2 <- xppp^2 # (x_{ppp})^2 #
xijk2 <- sum(matriz1^2) # (x_{ijk})^2 #
xipp2 <- sum(suma^2) # (x_{ipp})^2 #
xpjp2 <-sum(vecxpjp^2) # (x_{pjp})^2 #
xijp2 <-sum(matriz2^2) # (x_{ijp})^2 #

SSTO <- xijk2 - (1/(a*b*c))*xppp2
SSE <- xijk2 - (1/c)*xijp2
SSA <- (1/(b*c))*xipp2 - (1/(a*b*c))*xppp2
SSB <- (1/(a*c))*xpjp2 - (1/(a*b*c))*xppp2
SSAB <- SSTO-SSA-SSB-SSE

a-1
b-1
(a-1)*(b-1)
a*b*(c-1)
a*b*c-1

```

```

MSA <- SSA / ( a - 1 )
MSB <- SSB / ( b - 1 )
MSAB <- SSAB / ( ( a - 1 ) * ( b - 1 ) )
MSE <- SSE / ( a * b * ( c - 1 ) )

FA <- MSA / MSE
FB <- MSB / MSE
FAB <- MSAB / MSE

```

Entonces la Tabla ANOVA es

| Fuente de Variación   | SS       | Grados de Libertad | Media de Cuadrados(MS) | F-razon  |
|-----------------------|----------|--------------------|------------------------|----------|
| Factor A renglón      | 29.27521 | 1                  | 29.27521               | 5.532832 |
| Factor B columna      | 454.6992 | 3                  | 151.5664               | 28.64511 |
| Factor AB interacción | 27.34379 | 3                  | 9.114597               | 1.722602 |
| Error                 | 169.3178 | 32                 | 5.29118                |          |
| Total                 | 680.636  | 39                 |                        |          |

Sabemos que para encontrar el 5 % de significancia, se rechaza  $H_{AB} : \gamma_{ij} = 0$  si  $F_{AB} \geq F_{\alpha}[(a-1)(b-1), ab(c-1)]$  así utilizando el siguiente código

```

a<-2
b<-4
c<-5
alfa <- 0.05
qf(1-alfa , (a-1)*(b-1) , a*b*(c-1))

```

Obtenemos que

$$F_{\alpha}[(a-1)(b-1), ab(c-1)] = 2,90112$$

Con lo anterior y observando la tabla tenemos que

$$1,722602 < 2,90112$$

Lo que implica que  $H_{AB}$  no se rechaza.

- (b) Use el nivel del 5 % de significancia y pruebe  $H_A : \alpha_1 = \alpha_2 = 0$ .

Del cual sabemos que para encontrar el 5 % de significancia, se rechaza  $H_A : \alpha_1 = \alpha_2 = 0$  si  $F_A \geq F_{\alpha}[a-1, ab(c-1)]$  así utilizando el siguiente código

```

a<-2
b<-4
c<-5
alfa <- 0.05
qf(1-alfa , a-1 , a*b*(c-1))

```

Tenemos que

$$F_{\alpha}[a-1, ab(c-1)] = 4,149097$$

Con lo anterior y observando la tabla tenemos que

$$5,532832 > 4,149097$$

Lo que implica que  $H_A$  se rechaza.

- (c) Use el nivel del 5 % de significancia y pruebe  $H_B : \beta_1 = \beta_2 = \beta_3 = \beta_4 = 0$ .

Análogamente para encontrar el 5 % de significancia, se rechaza  $H_B$  si  $F_B \geq F_{\alpha}[b-1, ab(c-1)]$  así utilizando el siguiente código

```
a<-2
b<-4
c<-5
alfa <- 0.05
qf(1-alfa , b-1 , a*b*(c-1))
```

Tenemos que

$$F_{\alpha}[b-1, ab(c-1)] = 2,90112$$

Con lo anterior y observando la tabla tenemos que

$$28,64511 > 2,90112$$

Lo que implica que  $H_B$  se rechaza.

7. Para probar si cuatro marcas de gasolina dan el mismo rendimiento en términos de kilometraje, cada uno de los tres coches se conducía con cada una de las cuatro marcas de gasolina. Entonces cada una de las  $(3)(4) = 12$  combinaciones posibles fue repetido cuatro veces. El número de millas por galón para cada una de las cuatro repeticiones en cada celda se registra en la siguiente tabla:

| carro | Marca de gasolina |      |      |      |      |      |      |      |
|-------|-------------------|------|------|------|------|------|------|------|
|       | 1                 |      | 2    |      | 3    |      | 4    |      |
| 1     | 31.0              | 24.9 | 26.3 | 30.0 | 25.8 | 29.4 | 27.8 | 27.3 |
|       | 26.2              | 28.8 | 25.2 | 31.6 | 24.5 | 24.8 | 28.2 | 30.4 |
| 2     | 30.6              | 29.5 | 25.5 | 26.8 | 26.6 | 23.7 | 28.1 | 27.1 |
|       | 30.8              | 28.9 | 27.4 | 29.4 | 28.2 | 26.1 | 31.5 | 29.1 |
| 3     | 24.2              | 23.1 | 27.4 | 28.1 | 25.2 | 26.7 | 26.3 | 26.4 |
|       | 26.8              | 27.4 | 26.4 | 26.9 | 27.7 | 28.1 | 27.9 | 28.8 |

Pruebe la hipótesis  $H_{AB}$ : sin interacción,  $H_A$ : sin efecto de fila y  $H_B$ : sin efecto de columna, cada una con un nivel de significancia del 5 %.

Realicemos la tabla *ANOVA* en donde usaremos el siguiente código para obtener los datos

```
a<-3
b<-4
c<-4
```

```
x1<-c(31.0,24.9,26.2,28.8, 26.3,30.0,25.2,31.6, 25.8,29.4,24.5,24.8, 27.8,27.3,28.2,
sum(x1))
```

```
m1<-mean(x1)
```

```
x2<-c(30.6,29.5,30.8,28.9, 25.5,26.8,27.4,29.4, 26.6,23.7,28.2,26.1, 28.1,27.1,31.5)
sum(x2)
m2<-mean(x2)
```

```
x3 <-c(24.2,23.1,26.8,27.4, 27.4,28.1,26.4,26.9, 25.2,26.7,27.7,28.1, 26.3,26.4,27.1)
sum(x3)
m3<-mean(x3)
```

```
x11<-c()
x22<-c()
x33<-c()
for(i in 1:b){
  x11[i] <-x1[b*i-3]+x1[b*i-2]+x1[b*i-1]+x1[b*i]
  x22[i] <-x2[b*i-3]+x2[b*i-2]+x2[b*i-1]+x2[b*i]
  x33[i] <-x3[b*i-3]+x3[b*i-2]+x3[b*i-1]+x3[b*i]
}
```

```
#Matriz#
matriz1 <- rbind(x1, x2, x3)
matriz2 <- rbind(x11, x22, x33)
```

```
#Obtener el x_{pjp}#
```

```
colsuma <-colSums(matriz1)
vecxpjp <-c()
for(i in 1:b){
  vecxpjp[i] <-colsuma[4*i-3]+colsuma[4*i-2]+colsuma[4*i-1]+colsuma[4*i]
}
vecxpjp
```

```
suma<-c(sum(x1),sum(x2),sum(x3)) # Vector de x_{ipp}#
medias<-c(m1,m2,m3) # Vector de x_{ipp} media#
xppp <- sum(suma) # x_{ppp}#
xpppm <- mean(medias) # x_{ppp} media#
xppp2 <- xppp^2 # (x_{ppp})^2 #
xijk2 <- sum(matriz1^2) # (x_{ijk})^2 #
xipp2 <- sum(suma^2) # (x_{ipp})^2 #
xpjp2 <-sum(vecxpjp^2) # (x_{pjp})^2 #
xijp2 <-sum(matriz2^2) # (x_{ijp})^2 #
```

```
SSTO <- xijk2 - (1/(a*b*c))*xppp2
SSE <- xijk2 - (1/c)*xijp2
```

```
SSA <- (1/(b*c))*xipp2 - (1/(a*b*c))*xppp2
SSB <- (1/(a*c))*xpjp2 - (1/(a*b*c))*xppp2
SSAB <- SSTO-SSA-SSB-SSE
```

```
a-1
b-1
(a-1)*(b-1)
a*b*(c-1)
a*b*c-1
```

```
MSA <- SSA/(a-1)
MSB <- SSB/(b-1)
MSAB <- SSAB/((a-1)*(b-1))
MSE <- SSE/(a*b*(c-1))
```

```
FA <- MSA/MSE
FB <- MSB/MSE
FAB <- MSAB/MSE
```

Entonces la Tabla ANOVA es

| Fuente de Variación   | SS       | Grados de Libertad | Media de Cuadrados(MS) | F-razon  |
|-----------------------|----------|--------------------|------------------------|----------|
| Factor A renglón      | 15.60542 | 2                  | 7.802708               | 2.237648 |
| Factor B columna      | 21.58229 | 3                  | 7.194097               | 2.063111 |
| Factor AB interacción | 36.12458 | 6                  | 6.020764               | 1.726625 |
| Error                 | 125.5325 | 36                 | 3.487014               |          |
| Total                 | 198.8448 | 47                 |                        |          |

- Pruebe la hipótesis  $H_{AB}$ : sin interacción

Sabemos que para encontrar el 5 % de significancia, se rechaza  $H_{AB} : \gamma_{ij} = 0$  si  $F_{AB} \geq F_{\alpha}[(a-1)(b-1), ab(c-1)]$  así utilizando el siguiente código

```
a<-2
b<-4
c<-5
alfa <- 0.05
qf(1-alfa , (a-1)*(b-1) , a*b*(c-1))
```

Obtenemos que

$$F_{\alpha}[(a-1)(b-1), ab(c-1)] = 2,363751$$

Con lo anterior y observando la tabla tenemos que

$$1,726625 < 2,363751$$

Lo que implica que  $H_{AB}$  no se rechaza.

- Prueba de hipótesis  $H_A$ : sin efecto de fila.

Del cual sabemos que para encontrar el 5 % de significancia, se rechaza  $H_A : \alpha_1 = \alpha_2 = 0$  si  $F_A \geq F_{\alpha}[a-1, ab(c-1)]$  así utilizando el siguiente código

```
a<-3
b<-4
c<-4
alfa <- 0.05
qf(1-alfa ,(a-1),a*b*(c-1))
```

Tenemos que

$$F_{\alpha}[a-1, ab(c-1)] = 3,259446$$

Con lo anterior y observando la tabla tenemos que

$$2,237648 < 3,259446$$

Lo que implica que  $H_A$  no se rechaza.

- Prueba de hipótesis  $H_B$ : sin efecto de columna.

Análogamente para encontrar el 5 % de significancia, se rechaza  $H_B$  si  $F_B \geq F_{\alpha}[b-1, ab(c-1)]$  así utilizando el siguiente código

```
a<-3
b<-4
c<-4
alfa <- 0.05
qf(1-alfa ,(b-1),a*b*(c-1))
```

Tenemos que

$$F_{\alpha}[b-1, ab(c-1)] = 2,866266$$

Con lo anterior y observando la tabla tenemos que

$$2,063111 < 2,866266$$

Lo que implica que  $H_B$  no se rechaza.

9. Ledolter y Hogg (ver Referencias) informan que voluntarios que tenían antecedentes de tabaquismo clasificados como pesados, moderado, y no fumadores fueron aceptados hasta nueve hombres en cada categoría. Tres hombres en cada categoría fueron asignado aleatoriamente a cada uno de los siguientes tres pruebas de estres: bicicleta ergométrica, cinta rodante y pruebas de paso. El tiempo hasta el consumo máximo de oxígeno se registró en minutos de la siguiente manera:

| Historial de tabaquismo | Test             |                  |                  |
|-------------------------|------------------|------------------|------------------|
|                         | Bicicleta        | Rueda de andar   | Prueba de paso   |
| no fumador              | 12.8, 13.5, 11.2 | 16.2, 18.1, 17.8 | 22.6, 19.3, 18.9 |
| Moderado                | 10.9, 11.1, 9.8  | 15.5, 13.8, 16.2 | 20.1, 21.0, 15.9 |
| pesado                  | 8.7, 9.2, 7.5    | 14.7, 13.2, 8.1  | 16.2, 16.1, 17.8 |

- a) Analiza los resultados de este experimento. Obtenga la tabla ANOVA y pruebe los efectos principales y las interacciones.

Realicemos la tabla ANOVA en donde usaremos el siguiente código para obtener los datos

```
a<-3
b<-3
c<-3

x1<-c(12.8,13.5,11.2, 16.2,18.1,17.8, 22.6,19.3,18.9)
sum(x1)
m1<-mean(x1)
x2<-c(10.9,11.1,9.8, 15.5,13.8,16.2, 20.1,21.0,15.9)
sum(x2)
m2<-mean(x2)
x3<-c(8.7,9.2,7.5, 14.7,13.2,8.1, 16.2, 16.1, 17.8)
sum(x3)
m3<-mean(x3)

x11<-c()
x22<-c()
x33<-c()
for(i in 1:b){
  x11[i] <-x1[3*i-2]+x1[3*i-1]+x1[3*i]
  x22[i] <-x2[3*i-2]+x2[3*i-1]+x2[3*i]
  x33[i] <-x3[3*i-2]+x3[3*i-1]+x3[3*i]
}

#Matriz#
matriz1 <- rbind(x1, x2, x3)
matriz2 <- rbind(x11, x22, x33)

#Obtener el x_{pjp}#

colsuma <-colSums(matriz1)
vecxpjp <-c()
for(i in 1:b){
  vecxpjp[i] <-colsuma[3*i-2]+colsuma[3*i-1]+colsuma[3*i]
}
vecxpjp

suma<-c(sum(x1),sum(x2),sum(x3)) # Vector de x_{ipp}#
medias<-c(m1,m2,m3) # Vector de x_{ipp} media#
xppp <- sum(suma) # x_{ppp}#
xpppm <- mean(medias) # x_{ppp} media#
xppp2 <- xppp^2 # (x_{ppp})^2 #
```

```

xijk2 <- sum(matriz1^2)           # (x_{ijk})^2 #
xipp2 <- sum(suma^2)              # (x_{ipp})^2 #
xpjp2 <- sum(vecxpjp^2)          # (x_{pjp})^2 #
xijp2 <- sum(matriz2^2)          # (x_{ijp})^2 #

```

```

SSTO <- xijk2 - (1/(a*b*c))*xppp2
SSE <- xijk2 - (1/c)*xijp2
SSA <- (1/(b*c))*xipp2 - (1/(a*b*c))*xppp2
SSB <- (1/(a*c))*xpjp2 - (1/(a*b*c))*xppp2
SSAB <- SSTO-SSA-SSB-SSE

```

```

a-1
b-1
(a-1)*(b-1)
a*b*(c-1)
a*b*c-1

```

```

MSA <- SSA/(a-1)
MSB <- SSB/(b-1)
MSAB <- SSAB/((a-1)*(b-1))
MSE <- SSE/(a*b*(c-1))

```

```



FA <- MSA/MSE
FB <- MSB/MSE
FAB <- MSAB/MSE


```

Entonces la Tabla ANOVA es

| Fuente de Variación   | SS       | Grados de Libertad | Media de Cuadrados(MS) | F-razon   |
|-----------------------|----------|--------------------|------------------------|-----------|
| Factor A renglón      | 84.89852 | 2                  | 42.44926               | 12.8967   |
| Factor B columna      | 298.0719 | 2                  | 149.0359               | 45.27928  |
| Factor AB interacción | 2.814815 | 4                  | 0.7037037              | 0.2137954 |
| Error                 | 59.24667 | 18                 | 3.291481               |           |
| Total                 | 445.0319 | 26                 |                        |           |

b) Use box plots para comparar los datos gráficamente.

Comparación de las medias para la prueba de *Bicicleta*Comparación de las medias para la prueba de *Rueda de andar*

Comparación de las medias para la prueba de *Prueba de paso*

De aquí podemos observar que todos aquellos que no fumaron tuvieron mejor rendimiento en todas las pruebas como se esperaba, mientras que las personas que fumaron a gran medida tuvieron el peor rendimiento. Del cual se puede ver que en todas las medias tienen diferencia.

El código para realizar las bloxplot es

```
NoFumadorB <- c(12.8, 13.5, 11.2)
ModeradoB <- c(10.9, 11.1, 9.8)
PesadoB <- c(8.7, 9.2, 7.5)
Bicicleta <- cbind(NoFumadorB, ModeradoB, PesadoB)
boxplot(Bicicleta, main = "Bicicleta")
```

```
NoFumadorR <- c(16.2, 18.1, 17.8)
ModeradoR <- c(15.5, 13.8, 16.2)
PesadoR <- c(14.7, 13.2, 8.1)
Rueda <- cbind(NoFumadorR, ModeradoR, PesadoR)
boxplot(Rueda, main = "Rueda de andar")
```

```
NoFumadorP <- c(22.6, 19.3, 18.9)
ModeradoP <- c(20.1, 21.0, 15.9)
PesadoP <- c(16.2, 16.1, 17.8)
Prueba <- cbind(NoFumadorP, ModeradoP, PesadoP)
boxplot(Prueba, main = "Prueba de paso")
```

## Sección 7.6 Hogg

1. La media de  $Y$  cuando  $x = 0$  en el modelo de regresión lineal simple es  $\alpha - \beta\bar{x} = \alpha_1$ . El estimador de minimos cuadrados de  $\alpha_1$  es  $\hat{\alpha} - \hat{\beta}\bar{x} = \hat{\alpha}_1$ .

- a) Encuentre la distribución de  $\hat{\alpha}_1$  bajo los supuestos habituales del modelo.

Sabemos que

$$\hat{\alpha} \sim N\left(\alpha, \frac{\sigma^2}{n}\right) \quad y \quad \hat{\beta} \sim N\left(\beta, \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right)$$

Dado que  $\hat{\alpha}_1 = \hat{\alpha} - \hat{\beta}\bar{x}$  tenemos que  $\hat{\alpha}_1$  viene dada por una distribución normal la cual es

$$\begin{aligned} \hat{\alpha}_1 &\sim N(\mu_1 - \mu_2, \sigma_1^2 + \sigma_2^2) \\ &\sim N\left(\alpha - \beta\bar{x}, \frac{\sigma^2}{n} + \frac{\sigma^2(\bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right) \\ &\sim N\left(\alpha_1, \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right)\right) \end{aligned}$$

Por lo tanto  $\hat{\alpha}_1$  tiene una distribución normal la cual es

$$\hat{\alpha}_1 \sim N\left(\alpha_1, \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right)\right)$$

- b) Obtenga una expresión para un intervalo de confianza bilateral de  $100(1 - \gamma) \%$  para  $\alpha_1$

Haciendo uso del inciso anterior tenemos que

$$Z = \frac{\hat{\alpha}_1 - \alpha_1}{\sigma \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}}$$

Ahora consideremos a

$$W = \frac{n\hat{\sigma}^2}{\sigma^2}$$

De esta manera definamos a

$$T^2 = \frac{Z}{\sqrt{\frac{W}{n-2}}} = \frac{\frac{\hat{\alpha}_1 - \alpha_1}{\sigma \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}}}{\sqrt{\frac{n\hat{\sigma}^2}{\sigma^2}}} = \frac{\frac{\hat{\alpha}_1 - \alpha_1}{\hat{\sigma} \sqrt{\frac{n}{n-2}}}}{\hat{\sigma} \sqrt{\frac{n}{n-2}} \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}} \sim t_{n-2}$$

De esta manera un intervalo con  $100(1 - \gamma) \%$  de confianza para  $\hat{\alpha}_1$  es

$$\hat{\alpha}_1 = t_{\frac{\gamma}{2}}(n-2) \hat{\sigma} \sqrt{\frac{n}{n-2}} \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}$$

3. Para los datos dados en el ejercicio 6,5 – 3, con las suposiciones usuales,

| <i>Midterm</i> | <i>Final</i> | <i>Midterm</i> | <i>Final</i> |
|----------------|--------------|----------------|--------------|
| 70             | 87           | 67             | 73           |
| 74             | 79           | 70             | 83           |
| 80             | 88           | 64             | 79           |
| 84             | 98           | 74             | 91           |
| 80             | 96           | 82             | 94           |

a) Encuentre un intervalo de confianza del 95 % para  $\mu(x)$  cuando  $x = 68, 75$  y  $82$ .

Recordemos que el intervalo de confianza para  $\mu(x)$  viene dado por

$$\hat{\alpha} + \hat{\beta}(x - \bar{x}) \pm ct_{\frac{\gamma}{2}}(n - 2)$$

Donde

$$c = \sqrt{\frac{n\hat{\sigma}^2}{n-2}} \sqrt{\frac{1}{n} + \frac{(x - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}$$

Con esto los intervalos de confianza del 95 % son:

$$\begin{aligned} \mu(68) & \text{ es } [75,28068, 85,11132] \\ \mu(75) & \text{ es } [83,83858, 90,77742] \\ \mu(82) & \text{ es } [89,10949, 99,73051] \end{aligned}$$

El código utilizado para obtener los valores anteriores fue

```
x <- c(70, 74, 80, 84, 80, 67, 70, 64, 74, 82)
y <- c(87, 79, 88, 98, 96, 73, 83, 79, 91, 94)
n <- length(x)
```

```
intento <- data.frame(x,y)
```

```
regresion <- lm(y ~ x, intento)
summary(regresion)
anova(regresion)
```

```
xp <- mean(x)    #x promedio#
yp <- mean(y)    #y promedio#
```

```
w <- sum(x^2) - (xp^2)*n  #sum[(x_i - xp)^2]#
```

```
gama <- 0.05
t <- qt(1-(gama/2), 8)
```

```
xv <- c(68, 75, 82)
N <- length(xv)
ici <- c()
icd <- c()
```

```

D <- c()
I <-c()

sigma2 <- 180.0/n
B <- 1.016
A <- yp

for(i in 1:N){
  ici[i] = A + B*(xv[i]-xp)
  icd[i] <- sqrt( (n*sigma2)/(n-2) ) * sqrt( (1/n)+ ((xv[i]-xp)^2)/
D[i] <- ici[i]+icd[i]
I[i] <- ici[i]-icd[i]
cat("El intervalo de confianza para x=",xv[i],"es ","[",I[i],"",",",D[i])
}

```

Donde el código nos da

```

El intervalo de confianza para x= 68 es [ 75.28068 , 85.11132 ]
El intervalo de confianza para x= 75 es [ 83.83858 , 90.77742 ]
El intervalo de confianza para x= 82 es [ 89.10949 , 99.73051 ]

```

b) Encuentre un intervalo de predicción del 95 % para  $Y$  cuando  $x = 68, 75$  y  $82$ .

Recordemos que el intervalo de confianza para  $Y_{n+1}$  viene dado por

$$\hat{\alpha} + \hat{\beta}(x - \bar{x}) \pm dt_{\frac{\gamma}{2}}(n-2)$$

Donde

$$d = \sqrt{\frac{n\hat{\sigma}^2}{n-2}} \sqrt{1 + \frac{1}{n} + \frac{(x - \bar{x})^2}{\sum_{i=1}^n [(x_i - \bar{x})^2]}}$$

Con esto los intervalos de confianza del 95 % para  $Y$  son:

```

x = 68  es  [68,20402 , 92,18798]
x = 75  es  [75,83263 , 98,78337]
x = 82  es  [82,26069 , 106,5793]

```

El código utilizado para obtener los valores anteriores fue

```

x <- c(70, 74, 80, 84, 80, 67, 70, 64, 74, 82)
y <- c(87, 79, 88, 98, 96, 73, 83, 79, 91, 94)
n <- length(x)

intento <- data.frame(x,y)

regresion <- lm(y ~ x, intento)
summary(regresion)
anova(regresion)

```

```

xp <- mean(x)      #x promedio#
yp <- mean(y)      #y estimador#

w <- sum(x^2) - (xp^2)*n  #sum[(x_i - xp)^2]#

gama <- 0.05
t <- qt(1-(gama/2),8)

xv <- c(68, 75, 82)
N <- length(xv)
ici <- c()
icd <- c()
D <- c()
I <-c()

sigma2 <- 180.0/n  #Manual es el residuo y suma sq entre n #
B <- 1.016        #Manual es estimate std, x #
A <- yp

for(i in 1:N){
  ici[i] = A + B*(xv[i]-xp)
  icd[i] <- sqrt( (n*sigma2)/(n-2) ) * sqrt(1 + (1/n)+ ((xv[i]-xp)^2)/v)
  D[i] <- ici[i]+icd[i]
  I[i] <- ici[i]-icd[i]
  cat("El intervalo de confianza para x=",xv[i],"es ","[",I[i],"-",D[i],"]")
}

```

Donde el código nos devuelve que

El intervalo de confianza para  $x=68$  es [ 68.20402 , 92.18798 ]

El intervalo de confianza para  $x=75$  es [ 75.83263 , 98.78337 ]

El intervalo de confianza para  $x=82$  es [ 82.26069 , 106.5793 ]

5) Para los datos de cigarrillos del ejercicio 6,5 – 7, con las suposiciones usuales,

| <i>Brand</i>          | <i>x</i> | <i>y</i> | <i>Brand</i>         | <i>x</i> | <i>y</i> |
|-----------------------|----------|----------|----------------------|----------|----------|
| <i>Capri</i>          | 9        | 6        | <i>Now</i>           | 3        | 4        |
| <i>Carlton</i>        | 4        | 6        | <i>Salem</i>         | 17       | 18       |
| <i>Kent</i>           | 14       | 14       | <i>Triumph</i>       | 6        | 8        |
| <i>KoolMilds</i>      | 12       | 12       | <i>True</i>          | 7        | 8        |
| <i>MarlboroLights</i> | 10       | 12       | <i>Vantage</i>       | 8        | 13       |
| <i>MeritUltras</i>    | 5        | 7        | <i>VirginiaSlims</i> | 15       | 13       |

a) Encuentre un intervalo de confianza del 95 % para  $\mu(x)$  cuando  $x = 5, 10$  y  $15$ .

Recordemos que el intervalo de confianza para  $\mu(x)$  viene dado por

$$\hat{\alpha} + \hat{\beta}(x - \bar{x}) \pm ct_{\frac{\gamma}{2}}(n-2)$$

Donde

$$c = \sqrt{\frac{n\hat{\sigma}^2}{n-2}} \sqrt{\frac{1}{n} + \frac{(x - \bar{x})^2}{\sum_{i=1}^n [(x_i - \bar{x})^2]}}$$

Con esto los intervalos de confianza del 95 % son:

$$\begin{array}{ll} \mu(5) & \text{es } [4,896982, 8,443851] \\ \mu(10) & \text{es } [9,463715, 12,06812] \\ \mu(15) & \text{es } [12,71796, 17,00487] \end{array}$$

El código utilizado para obtener los valores anteriores fue

```
x <- c(9, 4, 14, 12, 10, 5, 3, 17, 6, 7, 8, 15)
y <- c(6, 6, 14, 12, 12, 7, 4, 18, 8, 8, 13, 13)
n <- length(x)

intento <- data.frame(x,y)

regresion <- lm(y ~ x, intento)
summary(regresion)
anova(regresion)

xp <- mean(x)      #x promedio#
yp <- mean(y)      #y estimador#

w <- sum(x^2) - (xp^2)*n #sum[(x_i - xp)^2]#

gama <- 0.05
t <- qt(1-(gama/2),10)

xv <- c(5, 10, 15)
N <- length(xv)
ici <- c()
icd <- c()
D <- c()
I <-c()

sigma2 <- 39.528/n #Manual es el residuo y suma sq entre n #
B <- 0.8191      #Manual es estimate std, x #
A <- yp

for(i in 1:N){
  ici[i] = A + B*(xv[i]-xp)
  icd[i] <- sqrt( (n*sigma2)/(n-2) ) * sqrt( (1/n)+ ((xv[i]-xp)^2)/w)
  D[i] <- ici[i]+icd[i]
  I[i] <- ici[i]-icd[i]
  cat("El intervalo de confianza para x=",xv[i],"es ","[",I[i],",",D[i],"]")
}
```

Donde el código nos da

El intervalo de confianza para  $x = 5$  es [ 4.896982 , 8.443851 ]

El intervalo de confianza para  $x = 10$  es [ 9.463715 , 12.06812 ]

El intervalo de confianza para  $x = 15$  es [ 12.71796 , 17.00487 ]

- b) Encuentre un intervalo de predicción del 95 % para  $Y$  cuando  $x = 5, 10$  y  $15$ .

Recordemos que el intervalo de confianza para  $Y_{n+1}$  viene dado por

$$\hat{\alpha} + \hat{\beta}(x - \bar{x}) \pm dt_{\frac{\gamma}{2}}(n-2)$$

Donde

$$d = \sqrt{\frac{n\hat{\sigma}^2}{n-2}} \sqrt{1 + \frac{1}{n} + \frac{(x - \bar{x})^2}{\sum_{i=1}^n [(x_i - \bar{x})^2]}}$$

Con esto los intervalos de confianza del 95 % para  $Y$  son:

$x = 5$  es [1,898713 , 11,44212]

$x = 10$  es [6,148579 , 15,38325]

$x = 15$  es [9,940188 , 19,78265]

El código utilizado para obtener los valores anteriores fue

```
x <- c(9, 4, 14, 12, 10, 5, 3, 17, 6, 7, 8, 15)
y <- c(6, 6, 14, 12, 12, 7, 4, 18, 8, 8, 13, 13)
n <- length(x)
```

```
intento <- data.frame(x,y)
```

```
regresion <- lm(y ~ x, intento)
summary(regresion)
anova(regresion)
```

```
xp <- mean(x)      #x promedio#
yp <- mean(y)      #y estimador#
```

```
w <- sum(x^2) - (xp^2)*n  #sum[(x_i - xp)^2]#
```

```
gama <- 0.05
t <- qt(1-(gama/2),10)
```

```
xv <- c(5, 10, 15)
N <- length(xv)
ici <- c()
icd <- c()
D <- c()
I <-c()
```

```
sigma2 <- 39.528/n  #Manual es el residuo y suma sq entre n #
```

```

B <- 0.8191          #Manual es estimate std , x #
A <- yp

for(i in 1:N){
  ici[i] = A + B*(xv[i]-xp)
  icd[i] <- sqrt( (n*sigma2)/(n-2) ) * sqrt( 1 + (1/n)+ ((xv[i]-xp)
D[i] <- ici[i]+icd[i]
I[i] <- ici[i]-icd[i]
  cat("El intervalo de confianza para x=",xv[i],"es ","[" ,I[i] ,",",D[i]
}

```

El código nos devuelve

El intervalo de confianza para x= 5 es [ 1.898713 , 11.44212 ]

El intervalo de confianza para x= 10 es [ 6.148579 , 15.38325 ]

El intervalo de confianza para x= 15 es [ 9.940188 , 19.78265 ]

9. Por el método de mínimos cuadrados, ajuste la ecuación cúbica  $y = \beta_1 + \beta_2 x + \beta_3 x^2 + \beta_4 x^3$  a los siguientes 10 puntos observados(x,y): (0,1), (-1,-3), (0,3), (1,3), (-1,-1), (2,10), (0,0), (-2,-9), (-1,-2), (2,8).

El método nos dice que resolver el siguiente sistema de ecuaciones

$$\beta_1 \sum_{j=1}^{10} x_{1j}^2 + \beta_2 \sum_{j=1}^{10} x_{1j}x_{2j} + \beta_3 \sum_{j=1}^{10} x_{1j}x_{3j} + \beta_4 \sum_{j=1}^{10} x_{1j}x_{4j} = \sum_{j=1}^{10} x_{1j}y_j$$

$$\beta_1 \sum_{j=1}^{10} x_{2j}x_{1j} + \beta_2 \sum_{j=1}^{10} x_{2j}^2 + \beta_3 \sum_{j=1}^{10} x_{2j}x_{3j} + \beta_4 \sum_{j=1}^{10} x_{2j}x_{4j} = \sum_{j=1}^{10} x_{2j}y_j$$

$$\beta_1 \sum_{j=1}^{10} x_{3j}x_{1j} + \beta_2 \sum_{j=1}^{10} x_{3j}x_{2j} + \beta_3 \sum_{j=1}^{10} x_{3j}^2 + \beta_4 \sum_{j=1}^{10} x_{3j}x_{4j} = \sum_{j=1}^{10} x_{3j}y_j$$

$$\beta_1 \sum_{j=1}^{10} x_{4j}x_{1j} + \beta_2 \sum_{j=1}^{10} x_{4j}x_{2j} + \beta_3 \sum_{j=1}^{10} x_{4j}x_{3j} + \beta_4 \sum_{j=1}^{10} x_{4j}^2 = \sum_{j=1}^{10} x_{4j}y_j$$

donde sea  $x_1 = 1$ ,  $x_2 = x$ ,  $x_3 = x^2$ ,  $x_4 = x^3$

$$\sum_{j=1}^{10} x_{1j}^2 = 1 + 1 + \dots + 1 = 10$$

$$\sum_{j=1}^{10} x_{1j}x_{2j} = 1(0) + 1(-1) + 1(0) + 1(1) + 1(-1) + 1(2) + 1(0) + 1(-2) + 1(-1) + 1(2) = 0$$

$$\sum_{j=1}^{10} x_{1j}x_{3j} = 1(0)^2 + 1(-1)^2 + 1(0)^2 + 1(1)^2 + 1(-1)^2 + 1(2)^2 + 1(0)^2 + 1(-2)^2 + 1(-1)^2 + 1(2)^2 = 16$$

$$\sum_{j=1}^{10} x_{1j}x_{4j} = 1(0)^3 + 1(-1)^3 + 1(0)^3 + 1(1)^3 + 1(-1)^3 + 1(2)^3 + 1(0)^3 + 1(-2)^3 + 1(-1)^3 + 1(2)^3 = 6$$

$$\sum_{j=1}^{10} x_{1j}y_j = 1(1) + 1(-3) + 1(3) + 1(3) + 1(-1) + 1(10) + 1(0) + 1(-9) + 1(-2) + 1(8) = 10$$

$$\sum_{j=1}^{10} x_{2j}x_{1j} = \sum_{j=1}^{10} x_{1j}x_{2j} = 0$$

$$\sum_{j=1}^{10} x_{2j}^2 = \sum_{j=1}^{10} x_{1j}x_{3j} = 16$$

$$\sum_{j=1}^{10} x_{2j}x_{3j} = \sum_{j=1}^{10} x_{1j}x_{4j} = 6$$

$$\begin{aligned}
\sum_{j=1}^{10} x_{2j}x_{4j} &= (0)^4 + (-1)^4 + (0)^4 + (1)^4 + (-1)^4 + (2)^4 + (0)^4 + (-2)^4 + (-1)^4 + (2)^4 = 52 \\
\sum_{j=1}^{10} x_{2j}y_j &= (0)(1) + (-1)(-3) + (0)(3) + (1)(3) + (-1)(-1) + 2(10) + 0(0) + (-2)(-9) + 1(-2) + 2(8) = 63 \\
\sum_{j=1}^{10} x_{3j}x_{1j} &= \sum_{j=1}^{10} x_{1j}x_{3j} = 16 \\
\sum_{j=1}^{10} x_{3j}x_{2j} &= \sum_{j=1}^{10} x_{2j}x_{3j} = 6 \\
\sum_{j=1}^{10} x_{3j}^2 &= \sum_{j=1}^{10} x_{2j}x_{4j} = 52 \\
\sum_{j=1}^{10} x_{3j}x_{4j} &= (0)^5 + (-1)^5 + (0)^5 + (1)^5 + (-1)^5 + (2)^5 + (0)^5 + (-2)^5 + (-1)^5 + (2)^5 = 30 \\
\sum_{j=1}^{10} x_{3j}y_j &= (0)^2(1) + (-1)^2(-3) + (0)^2(3) + (1)^2(3) + (-1)^2(-1) + 2^2(10) + 0^2(0) + (-2)^2(-9) + 1^2(-2) + 2^2(8) = 33 \\
\sum_{j=1}^{10} x_{4j}x_{1j} &= \sum_{j=1}^{10} x_{2j}x_{3j} = 6 \\
\sum_{j=1}^{10} x_{4j}x_{2j} &= \sum_{j=1}^{10} x_{3j}^2 = 52 \\
\sum_{j=1}^{10} x_{4j}x_{3j} &= \sum_{j=1}^{10} x_{3j}x_{4j} = 30 \\
\sum_{j=1}^{10} x_{4j}^2 &= (0)^6 + (-1)^6 + (0)^6 + (1)^6 + (-1)^6 + (2)^6 + (0)^6 + (-2)^6 + (-1)^6 + (2)^6 = 196 \\
\sum_{j=1}^{10} x_{4j}y_j &= (0)^3(1) + (-1)^3(-3) + (0)^3(3) + (1)^3(3) + (-1)^3(-1) + 2^3(10) + 0^3(0) + (-2)^3(-9) + 1^3(-2) + 2^3(8) = 225
\end{aligned}$$

De esta manera el sistema de ecuaciones es:

$$\begin{array}{rrrrrr}
10\beta_1 & + & 0\beta_2 & + & 16\beta_3 & + & 6\beta_4 & = & 10 \\
0\beta_1 & + & 16\beta_2 & + & 6\beta_3 & + & 52\beta_4 & = & 63 \\
16\beta_1 & + & 6\beta_2 & + & 52\beta_3 & + & 30\beta_4 & = & 33 \\
6\beta_1 & + & 52\beta_2 & + & 30\beta_3 & + & 196\beta_4 & = & 225
\end{array}$$

Resolviendo el sistema de ecuaciones con  $R$  y dado que  $y = \beta_1 + \beta_2x + \beta_3x^2 + \beta_4x^3$  se tiene que

$$y = 1,103668 + 2,032695x - 0,2974482x^2 + 0,6204147x^3$$

El código para resolver el sistema de ecuaciones en  $R$  es

```

A <- matrix(c(10,0,16,6, 0,16,6,52, 16,6,52,30, 6,52,30,196 ), ncol = 4 )
b <- c(10, 63, 33, 225)
Solucion <- solve(A, b)
cat("La soluciones del sistema viene dado por" ,Solucion)

```

El código nos imprime

La soluciones del sistema viene dado por 1.103668 2.032695 -0.2974482 0.6204147

11. (La información presentada en este ejercicio proviene de Westview Blueberry Farm y National Oceanic e Informes de Administración Atmosférica [NOAA].) Para los siguientes datos emparejados, (x,y), x da la lluvia para junio para Holland, Michigan, y da la producción de arándano en miles de libras de Westview Granja de arándanos: (4.11,56.2) (5.49,45.3) (5.35,31.0) (6.53,30.1) (5.18,40.0) (4.89,38.5) (2.09,50.0) (1.40,45.8) (4.52,45.9) (1.11,32.4) (0.60,18.2) (3.80,56.1) Los datos son de 1971 a 1989 para aquellos años en los que la última helada ocurrió el 10 de mayo o antes.

- a) Encuentre el coeficiente de correlación para estos datos.

Recordemos que el coeficiente de correlacion se define como

$$r = \frac{S_{xy}}{\sqrt{S_{xx}}\sqrt{S_{yy}}}$$

Del cual

$$S_{xx} = \sum_{i=1}^n x_i^2 - n\bar{x}^2 \quad S_{yy} = \sum_{i=1}^n y_i^2 - n\bar{y}^2 \quad S_{xy} = \sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}$$

Usando  $R$  obtuvimos

$$r = 0,1430206$$

El código utilizado fue

```
x=c(4.11,5.49,5.35,6.53,5.18,4.89,2.09,1.40,4.52,1.11,0.60,3.80)
y=c(56.2,45.3,31.0,30.1,40.0,38.5,50.0,45.8,45.9,32.4,18.2,56.1)
cor(x,y)
```

El código nos devuelve

```
[1] 0.1430206
```

b) Encuentre la línea de regresión de mínimos cuadrados


La línea de regresión de mínimos cuadrados es

$$y = 37,6843 + 0,8276x$$

La cual fue obtenida apartir del siguiente código en  $R$

```
x=c(4.11,5.49,5.35,6.53,5.18,4.89,2.09,1.40,4.52,1.11,0.60,3.80)
y=c(56.2,45.3,31.0,30.1,40.0,38.5,50.0,45.8,45.9,32.4,18.2,56.1)
data=data.frame(x,y)
qreg=lm(y~x,data)
summary(qreg) # Observando lo que nos da el código #
```

c) Haz un diagrama de dispersión de los datos con los mínimos cuadrados



La grafica fue obtenida apartir del siguiente codigo

```
# Datos #
```

```
x=c(4.11,5.49,5.35,6.53,5.18,4.89,2.09,1.40,4.52,1.11,0.60,3.80)
```

```
y=c(56.2,45.3,31.0,30.1,40.0,38.5,50.0,45.8,45.9,32.4,18.2,56.1)
```

```
# Graficar la linea #
```

```
lin<-seq(0, 60, 0.1) # Crea una secuencia de valores de x #
```


```
plot(x,y) # Grafica los datos, el cual es un diagrama de dispersio
```

```
lines(lin,37.6843 + 0.8276*lin ,col="red") # Grafica de la linea#
```

d) Calcule y represente gráficamente los residuos. ¿Parece apropiada la regresión lineal?

Dado que la linea de los mínimos cuadrados es  $y = 37,6843 + 0,8276x$  esto implica que  $\hat{y}_i = 37,6843 + 0,8276x$ , por otro lado recordemos que el residuo se encuentra definido como  $e_i = y_i - \hat{y}_i$

Con lo anterior, la gráfica es



Del cual podemos decir que no parece apropiada la regresión lineal debido a que una gran cantidad de valores no se encuentra cercana a la línea del eje  $x$ .

Lo grafica fue obtenida con el siguiente código

```
x=c(4.11,5.49,5.35,6.53,5.18,4.89,2.09,1.40,4.52,1.11,0.60,3.80)
y=c(56.2,45.3,31.0,30.1,40.0,38.5,50.0,45.8,45.9,32.4,18.2,56.1)
r=c()
re=c()
n=length(x)
for(i in 1:n){
  r[i]=0.8275959*x[i] + 37.68335
  re[i]=y[i]-r[i]
}
```


```
### Grafica de Residuos ###
xseq=seq(-300,300,0.01)
yseq = xseq -xseq
plot(x, re, main='Grafica de Residuos', xlab = 'x', ylab= 'e', col = 'cornflowerblue')
lines(xseq, yseq)
```

e) Encuentre la curva de regresión cuadrática de mínimos cuadrados.

La regresión cuadrática de mínimos cuadrados fue calculado con  $R$  la cual obtuvimos que

$$y = 12,845 + 22,566x + 3,218x^2$$

Y su gráfico es



Lo anterior fue obtenido con el siguiente código

```
x=c(4.11,5.49,5.35,6.53,5.18,4.89,2.09,1.40,4.52,1.11,0.60,3.80)
y=c(56.2,45.3,31.0,30.1,40.0,38.5,50.0,45.8,45.9,32.4,18.2,56.1)
x2=x^2
data=data.frame(x,y)
qreg=lm(y~x+x2,data)
summary(qreg)
```

# Realizar Grafica #

```
lin<-seq(0, 60, 0.1) # Crea una secuencia de valores de x #
```


```
plot(x,y) # Grafica los datos, el cual es un diagrama de dispersión
```

```
lines(lin, 12.845+22.566*lin-3.218*lin^2, col="red") # Grafica de la línea
```

f) Calcule y represente gráficamente los residuos. ¿La regresión cuadrática parece ser apropiada?

Dado que la línea de los mínimos cuadrados es  $12,845 + 22,566x + 3,218x^2$  esto implica que  $\hat{y}_i = 12,845 + 22,566x + 3,218x^2$ , por otro lado recordemos que el residuo se encuentra definido como  $e_i = y_i - \hat{y}_i$

Con lo anterior, la gráfica es



Del cual podemos decir que no parece apropiada la regresión cuadrática debido a que una gran cantidad de valores no se encuentra cercana a la línea del eje  $x$ .

Lo grafica fue obtenida con el siguiente codigo

```
x=c(4.11,5.49,5.35,6.53,5.18,4.89,2.09,1.40,4.52,1.11,0.60,3.80)
y=c(56.2,45.3,31.0,30.1,40.0,38.5,50.0,45.8,45.9,32.4,18.2,56.1)
x2=x^2
r=c()
re=c()
n=length(x)
for(i in 1:n){
  r[i]= -3.218*x2[i]+ 22.566*x[i] + 12.845
  re[i]=y[i]-r[i]
}
```

```
### Grafica de Residuos ###
xseq=seq(-300,300,0.01)
yseq = xseq -xseq
plot(x, re, main='Grafica de Residuos', xlab = 'x', ylab= 'e', col = 'cornflowerblue')
lines(xseq, yseq)
```

g) Dé una breve interpretación de sus resultados.

Observando ambas gráficas de la regresión cuadrática y la lineal podemos decir que la regresión cuadrática es un mejor modelo para los datos que la regresión lineal dado que los valores se encuentran menos dispersos.

13. Pruebe que:

$$\sum_{i=1}^n [Y_i - \alpha - \beta(x_i - \bar{x})]^2 = n(\hat{\alpha} - \alpha)^2 + (\hat{\beta} - \beta)^2 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x}_i)]^2.$$

Primero recordemos que

$$\hat{\alpha} = \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i \Leftrightarrow n\hat{\alpha} = \sum_{i=1}^n Y_i \quad y \quad \hat{\beta} = \frac{\sum_{i=1}^n Y_i(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \Leftrightarrow \hat{\beta} \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n Y_i(x_i - \bar{x})$$

Prueba

$$\begin{aligned} \sum_{i=1}^n [Y_i - \alpha - \beta(x_i - \bar{x})]^2 &= \sum_{i=1}^n [(\hat{\alpha} - \alpha) + (\hat{\beta} - \beta)(x_i - \bar{x}) + (Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x}))]^2 \\ &= \sum_{i=1}^n (\hat{\alpha} - \alpha)^2 + \sum_{i=1}^n (\hat{\beta} - \beta)^2 (x_i - \bar{x})^2 + \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2 \\ &\quad + 2 \sum_{i=1}^n (\hat{\alpha} - \alpha)(\hat{\beta} - \beta)(x_i - \bar{x}) + 2 \sum_{i=1}^n (\hat{\alpha} - \alpha)(Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})) \\ &\quad + 2 \sum_{i=1}^n (\hat{\beta} - \beta)(x_i - \bar{x})(Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})) \end{aligned} \quad (1)$$

Del cual observemos que

$$\begin{aligned} 2 \sum_{i=1}^n (\hat{\alpha} - \alpha)(\hat{\beta} - \beta)(x_i - \bar{x}) &= 2(\hat{\alpha} - \alpha)(\hat{\beta} - \beta) \sum_{i=1}^n (x_i - \bar{x}) = 2(\hat{\alpha} - \alpha)(\hat{\beta} - \beta)(n\bar{x} - n\bar{x}) = 2(\hat{\alpha} - \alpha)(\hat{\beta} - \beta)(0) \\ &= 0 \end{aligned}$$

$$\begin{aligned} 2 \sum_{i=1}^n (\hat{\alpha} - \alpha)(Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})) &= 2(\hat{\alpha} - \alpha) \sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})) = 2(\hat{\alpha} - \alpha) \left( \sum_{i=1}^n Y_i - \sum_{i=1}^n \hat{\alpha} - \sum_{i=1}^n \hat{\beta}(x_i - \bar{x}) \right) \\ &= 2(\hat{\alpha} - \alpha)(n\hat{\alpha} - n\hat{\alpha} - \hat{\beta} \sum_{i=1}^n (x_i - \bar{x})) = 2(\hat{\alpha} - \alpha) \left( -\hat{\beta} \sum_{i=1}^n (x_i - \bar{x}) \right) \\ &= 2(\hat{\alpha} - \alpha)(-\hat{\beta}(n\bar{x} - n\bar{x})) = 2(\hat{\alpha} - \alpha)(-\hat{\beta}(0)) \\ &= 0 \end{aligned}$$

$$\begin{aligned} 2 \sum_{i=1}^n (\hat{\beta} - \beta)(x_i - \bar{x})(Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})) &= 2(\hat{\beta} - \beta) \sum_{i=1}^n (x_i - \bar{x})(Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})) \\ &= 2(\hat{\beta} - \beta) \left( \sum_{i=1}^n (x_i - \bar{x})Y_i - \sum_{i=1}^n (x_i - \bar{x})\hat{\alpha} - \sum_{i=1}^n (x_i - \bar{x})\hat{\beta}(x_i - \bar{x}) \right) \\ &= 2(\hat{\beta} - \beta) \left( \hat{\beta} \sum_{i=1}^n (x_i - \bar{x})^2 - \hat{\alpha} \sum_{i=1}^n (x_i - \bar{x}) - \hat{\beta} \sum_{i=1}^n (x_i - \bar{x})^2 \right) \\ &= 2(\hat{\beta} - \beta) \left( -\hat{\alpha} \sum_{i=1}^n (x_i - \bar{x}) \right) \\ &= 2(\hat{\beta} - \beta)(-\hat{\alpha}(n\bar{x} - n\bar{x})) \\ &= 2(\hat{\beta} - \beta)(-\hat{\alpha}(0)) \\ &= 0 \end{aligned}$$

De esta manera regresando a (1) se concluye que

$$\begin{aligned}
 \sum_{i=1}^n [Y_i - \alpha - \beta(x_i - \bar{x})]^2 &= \sum_{i=1}^n (\hat{\alpha} - \alpha)^2 + \sum_{i=1}^n (\hat{\beta} - \beta)^2 (x_i - \bar{x})^2 + \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2 \\
 &\quad + 2 \sum_{i=1}^n (\hat{\alpha} - \alpha)(\hat{\beta} - \beta)(x_i - \bar{x}) + 2 \sum_{i=1}^n (\hat{\alpha} - \alpha)(Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})) \\
 &\quad + 2 \sum_{i=1}^n (\hat{\beta} - \beta)(x_i - \bar{x})(Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})) \\
 &= \sum_{i=1}^n (\hat{\alpha} - \alpha)^2 + \sum_{i=1}^n (\hat{\beta} - \beta)^2 (x_i - \bar{x})^2 + \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2 \\
 &= n(\hat{\alpha} - \alpha)^2 + (\hat{\beta} - \beta)^2 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2
 \end{aligned}$$

Q.E.D.

15. Pruebe que un intervalo del  $100(1 - \gamma)\%$  para  $\sigma^2$  es:

$$\left[ \frac{n\hat{\sigma}^2}{\chi_{\gamma/2}(n-2)}, \frac{n\hat{\sigma}^2}{\chi_{1-\gamma/2}(n-2)} \right]$$

Prueba:

Dado que

$$\frac{\sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2}{\sigma^2} = \frac{n\hat{\sigma}^2}{\sigma^2} \geq 0$$

Tenemos que

$$\frac{n\hat{\sigma}^2}{\sigma^2} \sim \chi_{\gamma/2}(n-2)$$

Se sigue que

$$P\left(-\chi_{\gamma/2}(n-2) \leq \frac{n\hat{\sigma}^2}{\sigma^2} \leq \chi_{\gamma/2}(n-2)\right) = 1 - \gamma \quad \Leftrightarrow \quad P\left(\frac{1}{-\chi_{\gamma/2}(n-2)} \geq \frac{\sigma^2}{n\hat{\sigma}^2} \geq \frac{1}{\chi_{\gamma/2}(n-2)}\right) = 1 - \gamma$$

$$P\left(\frac{n\hat{\sigma}^2}{\chi_{\gamma/2}(n-2)} \leq \sigma^2 \leq \frac{n\hat{\sigma}^2}{-\chi_{\gamma/2}(n-2)}\right) = 1 - \gamma \quad \Leftrightarrow \quad P\left(\frac{n\hat{\sigma}^2}{\chi_{\gamma/2}(n-2)} \leq \sigma^2 \leq \frac{n\hat{\sigma}^2}{\chi_{1-\gamma/2}(n-2)}\right) = 1 - \gamma$$

Por lo tanto un intervalo de  $(1 - \gamma)100\%$  de confianza para  $\sigma^2$  esta dado por

$$\left[ \frac{n\hat{\sigma}^2}{\chi_{\gamma/2}(n-2)}, \frac{n\hat{\sigma}^2}{\chi_{1-\gamma/2}(n-2)} \right]$$

Q.E.D.

17. Encuentre el intervalo de confianza del 95 % para  $\alpha$ ,  $\beta$  y  $\sigma^2$  para la puntuación de las evaluaciones de medio y final del periodo en el **Ejercicio 6.5.3**.

| <i>Midterm</i> | <i>Final</i> | <i>Midterm</i> | <i>Final</i> |
|----------------|--------------|----------------|--------------|
| 70             | 87           | 67             | 73           |
| 74             | 79           | 70             | 83           |
| 80             | 88           | 64             | 79           |
| 84             | 98           | 74             | 91           |
| 80             | 96           | 82             | 94           |

- Intervalo del 95 % de confianza para  $\alpha$

Recordemos que un intervalo de confianza para  $\alpha$  viene dado por

$$\hat{\alpha} \pm t_{\frac{\gamma}{2}}(n-2) \sqrt{\frac{\hat{\sigma}^2}{n-2}}$$

Haciendo uso de *R* el intervalo de confianza es

$$[83,34099 \quad , \quad 90,25901]$$

- Intervalo del 95 % de confianza para  $\beta$

Recordemos que un intervalo de confianza para  $\beta$  viene dado por

$$\hat{\beta} \pm t_{\frac{\gamma}{2}}(n-2) \sqrt{\frac{\hat{\sigma}^2}{n-2}} \sqrt{\frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2}}$$

Haciendo uso de *R* el intervalo de confianza es

$$[0,4787344 \quad , \quad 1,553266]$$

- Intervalo del 95 % de confianza para  $\sigma^2$

Recordemos que un intervalo de confianza para  $\sigma^2$  viene dado por

$$\left[ \frac{n\hat{\sigma}^2}{\chi_{\gamma/2}(n-2)}, \frac{n\hat{\sigma}^2}{\chi_{1-\gamma/2}(n-2)} \right]$$

Haciendo uso de *R* el intervalo de confianza es

$$[10,26545 \quad , \quad 82,57901]$$

Los intervalos de confianza anteriores se obtuvieron apartir del siguiente codigo

```

x <- c(70, 74, 80, 84, 80, 67, 70, 64, 74, 82)
y <- c(87, 79, 88, 98, 96, 73, 83, 79, 91, 94)
n <- length(x)

intento <- data.frame(x,y)

regresion <- lm(y ~ x, intento)
summary(regresion)
anova(regresion)

xp <- mean(x)      #x promedio#
yp <- mean(y)      #y promedio#

sigma2 <- 180.0/n   #sigma2#
B <- 1.016          #Beta#
A <- yp            #Alfa#

gamma <- 0.05
t <- qt(1-(gamma/2), n-2)

# Alfa #
w <- sqrt(sigma2/(n-2))
IA <- A - t*w
DA <- A + t*w

#Beta#
ww <- sqrt((n*sigma2)/(n-2))
www <- sum(x^2) - (xp^2)*n #sum[(x_i - xp)^2]#
IB <- B - t*ww*sqrt(1/www)
DB <- B + t*ww*sqrt(1/www)

#Sigma#
chi <- 0.05
c1 <- qchisq(1-(chi/2), n-2)
c2 <- qchisq(1-(1-chi/2), n-2)
IC <- (n*sigma2)/(c1)
DC <- (n*sigma2)/(c2)

cat("El intervalo de confianza para alfa=", "[", IA, ", ", DA, "]" , "\n")
cat("El intervalo de confianza para beta=", "[", IB, ", ", DB, "]" , "\n")
cat("El intervalo de confianza para sigma2=", "[", IC, ", ", DC, "]" , "\n")

El codigo nos devuelve
El intervalo de confianza para alfa= [ 83.34099 , 90.25901 ]
El intervalo de confianza para beta= [ 0.4787344 , 1.553266 ]
El intervalo de confianza para sigma2= [ 10.26545 , 82.57901 ]

```

19. Usando los datos del **Ejercicio 6.5.8(a)**, encuentre el intervalo de confianza del 95 % para  $\alpha$ ,  $\beta$  y  $\sigma^2$

| <i>Tipo</i>                       | <i>mpg City</i> | <i>mpg HWy</i> | <i>Curb Weight</i> |
|-----------------------------------|-----------------|----------------|--------------------|
| <i>FordFusionV6SE</i>             | 20              | 28             | 3230               |
| <i>ChevroletSebringSedanBase</i>  | 24              | 32             | 3287               |
| <i>ToyotaCamrySolaraSE</i>        | 24              | 34             | 3240               |
| <i>HondaAccordSedan</i>           | 20              | 29             | 3344               |
| <i>AudiA63,2</i>                  | 21              | 29             | 3825               |
| <i>BMW5 – series525iSedan</i>     | 20              | 29             | 3450               |
| <i>ChryslerPTCruiserBase</i>      | 22              | 29             | 3076               |
| <i>MercedesE – ClassE350Sedan</i> | 19              | 26             | 3740               |
| <i>VolkswagenPassatSedan2,0T</i>  | 23              | 32             | 3305               |
| <i>NissanAltima2,5</i>            | 26              | 35             | 3055               |
| <i>KiaOptimaLX2,5</i>             | 24              | 34             | 3142               |

- Intervalo del 95 % de confianza para  $\alpha$

Recordemos que un intervalo de confianza para  $\alpha$  viene dado por

$$\hat{\alpha} \pm t_{\frac{\gamma}{2}}(n-2) \sqrt{\frac{\hat{\sigma}^2}{n-2}}$$

Haciendo uso de  $R$  el intervalo de confianza es

$$[29,9873 \quad , \quad 31,28542]$$

- Intervalo del 95 % de confianza para  $\beta$

Recordemos que un intervalo de confianza para  $\beta$  viene dado por

$$\hat{\beta} \pm t_{\frac{\gamma}{2}}(n-2) \sqrt{\frac{\hat{\sigma}^2}{n-2}} \sqrt{\frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2}}$$

Haciendo uso de  $R$  el intervalo de confianza es

$$[0,9232949 \quad , \quad 1,526705]$$

- Intervalo del 95 % de confianza para  $\sigma^2$

Recordemos que un intervalo de confianza para  $\sigma^2$  viene dado por

$$\left[ \frac{n\hat{\sigma}^2}{\chi_{\gamma/2}(n-2)}, \frac{n\hat{\sigma}^2}{\chi_{1-\gamma/2}(n-2)} \right]$$

Haciendo uso de  $R$  el intervalo de confianza es

$$[0,428434 \quad , \quad 3,018083]$$

Los intervalos de confianza anteriores se obtuvieron apartir del siguiente codigo

```
x <- c(20, 24, 24, 20, 21, 20, 22, 19, 23, 26, 24)
y <- c(28, 32, 34, 29, 29, 29, 29, 26, 32, 35, 34)
n <- length(x)

intento <- data.frame(x,y)

regresion <- lm(y ~ x, intento)
summary(regresion)
anova(regresion)

xp <- mean(x)      #x promedio#
yp <- mean(y)      #y promedio#

sigma2 <- 8.150/n   #sigma2#
B <- 1.2250         #Beta#
A <- yp            #Alfa#

gamma <- 0.05
t <- qt(1-(gamma/2), n-2)

# Alfa #
w <- sqrt(sigma2/(n-2))
IA <- A - t*w
DA <- A + t*w

#Beta#
ww <- sqrt((n*sigma2)/(n-2))
www <- sum(x^2) - (xp^2)*n #sum[(x_i - xp)^2]#
IB <- B - t*ww*sqrt(1/www)
DB <- B + t*ww*sqrt(1/www)

#Sigma#
chi <- 0.05
c1 <- qchisq(1-(chi/2), n-2)
c2 <- qchisq(1-(1-chi/2), n-2)
IC <- (n*sigma2)/(c1)
DC <- (n*sigma2)/(c2)

cat("El intervalo de confianza para alfa=", "[", IA, ", ", DA, "]", "\n")
cat("El intervalo de confianza para beta=", "[", IB, ", ", DB, "]", "\n")
cat("El intervalo de confianza para sigma2=", "[", IC, ", ", DC, "]", "\n")
```

El codigo nos devuelve

El intervalo de confianza para alfa= [ 29.9873 , 31.28542 ]

El intervalo de confianza para beta= [ 0.9232949 , 1.526705 ]

El intervalo de confianza para  $\sigma^2 = [0.428434, 3.018083]$

## Seccion 12 Devore

33 El ejercicio 16 de la sección 12,2 incluyó la salida de *MINITAB* para una regresión de la altura de la hija sobre la altura del padre medio.

|                           |      |      |      |      |      |      |      |      |      |      |      |
|---------------------------|------|------|------|------|------|------|------|------|------|------|------|
| <i>Valordelpadremedio</i> | 66,0 | 65,5 | 71,5 | 68,0 | 70,0 | 65,5 | 67,0 | 70,5 | 69,5 | 64,5 | 67,5 |
| <i>Hija</i>               | 64,0 | 63,0 | 69,0 | 69,0 | 69,0 | 65,0 | 63,0 | 68,5 | 69,0 | 64,0 | 67,0 |

- a) Utilice el resultado para calcular un intervalo de confianza con un nivel de confianza del 95 % para la pendiente  $\beta_1$  de la línea de regresión de población e interprete el intervalo resultante.

Tenemos que en el Devore y Hogg se modifica como se define la regresión pero en este caso para definir el intervalo de confianza no afecta.

Recordemos que un intervalo de confianza para  $\beta_1$  viene dado por

$$\hat{\beta}_1 \pm t_{\frac{\gamma}{2}}(n-2) \sqrt{\frac{\hat{\sigma}^2}{n-2} \sqrt{\frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2}}}$$

Haciendo uso de *R* el intervalo de confianza es

$[0,5096982, 1,401302]$

El intervalo de confianza se obtuvo apartir del siguiente código

```
x <- c(66.0, 65.5, 71.5, 68.0, 70.0, 65.5, 67.0, 70.5, 69.5, 64.5, 67.5)
y <- c(64.0, 63.0, 69.0, 69.0, 69.0, 65.0, 63.0, 68.5, 69.0, 64.0, 67.0)
n <- length(x)
```

```
data <- data.frame(x, y)
```

```
regresion <- lm(y ~ x, data)
summary(regresion)
anova(regresion)
```

```
xp <- mean(x)      #x promedio#
yp <- mean(y)      #y promedio#
```

```
sigma2 <- 18.938/n      #sigma2#
B <- 0.9555             #Beta#
A <- 1.6497             #Alfa#
```

```

gamma <- 0.05
t <- qt(1-(gamma/2), n-2)

ww <- sqrt((n*sigma2)/(n-2))
www <- sum(x^2) - (xp^2)*n #sum[(x_i - xp)^2]#

IB <- B - t*ww*sqrt(1/www)
DB <- B + t*ww*sqrt(1/www)

cat("El intervalo de confianza para beta=", "[", IB, ", ", DB, "]" , "\n")

```

El código nos da  
El intervalo de confianza para beta= [ 0.5096982 , 1.401302 ]

- b) Suponga que anteriormente se había creído que cuando la altura de los padres medios aumentaba 1 pulgada, el cambio promedio verdadero asociado en la altura de la hija sería de al menos 1 pulgada. ¿Los datos de la muestra contradicen esta creencia? Enunciar y probar las hipótesis pertinentes.

Primero recordemos que el modelo de regresión lineal simple no debe usarse para más inferencias (estimaciones del valor medio o predicciones de valores futuros) a menos que la prueba de utilidad del modelo resulte en el rechazo de  $H_0$  para un  $\alpha$  adecuadamente pequeño. Apartir de esto tenemos si la hipótesis nula  $H_0 : \beta_1 = \beta_{10}$  el valor estadístico de prueba  $t = \frac{\hat{\beta}_1 - \beta_{10}}{s_{\hat{\beta}_1}}$  sucede que

| Hipotesis alternativa           | Región de rechazo para la prueba de nivel $\alpha$   |
|---------------------------------|------------------------------------------------------|
| $H_a : \beta_1 > \beta_{10}$    | $t \geq t_{\alpha}(n-2)$                             |
| $H_a : \beta_1 < \beta_{10}$    | $t \leq -t_{\alpha}(n-2)$                            |
| $H_a : \beta_1 \neq \beta_{10}$ | $t \geq t_{\alpha}(n-2)$ o $t \leq -t_{\alpha}(n-2)$ |

Sea  $H_0 : \beta_1 = 1$  y  $H_1 : \beta_1 < 1$ , con los datos obtengamos los siguientes valores

$$t = -0,2258 \quad -t_{\alpha}(n-2) = -1,383$$

Del cual notemos que

$$-0,2258 > -1,383$$

Es decir, no hay motivo para rechazar la hipótesis nula, con  $\alpha = 10\%$  donde no hay conflicto entre los datos con la afirmación de que la pendiente es al menos 1.

El código utilizado para obtener los valores anteriores fue:

37 Consulte los datos sobre  $x$  = valor de yodo e  $y$  = número de cetano dados en el *ejercicio*19.

|     |       |       |       |       |       |      |      |      |      |      |      |      |      |      |
|-----|-------|-------|-------|-------|-------|------|------|------|------|------|------|------|------|------|
| $x$ | 132,0 | 129,0 | 120,0 | 113,2 | 105,0 | 92,0 | 84,0 | 83,2 | 88,4 | 59,0 | 80,0 | 81,5 | 71,0 | 69,2 |
| $y$ | 46,0  | 48,0  | 51,0  | 52,1  | 54,0  | 52,0 | 59,0 | 58,7 | 61,6 | 64,0 | 61,4 | 54,6 | 58,8 | 58,0 |

- a) ¿El modelo de regresión lineal simple especifica una relación útil entre las dos variables? Use el procedimiento de prueba apropiado para obtener información sobre el  $P$  – *valor* y luego llegue a una conclusión con un nivel de significancia de ,01.

Sea  $H_0 : \beta_1 = 0$  y  $H_1 : \beta_1 \neq 0$ , con los datos y usando  $R$  tenemos que

$$t = -6,734 \quad t_{\alpha}(n-2) = 3,05454 \quad p - \text{valor} = 0,00002091$$

Del cual por el  $p$  – *valor* podemos notar que es menor que el nivel de significancia, lo que implica que se rechaza la hipótesis nula. Del cual el nivel 0,01, concluye que existe una relación lineal útil.

El código utilizado para encontrar los valores fue:

```
x<-c(132.0,129.0,120.0,113.2,105.0,92.0,84.0,83.2,88.4,59.0,80.0,81.5,71.0,69.2)
y<-c(46.0,48.0,51.0,52.1,54.0,52.0,59.0,58.7,61.6,64.0,61.4,54.6,58.8,58.0)
n <- length(x)
```

```
data <- data.frame(x,y)
```

```
regresion <- lm(y ~ x, data)
summary(regresion)
```

```
gamma <- 0.01
t <- qt(1-(gamma/2), n-2)
```

- b) Calcule un IC del 95 % para el cambio esperado en el número de cetano asociado con un aumento de 10g en el valor de yodo.

Recordemos que un intervalo de confianza para  $\beta_1$  viene dado por

$$\hat{\beta}_1 \pm t_{\frac{\gamma}{2}}(n-2) \sqrt{\frac{\hat{\sigma}^2}{n-2} \sqrt{\frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2}}}$$

Haciendo uso de  $R$  el intervalo de confianza es

$$[-0,2771354 \quad , \quad -0,1416446]$$

El intervalo de confianza se obtuvo apartir del siguiente código

```
x<-c(132.0,129.0,120.0,113.2,105.0,92.0,84.0,83.2,88.4,59.0,80.0,81.5,71.0,69.2)
y<-c(46.0,48.0,51.0,52.1,54.0,52.0,59.0,58.7,61.6,64.0,61.4,54.6,58.8,58.0)
n <- length(x)
```

```
data <- data.frame(x,y)
```

```
regresion <- lm(y ~ x, data)
summary(regresion)
anova(regresion)
```

```

xp <- mean(x)      #x promedio#
yp <- mean(y)      #y promedio#

sigma2 <- 78.92/n   #sigma2#
B <- -0.20939       #Beta#
A <- 75.21243       #Alfa#

gamma <- 0.05
t <- qt(1-(gamma/2), n-2)

ww <- sqrt((n*sigma2)/(n-2))
www <- sum(x^2) - (xp^2)*n #sum[(x_i - xp)^2]#

IB <- B - t*ww*sqrt(1/www)
DB <- B + t*ww*sqrt(1/www)

cat("El intervalo de confianza para beta=", "[", IB, ", ", DB, "]", "\n")

```

47. Astringencia es una característica del vino que hace que sea más áspero, seco y fuerte en la boca del catador del vino. El paper *Analysis of Tannins in Red Wine Using Multiple Methods: Correlation with Perceived Astringency* (Amer. J. Enol. Vitic., 2006: 481–485), reportó en una investigación sobre relación entre astringencia perceptible y la concentración de tanino, usando varios métodos analíticos. Aquí están los datos proporcionados por los autores en  $x$  = concentración de tanino y  $y$  = astringencia perceptible como fue determinado en el panel de los catadores.

|     |       |        |        |       |        |        |        |        |
|-----|-------|--------|--------|-------|--------|--------|--------|--------|
| $x$ | 0,718 | 0,808  | 0,924  | 1,000 | 0,667  | 0,529  | 0,514  | 0,559  |
| $y$ | 0,428 | 0,480  | 0,493  | 0,978 | 0,318  | 0,298  | -0,224 | 0,198  |
| $x$ | 0,766 | 0,470  | 0,726  | 0,762 | 0,666  | 0,562  | 0,378  | 0,779  |
| $y$ | 0,326 | -0,336 | 0,765  | 0,190 | 0,066  | -0,221 | -0,898 | 0,836  |
| $x$ | 0,674 | 0,858  | 0,406  | 0,927 | 0,311  | 0,319  | 0,518  | 0,687  |
| $y$ | 0,126 | 0,305  | -0,577 | 0,779 | -0,707 | -0,610 | -0,648 | -0,145 |
| $x$ | 0,907 | 0,638  | 0,234  | 0,781 | 0,326  | 0,433  | 0,319  | 0,238  |
| $y$ | 1,007 | -0,090 | -1,132 | 0,538 | -1,098 | -0,581 | -0,862 | -0,551 |

Los resultados de las sumas relevantes son:

$$\sum x_i = 19,404, \quad \sum y_i = -0,549, \quad \sum x_i^2 = 13,248032$$

$$\sum y_i^2 = 11,835795, \quad \sum x_i y_i = 3,497811$$

$$S_{xx} = 13,248032 - (19,404)^2/32 = 1,48193150$$

$$S_{yy} = 11,82637622$$

$$S_{xy} = 3,497811 - (19,404)(-0,549)/32 = 3,83071088$$

- a) Pruebe el siguiente modelo de regresión simple para estos datos. Después determine la proporción de astringencia observada que puede ser atribuida al modelo de relación entre la astringencia y la concentración de tanino.

El modelo de regresión lineal viene dado por:

$$y = \hat{\beta}_1 x + b$$

Donde

$$\hat{\beta}_1 = \frac{\sum(x_i - \bar{x})(Y_i - \bar{Y})}{\sum(x_i - \bar{x})^2} \quad y \quad b = \frac{\sum y \cdot \sum x^2 - \sum x \cdot \sum(x \cdot y)}{n \sum x^2 - (\sum x)^2}$$

Usando las sumas relevantes tenemos.

$$\hat{\beta}_1 = \frac{n \sum(x \cdot y) - \sum x \cdot \sum y}{n \sum x^2 - (\sum x)^2} = \frac{(3,497811) \cdot (32) - (19,404) \cdot (-0,549)}{(32) \cdot (13,248032) - (19,404)^2} = \frac{122,5827}{47,42181} = 2,584945$$

$$b = \frac{\sum y \cdot \sum x^2 - \sum x \cdot \sum(x \cdot y)}{n \sum x^2 - (\sum x)^2} = \frac{(-0,549) \cdot (13,248032) - (19,404) \cdot (3,497811)}{(32) \cdot (13,248032) - (19,404)^2} = \frac{-75,14469}{47,42181} = -1,584602$$

Entonces

$$y = -1,584602 + 2,584945x$$

El coeficiente de determinación está dado por

$$r^2 = \left( \frac{S_{XY}}{\sqrt{S_{XX}} \sqrt{S_{YY}}} \right)^2$$

De esta manera

$$r^2 = \left( \frac{3,83071088}{\sqrt{1,48193150} \sqrt{11,82637622}} \right)^2 = \left( \frac{3,83071088}{4,186392} \right)^2 = (0,9150387)^2 = 0,8372958$$

b) Calcule e interprete el intervalo de confianza para la pendiente de la verdadera regresión lineal.

El intervalo de confianza es

$$[2,268979 \quad , \quad 2,900821]$$

El cual fue obtenido apartir del siguiente codigo hecho en R

```
x=c(0.718,0.808,0.924,1.000,0.667,0.529,0.514,0.559,
0.766,0.470,0.726,0.762,0.666,0.562,0.378,0.779,
0.674,0.858,0.406,0.927,0.311,0.319,0.518,0.687,
0.907,0.638,0.234,0.781,0.326,0.433,0.319,0.238)
```

```
y=c(0.428,0.480,0.493,0.978,0.318,0.298,-0.224,0.198,
0.326,-0.336,0.765,0.190,0.066,-0.221,-0.898,0.836,
0.126,0.305,-0.577,0.779,-0.707,-0.610,-0.648,-0.145,
1.007,-0.090,-1.132,0.538,-1.098,-0.581,-0.862,-0.551)
```

```
n=length(x)
data=data.frame(x,y)
reg=lm(y~x,data)
```

```

summary( regr )
anova( regr )

sigma=1.9242
alpha=-1.5846
beta=2.5849

xvar=mean( x )
x1=.6
yg=alpha+beta*x1
s=sqrt( (sum(y^2)-alpha*sum(y)-beta*3.83071088)*1/(n-2))

gamma <- 0.05
t <- qt(1-(gamma/2) , n-2)

a=sqrt( (n*sqrt(sigma))/(n-2))
b=1.48193150
sb=s/sqrt(b)

lib=beta-t*sb
lsb=beta+t*sb

```

- c) Estime el promedio de astringencia para una sola muestra de vino cuya concentración de tanino sea .6, hágalo de tal forma que sea fiable y preciso.

El intervalo de confianza es

$$[-0,101649 \quad , \quad 0,05432899]$$

Donde la media de astringencia es  $\hat{y} = -0,03366$

El cual lo anterior fue obtenido con el siguiente código que es una continuación del anterior

```

li=yg-t*sy
ls=yg+t*sy

```

- d) Prediga la astringencia para una sola muestra de vino cuya concentración de tanino sea .6, hágalo de tal forma que sea fiable y preciso.

El intervalo de confianza es

$$[-0,4242084 \quad , \quad 0,3568884]$$

Donde la media de astringencia es  $\hat{y} = -0,03366$

El cual lo anterior fue obtenido con el siguiente código que es una continuación del anterior

```

li=yg-t*sqrt(s^2+sy^2)
ls=yg+t*sqrt(s^2+sy^2)

```

- e) ¿Hay una evidencia convincente para concluir que la media de astringencia sea positiva cuando la concentración de tanino sea .7? Declare lo y pruebe la hipótesis adecuada.

Sea  $H_0 : \beta = 0$  y  $H_1 : \beta \neq 0$ , dado que si la media era 0,6 el intervalo de confianza era muy cercano al 0 podemos concluir que si acepta la hipótesis para la concentración de tanino 0,7

57. La prueba de oxido de aceite de una turbina (TOST) y la prueba de rotación de la bomba (RBOT) son 2 diferentes procedimientos para evaluar la estabilidad del vapor de la oxidación de aceite en las turbinas. El artículo "*Dependence of Oxidation Stability of Steam Turbine Oil on Base Oil Composition*" (J. Soc. Tribologists Lubricat. Engrs., Oct. 1997: 19–24) reportó que las observaciones de la compañía con  $x =$  TOST tiempo en horas y  $y =$  RBOT tiempo en minutos para 12 especímenes de aceite.

|      |      |      |      |      |      |      |
|------|------|------|------|------|------|------|
| TOST | 4200 | 3600 | 3750 | 3675 | 4050 | 2770 |
| RBOT | 370  | 340  | 375  | 310  | 350  | 200  |
| TOST | 4870 | 4500 | 3450 | 2700 | 3750 | 3300 |
| RBOT | 400  | 375  | 285  | 225  | 345  | 285  |

- a) Calcule e interprete el valor de coeficiente de correlación de la muestra (como lo hicieron los autores del artículo).

El coeficiente de correlación es

$$r = 0,9231564$$

El cual fue obtenido en R con el siguiente código

```
x<-c(4200,3600,3750,3675,4050,2770,4870,4500,3450,2700,3750,3300)
y<-c(370,340,375,310,350,200,400,375,285,225,345,285)
cor(x,y)
```

- b) ¿Como afecta el valor  $r$  si  $x =$  el tiempo de RBOT y  $y =$  el tiempo de TOST?

Tenemos que  $r = 0,9231564$  con esto podemos decir que no lo afecta dado que es el mismo valor que el inciso anterior. Este valor fue obtenido a partir del siguiente código en R.

```
y=c(4200,3600,3750,3675,4050,2770,4870,4500,3450,2700,3750,3300)
x=c(370,340,375,310,350,200,400,375,285,225,345,285)
cor(x,y)
```


- c) ¿Cómo afectaría el valor  $r$  si el tiempo de RBOT fuera expresado en horas?

Tenemos que  $r = 0,9231564$  con esto podemos decir que no lo afecta al valor ya que obtuvimos el mismo que el inciso a. Este valor fue obtenido a partir del siguiente código en R


```
x=c(4200,3600,3750,3675,4050,2770,4870,4500,3450,2700,3750,3300)
y=c(370,340,375,310,350,200,400,375,285,225,345,285)*60
cor(x,y)
```


- d) Construya un diagrama de dispersión y diagramas de probabilidad normal y comente.

Diagrama de dispersión



### Diagramas de probabilidad normal





Notemos que los gráficos normales si parecen seguir una distribución normal cada uno, pero el gráfico de dispersión se le observa muestra una ligera curvatura.

Los anteriores graficas se obtuvieron de los siguientes codigos realizados en R

Diagrama de dispersión

```
x=c(4200,3600,3750,3675,4050,2770,4870,4500,3450,2700,3750,3300)
y=c(370,340,375,310,350,200,400,375,285,225,345,285)*60
plot(x,y,xlab='TOST',ylab='RBOT',main='Diagrama de dispersion ',col='red')
```

Diagramas de probabilidad normal

```
x=c(4200,3600,3750,3675,4050,2770,4870,4500,3450,2700,3750,3300)
y=c(370,340,375,310,350,200,400,375,285,225,345,285)*60
qqnorm(x,main="Diagrama de probabilidad normal de x")
qqline(x,col="red")
qqnorm(y,main="Diagrama de probabilidad normal de y")
qqline(y,col="red")
```

- e) Realice una prueba de hipótesis para decidir si el tiempo de RBOT y TOST están linealmente relacionados. Recordemos que la hipótesis cuando  $H_0 : \rho = 0$  es cierta tiene por valor estadístico de prueba  $T = \frac{R\sqrt{n-2}}{\sqrt{1-R^2}}$  sucede que

| Hipotesis alternativa | Región de rechazo para la prueba de nivel $\alpha$       |
|-----------------------|----------------------------------------------------------|
| $H_a : \rho > 0$      | $t \geq t_{\alpha}(n-2)$                                 |
| $H_a : \rho < 0$      | $t \leq -t_{\alpha}(n-2)$                                |
| $H_a : \rho \neq 0$   | $t \leq -t_{\alpha/2}(n-2)$ o $t \geq t_{\alpha/2}(n-2)$ |

El donde se quiere hacer una prueba de hipótesis

$H_0 : \rho = 0$

$H_a : \rho \neq 0$

Se obtuve que el valor de  $T = 7,593888$  y  $p$ -valor es aproximadamente 0,00002 donde podemos notar que es menor que el nivel de significancia, lo que implica que la hipótesis nula se rechaza en el nivel 0,001 teniendo una relación lineal útil.

Se usó el siguiente código en R

```
x=c(4200,3600,3750,3675,4050,2770,4870,4500,3450,2700,3750,3300)
y=c(370,340,375,310,350,200,400,375,285,225,345,285)*60
n=length(x)
data=data.frame(x,y)
regresion=lm(y ~ x, data)
summary(regresion)
yp=mean(y)
xp=mean(x)
a=(x-xp)^2
b=(y-yp)^2
R=sum((x-xp)*(y-yp))/(sqrt(sum(a))*sqrt(sum(b)))
T=R*sqrt(n-2)/sqrt(1-R^2)
```

71. La resistencia al desgaste de los componentes de cierto reactor nuclear hechos de Zircaloy-2 son parcialmente determinados por sus propiedades de la capa de óxido. Los siguientes datos que aparecen en el artículo que supone un nuevo método no destructivo para monitorear la capa de espesor (*"Monitoring of Oxide Layer Thickness on Zircaloy-2 by the Eddy Current Test Method," J. Test. Eval., 1987: 333–336*). Las variables son  $x$  = espesor de la capa de óxido ( $\mu\text{m}$ ) y  $y$  = Respuesta de corriente de Foucault (unidades arbitrarias).

|     |      |      |      |      |      |
|-----|------|------|------|------|------|
| $x$ | 0    | 7    | 17   | 114  | 133  |
| $y$ | 20,3 | 19,8 | 19,5 | 15,9 | 15,1 |

|     |      |      |      |     |     |
|-----|------|------|------|-----|-----|
| $x$ | 142  | 190  | 218  | 237 | 285 |
| $y$ | 14,7 | 11,9 | 11,5 | 8,3 | 6,6 |


- a) Los autores resumieron la relación dada por la ecuación de la línea de los mínimos cuadrados como  $y = 20,6 - 0,47x$ . Calcule y grafique los residuales contra  $x$  y después comente en la adecuación del modelo de regresión lineal simple.

Dado que la línea de los mínimos cuadrados es  $y = 20,6 - 0,47x$  esto implica que  $\hat{y}_i = 20,6 - 0,47x_i$ , por otro lado recordemos que el residuo se encuentra definido como  $e_i = y_i - \hat{y}_i$  y de igual forma tenemos que los residuos de estandarización vienen dados por  $e_i^* = \frac{e_i}{s_e \sqrt{1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{S_{xx}}}} = \frac{e_i}{s_e}$  donde

$s_e = 0,7921$  con esto calculemos dichos valores.

| $x$ | $y$  | $\hat{y} = 20,6 - 0,47x$ | $e = y - \hat{y}$ | $e^* = \frac{e}{s_e}$ |
|-----|------|--------------------------|-------------------|-----------------------|
| 0   | 20.3 | 20.600                   | -0.300            | -0.3787401            |
| 7   | 19.8 | 20.271                   | -0.471            | -0.5946219            |
| 17  | 19.5 | 19.801                   | -0.301            | -0.3800025            |
| 114 | 15.9 | 15.242                   | 0.658             | 0.8307032             |
| 133 | 15.1 | 14.349                   | 0.751             | 0.9481126             |
| 142 | 14.7 | 13.926                   | 0.774             | 0.9771493             |
| 190 | 11.9 | 11.670                   | 0.230             | 0.2903674             |
| 218 | 11.5 | 10.354                   | 1.146             | 1.4467870             |
| 237 | 8.3  | 9.461                    | -1.161            | -1.4657240            |
| 285 | 6.6  | 7.205                    | -0.605            | -0.7637925            |

Con lo anterior realicemos la gráfica de residuos




Del cual podemos observar que la gráfica varios puntos se encuentran despegados de la recta  $y = 0$  lo cual podemos decir que este modelo no es tan adecuado.

- b) Use  $s = 0,7921$  para calcular los residuos de la estandarización de una muestra de regresión lineal simple. Construya un diagrama de residuos de estandarización y comente. También construya un diagrama de probabilidad normal y comente.

Tabla del inciso (a) ya incluye los residuos de la estandarización de la muestra de regresión lineal, mas precisamente es la columna 5 de la tabla. Ahora construyamos un diagrama



Ahora construyamos el diagrama de probabilidad normal



Del cual podemos observar que la grafica de residuos estandarizados casi no cambiar con la grafica de residuos, de igual manera observamos que los diagramas de probabilidad normal muestran que los datos de los residuos estandarizados no siguen una distribución normal.

Todo lo anterior se realizo con el siguiente código

```
x<-c(0,7,17,114,133,142,190,218,237,285)
y<-c(20.3,19.8,19.5,15.9,15.1,14.7,11.9,11.5,8.3,6.6)
s <- 0.7921
n <- length(x)

yi<-c()
```

```
for(i in 1:n){
  yi[i] <- 20.6-0.047*x[i]
}
e <- (y - yi)
es <- e/s

### Grafica de Residuos ###
xseq=seq(-300,300,0.01)
yseq = xseq -xseq
plot(x, e, main='Grafica de Residuos', xlab = 'x', ylab= 'e', col = 'cornflowerblue')
lines(xseq, yseq)

### Grafica de Residuos de Estandarizacion ###
plot(x, es, main='Grafica de Residuos de Estandarizacion', xlab = 'x', ylab= 'e')
lines(xseq, yseq)

### Grafica normal de Residuos de Estandarizacion ###
par(mfrow=c(1,2)) # Parte la pantalla en 2
qqnorm(es, main='Diagrama de normal de Residuos de Estandarizacion')
qqline(es)
hist(es, freq=F, main='Histograma normal de Residuos de Estandarizacion')
curve(dnorm(x, mean(es), sd(es)), add=TRUE)
```

## Sección 12 Devore

79. Sea  $y$  = ventas en un establecimiento de comida rápida (\$1000's),  $x_1$  = número de puntos de venta de la competencia dentro de una milla radio,  $x_2$  = población dentro de un radio de 1 milla (miles de personas), y  $x_3$  sea una variable indicadora que es igual a 1 si la salida tiene una ventana de acceso y 0 en caso contrario. Supongamos que la verdadera regresión el modelo es

$$Y = 10.0 - 1.2x_1 + 6.8x_2 + 15.3x_3 + \varepsilon$$

- a) ¿Cuál es el valor medio de las ventas cuando el número de puntos de venta que compiten es 2, hay 8000 personas dentro de un radio de 1 milla, y el toma de corriente tiene una ventana de acceso?

Notemos que  $x_1 = 2$ ,  $x_2 = 8$  y  $x_3 = 1$  de esta manera para calcular los valor medio de ventas reemplazamos los valores anteriores en la esperanza de  $Y$  así

$$\begin{aligned} E[Y] &= 10.0 - 1.2x_1 + 6.8x_2 + 15.3x_3 \\ &= 10.0 - 1.2(2) + 6.8(8) + 15.3(1) \\ &= 77.3 \end{aligned}$$

Por lo tanto, el valor medio de ventas es 77.3

- b) ¿Cuál es el valor medio de las ventas de un punto de venta sin ventanilla de autoservicio que tiene tres puntos de venta de la competencia y 5000 personas dentro de un radio de 1 milla?

Se resuelve análogamente el inciso anterior, en este caso tenemos que  $x_1 = 3$ ,  $x_2 = 5$  y  $x_3 = 0$  entonces

$$\begin{aligned} E[Y] &= 10.0 - 1.2x_1 + 6.8x_2 + 15.3x_3 \\ &= 10.0 - 1.2(3) + 6.8(5) \\ &= 40.4 \end{aligned}$$

Por lo tanto, el valor medio de ventas es 40.4

*Nota:*  $x_3 = 0$  debido a que tenemos el un punto de venta sin ventanilla de autoservicio, lo cual por como esta definido  $x_3$  el valor que tomara es 0.

- c) Interprete  $\beta_3$

Por como esta planteado el modelo del problema podemos decir que  $\beta_3$  la diferencia en las ventas medias entre la ventanilla de autoservicio y la ventanilla sin autoservicio. Representando un factor muy relevante dado que influyen en el ingreso del establecimiento.

81. El artículo "Precios de venta/M2. Pie. de edificios de oficinas en el centro de Chicago: ¿cuánto vale ser un edificio antiguo pero de clase A?" (J. Real Estate Res., 2010 : 1–22) consideró un modelo de regresión

para relacionar  $y = \ln(\$ft^2)$  con 16 predictores, incluyendo la edad, la edad al cuadrado, el número de pisos, la tasa de ocupación y las variables indicadoras para saber si un edificio tiene un restaurante y si tiene salas de conferencias. El modelo se ajustó a datos resultantes de 203 de ventas.

- a) El coeficiente de determinación múltiple fue de .711. ¿Cuál es el valor del coeficiente de determinación múltiple ajustado? ¿Sugiere que el valor  $R^2$  relativamente alto fue el resultado de incluir demasiados predictores en el modelo en relación con la cantidad de datos disponibles?

Primero recordemos que el coeficiente de determinación múltiple es

$$R^2 = 1 - \frac{SSE}{SST}$$

De manera análoga el coeficiente ajustado de determinación múltiple se define por

$$R_a^2 = 1 - \frac{MSE}{MST} = 1 - \frac{\frac{SSE}{n-(k+1)}}{\frac{SST}{n-1}} = 1 - \frac{n-1}{n-(k+1)} \frac{SSE}{SST}$$

Con lo anterior sabemos que

$$R^2 = 0.711 = 1 - \frac{SSE}{SST} \Leftrightarrow \frac{SSE}{SST} = 1 - 0.711 = 0.289$$

Entonces

$$R_a^2 = 1 - \frac{n-1}{n-(k+1)} \frac{SSE}{SST} = 1 - \frac{203-1}{203-(16+1)} \cdot 0.289 = 0.68613$$

Es decir, el valor del coeficiente de determinación múltiple ajustado es 0.68613.

Tenemos que el valor de  $R^2$  está más cercano a 1 y de la misma manera el valor  $R_a$  se encuentra bastante cercano al valor de  $R$  de lo que podemos decir que el modelo es bueno.

- b) Usando el valor  $R^2$  de (a), realice una prueba de hipótesis para ver si existe una relación lineal útil entre la variable dependiente y al menos uno de los predictores.

Recordemos la prueba de utilidad del modelo.

Hipótesis nula:  $H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$

Hipótesis alternativa:  $H_a : \text{al menos uno } \beta_i \neq 0 \quad (i = 1, \dots, k)$

Valor de la estadística de prueba:

$$f = \frac{R^2/k}{(1-R^2)/[n-(k+1)]} = \frac{SSR/k}{SSE/[n-(k+1)]} = \frac{MSR}{MSE}$$

donde  $SSR = SST - SSE$

Región de rechazo para una prueba de nivel  $\alpha$ :  $f \geq F_{\alpha, k, n-(k+1)}$

Por un lado tenemos que

$$f = \frac{R^2/k}{(1-R^2)/[n-(k+1)]} = \frac{0.711/16}{(1-0.711)/[203-(16+1)]} = 28.59991$$

Y por otro lado usando  $R$  considerando el nivel de significancia de 0.001 tenemos

$$F_{\alpha,k,n-(k+1)} = 2.624483$$

Del cual tenemos que

$$28.59991 > 2.624483$$

Lo cual significa que se rechaza  $H_0$ , por lo tanto, existe una relación útil con al menos un  $\beta_i$  del modelo. Lo que implica que este  $\beta_i$  es estadísticamente significativo y que el modelo es útil para predecir la variable dependiente.

El código utilizado fue

```
alfa <- 0.001
k <- 16
n <- 203

f <- qf(1-alfa, k, n-(k+1))
```

- c) El coeficiente estimado de la variable indicadora de si un edificio era o no clase A fue de .364. Interprete este coeficiente estimado, primero en términos de  $y$  y luego en términos de  $\$/ft^2$ .

En términos en términos de  $y$  solo indica que con todos los demás predictores constantes, la diferencia para ser de la clase A.

En términos de  $\$/ft^2$  representa el efecto es multiplicativo. Se estima que los edificios de clase A valen un porcentaje de dólares más con todos los demás predictores constantes.

- d) La relación  $t$  para el coeficiente estimado de (c) fue de 5.49. ¿Qué te dice esto?

Recordando

---

Hipotesis nula:  $H_0 : \beta_1 = 0$

|                              |                                          |
|------------------------------|------------------------------------------|
| <i>Hipotesis alternativa</i> | <i>Region de rechazo</i>                 |
| $H_a : \beta_1 \neq 0$       | $ t  \geq t_{\frac{\alpha}{2}, n-(k+1)}$ |

---

Tenemos que si consideramos a  $\alpha = 0.001$  se sigue que

$$t_{\frac{\alpha}{2}, n-(k+1)} = 3.343601$$

Del cual notemos que

$$5.49 > 3.343601$$

Lo cual implica que se rechaza la hipótesis nula, es decir, el coeficiente estimado del inciso anterior es estadísticamente significativo.

El código utilizado fue

```

n <- 203
k <- 16
alpha <- 0.001
t <- qt(1-(alpha/2), n-(k+1))

```

83. Un experimento llevado a cabo para estudiar el efecto de el contenido molar de cobalto ( $x_1$ ) y la temperatura de calcinación ( $x_2$ ) en el área superficial de un catalizador de hidróxido de hierro-cobalto ( $y$ ) dieron como resultado los datos adjuntos (“Structural Changes and Surface Properties of  $\text{Co}_x\text{Fe}_{3-x}\text{O}_4$  Spinel,” J. Chem.Tech. Biotech., 1994: 161–170).

|       |      |      |      |      |      |       |       |
|-------|------|------|------|------|------|-------|-------|
| $x_1$ | .6   | .6   | .6   | .6   | .6   | 1.0   | 1.0   |
| $x_2$ | 200  | 250  | 400  | 500  | 600  | 200   | 250   |
| $y$   | 90.6 | 82.7 | 58.7 | 43.2 | 25.0 | 127.1 | 112.3 |

|       |      |      |     |      |      |      |      |
|-------|------|------|-----|------|------|------|------|
| $x_1$ | 1.0  | 1.0  | 1.0 | 2.6  | 2.6  | 2.6  | 2.6  |
| $x_2$ | 400  | 500  | 600 | 200  | 250  | 400  | 500  |
| $y$   | 19.6 | 17.8 | 9.1 | 53.1 | 52.0 | 43.4 | 42.4 |

|       |      |      |      |      |      |      |
|-------|------|------|------|------|------|------|
| $x_1$ | 2.6  | 2.8  | 2.8  | 2.8  | 2.8  | 2.8  |
| $x_2$ | 600  | 200  | 250  | 400  | 500  | 600  |
| $y$   | 31.6 | 40.9 | 37.9 | 27.5 | 27.3 | 19.0 |

Una solicitud al paquete SAS para ajustar la función de regresión  $\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3$  donde  $x_3 = x_1 x_2$  (un predictor de interacción) produjo el resultado adjunto.

Dependent Variable: SURFAREA

#### Analysis of Variance

| Source  | DF | Sum of Squares | Mean Square | F Value | Prob > F |
|---------|----|----------------|-------------|---------|----------|
| Model   | 3  | 15223.52829    | 5074.50943  | 18.924  | 0.0001   |
| Error   | 16 | 4290.53971     | 268.15873   |         |          |
| C Total | 19 | 19514.06800    |             |         |          |

|          |          |          |        |
|----------|----------|----------|--------|
| Root MSE | 16.37555 | R-square | 0.7801 |
| Dep Mean | 48.06000 | Adj R-sq | 0.7389 |
| C.V.     | 34.07314 |          |        |

#### Parameter Estimates

| Variable | DF | Parameter Estimate | Standard Error | T for H0: Parameter=0 | Prob >  T |
|----------|----|--------------------|----------------|-----------------------|-----------|
| INTERCEP | 1  | 185.485740         | 21.19747682    | 8.750                 | 0.0001    |
| COBCON   | 1  | -45.969466         | 10.61201173    | -4.332                | 0.0005    |
| TEMP     | 1  | -0.301503          | 0.05074421     | -5.942                | 0.0001    |
| CONTEMP  | 1  | 0.088801           | 0.02540388     | 3.496                 | 0.0030    |

- a) Prediga el valor del área superficial cuando el cobalto el contenido es 2.6 y la temperatura es 250, y calcule el valor del residual correspondiente.

Notemos que  $x_1 = 2.6$ ,  $x_2 = 250$  y  $x_3 = 650$ , además usando la tabla de análisis de varianza que nos da el problema tenemos la regresión lineal y con esta obtendremos el área superficial

$$\begin{aligned}\hat{y} &= 185.48574 - 45.969466x_1 - 0.301503x_2 + 0.088801x_1x_2 \\ &= 185.48574 - 45.969466(2.6) - 0.301503(250) + 0.088801(650) \\ &= 48.3100284\end{aligned}$$

Por lo tanto el valor del área superficial con los valores dados es 48.3100284

Ahora calculemos el valor del residual correspondiente, de aquí observando los datos cuando  $x_1 = 2.6$  y  $x_2 = 250$  se sigue que  $y = 52$ , de esta manera

$$e = y - \hat{y} = 52 - 48.3100284 = 3.6899716$$

Por lo tanto el valor de residual correspondiente es 3.6899716.

- b) Como  $\hat{\beta}_1 = -46$  ¿Es legítimo concluir que si el contenido de cobalto aumenta en 1 unidad mientras los valores de los otros predictores permanecen fijos, se puede esperar que el área superficial disminuya en aproximadamente 46 unidades? Explique su razonamiento.

Sí, es podemos concluir que si el contenido de cobalto aumenta en 1 unidad mientras los valores de los otros predictores permanecen fijos, de esta manera se puede esperar que el área superficial disminuya en aproximadamente 46 unidades porque al observar los  $p$ -valores de la interacción de  $x_1$  y  $x_2$  son menores que 0.01 en el modelo, es decir, se rechazaría la hipótesis nula de que  $H_0 : \beta_i = 0$  teniendo que los predictores en la interacción son significativos a la variable dependiente.

- c) ¿Parece haber una relación útil entre  $y$  y los predictores?

Recordemos la prueba de utilidad del modelo.

---

Hipótesis nula:  $H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$

Hipótesis alternativa:  $H_a : \text{al menos uno } \beta_i \neq 0 \quad (i = 1, \dots, k)$

Valor de la estadística de prueba:

$$f = \frac{R^2/k}{(1 - R^2)/[n - (k + 1)]} = \frac{SSR/k}{SSE/[n - (k + 1)]} = \frac{MSR}{MSE}$$

donde  $SSR = SST - SSE$

Región de rechazo para una prueba de nivel  $\alpha$ :  $f \geq F_{\alpha, k, n - (k + 1)}$

---

De manera analoga recordemos el siguiente criterio.

- Si  $p\text{valor} < 0.01$  se rechaza  $H_0$

Y haciendo uso de la tabla que nos da el enunciado tenemos que

$$F = 18.924 \quad P_{valor} = 0.0001$$

Entonces por el criterio dado tendríamos que se rechaza  $H_0$ , debido a que  $0.0001 < 0.01$ , por lo tanto, si existe una relación útil con al menos un  $\beta_i$  del modelo. Lo que implica que este  $\beta_i$  es estadísticamente significativo y que el modelo es útil para predecir la variable dependiente, siento en este caso y.

- d) Dado que el contenido molar y la temperatura de calcinación permanece en el modelo, ¿el predictor de interacción  $x_3$  proporciona información útil sobre y? Enuncie y pruebe las hipótesis apropiadas usando un nivel de significancia de .01.

Recordando

---

Hipotesis nula:  $H_0 : \beta_i = 0$

$$\begin{array}{ll} \text{Hipotesis alternativa} & \text{Region de rechazo} \\ H_a : \beta_i \neq 0 & |t| \geq t_{\frac{\alpha}{2}, n-(k+1)} \end{array}$$


---

Observando la tabla dada que nos da el enunciado tenemos que

$$t = 3.496$$

Considerando la significancia de 0.01 se tiene que

$$t_{\frac{\alpha}{2}, n-(k+1)} = 2.898231$$

Teniendo así que

$$3.496 > 2.898231$$

Implicando que la hipótesis nula se rechaza, es decir, el predictor de interacción  $x_3$  proporciona información útil sobre y.

- e) La desviación estándar estimada de  $\hat{Y}$  cuando el contenido molar es 2.0 y la temperatura de calcinación es 500 es  $S_{\hat{y}} = 4.69$  Calcule un intervalo de confianza del 95 % para el valor medio del área superficial en estas circunstancias.

Recordemos que el intervalo de confianza para el valor medio viene dado por

$$\hat{y} \pm t_{\frac{\alpha}{2}, n-k-1} S_{\hat{y}}$$

Donde el inciso nos pide que el intervalo de confianza del 95 % donde  $x_1 = 2.0$ ,  $x_2 = 500$  y  $S_{\hat{y}} = 4.69$  del cual se sigue que

$$\begin{aligned} \hat{y} &= 185.48574 - 45.969466x_1 - 0.301503x_2 + 0.088801x_1x_2 \\ &= 185.48574 - 45.969466(2.0) - 0.301503(500) + 0.088801(1000) \\ &= 31.596308 \end{aligned}$$

Asi utilizando  $R$  tenemos que el intervalo de confianza es

$$[21.65395, 41.53866]$$

El código utilizado para calcular el intervalo es


```
yg <- 31.596308
alfa <- 0.05
n <- 20
k <- 3
t <- qt(1-(alfa)/2, n-k-1)
S <- 4.69
```

```
I <- yg - t*S
D <- yg + t*S
```

```
cat("El intervalo de confianza es","[",I,"",D,""]", "\n")
```

- f) Con base en gráficos de diagnóstico apropiados, ¿hay alguna razón para cuestionar el modelo de regresión de suposiciones?

Observando la siguiente gráfica



No existe una razón para cuestionar el modelo de regresión dado que al graficar los residuos estandarizados observamos que sus valores sí siguen una distribución normal.

El código utilizado para obtener la gráfica fue

```
X1<-c(.6,.6,.6,.6,.6,1.0,1.0,1.0,1.0,1.0,2.6,2.6,2.6,2.6,2.6,2.8,2.8,2.8,2.8,2.8)
X2<-c(200,250,400,500,600,200,250,400,500,600,200,250,400,500,600,200,250,400,500,600)
Y<-c(90.6,82.7,58.7,43.2,25.0,127.1,112.3,19.6,17.8,9.1,53.1,52.0,43.4,42.4,31.5,112.3,112.3,112.3,112.3,112.3)
X12 <- X1*X2
```

```

n<-length(x1)

datos <- data.frame(X1,X2,X12,Y)

modelo <- lm(Y ~ X1+X2+X12, datos)
summary(modelo)

residuos<-rstandard(modelo)
qqnorm(residuos)
qqline(residuos)

```

85. El artículo "*The Undrained Strength of Some Thawed Permafrost Soils*" (*Canad. Geotech. J.*, 1979: 420–427) contiene los siguientes datos sobre la resistencia al corte no drenado del suelo arenoso, ( $y$  en kPa), profundidad ( $x_1$ , en m) y el contenido de agua ( $x_2$ , in %)



| Obs | $y$  | $x_1$ | $x_2$ | $\hat{y}$ | $y - \hat{y}$ | $e^*$ |
|-----|------|-------|-------|-----------|---------------|-------|
| 1   | 14.7 | 8.9   | 31.5  | 23.35     | -8.65         | -1.50 |
| 2   | 48.0 | 36.6  | 27.0  | 46.38     | 1.62          | .54   |
| 3   | 25.6 | 36.8  | 25.9  | 27.13     | -1.53         | -.53  |
| 4   | 10.0 | 6.1   | 39.1  | 10.99     | -.99          | -.17  |
| 5   | 16.0 | 6.9   | 39.2  | 14.10     | 1.90          | .33   |
| 6   | 16.8 | 6.9   | 38.3  | 16.54     | .26           | .04   |
| 7   | 20.7 | 7.3   | 33.9  | 23.34     | -2.64         | -.42  |
| 8   | 38.8 | 8.4   | 33.8  | 25.43     | 13.37         | 2.17  |
| 9   | 16.9 | 6.5   | 27.9  | 15.63     | 1.27          | .23   |
| 10  | 27.0 | 8.0   | 33.1  | 24.29     | 2.71          | .44   |
| 11  | 16.0 | 4.5   | 26.3  | 15.36     | .64           | .20   |
| 12  | 24.9 | 9.9   | 37.8  | 29.61     | -4.71         | -.91  |
| 13  | 7.3  | 2.9   | 34.6  | 15.38     | -8.08         | -1.53 |
| 14  | 12.8 | 2.0   | 36.4  | 7.96      | 4.84          | 1.02  |


Los valores predichos y residuales fueron calculados por un modelo de regresión cuadrática, el cual resultó en la estimación de la siguiente función de regresión

$$y = -151.36 - 16.22x_1 + 13.48x_2 + 0.094x_1^2 - 0.253x_2^2 + 0.492x_1x_2$$

- (a) Realice los gráficos de  $e^*$  contra  $x_1$ ,  $e^*$  contra  $x_2$  y  $e^*$  contra  $\hat{y}$  ¿Sugiere que el modelo cuadrático completo debería ser modificado? Explique su respuesta.

Grafico de  $e^*$  contra  $x_1$

Grafico de  $e^*$  contra  $x_2$ Grafico de  $e^*$  contra  $\hat{y}$



No, dado que al realizar los residuos contra los demás podemos observar que la mayoría de los valores se encuentran cercanos al eje  $x$  lo que implica que es un buen modelo.

El código para hacer las graficas fue

```
x1 <- c(8.9, 36.6, 36.8, 6.1, 6.9, 6.9, 7.3, 8.4, 6.5, 8.0, 4.5, 9.9, 2.9, 2.0)
x2 <- c(31.5, 27.0, 25.9, 39.1, 39.2, 38.3, 33.9, 33.8, 27.9, 33.1, 26.3, 37.8,
yg <- c(23.35, 46.38, 27.13, 10.99, 14.10, 16.54, 23.34, 25.43, 15.63, 24.29, 1
ea <- c(-1.50, .54, -.53, -.17, .33, .04, -.42, 2.17, .23, .44, .20, -.91, -1.5
```

```
### Grafica de Residuos ###
```

```
#x1 contra e*#
```

```
xseq=seq(-300,300,0.01)
```

```
yseq = xseq - xseq
```

```
plot(x1, ea, main='Grafica de  $e^*$  contra x_1', xlab = 'x_1', ylab= 'e*', col =
```

```
)
```

```
lines(xseq, yseq)
```

```
#x2 contra e*#
```

```
plot(x2, ea, main='Grafica de  $e^*$  contra x_2', xlab = 'x_2', ylab= 'e*', col =
```

```
)
```

```
lines(xseq, yseq)
```

```
#y gorro contra e*#
```

```
plot(yg, ea, main='Grafica de  $e^*$  contra y gorrito', xlab = 'yg', ylab= 'e*', c
```

```
)
```

```
lines(xseq, yseq)
```

```
qqnorm(ea)
```

```
qqline(ea)
```

- (b) El valor de  $R^2$  para el modelo completo es 0.759. Pruebe el nivel .05 para la hipótesis nula declarando que no hay una relación lineal entre la variable dependiente y cualquiera de los 5 predictores.

Recordemos lo siguiente

Hipotesis nula:  $H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$

Hipotesis alternativa:  $H_a : \text{al menos uno } \beta_i \neq 0 \quad (i = 1, \dots, k)$

Valor de la estadística de prueba:

$$f = \frac{R^2/k}{(1 - R^2)/[n - (k + 1)]} = \frac{SSR/k}{SSE/[n - (k + 1)]} = \frac{MSR}{MSE}$$

donde  $SSR = SST - SSE$

Región de rechazo para una prueba de nivel  $\alpha$ :  $f \geq F_{\alpha, k, n - (k + 1)}$

Por un lado tenemos que

$$f = \frac{R^2/k}{(1 - R^2)/[n - (k + 1)]} = \frac{0.759/5}{(1 - 0.759)/[14 - (5 + 1)]} = 5.03900$$

Y por otro lado usando  $R$  considerando el nivel de significancia de 0.05 tenemos

$$F_{\alpha, k, n - (k + 1)} = 3.687499$$

Del cual tenemos que

$$5.03900 > 3.687499$$

Lo cual significa que se rechaza  $H_0$ , por lo tanto, existe una relación útil utilizando significativa en el nivel .05. Existiendo una relación lineal entre la variable dependiente y cualquiera de los 5 predictivos.

- (c) Cada uno de las hipótesis nula  $H_0 : \beta_i = 0$ , contra  $H_a : \beta_i \neq 0$ ,  $i = 1, 2, 3, 4, 5$  la cual no es rechazada en el nivel de 5%. ¿Tiene sentido en vista del resultado en (b)? Explique.

Usando  $R$  obtenemos la regresión lineal, el cual nos regresa

Coefficients:

|             | Estimate   | Std. Error | t value | Pr(> t ) |
|-------------|------------|------------|---------|----------|
| (Intercept) | -151.35551 | 134.06915  | -1.129  | 0.2916   |
| X1          | -16.21614  | 8.83147    | -1.836  | 0.1037   |
| X2          | 13.47558   | 8.18686    | 1.646   | 0.1384   |
| X11         | 0.09353    | 0.07093    | 1.319   | 0.2238   |
| X22         | -0.25282   | 0.12706    | -1.990  | 0.0818 . |
| X12         | 0.49224    | 0.22813    | 2.158   | 0.0630 . |
| ---         |            |            |         |          |

Del cual apartir del  $P$  – valor podemos observar que es cierto que algunos no se rechazan en el nivel del 5 %, con esto podemos decir que si tiene sentido el resultado del inciso anterior.

Dado que cuando trabajamos las hipotesis individuales podemos decir que cuando no se rechaza la hipotesis nula implica que se puede eliminar solo este predictor, mientras que cuando hacemos la eficacia del modelo vemos que al menos un predictor tenga ralización con la variable dependiente.

- (d) Se mostró en la Sección 12.8 que  $V(Y) = \sigma^2 = V(\hat{Y}) + V(Y - \hat{Y})$ . El estimador de  $\sigma$  es  $\hat{\sigma} = s = 6.99$  (para el modelo cuadrático completo). Primero obtenga la desviación estándar de  $Y - \hat{Y}$ , y después estime la desviación estándar de  $\hat{Y}$  (i.e.,  $\hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_1^2 + \hat{\beta}_4 x_2^2 + \hat{\beta}_5 x_1 x_2$  cuando  $x_1 = 8$  y  $x_2 = 33.1$ ). Finalmente, calcule el intervalo de confianza del 95 % para la media de la fuerza [Hint: ¿Qué es  $(y - \hat{y})/e^*$ ?]

Primero obtengamos la desviación estándar de  $Y - \hat{Y}$  cuando  $x_1 = 8$  y  $x_2 = 33.1$ .

Del cual recordemos que  $Var(Y_i - \hat{Y}_i) = S^2[1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{S_{xx}}]$  donde la desviación estándar de los residuos viene dado por la raíz de la ecuación anterior y la ecuación de los residuos estandarizados viene dada por  $e_i^* = \frac{y_i - \hat{y}_i}{s\sqrt{1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{S_{xx}}}}$

Del cual haciendo uso del hint notemos que la desviación estándar del valor predicho es el residual dividido por el residual estandarizado, de esta manera

$$\frac{27 - 24.29}{0.44} = \frac{2.71}{0.44} = 6.15909$$

Así la desviación estándar de  $Y - \hat{Y}$  cuando  $x_1 = 8$  y  $x_2 = 33.1$  es 6.15909

Posteriormente obtengamos la desviación estándar de  $\hat{Y}$  cuando  $x_1 = 8$  y  $x_2 = 33.1$ .

Partiendo de  $\hat{\sigma} = 6.99$  y de que  $V(Y) = \sigma^2 = V(\hat{Y}) + V(Y - \hat{Y})$  tenemos que  $S = \sqrt{V(\hat{Y}) + V(Y - \hat{Y})}$ , es decir

$$6.99 = \sqrt{V(\hat{Y}) + (6.15909)^2} \Leftrightarrow (6.99)^2 - (6.15909)^2 = V(\hat{Y})$$

$$V(\hat{Y}) = 10.92571 \Leftrightarrow S_{\hat{Y}} = 3.30540$$

Así la desviación estándar de  $\hat{Y}$  cuando  $x_1 = 8$  y  $x_2 = 33.1$  es 3.30540

Finalmente obtengamos el intervalo de confianza del 95 % para la media de la fuerza.

Recordemos que el intervalo de confianza para el valor medio viene dado por

$$\hat{y} \pm t_{\frac{\alpha}{2}, n-k-1} S_{\hat{y}}$$

Dado que nos pide que el intervalo de confianza del 95 % donde  $x_1 = 8$ ,  $x_2 = 33.1$  y  $S_{\hat{y}} = 3.30540$  del cual se sigue que

$$[16.66773, 31.91227]$$

El código con el que se obtuvo el intervalo fue

```

yg <- 24.29
Sy <- 3.30540
n <- 14
k <- 5
alpha <- 0.05
t <- qt(1-(alpha/2), n-(k+1))

```

```

I <- yg - t*Sy
D <- yg + t*Sy

```

```
cat("El intervalo de confianza es=", "[", I, ", ", D, "]", "\n")
```

- (e) En ciertas ocasiones un investigador quiere decidir si un grupo de  $m$  predictores ( $m < 1$ ) puede ser eliminado simultáneamente del modelo. La hipótesis nula dice que todos los  $\beta$ 's asociados con la interpretación de que los  $m$  predictores son 0, lo cual es interpretado en la media tanto como  $k - m$  predictores estén retenidos en el modelo, los  $m$  predictores bajo consideración colectivamente provee información inútil sobre  $y$ . Entonces la prueba es llevada a cabo por el modelo completo, con todos los  $k$  predictores para obtener  $SSE(\text{completo})$  y después el modelo de regresión "reducido" consiste solo en los  $k - m$  predictores no siendo considerados para la eliminación de la obtención de  $SSE(\text{rojo})$ . La prueba del estadístico es

$$F = \frac{[SSE(\text{rojo}) - SSE(\text{completo})]/m}{SSE(\text{completo})/[n - (k + 1)]}$$

La prueba es la cola superior y basada en el numerador  $m$  df y  $n - (k + 1)$ . El modelo de regresión de primer orden con los predictores  $x_1$  y  $x_2$  resulta en  $SSE = 894.5$ . Enuncie y pruebe al nivel de significación .05 el valor nulo hipótesis de que ninguno de los tres de segundo orden predictores (una interacción y dos cuadráticas) predictores) proporciona información útil sobre  $y$  siempre que los dos predictores de primer orden se mantienen en el modelo.

Tenemos que  $SSE(\text{completo}) = s^2(n - (k + 1))$  donde  $s^2 = \frac{SSE(\text{rojo})}{n - (k + 1)}$  entonces

$$s = \sqrt{\frac{SSE}{n - (k + 1)}} \Rightarrow SSE(\text{completo}) = s^2(n - (k + 1)) = 6.99^2(14 - 6) = 390.8808$$

Entonces

$$F = \frac{[SSE(\text{rojo}) - SSE(\text{completo})]/m}{SSE(\text{completo})/[n - (k + 1)]} = \frac{(894.95 - 390.8808)/(5 - 2)}{390.8808/(14 - (6))} = 3.43886$$

Y por otro lado usando  $R$  considerando el nivel de significancia de 0.05 tenemos

$$F_{\alpha, k, n - (k + 1)} = 3.687499$$

Del cual tenemos que

$$3.43886 < 3.687499$$

Lo cual significa que no se rechaza  $H_0$  lo que implica que los términos cuadráticos pueden ser borrado.

El código utilizado fue

```
alfa <- 0.05
k <- 5
n <- 14

f <- qf(1-alfa, k, n-(k+1))
```

91 Ajuste el modelo  $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$  para los datos

| $x_1$ | $x_2$ | $y$ |
|-------|-------|-----|
| -1    | -1    | 1   |
| -1    | 1     | 1   |
| 1     | -1    | 0   |
| 1     | 1     | 4   |

a) Determine  $X$  y  $y$  y exprese las ecuaciones normales en términos de matrices.

Recordemos lo siguiente

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \quad b = \begin{pmatrix} b_0 \\ b_1 \\ \vdots \\ b_k \end{pmatrix} \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix} \quad \varepsilon = \begin{pmatrix} \varepsilon_0 \\ \varepsilon_1 \\ \vdots \\ \varepsilon_k \end{pmatrix} \quad X = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1k} \\ 1 & x_{21} & x_{22} & \cdots & x_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{nk} \end{pmatrix}$$

Donde trabajando con el modelo  $y = X\beta + \varepsilon$  el sistema de ecuaciones a resolver es  $X^T y = X^T X b$  del cual

$$X^T X b = \begin{pmatrix} \sum_{i=1}^n 1 & \sum_{i=1}^n x_{i1} & \cdots & \sum_{i=1}^n x_{ik} \\ \sum_{i=1}^n x_{i1} & \sum_{i=1}^n x_{i1}x_{i1} & \cdots & \sum_{i=1}^n x_{i1}x_{ik} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n x_{ik} & \sum_{i=1}^n x_{ik} & \cdots & \sum_{i=1}^n x_{ik}x_{ik} \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n x_{i1}y_i \\ \vdots \\ \sum_{i=1}^n x_{ik}y_i \end{pmatrix}$$

de manera análoga el estimador  $\hat{\beta} = b = [X^T X]^{-1} X^T y$  si existe la inversa de  $X^T X$  además  $\hat{y} = X\hat{\beta}$

Con lo anterior en mente tenemos que

$$X = \begin{pmatrix} 1 & -1 & -1 \\ 1 & -1 & 1 \\ 1 & 1 & -1 \\ 1 & 1 & 1 \end{pmatrix} \quad y = \begin{pmatrix} 1 \\ 1 \\ 0 \\ 4 \end{pmatrix}$$

La ecuación normales es

$$X^T X b = X^T y \Leftrightarrow \begin{pmatrix} 1 & 1 & 1 & 1 \\ -1 & -1 & 1 & 1 \\ -1 & 1 & -1 & 1 \end{pmatrix} \begin{pmatrix} 1 & -1 & -1 \\ 1 & -1 & 1 \\ 1 & 1 & -1 \\ 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} b_0 \\ b_1 \\ b_2 \end{pmatrix} = \begin{pmatrix} 1 & 1 & 1 & 1 \\ -1 & -1 & 1 & 1 \\ -1 & 1 & -1 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 0 \\ 4 \end{pmatrix} \Leftrightarrow$$

$$\begin{pmatrix} 4 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 4 \end{pmatrix} \begin{pmatrix} b_0 \\ b_1 \\ b_2 \end{pmatrix} = \begin{pmatrix} 6 \\ 2 \\ 4 \end{pmatrix}$$

b) Determine el vector  $\hat{\beta}$ , que contiene las estimaciones de los tres coeficientes del modelo.

Tenemos

$$\begin{aligned} \hat{\beta} = b = [X^T X]^{-1} X^T y &= \left[ \begin{pmatrix} 1 & 1 & 1 & 1 \\ -1 & -1 & 1 & 1 \\ -1 & 1 & -1 & 1 \end{pmatrix} \begin{pmatrix} 1 & -1 & -1 \\ 1 & -1 & 1 \\ 1 & 1 & -1 \\ 1 & 1 & 1 \end{pmatrix} \right]^{-1} \begin{pmatrix} 1 & 1 & 1 & 1 \\ -1 & -1 & 1 & 1 \\ -1 & 1 & -1 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 0 \\ 4 \end{pmatrix} \\ &= \begin{pmatrix} \frac{1}{4} & 0 & 0 \\ 0 & \frac{1}{4} & 0 \\ 0 & 0 & \frac{1}{4} \end{pmatrix} \begin{pmatrix} 6 \\ 2 \\ 4 \end{pmatrix} \\ &= \begin{pmatrix} 1.5 \\ 0.5 \\ 1 \end{pmatrix} \end{aligned}$$

c) Determine  $\hat{y}$ , las predicciones para las cuatro observaciones y también los cuatro residuales. Encuentre  $SSE$  sumando los cuatro residuos al cuadrado. Use esto para obtener la varianza estimada  $MSE$ .

Determinemos a

$$\hat{y} = X\hat{B} = \begin{pmatrix} 1 & -1 & -1 \\ 1 & -1 & 1 \\ 1 & 1 & -1 \\ 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1.5 \\ 0.5 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 2 \\ 1 \\ 3 \end{pmatrix}$$

Ahora calculemos los 4 residuales así

$$y - \hat{y} = \begin{pmatrix} 1 \\ 1 \\ 0 \\ 4 \end{pmatrix} - \begin{pmatrix} 0 \\ 2 \\ 1 \\ 3 \end{pmatrix} = \begin{pmatrix} 1 \\ -1 \\ -1 \\ 1 \end{pmatrix}$$

Ahora calculemos a  $SSE$  así

$$SSE = ||y - \hat{y}||^2 = (1)^2 + (-1)^2 + (-1)^2 + (1)^2 = 4$$

Por otro lado recordemos que  $MSE = S^2$  de esta manera

$$MSE = \frac{SSE}{n - (k + 1)} = \frac{4}{4 - (2 + 1)} = \frac{4}{1} = 4$$

d) Utilice  $MSE$  y  $c_{11}$  para obtener un intervalo de confianza de 95 % para  $\beta_1$ .

Recordemos que el  $100(1 - \alpha)\%$  intervalo de confianza para  $\beta_i$  es

$$\beta_i \pm t_{\frac{\alpha}{2}, n-(k+1)} S_{\hat{\beta}_i}$$

Donde  $S_{\hat{\beta}_i} = S\sqrt{C_{ii}}$  del cual  $C = [X^T X]^{-1}$

De esta manera tenemos que

$$C = \begin{pmatrix} \frac{1}{4} & 0 & 0 \\ 0 & \frac{1}{4} & 0 \\ 0 & 0 & \frac{1}{4} \end{pmatrix} \Rightarrow C_{11} = \frac{1}{4} \Rightarrow \sqrt{C_{11}} = \frac{1}{2} \quad S = \sqrt{MSE} = \sqrt{4} = 2 \quad \beta_1 = 0.5$$

Se sigue

$$S_{\hat{\beta}_1} = 2 \cdot \frac{1}{2} = 1$$

Así utilizando  $R$  tenemos que el intervalo de confianza es

$$[-12.2062, 13.2062]$$

El código con el que se obtuvo el intervalo fue

```
B1 <- 0.5
sc <- 1
n <- 4
k <- 2
alpha <- 0.05
t <- qt(1-(alpha/2), n-(k+1))

I <- B1 - t*sc
D <- B1 + t*sc

cat("El intervalo de confianza es=", "[", I, ", ", D, "]" , "\n")
```

- e) Realice una prueba  $t$  para la hipótesis  $H_0 : \beta_1 = 0$  contra la alternativa de *dos – colas* e interprete el resultado.

Recordemos lo siguiente

Hipotesis nula:  $H_0 : \beta_i = 0$

Valor de la estadística de prueba:

$$T = \frac{\hat{\beta}_i}{S_{\hat{\beta}_i}}$$

| Hipotesis alternativa  | Region de rechazo para una prueba de nivel $\alpha$ |
|------------------------|-----------------------------------------------------|
| $H_a : \beta_1 \geq 0$ | $T \geq t_{\alpha, n-(k+1)}$                        |
| $H_a : \beta_1 \leq 0$ | $T \leq -t_{\alpha, n-(k+1)}$                       |
| $H_a : \beta_1 \neq 0$ | $ T  \geq t_{\frac{\alpha}{2}, n-(k+1)}$            |

Con lo anterior obtengamos el intervalo de confianza cuando  $H_a : \beta \neq 0$  de esta manera consideremos el intervalo de confianza del 95 % del cual tenemos que

$$T = \frac{0.5}{1} = 0.5 \quad t_{\frac{\alpha}{2}, n-(k+1)} = 12.7062$$

Del cual se sigue que

$$|T| < t_{\frac{\alpha}{2}, n-(k+1)}$$

Lo cual significa que no se rechaza  $H_0$  con el 0.05 nivel, lo que implica que  $x_1$  no es un valor significativo.

- f) Forme la tabla de análisis de varianza y realice la prueba F para la hipótesis  $H_0 : \beta_1 = \beta_2 = 0$ . Encuentra  $R^2$  e interpreta.

Recordemos la prueba  $F$

Hipotesis nula:  $H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$

Hipotesis alternativa:  $H_a : \text{al menos uno } \beta_i \neq 0 \quad (i = 1, \dots, k)$

Valor de la estadística de prueba:

$$f = \frac{R^2/k}{(1-R^2)/[n-(k+1)]} = \frac{SSR/k}{SSE/[n-(k+1)]} = \frac{MSR}{MSE}$$

donde  $SSR = SST - SSE$

Región de rechazo para una prueba de nivel  $\alpha$ :  $f \geq F_{\alpha, k, n-(k+1)}$

De manera análoga recordemos que la tabla ANOVA viene dada por

| Source    | Suma de Cuadrados(SS) | Grados de Libertad | Media de Cuadrados(MS)      | F-razon               |
|-----------|-----------------------|--------------------|-----------------------------|-----------------------|
| Regresion | SS(T)                 | m-1                | $MS(T) = \frac{SS(T)}{m-1}$ | $\frac{MS(T)}{MS(E)}$ |
| Error     | SS(E)                 | n-m                | $MS(E) = \frac{SS(E)}{n-m}$ |                       |
| Total     | SS(TO)                | n-1                |                             |                       |

Del cual observemos que nos hace falta calcular  $SST$ ,  $SS(TO)$  y  $MST$  de esta manera tenemos que  $\bar{y} = 1.5$  así

$$y - \bar{y} = \begin{pmatrix} 1 \\ 1 \\ 0 \\ 4 \end{pmatrix} - \begin{pmatrix} 1.5 \\ 1.5 \\ 1.5 \\ 1.5 \end{pmatrix} = \begin{pmatrix} -0.5 \\ -0.5 \\ -1.5 \\ 2.5 \end{pmatrix} \Rightarrow SST = \|y - \bar{y}\|^2 = (-0.5)^2 + (-0.5)^2 + (-1.5)^2 + (2.25)^2 =$$

De esta manera nuestra tabla ANOVA es

| Source    | SS | Grados de Libertad | Media de Cuadrados(MS) | F-razon |
|-----------|----|--------------------|------------------------|---------|
| Regresion | 5  | 2                  | 2.5                    | 0.625   |
| Error     | 4  | 1                  | 4.0                    |         |
| Total     | 9  | 3                  |                        |         |

Del cual tenemos que

$$f = 0.625$$

Por otro lado usando  $R$  tenemos que

$$F_{a,k,n-(k+1)} = 199.5$$

De lo que se sigue que

$$f < F_{a,k,n-(k+1)}$$

Es decir, no se rechaza la región en el nivel de 0.05 lo que implica que no existe una relación significativa.

Por otro lado tenemos que

$$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{4}{5} = 0.2$$

Del cual vemos que el valor de  $R^2$  se encuentra mas cercano a cero, lo que podemos decir que no es un buen modelo.

- 93 Supongamos que el modelo consta de solo  $Y = \beta_0 + \varepsilon$  entonces  $k = 0$ . Estime  $\beta_0$  a partir de  $[X^T X]^{-1} X^T y$ . Encuentre expresiones simples para  $s$  y  $c_{00}$ , y utilícelas junto con la Ecuación (12.25) para expresar simplemente el intervalo de confianza de 95 % para  $\beta_0$ . Su resultado debe ser equivalente al intervalo de confianza  $t$  de una muestra en la Sección 8.3.

Recordemos lo siguiente

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \quad b = \begin{pmatrix} b_0 \\ b_1 \\ \vdots \\ b_k \end{pmatrix} \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix} \quad \varepsilon = \begin{pmatrix} \varepsilon_0 \\ \varepsilon_1 \\ \vdots \\ \varepsilon_k \end{pmatrix} \quad X = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1k} \\ 1 & x_{21} & x_{22} & \cdots & x_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{nk} \end{pmatrix}$$

Donde trabajando con el modelo  $y = X\beta + \varepsilon$  el sistema de ecuaciones a resolver es  $X^T y = X^T X b$  del cual

$$X^T X b = \begin{pmatrix} \sum_{i=1}^n 1 & \sum_{i=1}^n x_{i1} & \cdots & \sum_{i=1}^n x_{ik} \\ \sum_{i=1}^n x_{i1} & \sum_{i=1}^n x_{i1}x_{i1} & \cdots & \sum_{i=1}^n x_{i1}x_{ik} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n x_{ik} & \sum_{i=1}^n x_{ik} & \cdots & \sum_{i=1}^n x_{ik}x_{ik} \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n x_{i1}y_i \\ \vdots \\ \sum_{i=1}^n x_{ik}y_i \end{pmatrix}$$

de manera análoga el estimador  $\hat{\beta} = b = [X^T X]^{-1} X^T y$  si existe la inversa de  $X^T X$  además  $\hat{y} = X\hat{\beta}$

Dado que  $k = 0$  se sigue que

$$\hat{\beta} = (\hat{\beta}_0) \quad \epsilon = (\epsilon_0) \quad X = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix}$$

Entonces

$$\begin{aligned} \beta_0 &= [X^T X]^{-1} X^T y = [|X|^2]^{-1} (1 \ 1 \ \dots \ 1) \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \\ &= [n]^{-1} \left( \sum_{i=1}^n y_i \right) \\ &= \left[ \frac{\sum_{i=1}^n y_i}{n} \right] \\ &= \bar{y} \end{aligned}$$

De esta manera tenemos que  $B_0 = \bar{y}$ , ahora encontremos las expresiones simples de  $S$  y  $c_{00}$  del cual recordemos que  $S^2 = \frac{SSE}{n-(k+1)}$  donde  $SSE = \|y - \hat{y}\|^2$  y tenemos que  $C = [X^T X]^{-1}$  así con lo calculado anteriormente tenemos que

$$C_{00} = \frac{1}{n}$$

Ahora calculemos  $SSE$  así

$$\hat{y} = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} \cdot \bar{y} = \begin{pmatrix} \bar{y} \\ \bar{y} \\ \vdots \\ \bar{y} \end{pmatrix} \Rightarrow SSE = \left\| \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} - \begin{pmatrix} \bar{y} \\ \bar{y} \\ \vdots \\ \bar{y} \end{pmatrix} \right\|^2 = \sum_{i=1}^n (y_i - \bar{y})^2$$

De esta manera tenemos que

$$S^2 = \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - (0 + 1)} = \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - 1} \Rightarrow S = \sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - 1}}$$

Finalmente usemos la ecuación (12.25) para expresar simplemente el intervalo de confianza de 95 % para  $\beta_0$ .

Ecuación 12.25

$$\beta_i \pm t_{\frac{\alpha}{2}, n-(k+1)} S_{\hat{\beta}_i}$$

Donde  $S_{\hat{\beta}_i} = S\sqrt{C_{ii}}$

De esta manera sustituyendo los valores obtenidos tenemos

$$\bar{y} \pm t_{\frac{0.05}{2}, n-(0+1)} \frac{S}{\sqrt{n}} \Leftrightarrow \bar{y} \pm t_{0.25, n-1} \sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n(n-1)}}$$

- 103 Las medidas aquí son similares a las de *Ejemplo 12.36*, excepto que aquí los estudiantes tomaron las medidas en casa y los resultados sufrieron en precisión. Estas son medidas de una muestra de diez estudiantes:

| <i>Envergadura</i> | <i>Pie</i> | <i>Altura</i> |
|--------------------|------------|---------------|
| 74                 | 13.0       | 75            |
| 56                 | 8.5        | 66            |
| 65                 | 10.0       | 69            |
| 66                 | 9.5        | 66            |
| 62                 | 9.0        | 54            |
| 69                 | 11.0       | 72            |
| 75                 | 12.0       | 75            |
| 66                 | 9.0        | 63            |
| 66                 | 9.0        | 66            |
| 63                 | 8.5        | 63            |

- a) Regresión de la envergadura en las otras dos variables. Realice la prueba de utilidad del modelo y las pruebas para los dos coeficientes de regresión individuales de los predictores.

Primero recordemos lo siguiente

---

Hipotesis nula:  $H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$

Hipotesis alternativa:  $H_a : \text{al menos uno } \beta_i \neq 0 \quad (i = 1, \dots, k)$

Valor de la estadística de prueba:

$$f = \frac{R^2/k}{(1 - R^2)/[n - (k + 1)]} = \frac{SSR/k}{SSE/[n - (k + 1)]} = \frac{MSR}{MSE}$$

donde  $SSR = SST - SSE$

Región de rechazo para una prueba de nivel  $\alpha$ :  $f \geq F_{\alpha, k, n-(k+1)}$

---

De manera analoga

---

Hipotesis nula:  $H_0 : \beta_1 = 0$

|                              |                                  |
|------------------------------|----------------------------------|
| <i>Hipotesis alternativa</i> | <i>Región de rechazo</i>         |
| $H_a : \beta_1 \neq 0$       | $ t  \geq t_{\alpha/2, n-(k+1)}$ |

---

Haciendo uso de  $R$  obtenemos lo siguiente

Call:

```
lm(formula = Y ~ X1 + X2, data = datos)
```

Residuals:

|  | Min     | 1Q      | Median | 3Q     | Max    |
|--|---------|---------|--------|--------|--------|
|  | -5.5966 | -1.3249 | 0.3599 | 2.0979 | 2.8140 |

Coefficients:

|             | Estimate  | Std. Error | t value | Pr(> t ) |
|-------------|-----------|------------|---------|----------|
| (Intercept) | 35.003848 | 11.150624  | 3.139   | 0.0164 * |
| X1          | 3.178772  | 1.075599   | 2.955   | 0.0212 * |
| X2          | -0.006467 | 0.263898   | -0.025  | 0.9811   |

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3 on 7 degrees of freedom

Multiple R-squared: 0.7748, Adjusted R-squared: 0.7104

F-statistic: 12.04 on 2 and 7 DF, p-value: 0.005424

Del cual utilizando lo anterior veamos la prueba de utilidad del modelo consideran el nivel de significancia de 0.01 % tenemos que

$$f = 12.04 \quad F_{0.1,2,7} = 9.55 \quad \Rightarrow \quad f > F_{0.1,2,7}$$

Lo que significa que el modelo si es útil con significancia 0.01 % dado que se rechaza la hipótesis nula.

Ahora realicemos las pruebas de los dos coeficientes de la regresión, en ambos consideremos el nivel de significancia de 0.05 % de esta manera tenemos

- Considerando a  $H_0 : \beta_1 = 0$  y  $H_a : \beta_1 \neq 0$  observando lo obtenido con  $R$  se tiene que  $|t| = 2.96$  y por otro lado  $t_{0.25,7}$  lo cual implica que  $|t| > t_{0.25,7}$  así se rechaza la hipótesis nula, es decir, el predictor que tiene se le asigna al *pie* es necesario dado que tiene una relación con la variable dependiente.
- Considerando a  $H_0 : \beta_1 = 0$  y  $H_a : \beta_1 \neq 0$  observando lo obtenido con  $R$  se tiene que  $|t| = 0.02$  y por otro lado  $t_{0.25,7}$  lo cual implica que  $|t| < t_{0.25,7}$  así no se rechaza la hipótesis nula, es decir, el predictor que tiene se le asigna a la *altura* no es necesario..

El código utilizado para obtener la regresión fue

```
datos <- c(74,13.0,75,56,8.5,66,65,10.0,69,66,9.5,66,62,9.0,54,69,11.0,72,75,12.0)
intento <- matrix(datos, ncol=10, nrow=3)
buena <- t(intento)
```

```
X1 <- buena[,2]
```

```
X2 <- buena[,3]
```

```
Y <- buena[,1]
```

```
# Crear un data frame con los datos
```

```
datos <- data.frame(X1, X2, Y)
```

```
modelo <- lm(Y ~ X1+X2, datos)
summary(modelo)
```

- b) Obtenga los elementos diagonales de la matriz del sombrero (palancas). Identifique el punto con el mayor apalancamiento. ¿Qué tiene de inusual el punto? Dada la afirmación del instructor de que no había estudiantes en la clase que midieran menos de cinco pies, ¿diría que hubo un error? Da otra razón por la que las medidas de este estudiante parecen incorrectas.

Notemos que

$$X = \begin{pmatrix} 1 & 13.0 & 75 \\ 1 & 8.5 & 66 \\ 1 & 10.0 & 69 \\ 1 & 9.5 & 66 \\ 1 & 9.0 & 54 \\ 1 & 11.0 & 72 \\ 1 & 12.0 & 75 \\ 1 & 9.0 & 63 \\ 1 & 9.0 & 66 \\ 1 & 8.5 & 63 \end{pmatrix}$$

Con lo anterior en mente, recordemos lo siguiente los elementos diagonales de  $H$  a veces se denominan apalancamientos para indicar su influencia sobre la regresión.

Los apalancamientos fueron obtenidos usando  $R$  así tenemos la siguiente tabla

| Observaciones | Pie  | Altura | Envergadura | Apalancamiento |
|---------------|------|--------|-------------|----------------|
| 1             | 13.0 | 75     | 74          | 0.5549944      |
| 2             | 8.5  | 66     | 56          | 0.3106461      |
| 3             | 10.0 | 69     | 65          | 0.1291486      |
| 4             | 9.5  | 66     | 66          | 0.1118326      |
| 5             | 9.0  | 54     | 62          | 0.8845599      |
| 6             | 11.0 | 72     | 69          | 0.1723585      |
| 7             | 12.0 | 75     | 75          | 0.3087221      |
| 8             | 9.0  | 63     | 66          | 0.1464646      |
| 9             | 9.0  | 66     | 66          | 0.1790925      |
| 10            | 8.5  | 63     | 63          | 0.2021805      |

El punto con mayor apalancamiento es la observación 5 la cual tiene 0.88 de apalancamiento, así centrándonos en los datos de esta observación, se puede observar que el estudiante en cuestión presenta la estatura más baja de todos los estudiantes, a pesar de que su tamaño de pie es similar al de otros compañeros y de manera análoga su envergadura. Pero por tener un apalancamiento demasiado alto en comparación con los demás, se da la posibilidad de un error al obtener dichas medidas.

El código de  $R$  utilizado es

```
datos <- c(74, 13.0, 75, 56, 8.5, 66, 65, 10.0, 69, 66, 9.5, 66, 62, 9.0, 54, 69, 11.0, 72, 75, 12.0)
intento <- matrix(datos, ncol=10, nrow=3)
```

```

buena <- t(intento)

primera <- buena[,2]
segunda <- buena[,3]
n <- length(primera)

uno <-c()

for(i in 1:n){
    uno[i] = 1
}

X <- cbind(uno, primera, segunda)
Xt <-t(X)

H <- X %*%solve(Xt%*%X) %*%t(X)

L <-c()

for(i in 1:n){
    L[i] = H[i,i]
}

```

- c) Para los otros puntos con alto apalancamiento, ¿qué los distingue de los puntos con valores de apalancamiento ordinarios?

La observación 1 tiene un apalancamiento de 0.554999 lo cual analizando los datos de la observación tienen sentido dicho valor, debido a que tiene los parametros mas altos en todas las medidas que se realizaron.

La observacion 2 tiene apancamiento 0.3106461 lo cual analizando los datos de la observación tienen sentido dicho valor, debido a que tiene los parametros mas bajos en las medidas de pie y envergadura, pero en altura igual tiene un valor muy bajo comparado con los demas, cabe destacar que la envergadura con relacion a su altura si difieren bastante dado que dichos parametros deben tener valores muy similares.

La observacion 7 tiene apancamiento 0.3087 lo cual analizando los datos de la observación tienen sentido dicho valor, debido a que tiene parametros altos en todas medidas.

- d) Examinando los residuos, encuentre a otro estudiante cuyos datos puedan estar equivocados.

Usando *R* tenemos que

| <i>Observaciones</i> | <i>Residuos</i> |
|----------------------|-----------------|
| 1                    | -1.8428732      |
| 2                    | -5.5966009      |
| 3                    | -1.3453583      |
| 4                    | 1.2246272       |
| 5                    | -1.2635883      |
| 6                    | -0.5047298      |
| 7                    | 2.3358987       |
| 8                    | 2.7946128       |
| 9                    | 2.8140131       |
| 10                   | 1.3839987       |

La observación 2 tiene el residuo mayor a comparación de todos los demás, y esto puede ser debido a lo dicho en el inciso anterior dado que la envergadura y su altura tiene una diferencia de 10 pies y sabemos que la envergadura tiende a ser casi igual a la altura. Por lo tanto, este dato seguramente se encuentra equivocado.

El código utilizado para el obtener los residuos fue

```
datos <- c(74, 13.0, 75, 56, 8.5, 66, 65, 10.0, 69, 66, 9.5, 66, 62, 9.0, 54, 69, 11.0, 72, 75, 12.0)
intento <- matrix(datos, ncol=10, nrow=3)
buena <- t(intento)

primera <- buena[, 2]
segunda <- buena[, 3]
n <- length(primera)

uno <- c()

for(i in 1:n){
  uno[i] = 1
}

X <- cbind(uno, primera, segunda)
Xt <- t(X)

H <- X %*% solve(Xt %*% X) %*% Xt(X)

L <- c()

for(i in 1:n){
  L[i] = H[i, i]
}

y <- buena[, 1]
r <- y - H%*%y
```

e) Discutir la eliminación de puntos cuestionables para obtener resultados de regresión válidos.

Las observaciones cuestionables es la numero 5 por lo dicho en el inciso *b* y la observación numero 2 por lo dicho en el inciso anterior.

## Sección 9.1 Hogg

3. En el juego *Daily3* de la lotería de Michigan, dos veces al día se genera un entero de tres dígitos, uno a la vez. Sea  $p_i$  la probabilidad de generar el dígito  $i$ ,  $i = 0, 1, \dots, 9$ . Sea  $\alpha = 0.05$  y use los siguientes 50 dígitos para probar  $H_0 : p_0 = p_1 = \dots = p_9 = \frac{1}{10}$ .

|   |   |   |   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|---|---|---|
| 1 | 6 | 9 | 9 | 3 | 8 | 5 | 0 | 6 | 7 |
| 4 | 7 | 5 | 9 | 4 | 6 | 5 | 6 | 4 | 4 |
| 4 | 8 | 0 | 9 | 3 | 2 | 1 | 5 | 4 | 5 |
| 7 | 3 | 2 | 1 | 4 | 6 | 7 | 1 | 3 | 4 |
| 4 | 8 | 8 | 6 | 1 | 6 | 1 | 2 | 8 | 8 |

Recordemos lo siguiente

Sea

$$Q_{k-1} = \sum_{i=1}^k \frac{(Y_i - np_i)^2}{np_i}$$

Del cual  $Q_{k-1}$  es aproximadamente  $\chi^2(k-1)$ .

Consideremos la prueba de hipótesis  $H_0 : p_i = p_{i0}$ ,  $i = 1, \dots, k$  donde si  $H_0$  es verdadero, es decir,  $np_{i0}$  son aproximadamente iguales. Esto es

$$q_{k-1} = \sum_{i=1}^k \frac{(y_i - np_{i0})^2}{np_{i0}}$$

Donde dado que  $Q_{k-1}$  es aproximadamente  $\chi^2(k-1)$ , rechazaremos  $H_0$  si  $q_{k-1} \geq \chi_{\alpha}^2(k-1)$ , donde  $\alpha$  es el nivel de significancia deseado de la prueba.

La prueba de hipótesis del ejercicio es

$$H_0 : p_0 = p_{00} = p_1 = p_{10} = \dots = p_9 = p_{90} = \frac{1}{10}$$

Del cual  $n = 50$  debido que es a la cantidad de dígitos a probar, así observando dichos dígitos tenemos

que  $k = 10$  obteniendo la siguiente tabla

| Numero | Veces que se repite | $np_{i0}$                   |
|--------|---------------------|-----------------------------|
| 0      | 2                   | $50 \cdot \frac{1}{10} = 5$ |
| 1      | 6                   | 5                           |
| 2      | 3                   | 5                           |
| 3      | 4                   | 5                           |
| 4      | 9                   | 5                           |
| 5      | 5                   | 5                           |
| 6      | 7                   | 5                           |
| 7      | 4                   | 5                           |
| 8      | 6                   | 5                           |
| 9      | 4                   | 5                           |

Con lo anterior tenemos que

$$\begin{aligned}
 q_9 &= \frac{(2-5)^2}{5} + \frac{(6-5)^2}{5} + \frac{(3-5)^2}{5} + \frac{(4-5)^2}{5} + \frac{(9-5)^2}{5} \\
 &+ \frac{(5-5)^2}{5} + \frac{(7-5)^2}{5} + \frac{(4-5)^2}{5} + \frac{(6-5)^2}{5} + \frac{(4-5)^2}{5} \\
 &= 7.6
 \end{aligned}$$

Por otro lado usando  $R$

$$\chi^2_{0.05,9} = 16.91898$$

De esta manera

$$7.6 < 16.91898$$

Por lo tanto no se rechaza  $H_0$ , es decir, la manera en la que reparten su tiempo de las seis categorías si es de la misma manera.

El código utilizado fue

```

alfa <- 0.05
k <- 10
qchisq(1-alfa , k-1)

```

5. Sea  $X$  el número de niñas en una familia de tres hijos. Utilizaremos un estadístico de bondad de ajuste *chi – cuadrado* para probar la hipótesis nula de que la distribución de  $X$  es  $b(3,0.5)$ .

- a. Define el estadístico de prueba y la región crítica, utilizando un nivel de significancia  $\alpha = 0.05$ .

Recordemos lo siguiente

Sea

$$Q_{k-1} = \sum_{i=1}^k \frac{(Y_i - np_i)^2}{np_i}$$

Del cual  $Q_{k-1}$  es aproximadamente  $\chi^2(k-1)$ .

Consideremos la prueba de hipótesis  $H_0 : p_i = p_{i0}, i = 1, \dots, k$  donde si  $H_0$  es verdadero, es decir,  $np_{i0}$  son aproximadamente iguales. Esto es

$$q_{k-1} = \sum_{i=1}^k \frac{(y_i - np_{i0})^2}{np_{i0}}$$

Donde dado que  $Q_{k-1}$  es aproximadamente  $\chi^2(k-1)$ , rechazaremos  $H_0$  si  $q_{k-1} \geq \chi_{\alpha}^2(k-1)$ , donde  $\alpha$  es el nivel de significancia deseado de la prueba.

Entonces consideremos la siguiente prueba de hipotesis.

Hipotesis nula  $H_0 : p_i = p_{i0}, i = 1, \dots, k$ .

Hipotesis alternativa  $H_a : p_i \neq p_{i0}$  para al menos un  $i, i = 1, \dots, k$ .

Y por el recordemos sabemos que se rechaza  $H_0$  si  $q_{k-1} \geq \chi_{\alpha, k-1}^2$

De esta manera el estadístico de prueba es  $q_{k-1}$  y usando  $R$  para obtener la región crítica tenemos

$$\chi_{\alpha, k-1}^2 = 7.814728$$

Entonces

$$q_3 > 7.814728$$

El código de  $R$  utilizado fue

```
alfa <- 0.05
k <- 4
qchisq(1-alfa, k-1)
```

- b. Entre los estudiantes que estaban tomando estadística, 52 provenían de familias con tres hijos. Para estas familias,  $x = 0, 1, 2$  y  $3$  para 5, 17, 24 y 6 familias, respectivamente. Calcula el valor del estadístico de prueba y declara tu conclusión, considerando cómo se seleccionó la muestra.

Con lo anterior calculemos las probabilidades de cada  $x$  considerando que es una distribución binomial dada por  $b(3, 0.5)$  entonces tenemos que

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

Dado que el valor  $p = \frac{1}{2}$  este parámetro realiza una simetría entre los siguientes valores

$$\begin{aligned} p_{10} = p_{40} &= \binom{3}{0} \left(\frac{1}{2}\right)^0 \left(1 - \frac{1}{2}\right)^{3-0} = \binom{3}{3} \left(\frac{1}{2}\right)^3 \left(1 - \frac{1}{2}\right)^{3-3} = 0.125 \\ p_{20} = p_{30} &= \binom{3}{1} \left(\frac{1}{2}\right)^1 \left(1 - \frac{1}{2}\right)^{3-1} = \binom{3}{2} \left(\frac{1}{2}\right)^2 \left(1 - \frac{1}{2}\right)^{3-2} = 0.375 \end{aligned}$$

De lo anterior tenemos que

| $x$ | $y_i$ | $np_{i0}$               |
|-----|-------|-------------------------|
| 0   | 5     | $52 \cdot 0.125 = 6.5$  |
| 1   | 17    | $52 \cdot 0.375 = 19.5$ |
| 2   | 24    | $52 \cdot 0.375 = 19.5$ |
| 3   | 6     | $52 \cdot 0.125 = 6.5$  |

Obteniendo la siguiente tabla

$$q_3 = \frac{(5 - 6.5)^2}{6.5} + \frac{(17 - 19.5)^2}{19.5} + \frac{(24 - 19.5)^2}{19.5} + \frac{(6 - 6.5)^2}{6.5} = 1.74358$$

Así utilizando el inciso a notemos que

$$1.74358 < 7.814728$$

Es decir no se rechaza la hipótesis nula, esto significa que los datos respaldan la hipótesis de que  $b(3, 0.5)$  es un modelo probabilístico razonable para  $X$ .

9. Sea  $X$  la cantidad de grasa de mantequilla (en libras) producida por 90 vacas durante un período de producción de leche de 305 días después del nacimiento de su primer ternero. Prueba la hipótesis de que la distribución de  $X$  es  $N(\mu, \sigma^2)$ , usando  $k = 10$  clases de igual probabilidad. Puede tomar  $\bar{x} = 511.633$  y  $s_x = 87.576$  como estimaciones de  $\mu$  y  $\sigma$ , respectivamente. Los datos son los siguientes:

|     |     |     |     |     |     |     |     |     |     |
|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|
| 486 | 537 | 513 | 583 | 453 | 510 | 570 | 500 | 458 | 555 |
| 618 | 327 | 350 | 643 | 500 | 497 | 421 | 505 | 637 | 599 |
| 392 | 574 | 492 | 635 | 460 | 696 | 593 | 422 | 499 | 524 |
| 539 | 339 | 472 | 427 | 532 | 470 | 417 | 437 | 388 | 481 |
| 537 | 489 | 418 | 434 | 466 | 464 | 544 | 475 | 608 | 444 |
| 573 | 611 | 586 | 613 | 645 | 540 | 494 | 532 | 691 | 478 |
| 513 | 583 | 457 | 612 | 628 | 516 | 452 | 501 | 453 | 643 |
| 541 | 439 | 627 | 619 | 617 | 394 | 607 | 502 | 395 | 470 |
| 531 | 526 | 496 | 561 | 491 | 380 | 345 | 274 | 672 | 509 |

Recordemos

Usando la prueba de bondad *Chi – Cuadrada*

$$Q_{k-1} = \sum_{i=1}^k \frac{(Y_i - np_i)^2}{np_i}$$

Cuando se usan  $m$  estimadores, entonces  $Q_{k-1} \sim \chi_{k-1-m}^2$  del cual para la siguiente prueba de hipótesis tenemos

$$H'_0 : p_i = \bar{p}_{i0} \quad i = 1, \dots, k$$

Se rechaza  $H'_0$  si  $q_{k-1} \geq \chi^2_{\alpha}(k-1-m)$  a un nivel de significancia  $\alpha$ .

Donde

$$q_{k-1} = \sum_{j=1}^k \frac{(y_j - np_{i0})^2}{np_{i0}}$$

Dado que  $X$  es  $N(\mu, \sigma^2)$  tenemos que debemos de obtener los percentiles de la distribución normal, así recordando que para encontrar el valor  $z$  correspondiente al percentil  $k$ , necesitamos encontrar el valor  $z$  tal que la probabilidad acumulativa hasta ese valor  $z$  sea igual a  $k/100$ . Donde usando la función de distribución acumulativa de la distribución normal estándar para encontrar el valor correspondiente al percentil  $k$ , utilizando la fórmula:

Valor del percentil  $k = \text{media} + (\text{desviación estándar} \cdot \text{valor } z \text{ correspondiente al percentil } k)$

Dado que conocemos los estimadores de la media y desviación estándar tenemos que

$$x_i = 511.633 + 87.576 \cdot z_i$$

De esta manera usando  $R$  obtengamos los intervalos de las clases así realicemos la siguiente tabla

| Clases                        | Frecuencia | $p_{i0}$       | $n \cdot p_{i0}$ |
|-------------------------------|------------|----------------|------------------|
| $A_1 = (-\infty, 399.3998]$   | 10         | $\frac{1}{10}$ | 9                |
| $A_2 = (399.3998, 437.9272]$  | 7          | $\frac{1}{10}$ | 9                |
| $A_3 = (437.9272, 465.7081]$  | 9          | $\frac{1}{10}$ | 9                |
| $A_4 = (465.7081, 489.4459]$  | 9          | $\frac{1}{10}$ | 9                |
| $A_5 = (489.4459, 511.6330]$  | 13         | $\frac{1}{10}$ | 9                |
| $A_6 = (511.6330, 533.8201]$  | 8          | $\frac{1}{10}$ | 9                |
| $A_7 = (533.8201, 557.5579]$  | 7          | $\frac{1}{10}$ | 9                |
| $A_8 = (557.5579, 585.3388]$  | 6          | $\frac{1}{10}$ | 9                |
| $A_9 = (585.3388, 623.8662]$  | 11         | $\frac{1}{10}$ | 9                |
| $A_{10} = (623.8662, \infty)$ | 10         | $\frac{1}{10}$ | 9                |

Por otro lado dado que estamos usando los siguientes 2 estimadores  $\bar{x}$  y  $s_x$  tenemos que  $Q_{k-1} \sim \chi^2_{n-1-2}$  de esta manera consideremos la prueba

$$H'_0 : P_i = \hat{P}_{i0} \quad i = 1, \dots, k$$

Y por el recordatorio sabemos que se rechaza  $H'_0$  si  $q_{k-1} \geq \chi^2_{\alpha, k-3}$  a un nivel de significancia  $\alpha$ . Entonces

$$\begin{aligned} q_9 &= \frac{(10-9)^2}{9} + \frac{(7-9)^2}{9} + \frac{(9-9)^2}{9} + \frac{(9-9)^2}{9} + \frac{(13-9)^2}{9} \\ &+ \frac{(8-9)^2}{9} + \frac{(7-9)^2}{9} + \frac{(6-9)^2}{9} + \frac{(11-9)^2}{9} + \frac{(10-9)^2}{9} \\ &= 4.44444 \end{aligned}$$

Y de manera análoga usando  $R$  notemos que

$$\chi^2_{\alpha, k-3} = 14.06714$$

Lo que implica que

$$4.44444 < 14.06714$$

Por lo tanto no se rechaza  $H'_0$ , es decir, con solo estos datos estamos bastante dispuestos a aceptar que  $X$  tiene una distribución de Normal.

El código utilizado para obtener los datos anteriores fue

```
### Obtener los intervalos ###  
xb <- 511.633  
sx <- 87.576  
k <- 10  
qnorm(c(0:k)/k, 511.633, 87.576)  
  
## Obtener Chi-Cuadrada con significancia alfa ###  
alfa <- 0.05  
qchisq(1-alfa, k-3)
```

## Sección 9.2 Hogg

1. Deseamos ver si dos grupos de enfermeras se reparten su tiempo en seis categorías diferentes de la misma manera. Es decir, la hipótesis bajo consideración es  $H_0 : p_{i1} = p_{i2}, i = 1, 2, \dots, 6$ . Para probar esta hipótesis, las enfermeras han observado al azar a lo largo de varios días, cada observación resultó en una marca en una de las seis categorías. El resumen de los resultados viene dado por la siguiente tabla de frecuencia:

|          | Categoría |    |    |    |    |    | Total |
|----------|-----------|----|----|----|----|----|-------|
|          | 1         | 2  | 3  | 4  | 5  | 6  |       |
| Grupo I  | 95        | 36 | 71 | 21 | 45 | 32 | 300   |
| Grupo II | 53        | 26 | 43 | 18 | 32 | 28 | 200   |

Utilice una prueba de chi-cuadrada con  $\alpha = 0,05$ .

Recordemos

La prueba de homogeneidad

Consiste en ver si dos distribuciones multinomiales son iguales (homogéneas), siendo su prueba de hipótesis

$$H_0 : p_{i1} = p_{i2} \quad i = 1, \dots, k$$

Se rechaza  $H_0$  si  $q_{k-1} \geq \chi^2_{\alpha, (h-1)(k-1)}$

Del cual tenemos que con parámetros especificados y usando estimadores son:

$$Q_{k-1} = \sum_{j=1}^h \sum_{i=1}^k \frac{(y_{ij} - n_j p_{ij})^2}{n_j p_{ij}} \quad Q_{k-1} = \sum_{j=1}^h \sum_{i=1}^k \frac{(y_{ij} - n_j \hat{p}_i)^2}{n_j \hat{p}_i}$$

Donde al usar estimadores tenemos que

$$\hat{p}_i = \frac{\sum_{j=1}^h y_{ij}}{\sum_{j=1}^h n_j}$$

Dado que nos interesa ver si las 6 categorías diferentes reparten su tiempo de la misma manera se considera la hipótesis

$$H_0 : p_{i1} = p_{i2} \quad i = 1, \dots, 6$$

Donde se realizaron 2 grupos, de esta manera tenemos que  $h = 2$  con esto completamos la tabla de la siguiente manera

|          | 1   | 2  | 3   | 4  | 5  | 6  | Total |
|----------|-----|----|-----|----|----|----|-------|
| Grupo I  | 95  | 36 | 71  | 21 | 45 | 32 | 300   |
| Grupo II | 53  | 26 | 43  | 18 | 32 | 28 | 200   |
| Total    | 148 | 62 | 114 | 39 | 77 | 60 | 500   |

Por lo tanto, las estimaciones de  $n_1 p_{i1} = n_2 p_{i2}$  son

$$\begin{array}{lll} \frac{148 \cdot 300}{500} \approx 88.8 & \frac{148 \cdot 200}{500} \approx 59.2 & \frac{62 \cdot 300}{500} \approx 37.2 \\ \frac{62 \cdot 200}{500} \approx 24.8 & \frac{114 \cdot 300}{500} \approx 68.4 & \frac{114 \cdot 200}{500} \approx 45.6 \\ \frac{39 \cdot 300}{500} \approx 23.4 & \frac{39 \cdot 200}{500} \approx 15.6 & \frac{77 \cdot 300}{500} \approx 46.2 \\ \frac{77 \cdot 200}{500} \approx 30.8 & \frac{60 \cdot 300}{500} \approx 36.0 & \frac{60 \cdot 200}{500} \approx 24.0 \end{array}$$

Entonces

$$\begin{aligned} q &= \frac{(95 - 88.8)^2}{88.8} + \frac{(53 - 59.2)^2}{59.2} + \frac{(36 - 37.2)^2}{37.2} + \frac{(26 - 24.8)^2}{24.8} + \frac{(71 - 68.4)^2}{68.4} + \frac{(43 - 45.6)^2}{45.6} \\ &+ \frac{(21 - 23.4)^2}{23.4} + \frac{(18 - 15.6)^2}{15.6} + \frac{(45 - 46.2)^2}{46.2} + \frac{(32 - 30.8)^2}{30.8} + \frac{(32 - 36.0)^2}{36.0} + \frac{(28 - 24.0)^2}{24.0} \\ &= 3.230475 \end{aligned}$$

Por otro lado

$$\chi^2_{\alpha, (k-1)(h-1)} = \chi^2_{0.05, (2-1)(6-1)} = 11.0705$$

Entonces

$$3.230475 < 11.0705$$

Por lo tanto no se rechaza  $H_0$ , es decir, con estos datos no podemos decir que haya una diferencia entre los dos métodos grupos de enfermeras al momento de repartir su tiempo.

El código utilizado para obtener lo anterior fue

```
G1<-c(95 ,36 ,71 ,21 ,45 ,32)
G2<-c(53 ,26 ,43 ,18 ,32 ,28)
n<-length(G1)
k<- 6
h<- 2
T1<-c()

for(i in 1:n){
  T1[i] = G1[i] + G2[i]
}

Total <- sum(T1)

Glp<-c()
```

```

G2p<-c ()
for(j in 1:n){
  G1p[j]=(300*T1[j])/Total
  G2p[j]=(200*T1[j])/Total
}

c <-c ()

for(i in 1:n){
c[i]=( (G1[i]-G1p[i])^2/G1p[i] ) + ( (G2[i]-G2p[i])^2/G2p[i] )
}

sum(c)

### Considerar nivel de significancia de alfa ###
alfa <- 0.05
qchisq(1-alfa , (h-1)*(k-1))

```

3. Cada una de dos clases comparables de 15 estudiantes respondió a dos métodos diferentes de instrucciones, dando las siguientes puntuaciones en una prueba estandarizada:

|          |    |    |    |    |    |    |    |    |
|----------|----|----|----|----|----|----|----|----|
| Class U: | 91 | 42 | 39 | 62 | 55 | 82 | 67 | 44 |
|          | 51 | 77 | 61 | 52 | 76 | 41 | 59 |    |
| Class V: | 80 | 71 | 55 | 67 | 61 | 93 | 49 | 78 |
|          | 57 | 88 | 79 | 81 | 63 | 51 | 75 |    |

Use una prueba de chi-cuadrada con  $\alpha = 0.05$  para probar la igualdad de las distribuciones de los puntajes de las pruebas dividiendo el combinado muestra en tres partes iguales (bajo, medio, alto).

Recordemos

La prueba de homogeneidad

Consiste en ver si dos distribuciones multinomiales son iguales(homogéneas), siendo su prueba de hipótesis

$$H_0 : p_{i1} = p_{i2} \quad i = 1, \dots, k$$

Se rechaza  $H : 0$  si  $q_{k-1} \geq \chi^2_{\alpha, (h-1)(k-1)}$

Del cual tenemos que con parametros especificados y usando estimadores son:

$$Q_{k-1} = \sum_{j=1}^h \sum_{i=1}^k \frac{(y_{ij} - n_j p_{ij})^2}{n_j p_{ij}} \quad Q_{k-1} = \sum_{j=1}^h \sum_{i=1}^k \frac{(y_{ij} - n_j \hat{p}_i)^2}{n_j \hat{p}_i}$$

Donde al usar estimadores tenemos que

$$\hat{p}_i = \frac{\sum_{j=1}^h y_{ij}}{\sum_{j=1}^h n_j}$$

Usando *R* calculemos los terciles para dividir en tres partes, donde

| Percentil | Valor  |
|-----------|--------|
| 33.3 %    | 56.314 |
| 66.6 %    | 75.314 |

Con lo anterior tenemos lo siguiente

|         | Bajo = $(-\infty, 56.314]$ | Medio = $(56.314, 75.314]$ | Alto = $(75.314, \infty)$ | Total |
|---------|----------------------------|----------------------------|---------------------------|-------|
| Class U | 7                          | 4                          | 4                         | 15    |
| Class V | 3                          | 6                          | 6                         | 15    |
| Total   | 10                         | 10                         | 10                        | 30    |

Dado que nos interesa ver que las distribuciones diferentes satisfacen la igualdad al ser distribuida en 3 partes consideremos la hipótesis

$$H_0 : p_{i1} = p_{i2} = p_{i3} \quad i = 1, 2, 3.$$

Al estar dividida en 2 clases tenemos que  $h = 2$ , observando la tabla anterior notemos que cada estimación viene dada por

$$\frac{n_j \cdot \hat{p}_i}{n} = \frac{15 \cdot 10}{30} = 5 \quad i = 1, 2, 3 \quad j = 1, 2$$

Entonces

$$q = \frac{(7-5)^2}{5} + \frac{(4-5)^2}{5} + \frac{(4-5)^2}{5} + \frac{(3-5)^2}{5} + \frac{(6-5)^2}{5} + \frac{(6-5)^2}{5} = 2.4$$

Por otro lado tenemos que

$$\chi^2_{\alpha, (h-1)(k-1)} = \chi^2_{0.05, (2-1)(3-1)} = \chi^2_{0.05, 2} = 5.991465$$

Del cual tenemos que

$$2.4 < 5.991465$$

Por lo tanto no se rechaza la hipótesis, es decir, las clases *U* y *V* tienen dos distribuciones parecidas.

El código utilizado en *R* para obtener los valores anterior es

```
### Obtener cuantiles ###
datos<-c(91 ,42 ,39 ,62 ,55 ,82 ,67 ,44 ,51 ,77 ,61 ,52 ,76 ,41 ,59, 80 ,71 ,55 ,67)
terciles <- quantile(datos , probs = c(0.333 , 0.666))
terciles
```

```
### Obtener valor de q ###
```

```
G1<-c(7 , 4 , 4)
```

```
G2<-c(3 , 6 , 6)
```

```

G1S <- sum(G1)
G2S <- sum(G2)

n<-length(G1)
T1<-c()

for(i in 1:n){
  T1[i] = G1[i] + G2[i]
}

Total <- sum(T1)

D
G1p<-c()
G2p<-c()
for(j in 1:n){
  G1p[j]=(G1S*T1[j])/Total
  G2p[j]=(G2S*T1[j])/Total
}

c <-c()

for(i in 1:n){
  c[i]=( (G1[i]-G1p[i])^2/G1p[i] ) + ( (G2[i]-G2p[i])^2/G2p[i] )
}

sum(c)

### Obtener chi-cuadrada con nivel de significancia alfa ###
alfa <- 0.05
k <- 3
h <- 2
qchisq(1-alfa , (h-1)*(k-1))

```

5. En la siguiente tabla de contingencia, se clasifican 1015 personas por género y según estén a favor, en contra o sin opinión sobre la prohibición total de fumar, en lugares públicos:

| Género    | Fumar en lugares públicos |           |             | Total |
|-----------|---------------------------|-----------|-------------|-------|
|           | a favor                   | en contra | sin opinion |       |
| Masculino | 262                       | 231       | 10          | 503   |
| Femenino  | 302                       | 205       | 5           | 512   |
| Total     | 564                       | 436       | 15          | 1015  |

Pruebe la hipótesis nula de que el género y la opinión sobre fumar en lugares públicos son independientes. Proporcione el *valor p* aproximado de esta prueba.

Recordemos

La prueba de independencia

Consiste en ver si dos distribuciones multinomiales son independientes, siendo su prueba de hipótesis

$$H_0 : p_{i1} = p_{i\cdot} p_{\cdot j} \quad i = 1, \dots, k \quad j = 1, \dots, h$$

Se rechaza  $H_0$  : si  $q_{k-1} \geq \chi^2_{\alpha, (h-1)(k-1)}$

Donde  $p_{i\cdot} = \sum_{j=1}^h p_{ij}$ ,  $p_{\cdot j} = \sum_{i=1}^k p_{ij}$  de la misma manera tenemos que  $y_{ij}$  = numero de veces que los valores se encuentran en  $A_i \cap B_j$

Al usar parámetros especificados o usando estimadores se tiene:

$$Q_{kh-1} = \sum_{j=1}^h \sum_{i=1}^k \frac{(y_{ij} - n_j p_{i\cdot})^2}{n_j p_{i\cdot}} \sim \chi^2_{kh-1} \quad Q_{kh-1} = \sum_{j=1}^h \sum_{i=1}^k \frac{(y_{ij} - n_j \hat{p}_i)^2}{n(y_{i\cdot}/n)(y_{\cdot j}/n)} \sim \chi^2_{(k-1)(h-1)}$$

Del cual  $y_{\cdot j} = \sum_{i=1}^k y_{ij}$  y  $y_{i\cdot} = \sum_{j=1}^h y_{ij}$ .

Consideremos la siguiente prueba de hipótesis  $H_0 : p_{i1} = p_{i\cdot} p_{\cdot j} \quad i = 1, \dots, 3 \quad j = 1, \dots, 2$  así observando la tabla tenemos que las estimaciones de  $p_{i1} = p_{i\cdot} p_{\cdot j}$  son

$$\begin{aligned} \frac{564 \cdot 503}{1015} &\approx 279 & \frac{564 \cdot 512}{1015} &\approx 285 & \frac{436 \cdot 503}{1015} &\approx 216 \\ \frac{436 \cdot 512}{1015} &\approx 220 & \frac{15 \cdot 503}{1015} &\approx 7.43 & \frac{15 \cdot 512}{1015} &\approx 7.57 \end{aligned}$$

Entonces

$$\begin{aligned} q &= \frac{(262 - 279)^2}{279} + \frac{(302 - 285)^2}{285} + \frac{(231 - 216)^2}{216} + \frac{(205 - 220)^2}{220} + \frac{(10 - 7.43)^2}{7.43} + \frac{(5 - 7.57)^2}{7.57} \\ &= 5.974672 \end{aligned}$$

Usando  $R$  calculemos el  $p$  – valor del cual tenemos que

$$p - \text{valor} = 0.05042158$$

Con el  $p$  – valor podemos decir que la hipótesis nula no se rechaza dado que el valor se encuentra entre  $(0.05, 0.1)$  el cual vamos a verificando, de esta manera tenemos que

$$\chi^2_{\alpha, (k-1)(h-1)} = \chi^2_{0.05, (2-1)(3-1)} = \chi^2_{0.05, 2} = 5.991465$$

Notando así que

$$5.974672 < 5.991465$$

Por lo tanto no se rechaza la hipótesis nula, es decir, el genero y la opinión sobre fumar en lugares públicos son independientes entre si.

El código usado para obtener lo anterior fue

```

G1<-c(262, 231, 10)
G2<-c(302, 205, 5)

G1S <- sum(G1)
G2S <- sum(G2)

n<-length(G1)
T1<-c()

for(i in 1:n){
    T1[i] = G1[i] + G2[i]
}

Total <- sum(T1)

D
G1p<-c()
G2p<-c()
for(j in 1:n){
    G1p[j]=(G1S*T1[j])/Total
    G2p[j]=(G2S*T1[j])/Total
}

c <-c()

for(i in 1:n){
c[i]=( (G1[i]-G1p[i])^2/G1p[i] ) + ( (G2[i]-G2p[i])^2/G2p[i] )
}

sum(c)

### P-valor ###
k <- 3
h <- 2
pvalor <- 1-pchisq(5.974672, (h-1)*(k-1))

### Estimacion alfa ###
alfa <- 0.05
qchisq(1-alfa, (h-1)*(k-1))

```