

Maestría en Ciencia de Datos e Información

Tarea 2

Matemáticas

Alumno: Eduardo Alanís García
Profesora: Dra. Briceyda B. Delgado López
Entrega: 26 de septiembre de 2026

Instrucciones

Lea el archivo *Formato de tareas* que se encuentra en la siguiente liga <https://drive.google.com/drive/u/0/folders/1F-FI1J5PviBc-EPhfLbnE8PSvWnkgeHj>.

En la siguiente lista de ejercicios NO se admite ningún tipo de código en la solución de los ejercicios, cada uno de ellos se puede resolver de forma analítica. La única excepción es el ejercicio 5, donde se indica sea resuelto usando el paquete R. Párrafos que contengan código en la entrega no se van a considerar en la calificación.

Ejercicios

Ejercicio 1 (15 puntos). La función de densidad de una variable aleatoria está dada por

$$f(x) = \begin{cases} a + bx^2, & 0 \leq x \leq 1, \\ 0, & \text{en otro caso.} \end{cases}$$

Si la esperanza es $E(X) = \frac{3}{5}$. Encuentre a y b .

Solución. Por definición de función de densidad [1] cumple que

$$\int_{-\infty}^{\infty} f(x) dx = 1$$

Como $f(x) = 0$ fuera del intervalo $[0, 1]$, tenemos

$$\int_0^1 (a + bx^2) dx = 1$$

Entonces:

$$\int_0^1 (a + bx^2) dx = \left[ax + \frac{b}{3}x^3 \right]_0^1 = a + \frac{b}{3}.$$

Por lo tanto

$$a + \frac{b}{3} = 1$$

Por otro lado, por definición, la esperanza de una variable aleatoria continua [1, Sección 2.6; 2] es

$$E(X) = \int_{-\infty}^{\infty} x f(x) dx.$$

De esta manera:

$$E(X) = \int_0^1 x(a + bx^2) dx = \int_0^1 (ax + bx^3) dx = \left[\frac{a}{2}x^2 + \frac{b}{4}x^4 \right]_0^1 = \frac{a}{2} + \frac{b}{4}$$

Como se nos indica que $E(X) = \frac{3}{5}$, obtenemos

$$\frac{a}{2} + \frac{b}{4} = \frac{3}{5}$$

Obteniendo el sistema

$$\begin{cases} a + \frac{1}{3}b = 1 \\ \frac{1}{2}a + \frac{1}{4}b = \frac{3}{5} \end{cases}$$

Resolvemos por Gauss-Jordan

$$\left[\begin{array}{cc|c} 1 & \frac{1}{3} & 1 \\ \frac{1}{2} & \frac{1}{4} & \frac{3}{5} \end{array} \right] \xrightarrow{R_2 \leftarrow R_2 - \frac{1}{2}R_1} \left[\begin{array}{cc|c} 1 & \frac{1}{3} & 1 \\ 0 & \frac{1}{12} & \frac{1}{10} \end{array} \right] \xrightarrow{R_2 \leftarrow 12R_2} \left[\begin{array}{cc|c} 1 & \frac{1}{3} & 1 \\ 0 & 1 & \frac{6}{5} \end{array} \right] \xrightarrow{R_1 \leftarrow R_1 - \frac{1}{3}R_2} \left[\begin{array}{cc|c} 1 & 0 & \frac{3}{5} \\ 0 & 1 & \frac{6}{5} \end{array} \right]$$

Por lo tanto,

$$a = \frac{3}{5}, \quad b = \frac{6}{5}$$

Verificación. Tenemos que $f(x) = \frac{3}{5} + \frac{6}{5}x^2$ en $[0,1]$, que es no negativa en todo el intervalo, verificamos las dos condiciones:

$$\int_0^1 \left(\frac{3}{5} + \frac{6}{5}x^2 \right) dx = \frac{3}{5} + \frac{6}{5} \cdot \frac{1}{3} = \frac{3}{5} + \frac{2}{5} = 1,$$

$$\int_0^1 x \left(\frac{3}{5} + \frac{6}{5}x^2 \right) dx = \frac{3}{10} + \frac{6}{5} \cdot \frac{1}{4} = \frac{3}{10} + \frac{3}{10} = \frac{6}{10} = \frac{3}{5}$$

Ambas condiciones se satisfacen, por lo que los valores $a = \frac{3}{5}$ y $b = \frac{6}{5}$ son correctos.

Ejercicio 2 (10 puntos). La estatura de las mujeres adultas en Estados Unidos se distribuye normalmente con media de $\mu = 64.5$ pulgadas y desviación estándar de $\sigma = 2.4$ pulgadas. Hallar la probabilidad de que una mujer elegida al azar mida

- (a) Mida menos de 63 pulgadas;
- (b) Mida entre 63 y 70 pulgadas.
- (c) Alice mide 72 pulgadas. ¿Qué porcentaje de mujeres mide menos que Alicia?

Solución. Sea X la variable aleatoria que representa la estatura (en pulgadas) de una mujer adulta elegida al azar en Estados Unidos. Por el enunciado, $X \sim N(\mu, \sigma^2)$ con

$$\mu = 64.5, \quad \sigma = 2.4.$$

Para calcular cualquier probabilidad usamos la estandarización [1, Sección 3.13]

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

y consultamos el valor correspondiente en la tabla de la distribución normal estándar, $\Phi(z) = P(Z \leq z)$ [1, Sección 3.13].

(a) $P(X < 63)$. Estandarizamos el valor $x = 63$:

$$z = \frac{63 - \mu}{\sigma} = \frac{63 - 64.5}{2.4} = \frac{-1.5}{2.4} = -0.625$$

Buscamos $\Phi(-0.625)$. Usando la simetría de la normal estándar, $\Phi(-z) = 1 - \Phi(z)$, así que basta encontrar $\Phi(0.625)$. En la tabla, los valores más cercanos son

$$\Phi(0.62) = 0.73237, \quad \Phi(0.63) = 0.73565$$

De esta manera para $z = 0.625$ (punto medio entre ambos) obtenemos

$$\Phi(0.625) \approx \frac{0.73237 + 0.73565}{2} = 0.73401 \approx 0.7340$$

Por lo tanto,

$$P(X < 63) = \Phi(-0.625) = 1 - \Phi(0.625) \approx 1 - 0.7340 = 0.2660$$

Es decir, la probabilidad de que una mujer elegida al azar mida menos de 63 pulgadas es de aproximadamente 0.2660, es decir, un 26.60 %.

(b) $P(63 < X < 70)$. Ya tenemos z para $x = 63$ del inciso anterior. Estandarizamos ahora $x = 70$:

$$z = \frac{70 - \mu}{\sigma} = \frac{70 - 64.5}{2.4} = \frac{5.5}{2.4} \approx 2.29$$

Buscamos en la tabla $\Phi(2.29) = 0.98899 \approx 0.9890$.

Como la probabilidad de que X esté entre dos valores es la diferencia de las probabilidades acumuladas hasta cada uno de ellos [1, Sección 2.3]

$$P(63 < X < 70) = P(X < 70) - P(X < 63) = \Phi(2.29) - \Phi(-0.625)$$

De esta manera

$$P(63 < X < 70) \approx 0.9890 - 0.2660 = 0.7230.$$

Por lo tanto, la probabilidad de que una mujer elegida al azar mida entre 63 y 70 pulgadas es de aproximadamente 0.7230, es decir, un 72.30 %.

(c) Porcentaje de mujeres que miden menos que Alice ($x = 72$). Estandarizamos $x = 72$:

$$z = \frac{72 - \mu}{\sigma} = \frac{72 - 64.5}{2.4} = \frac{7.5}{2.4} = 3.125$$

De esta manera

$$P(X < 72) = \Phi(3.125) \approx 0.9991.$$

Esto significa que aproximadamente el 99.91 % de las mujeres miden menos que Alice; es decir, solo alrededor del 0.09 % de las mujeres son tan altas como ella o más altas.

Ejercicio 3 (25 puntos). Realice un análisis de las temperaturas promedio de uno de los 32 estados de México de los años 1993 al 2023 aproximando a través del método de mínimos cuadrados para el caso lineal, cuadrático y cúbico. El caso lineal y cuadrático se explicaron en clase, para en caso cúbico es necesario utilizar el mismo razonamiento y deducir las fórmulas resultantes. Explicar paso a paso el método.

Los estados y el periodo se asignarán de forma personalizada, véase el final del archivo. Los datos provienen del Servicio Meteorológico Nacional¹ De click en la pestaña Climatología, seguido de Temperaturas y Lluvia, luego seleccione la opción Resúmenes mensuales de Temperaturas y Lluvia.

Estado asignado: **Aguascalientes**

Solución. Deduciremos primero la fórmula correspondiente al caso cúbico, siguiendo el mismo razonamiento empleado en clase para los casos lineal y cuadrático [2].

Consideremos una función cúbica

$$p(t) = \alpha + \beta t + \gamma t^2 + \theta t^3$$

que minimice la suma de los errores cuadrados. El problema consiste entonces en resolver

$$\min_{\alpha, \beta, \gamma, \theta} \sum_{i=1}^n (\alpha + \beta t_i + \gamma t_i^2 + \theta t_i^3 - y_i)^2.$$

Definimos la función

$$F(\alpha, \beta, \gamma, \theta) = \sum_{i=1}^n (\alpha + \beta t_i + \gamma t_i^2 + \theta t_i^3 - y_i)^2.$$

Para minimizar F respecto a las variables α, β, γ y θ , las condiciones necesarias son

$$\frac{\partial F}{\partial \alpha} = \frac{\partial F}{\partial \beta} = \frac{\partial F}{\partial \gamma} = \frac{\partial F}{\partial \theta} = 0.$$

Calculamos cada una de estas derivadas parciales.

¹<https://smn.conagua.gob.mx/es/8-smn-general>

Derivada respecto a α .

$$\frac{\partial F}{\partial \alpha} = 2 \sum_{i=1}^n (\alpha + \beta t_i + \gamma t_i^2 + \theta t_i^3 - y_i) = 0 \iff \alpha n + \beta \sum_{i=1}^n t_i + \gamma \sum_{i=1}^n t_i^2 + \theta \sum_{i=1}^n t_i^3 = \sum_{i=1}^n y_i.$$

Derivada respecto a β .

$$\frac{\partial F}{\partial \beta} = 2 \sum_{i=1}^n (\alpha + \beta t_i + \gamma t_i^2 + \theta t_i^3 - y_i) t_i = 0 \iff \alpha \sum_{i=1}^n t_i + \beta \sum_{i=1}^n t_i^2 + \gamma \sum_{i=1}^n t_i^3 + \theta \sum_{i=1}^n t_i^4 = \sum_{i=1}^n y_i t_i.$$

Derivada respecto a γ .

$$\frac{\partial F}{\partial \gamma} = 2 \sum_{i=1}^n (\alpha + \beta t_i + \gamma t_i^2 + \theta t_i^3 - y_i) t_i^2 = 0 \iff \alpha \sum_{i=1}^n t_i^2 + \beta \sum_{i=1}^n t_i^3 + \gamma \sum_{i=1}^n t_i^4 + \theta \sum_{i=1}^n t_i^5 = \sum_{i=1}^n y_i t_i^2.$$

Derivada respecto a θ .

$$\frac{\partial F}{\partial \theta} = 2 \sum_{i=1}^n (\alpha + \beta t_i + \gamma t_i^2 + \theta t_i^3 - y_i) t_i^3 = 0 \iff \alpha \sum_{i=1}^n t_i^3 + \beta \sum_{i=1}^n t_i^4 + \gamma \sum_{i=1}^n t_i^5 + \theta \sum_{i=1}^n t_i^6 = \sum_{i=1}^n y_i t_i^3.$$

De esta manera, obtenemos el siguiente sistema de ecuaciones

$$\begin{aligned} \alpha n + \beta \sum_{i=1}^n t_i + \gamma \sum_{i=1}^n t_i^2 + \theta \sum_{i=1}^n t_i^3 &= \sum_{i=1}^n y_i, \\ \alpha \sum_{i=1}^n t_i + \beta \sum_{i=1}^n t_i^2 + \gamma \sum_{i=1}^n t_i^3 + \theta \sum_{i=1}^n t_i^4 &= \sum_{i=1}^n y_i t_i, \\ \alpha \sum_{i=1}^n t_i^2 + \beta \sum_{i=1}^n t_i^3 + \gamma \sum_{i=1}^n t_i^4 + \theta \sum_{i=1}^n t_i^5 &= \sum_{i=1}^n y_i t_i^2, \\ \alpha \sum_{i=1}^n t_i^3 + \beta \sum_{i=1}^n t_i^4 + \gamma \sum_{i=1}^n t_i^5 + \theta \sum_{i=1}^n t_i^6 &= \sum_{i=1}^n y_i t_i^3. \end{aligned}$$

El cual podemos reescribir en forma matricial como sigue.

$$\begin{pmatrix} n & \sum_{i=1}^n t_i & \sum_{i=1}^n t_i^2 & \sum_{i=1}^n t_i^3 \\ \sum_{i=1}^n t_i & \sum_{i=1}^n t_i^2 & \sum_{i=1}^n t_i^3 & \sum_{i=1}^n t_i^4 \\ \sum_{i=1}^n t_i^2 & \sum_{i=1}^n t_i^3 & \sum_{i=1}^n t_i^4 & \sum_{i=1}^n t_i^5 \\ \sum_{i=1}^n t_i^3 & \sum_{i=1}^n t_i^4 & \sum_{i=1}^n t_i^5 & \sum_{i=1}^n t_i^6 \end{pmatrix} \begin{pmatrix} \alpha \\ \beta \\ \gamma \\ \theta \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n y_i t_i \\ \sum_{i=1}^n y_i t_i^2 \\ \sum_{i=1}^n y_i t_i^3 \end{pmatrix}.$$

Por lo tanto, los coeficientes de la función cubica buscada son

$$\begin{pmatrix} \alpha \\ \beta \\ \gamma \\ \theta \end{pmatrix} = \begin{pmatrix} n & \sum_{i=1}^n t_i & \sum_{i=1}^n t_i^2 & \sum_{i=1}^n t_i^3 \\ \sum_{i=1}^n t_i & \sum_{i=1}^n t_i^2 & \sum_{i=1}^n t_i^3 & \sum_{i=1}^n t_i^4 \\ \sum_{i=1}^n t_i^2 & \sum_{i=1}^n t_i^3 & \sum_{i=1}^n t_i^4 & \sum_{i=1}^n t_i^5 \\ \sum_{i=1}^n t_i^3 & \sum_{i=1}^n t_i^4 & \sum_{i=1}^n t_i^5 & \sum_{i=1}^n t_i^6 \end{pmatrix}^{-1} \begin{pmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n y_i t_i \\ \sum_{i=1}^n y_i t_i^2 \\ \sum_{i=1}^n y_i t_i^3 \end{pmatrix}$$

Herramientas y datos. Los promedios anuales se obtuvieron de los resúmenes mensuales del Servicio Meteorológico Nacional. Las sumas y la gráfica se calcularon con R. El procedimiento completo y los datos están disponibles en: [Mínimos Cuadrados R \(Eduardo Alanís García\)](#).

Aplicaremos ahora el método de mínimos cuadrados a los datos de temperatura, usando el caso lineal y el cuadrático (vistos en clase [2]) y el caso cúbico (deducido arriba).

Para ello consideramos los años con la variable $t_i = i$, $i = 1, \dots, 31$, de modo que $t_1 = 1$ corresponde a 1993 y $t_{31} = 31$ corresponde a 2023; y_i denota la temperatura promedio del i -ésimo año.

Cuadro 1: Temperatura media anual de Aguascalientes, 1993–2023.

Año	t_i	y_i (°C)	Año	t_i	y_i (°C)
1993	1	17.5	2009	17	17.8
1994	2	17.7	2010	18	17.8
1995	3	17.6	2011	19	18.0
1996	4	17.4	2012	20	17.9
1997	5	17.4	2013	21	17.9
1998	6	17.6	2014	22	17.5
1999	7	17.6	2015	23	17.6
2000	8	17.7	2016	24	17.4
2001	9	18.0	2017	25	17.9
2002	10	18.0	2018	26	17.8
2003	11	17.2	2019	27	18.4
2004	12	17.1	2020	28	18.1
2005	13	17.7	2021	29	17.4
2006	14	17.9	2022	30	17.9
2007	15	17.7	2023	31	18.7
2008	16	17.9			

Con $n = 31$ datos se obtienen

$$\begin{aligned}\sum_{i=1}^{31} t_i &= 496, & \sum_{i=1}^{31} t_i^2 &= 10416, & \sum_{i=1}^{31} t_i^3 &= 246016, & \sum_{i=1}^{31} t_i^4 &= 6\,197\,520, \\ \sum_{i=1}^{31} t_i^5 &= 162\,616\,576, & \sum_{i=1}^{31} t_i^6 &= 4\,388\,434\,896, \\ \sum_{i=1}^{31} y_i &= 550.1, & \sum_{i=1}^{31} y_i t_i &= 8843.2, & \sum_{i=1}^{31} y_i t_i^2 &= 186259.6, & \sum_{i=1}^{31} y_i t_i^3 &= 4\,408\,958.8.\end{aligned}$$

Con estos valores resolvemos los tres sistemas normales.

Caso lineal

El sistema para $p_1(t) = \alpha + \beta t$ el sistema es

$$\begin{pmatrix} n & \sum t_i \\ \sum t_i & \sum t_i^2 \end{pmatrix} \begin{pmatrix} \alpha \\ \beta \end{pmatrix} = \begin{pmatrix} \sum y_i \\ \sum y_i t_i \end{pmatrix}.$$

Sustituyendo,

$$\begin{pmatrix} \alpha \\ \beta \end{pmatrix} = \begin{pmatrix} 31 & 496 \\ 496 & 10416 \end{pmatrix}^{-1} \begin{pmatrix} 550.1 \\ 8843.2 \end{pmatrix} = \begin{pmatrix} \frac{21}{155} & -\frac{1}{155} \\ -\frac{1}{155} & \frac{1}{2480} \end{pmatrix} \begin{pmatrix} 550.1 \\ 8843.2 \end{pmatrix} \approx \begin{pmatrix} 17.47677419 \\ 0.01677419 \end{pmatrix}.$$

De modo que la aproximación lineal es

$$p_1(t) \approx 17.47677419 + 0.01677419 t.$$

Caso cuadrático

Para $p_2(t) = \alpha + \beta t + \gamma t^2$, el sistema es

$$\begin{pmatrix} n & \sum t_i & \sum t_i^2 \\ \sum t_i & \sum t_i^2 & \sum t_i^3 \\ \sum t_i^2 & \sum t_i^3 & \sum t_i^4 \end{pmatrix} \begin{pmatrix} \alpha \\ \beta \\ \gamma \end{pmatrix} = \begin{pmatrix} \sum y_i \\ \sum y_i t_i \\ \sum y_i t_i^2 \end{pmatrix}.$$

Sustituyendo,

$$\begin{pmatrix} \alpha \\ \beta \\ \gamma \end{pmatrix} = \begin{pmatrix} 31 & 496 & 10416 \\ 496 & 10416 & 246016 \\ 10416 & 246016 & 6\,197\,520 \end{pmatrix}^{-1} \begin{pmatrix} 550.1 \\ 8843.2 \\ 186259.6 \end{pmatrix} = \begin{pmatrix} \frac{1489}{4495} & -\frac{189}{4495} & \frac{1}{899} \\ -\frac{189}{4495} & \frac{5439}{791120} & -\frac{2}{9889} \\ \frac{1}{899} & -\frac{2}{9889} & \frac{1}{158224} \end{pmatrix} \begin{pmatrix} 550.1 \\ 8843.2 \\ 186259.6 \end{pmatrix} \approx \begin{pmatrix} 17.58222470 \\ -0.00239862 \\ 0.00059915 \end{pmatrix}.$$

Así, la aproximación cuadrática es

$$p_2(t) \approx 17.58222470 - 0.00239862 t + 0.00059915 t^2.$$

Caso cúbico

Usando el sistema 4×4 deducido al inicio para $p_3(t) = \alpha + \beta t + \gamma t^2 + \theta t^3$, sustituimos los valores numéricos:

$$\begin{pmatrix} \alpha \\ \beta \\ \gamma \\ \theta \end{pmatrix} = \begin{pmatrix} 31 & 496 & 10416 & 246016 \\ 496 & 10416 & 246016 & 6197520 \\ 10416 & 246016 & 6197520 & 162616576 \\ 246016 & 6197520 & 162616576 & 4388434896 \end{pmatrix}^{-1} \begin{pmatrix} 550.1 \\ 8843.2 \\ 186259.6 \\ 4408958.8 \end{pmatrix}$$

$$= \begin{pmatrix} \frac{597}{899} & -\frac{851}{5394} & \frac{9}{899} & -\frac{1}{5394} \\ -\frac{5394}{851} & \frac{1669536}{78655} & -\frac{1008678}{3325} & \frac{48416544}{3121} \\ \frac{9}{899} & -\frac{3325}{1008678} & \frac{657}{2689808} & -\frac{5}{1008678} \\ -\frac{1}{5394} & \frac{3121}{48416544} & -\frac{5}{1008678} & \frac{5}{48416544} \end{pmatrix} \begin{pmatrix} 550.1 \\ 8843.2 \\ 186259.6 \\ 4408958.8 \end{pmatrix} \approx \begin{pmatrix} 17.41835373 \\ 0.05458013 \\ -0.00378243 \\ 0.00009128 \end{pmatrix}.$$

Por lo que la aproximación cúbica es

$$p_3(t) \approx 17.41835373 + 0.05458013 t - 0.00378243 t^2 + 0.00009128 t^3.$$

Resultados

Las tres aproximaciones por mínimos cuadrados para la temperatura promedio anual de Aguascalientes, son:

$$p_1(t) \approx 17.47677 + 0.01677 t,$$


$$p_2(t) \approx 17.58222 - 0.00240 t + 0.00060 t^2,$$

$$p_3(t) \approx 17.41835 + 0.05458 t - 0.00378 t^2 + 0.00009 t^3.$$

Evalutando en los extremos del periodo se obtiene:

	$p_1(t)$	$p_2(t)$	$p_3(t)$
$t = 1$ (1993)	17.4935 °C	17.5804 °C	17.4692 °C
$t = 31$ (2023)	17.9968 °C	18.0837 °C	18.1948 °C

Ademas las graficas compartiva es



Los tres polinomios señalan un aumento de la temperatura media anual de Aguascalientes entre 1993 y 2023: los modelos lineal y cuadrático estiman un incremento de $\approx 0.5^\circ\text{C}$ y el cúbico de $\approx 0.7^\circ\text{C}$. Dentro del periodo 1993–2023 los tres polinomios prácticamente coinciden, ya que la diferencia máxima entre el modelo lineal y el cúbico es de $\approx 0.2^\circ\text{C}$ (en $t = 31$), y entre el lineal y el cuadrático de $\approx 0.09^\circ\text{C}$. Los términos adicionales solo agregan una curvatura leve, menor que la variación de año a año que muestran los datos. Por simplicidad, el modelo lineal es suficiente para describir la tendencia: indica un aumento de $\approx 0.017^\circ\text{C}$ por año, es decir, unos 0.17°C por década.

Además, notemos que los puntos se dispersan alrededor de las tres curvas, por lo que los modelos describen la tendencia general y no los valores de cada año. Asimismo, estos modelos solo son válidos para el periodo 1993–2023.

Ejercicio 4 (10 puntos). El cáncer de próstata es el más frecuente entre los varones. Como indicador de si un varón padece cáncer de próstata, los médicos suelen realizar una prueba que mide el nivel de la proteína PSA (antígeno prostático específico) que sólo produce la glándula prostática. Aunque unos niveles más altos de PSA son indicativos de cáncer, la prueba es muy poco fiable. De hecho, la probabilidad de que un hombre no canceroso tenga un nivel elevado de PSA es de aproximadamente 0,135, probabilidad que aumenta a aproximadamente 0,268 si el hombre tiene cáncer. Si, basándose en otros factores, un médico está seguro en un 65 % de que un varón tiene cáncer de próstata, ¿cuál es la probabilidad condicional de que tenga cáncer si

Sugerencia: Aplique el Teorema de Bayes.

- (a) La prueba indica un nivel elevado de PSA?,

Solución. Definimos los eventos:

$C = \{\text{el varón tiene cáncer de próstata}\}, \quad A = \{\text{la prueba indica un nivel elevado de PSA}\}.$

Por el enunciado

$$P(C) = 0.65 \quad \Rightarrow \quad P(C^c) = 1 - P(C) = 1 - 0.65 = 0.35,$$

y las probabilidades condicionales son:

$$P(A | C^c) = 0.135, \quad P(A | C) = 0.268.$$

La primera es la probabilidad de que un hombre sin cáncer tenga un nivel elevado de PSA (falso positivo), y la segunda es la probabilidad de que un hombre con cáncer tenga un nivel elevado de PSA (verdadero positivo).

Con esta información, podemos calcular la probabilidad total de que la prueba arroje un nivel elevado de PSA, usando el teorema de probabilidad total [1, Sección 1.14]:

$$P(A) = P(A | C)P(C) + P(A | C^c)P(C^c) = (0.268)(0.65) + (0.135)(0.35) = 0.1742 + 0.04725 = 0.22145.$$

Finalmente, aplicando el Teorema de Bayes [1, Sección 1.15; 2], obtenemos la probabilidad de que un varón tenga cáncer dado que la prueba indicó un nivel elevado de PSA:

$$P(C | A) = \frac{P(A | C)P(C)}{P(A | C)P(C) + P(A | C^c)P(C^c)} = \frac{P(A | C)P(C)}{P(A)} = \frac{0.1742}{0.22145} \approx 0.78664.$$

En conclusión, si la prueba muestra un nivel elevado de PSA, la probabilidad de que el varón efectivamente tenga cáncer de próstata es de aproximadamente 78.66 %.

(b) La prueba no indica un nivel elevado de PSA?

Solución. En este caso nos interesa el complemento de A , es decir, que la prueba *no* indique un nivel elevado de PSA. Por el enunciado sabemos que

$$P(C) = 0.65 \quad \implies \quad P(C^c) = 1 - P(C) = 1 - 0.65 = 0.35,$$

y que

$$P(A | C^c) = 0.135, \quad P(A | C) = 0.268,$$

por lo que las probabilidades de los complementos son:

$$P(A^c | C) = 1 - P(A | C) = 1 - 0.268 = 0.732, \quad P(A^c | C^c) = 1 - P(A | C^c) = 1 - 0.135 = 0.865.$$

La primera es la probabilidad de que un hombre con cáncer no presente un nivel elevado de PSA (falso negativo), y la segunda es la probabilidad de que un hombre sin cáncer no presente un nivel elevado de PSA (verdadero negativo).

Con esta información, calculamos la probabilidad total de que la prueba no arroje un nivel elevado de PSA, usando el teorema de probabilidad total:

$$P(A^c) = P(A^c | C)P(C) + P(A^c | C^c)P(C^c) = (0.732)(0.65) + (0.865)(0.35) = 0.4758 + 0.30275 = 0.77855.$$

Finalmente, aplicando el Teorema de Bayes, obtenemos la probabilidad de que un varón tenga cáncer dado que la prueba no indicó un nivel elevado de PSA:

$$P(C | A^c) = \frac{P(A^c | C)P(C)}{P(A^c | C)P(C) + P(A^c | C^c)P(C^c)} = \frac{P(A^c | C)P(C)}{P(A^c)} = \frac{0.4758}{0.77855} \approx 0.61114.$$

En conclusión, aunque la prueba no muestre un nivel elevado de PSA, la probabilidad de que el varón tenga cáncer es de aproximadamente 61.11 %.

Ejercicio 5 (25 puntos). Realice un análisis de componentes principales (PCA por sus siglas en inglés) aplicado a la base de datos USArrests del paquete básico de R que contiene el porcentaje de asaltos (Assault), asesinatos (Murder) y secuestros (Rape) por cada 100,000 habitantes para cada uno de los 50 estados de USA (1973). Además, también incluye el porcentaje de la población de cada estado que vive en zonas rurales (UrbanPop). En este caso, el número de variables es $p = 4$ y el número de observaciones es $n = 50$.

Herramienta utilizada: R. El código completo, con salidas y comentarios adicionales, se encuentra disponible en: [Ejercicio 5 - Análisis de Componentes Principales \(Eduardo Alanís García\)](#).

- (a) Centralice las variables para que estas tengan media cero. Muestre los resultados en una tabla.

Solución.

```
1 data("USArrests")
2
3 datos = USArrests
4 datos_centrados = datos |> scale(center = T, scale = F) |> as.data.frame()
5 lapply(datos_centrados, mean)
```

```
1 $Murder
2 [1] -2.84023e-16
3
4 $Assault
5 [1] 9.088182e-15
6
7 $UrbanPop
8 [1] -6.253574e-15
9
10 $Rape
11 [1] 8.518533e-16
```

Se observa, todas las medias son del orden de 10^{-15} – 10^{-16} , es decir, numéricamente cero.

```
1 datos_centrados |> head(n = 10)
```

```
1      Murder Assault UrbanPop  Rape
2 Alabama    5.412    65.24    -7.54 -0.032
3 Alaska     2.212    92.24   -17.54 23.268
4 Arizona     0.312   123.24    14.46  9.768
5 Arkansas    1.012    19.24   -15.54 -1.732
6 California  1.212   105.24    25.46 19.368
7 Colorado    0.112    33.24    12.46 17.468
8 Connecticut -4.488   -60.76    11.46 -10.132
9 Delaware   -1.888    67.24     6.46 -5.432
10 Florida     7.612   164.24    14.46 10.668
11 Georgia     9.612    40.24    -5.54  4.568
```

- (b) Calcule la matriz de covarianza. En caso de obtener una variabilidad muy alta, primero estandarice para tener una desviación estándar igual a 1.

Solución.

```
1 matriz_covarianza = datos_centrados |> cov() |> as.data.frame()
2 lapply(datos_centrados, var)
```

```
1 $Murder
2 [1] 18.97047
3
4 $Assault
5 [1] 6945.166
6
7 $UrbanPop
8 [1] 209.5188
9
10 $Rape
11 [1] 87.72916
```

Se observa que la varianza de Assault (6945.17) es casi 366 veces mayor que la de Murder (18.97), y también muy superior a la de UrbanPop (209.52) y Rape (87.73). Por ello, estandarizamos las variables para que todas tengan desviación estándar igual a 1.

```
1 datos_estandarizados = datos |> scale(center = T, scale = T) |> as.data.
  frame()
2 lapply(datos_estandarizados, var)
```

```
1 $Murder
2 [1] 1
3
4 $Assault
5 [1] 1
6
7 $UrbanPop
8 [1] 1
9
10 $Rape
11 [1] 1
```

```
1 matriz_covarianza_estandarizada = datos_estandarizados |> cov() |> as.
  data.frame()
2 matriz_covarianza_estandarizada
```

```
1      Murder    Assault    UrbanPop    Rape
2 Murder  1.00000000 0.8018733 0.06957262 0.5635788
3 Assault 0.80187331 1.0000000 0.25887170 0.6652412
4 UrbanPop 0.06957262 0.2588717 1.00000000 0.4113412
5 Rape    0.56357883 0.6652412 0.41134124 1.0000000
```

- (c) Encuentre los eigenvalores y los eigenvectores de la matriz de covarianza.

Solución.

```
1 valores = matriz_covarianza_estandarizada |> eigen()
2 valores_propios = valores$values
3 vectores_propios = valores$vectors |> as.data.frame()
```

```
1 valores_propios
```

```
1 [1] 2.4802416 0.9897652 0.3565632 0.1734301
```


```
1 vectores_propios
```

```
1          V1          V2          V3          V4
2 1 -0.5358995  0.4181809 -0.3412327  0.64922780
3 2 -0.5831836  0.1879856 -0.2681484 -0.74340748
4 3 -0.2781909 -0.8728062 -0.3780158  0.13387773
5 4 -0.5434321 -0.1673186  0.8177779  0.08902432
```

- (d) Tomando la mayor cantidad de componentes principales $\min(n - 1, p) = \min(49, 4) = 4$. Calcule los componentes principales y grafique de forma bidimensional a las primeras dos componentes principales.

Solución.

```
1 pca = datos |> prcomp(center = TRUE, scale. = TRUE)
2 componentes = pca[["x"]] |> as.data.frame()
3
4 plot(x = componentes$PC1, y = componentes$PC2,
5      xlab = "PC1", ylab = "PC2", pch = 19, col = "steelblue")
6 text(componentes$PC1, componentes$PC2, labels = rownames(datos), pos = 3,
7      cex = 0.6)
```



(e) Interprete la información que representa cada componente principal.

Solución.

```
1 summary(pca)
```

```
1 Importance of components:
2
3          PC1      PC2      PC3      PC4
4 Standard deviation  1.5749 0.9949 0.59713 0.41645
5 Proportion of Variance 0.6201 0.2474 0.08914 0.04336
6 Cumulative Proportion 0.6201 0.8675 0.95664 1.00000
```

Las dos primeras componentes concentran el 86.75 % de la varianza total, por lo que basta con analizarlas a ellas [3, 4].

```
1 pca[["rotation"]]
2
3          PC1      PC2      PC3      PC4
4 Murder    -0.5358995 -0.4181809 0.3412327 0.64922780
5 Assault   -0.5831836 -0.1879856 0.2681484 -0.74340748
6 UrbanPop  -0.2781909 0.8728062 0.3780158 0.13387773
7 Rape      -0.5434321 0.1673186 -0.8177779 0.08902432
```

Para el primer componente 1 (62.01 % de la varianza), sus loadings son

$$PC_1 = -0.536 \text{ Murder}_z - 0.583 \text{ Assault}_z - 0.278 \text{ UrbanPop}_z - 0.543 \text{ Rape}_z.$$

Los coeficientes de Murder, Assault y Rape son de magnitud muy similar (entre -0.54 y -0.58), y considerablemente mayores en valor absoluto que el de UrbanPop (-0.278). Por lo tanto, PC1 puede interpretarse como el indicador de criminalidad violenta.

Para el componente 2 (24.74 % de la varianza), sus loadings son

$$PC_2 = -0.418 \text{ Murder}_z - 0.188 \text{ Assault}_z + 0.873 \text{ UrbanPop}_z + 0.167 \text{ Rape}_z.$$

Aquí domina claramente el coeficiente de UrbanPop (-0.873), muy por encima del resto. Esto indica que PC2 representa principalmente el grado de urbanización de cada estado.

En conclusión, las dos primeras componentes principales resumen, de forma casi independiente, dos aspectos distintos de los datos: qué tan violento es un estado (PC1) y qué tan urbano es (PC2), conservando el 86.75 % de la información original en solo dos dimensiones.

Ejercicio 6 (15 puntos). Lea el artículo Genes mirror geography within Europe, que se encuentra en la carpeta de referencias compartida de Drive. <https://drive.google.com/drive/u/0/folders/1F-FI1J5PviBc-EPhfLbnE8PSvWnkgeHj> Explique de forma resumida de qué se trata el artículo y realice un conclusión de cómo el algoritmo de componentes principales es de gran utilidad en la reducción de la dimensionalidad.

Solución. Este artículo [5] estudia qué tanto se parece la variación genética de los europeos a su distribución geográfica. Los autores usaron datos del proyecto POPRES: unos 3.000 individuos genotipados en más de 500.000 SNP (variantes de ADN). Después de aplicar filtros de calidad y de origen, el análisis se hizo con 1.387 individuos y 197.146 SNP.

Para resumir toda esa información genética usaron el análisis de componentes principales (PCA), quedándose solo con los dos primeros componentes, PC1 y PC2. Al graficar a los individuos con estos dos ejes, el resultado se parece notablemente a un mapa de Europa: las poblaciones vecinas quedan cerca entre sí y se distinguen zonas como la península ibérica, la itálica y el sureste europeo. Incluso se detecta estructura entre los suizos según su idioma (francés, alemán o italiano).

Esta relación también se comprobó de manera numérica: tras rotar los ejes del PCA, el eje genético norte-sur se correlacionó con la latitud ($r^2 = 0,77$) y el eje este-oeste con la longitud ($r^2 = 0,78$).

Además, esta representación reducida sirve para estimar el origen geográfico de una persona. Con un método de asignación basado en regresión sobre PC1 y PC2, el 50 % de los individuos quedó a menos de 310 km de su origen reportado y el 90 % a menos de 700 km.

Conclusión: Existe una gran utilidad del análisis de componentes principales en la reducción de la dimensionalidad, para este artículo cada individuo tiene casi 200.000 dimensiones (una por SNP), lo que hace imposible visualizarlas o interpretarlas directamente. El PCA transforma esa información en solo dos ejes que conservan la información más importante, en este caso, la estructura geográfica de la población europea.

Es notable que PC1 y PC2 explican apenas el 0.30 % y el 0.15 % de la variación total, y aun así capturan un patrón claro. Esto ocurre porque la señal de ancestría es coherente a lo largo de miles de SNP, mientras que el ruido y la variación individual se reparten en muchas otras direcciones.

De esta manera, se puede decir que el PCA facilita la visualización, la interpretación y el análisis de datos de alta dimensionalidad, y conserva los patrones relevantes de los datos originales [3, 4]. Este artículo lo demuestra al convertir un conjunto de datos genéticos muy complejo en una representación bidimensional comprensible, que permite identificar relaciones difíciles de observar de otra forma.

Referencias

- [1] Luis Rincón. Introducción a la probabilidad. Libro en línea, 2014. URL <https://docencia.fciencias.unam.mx/lars/libros/Rinc%C3%B3n%282014%29Introducci%C3%B3n-a-la-probabilidad.pdf>. Universidad Nacional Autónoma de México, Ciudad Universitaria.
- [2] Briceyda B. Delgado López. Notas de clase, unidad 2. Material de curso no publicado, disponible en Google Drive, 2026. Maestría en Ciencia de Datos e Información, INFOTEC/MCDI.
- [3] Cristina Gil Martínez. Análisis de componentes principales (PCA). RPubS. URL https://rpubs.com/cristina_gil/pca.

- [4] Serrano.Academy. Análisis de componentes principales (PCA). Video de YouTube. URL https://www.youtube.com/watch?v=7My_PBhxeP4.
- [5] John Novembre, Toby Johnson, Katarzyna Bryc, Zoltán Kutalik, Adam R. Boyko, Adam Auton, Amit Indap, Karen S. King, Sven Bergmann, Matthew R. Nelson, Matthew Stephens, and Carlos D. Bustamante. Genes mirror geography within Europe. *Nature*, 456(7218):98–101, 2008. doi: 10.1038/nature07331.