

Unidad 2: Introducción a la Probabilidad, Método de Mínimos Cuadrados

Profesora: Briceyda B. Delgado

Materia: Matemáticas

3 de Septiembre de 2026

1 Introducción a la Probabilidad

- Axiomas de Probabilidad
- Teorema de Bayes
- Esperanza, Varianza y Covarianza

2 Método de Mínimos Cuadrados

- Aproximación por una constante
- Aproximación por una función lineal
- Aproximación por una función cuadrática

- La probabilidad es una rama de las matemáticas que estudia los fenómenos aleatorios.
- Se utiliza para cuantificar la incertidumbre en experimentos cuyos resultados no se pueden predecir con certeza.
- Ejemplos típicos incluyen lanzar una moneda, tirar un dado o predecir el clima.

- **Experimento Aleatorio:** Un proceso cuyo resultado no se puede predecir con certeza.
- **Espacio Muestral (S):** Conjunto de todos los resultados posibles de un experimento aleatorio.
- **Evento (A):** Subconjunto del espacio muestral, es decir, un conjunto de posibles resultados.
- **Probabilidad ($P(A)$):** Medida numérica que asigna la "posibilidad" de que ocurra el evento A .

Ejemplo de Probabilidad

- Supongamos que nuestro **experimento** aleatorio consiste en el lanzamiento de un dado. El **espacio muestral** es:

$$S = \{1, 2, 3, 4, 5, 6\}$$

- Si A es el **evento** "obtener un número mayor que 4", entonces el evento A consta de los elementos

$$A = \{5, 6\}.$$

Y la **probabilidad** de ocurrencia de dicho evento, está dada por

$$P(A) = \frac{2}{6} = \frac{1}{3},$$

es decir, la cardinalidad de A dividida entre la cardinalidad del espacio muestral S .

Axiomas de Probabilidad

- ❶ **Axioma 1** Sea E un evento, entonces

$$0 \leq P(E) \leq 1.$$

- ❷ **Axioma 2** La probabilidad de todo el espacio muestral es

$$P(S) = 1,$$

donde S es el espacio muestral.

- ❸ **Axioma 3** Sean $E_1, E_2, \dots, E_n$ eventos mutuamente exclusivos, es decir, $E_i \cap E_j = \emptyset$ $i \neq j$. Entonces

$$P\left(\bigcup_{i=1}^n E_i\right) = \sum_{i=1}^n P(E_i).$$

Dos consecuencias de los axiomas anteriores son: Sean E y F dos eventos, entonces

1

$$P(E^c) = 1 - P(E),$$

donde E^c representa el complemento de E .

2

$$P(E \cup F) = P(E) + P(F) - P(E \cap F).$$

Una herramienta muy útil en el cálculo de probabilidades son las conocidas **Leyes de De Morgan**:

$$(A \cup B)^c = A^c \cap B^c, \quad (A \cap B)^c = A^c \cup B^c.$$

Example

Un 50% de la población paga un servicio de telefonía, un 30% de la población paga un servicio de streaming y un 23% de la población paga ambos servicios de telefonía y streaming. ¿Qué porcentaje de la población no paga un servicio de telefonía ni tampoco de streaming?

Solución:

- 1 **Definición de los eventos:** Sean E el evento de que al elegir de forma aleatoria una persona de la población esta pague algún servicio de telefonía y sea F el que pague algún servicio de streaming.
- 2 **Identificar el problema.** El porcentaje de la población que no paga servicio de telefonía ni tampoco de streaming corresponde a calcular

$$P(E^c \cap F^c).$$

- 3 **Datos del problema y solución.** Entonces, la probabilidad de que esta persona pague algún servicio de telefonía o streaming es

$$P(E \cup F) = P(E) + P(F) - P(E \cap F) = .5 + .3 - .23 = 0.57.$$

Mientras que la probabilidad de que dicha persona no pague ningún servicio de telefonía ni tampoco de streaming se representa por $P(E^c \cap F^c)$. Por las leyes de De Morgan $(E \cup F)^c = E^c \cap F^c$, lo cual implica que

$$P((E \cup F)^c) = P(E^c \cap F^c)$$

El problema se reduce a calcular

$$P((E \cup F)^c) = 1 - P(E \cup F) = 1 - 0.57 = 0.43.$$

Definition

Dados dos eventos E y F , la **probabilidad condicional** de E dado F se define como

$$P(E|F) = \frac{P(E \cap F)}{P(F)},$$

siempre y cuando $P(F) > 0$. $E|F$ denota la ocurrencia del evento E dado que ya ocurrió el evento F .

El **Teorema de Bayes** es una fórmula que relaciona la probabilidad condicional con la probabilidad marginal.

Theorem

Dados los eventos A y B , la probabilidad condicional de que ocurra el evento A dado el evento B está dada por

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}.$$

Dado que $B = (B \cap A) \cup (B \cap A^c)$, entonces

$$\begin{aligned} P(B) &= P(B \cap A) + P(B \cap A^c) \\ &= P(B|A)P(A) + P(B|A^c)P(A^c) \end{aligned}$$

Reescribiendo, la ecuación anterior, tenemos que

$$P(A|B) = \frac{P(B|A)P(A)}{P(B|A)P(A) + P(B|A^c)P(A^c)}.$$

Este teorema es útil para actualizar las probabilidades a medida que obtenemos nueva información.

Definición de Variable Aleatoria

Una **variable aleatoria** (v.a.) es una función que asigna un número real a cada posible resultado de un experimento aleatorio.

- Una v.a. se clasifica en:
 - **Discreta**: Toma un número finito o numerable de valores.
 - **Continua**: Puede tomar cualquier valor en un intervalo de los números reales.

Example

Variable aleatorias que representan ciertos resultado de lanzamiento de dados o monedas, son ejemplos de variables aleatorias discretas. Número de caras obtenidas al lanzar una moneda tres veces.

La variable que asigna la estatura o el peso a una persona seleccionada de cierta población aleatoriamente, es un ejemplo de una variable aleatoria continua ya que teóricamente cualquier valor entre $(0, 3)$ metros es posible para la estatura y entre $(0, 700)$ kilogramos para el peso.

Example

Supongamos que lanzamos dos dados y sumamos los resultados de ambos, definimos X como la variable aleatoria que representa la suma de los resultados de los dos dados.

- El espacio muestral $\mathcal{S}$ (conjunto de resultados posibles asociados al experimento) consiste de 36 combinaciones de resultados posibles, i.e.

$$\mathcal{S} = \{(1, 1), (1, 2), \dots, (1, 6), (2, 1), (2, 2), \dots, (2, 6), \dots, (6, 1), \dots, (6, 6)\}$$

- Al sumar los resultados de ambos dados, los posibles resultados van del 2 al 12. Entonces la variable aleatoria X vista como función

$$X: \mathcal{S} \rightarrow \{2, \dots, 12\}.$$

- Por ejemplo, la probabilidad de que la suma de ambos dados sea igual a 7, se obtiene analizando las combinaciones cuya suma nos da 7:

$$(1, 6), \quad (2, 5), \quad (3, 4), \quad (4, 3), \quad (5, 2), \quad (6, 1).$$

- Entonces

$$P(X = 7) = P((1, 6) \cup (2, 5) \cup (3, 4) \cup (4, 3) \cup (5, 2) \cup (6, 1)) = \frac{6}{36} = \frac{1}{6}.$$

Definition

Sean X y Y dos variables aleatorias.

La **esperanza** (o valor esperado) de X es

- Discreta: $E[X] = \sum_i x_i P(X = x_i)$, donde la suma es sobre todo los valores discretos que toma la variable X .
- Continua: $E[X] = \int_{-\infty}^{\infty} xf(x)dx$,

donde f es la función de densidad de probabilidad de X .

La **varianza** de X es:

$$\text{Var}(X) = E[(X - E[X])^2] = E[X^2] - (E[X])^2.$$

La **covarianza** entre dos variables aleatorias X e Y está dada por

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])].$$

Método de Mínimos cuadrados

Suponga que tenemos un conjunto de datos discreto (t_i, y_i) ,
 $i = 1, 2, 3, \dots, n$.

¿Cómo podemos determinar una función $p(t)$ que aproxime al conjunto de datos en el siguiente sentido?

$$p(t_i) \approx y_i \quad \text{para} \quad i = 1, 2, \dots$$

La idea que seguiremos es la de calcular la mejor aproximación en términos de mínimos cuadrados. En resumen, queremos calcular una función sencilla (lineal, cuadrática, etc) tal que minimice las distancias entre las aproximaciones y los datos. Ya que dicha aproximación se basa en los cuadrados de las distancias, el nombre de este método es **método de mínimos cuadrados**.

Modelo de la temperatura media anual

Consideremos un conjunto de datos que representa el cambio en la temperatura media de 1856 al año 2000. Primero nos concentraremos en modelar la temperatura anual promedio entre los años 1991 y 2000. Los datos se muestran en la siguiente tabla.

Año	Año computacional	Desviación de la temperatura
1991	1	0.29
1992	2	0.14
1993	3	0.19
1994	4	0.26
1995	5	0.28
1996	6	0.22
1997	7	0.43
1998	8	0.59
1999	9	0.33
2000	10	0.29

Table 1: Desviación global de la temperatura media anual medida en grados centígrados por años

Aproximación por una constante

La aproximación más sencilla es la de una constante, es decir,

$$p = p(t) = \alpha,$$

donde buscamos una constante α tal que minimice la suma de los cuadrados de las diferencias con los valores observados.

$$\min_{\alpha} \sum_{i=1}^n (y_i - \alpha)^2$$

Consideremos la función

$$F(\alpha) = \sum_{i=1}^n (y_i - \alpha)^2,$$

donde F mide la desviación total de α al conjunto de datos (t_i, y_i) .

Derivando la función e igualando a cero, tenemos que el valor óptimo de la **función constante** α es simplemente el promedio de los valores y_i :

$$\alpha = \frac{1}{n} \sum_{i=1}^n y_i$$

Para verificar que efectivamente se trata de un mínimo relativo, observe que

$$F''(\alpha) = 2 \sum_{i=1}^n 1 = 20 > 0.$$

Así, con los datos del problema (véase Tabla 1) de la temperatura tenemos que la función constante es

$$\begin{aligned} \alpha &= \frac{1}{10} \sum_{i=1}^{10} y_i = \frac{1}{10} (0.29 + 0.14 + 0.19 + 0.26 + 0.28 + 0.22 + 0.43 \\ &\quad + 0.59 + 0.33 + 0.29) = 0.312 \end{aligned}$$




Fig. 5.8 Two constant approximations of the global annual mean temperature deviation measurements (relative to the 1961–1990 mean); from year 1991 to 2000

Aproximación por una función lineal

Ahora consideramos una función lineal $p(t) = \alpha + \beta t$ que minimice la suma de los errores cuadrados. El problema es:

$$\min_{\alpha, \beta} \sum_{i=1}^n (\alpha + \beta t_i - y_i)^2.$$

Análogamente, consideramos la función de dos variables:

$$F(\alpha, \beta) = \sum_{i=1}^n (\alpha + \beta t_i - y_i)^2$$

Recordemos, queremos minimizar F con respecto a las variables α y β . Entoces una condición necesaria es

$$\frac{\partial F}{\partial \alpha} = 0, \quad \frac{\partial F}{\partial \beta} = 0.$$

Derivando, tenemos que

$$\frac{\partial F}{\partial \alpha} = 2 \sum_{i=1}^n (\alpha + \beta t_i - y_i) = 0$$

$$\frac{\partial F}{\partial \beta} = 2 \sum_{i=1}^n (\alpha + \beta t_i - y_i) t_i = 0$$

Para encontrar α y β , resolvemos las siguientes ecuaciones normales:

$$\begin{aligned} n\alpha + \beta \sum t_i &= \sum y_i, \\ \alpha \sum t_i + \beta \sum t_i^2 &= \sum t_i y_i. \end{aligned}$$

El cual podemos reescribir el forma matricial como sigue

$$\begin{pmatrix} n & \sum t_i \\ \sum t_i & \sum t_i^2 \end{pmatrix} \begin{pmatrix} \alpha \\ \beta \end{pmatrix} = \begin{pmatrix} \sum y_i \\ \sum t_i y_i \end{pmatrix}$$

Resolviendo, tenemos que los coeficientes de la **función lineal** buscada son

$$\begin{pmatrix} \alpha \\ \beta \end{pmatrix} = \begin{pmatrix} n & \sum t_i \\ \sum t_i & \sum t_i^2 \end{pmatrix}^{-1} \begin{pmatrix} \sum y_i \\ \sum t_i y_i \end{pmatrix}$$

Regresando a nuestro ejemplo, tenemos que

$$\sum_{i=1}^{10} t_i = 1 + 2 + \cdots + 10 = 55,$$

$$\sum_{i=1}^{10} y_i = 0.29 + 0.14 + \cdots + 0.29 = 3.12,$$

$$\sum_{i=1}^{10} t_i^2 = 1^2 + 2^2 + \cdots + 10^2 = 385$$

$$\sum_{i=1}^{10} t_i y_i = 1(0.29) + 2(2.014) + \cdots + 10(0.29) = 20$$

Sustituyendo en la matriz, tenemos que

$$\begin{pmatrix} 10 & 55 \\ 55 & 385 \end{pmatrix}^{-1} = \frac{1}{825} \begin{pmatrix} 385 & -55 \\ -55 & 10 \end{pmatrix}$$

Así,

$$\begin{pmatrix} \alpha \\ \beta \end{pmatrix} = \frac{1}{825} \begin{pmatrix} 385 & -55 \\ -55 & 19 \end{pmatrix} \begin{pmatrix} 3.12 \\ 20 \end{pmatrix} \approx \begin{pmatrix} 0.123 \\ 0.034 \end{pmatrix}$$

Así, la función lineal buscada es

$$p(t) = 0.123 + 0.034 t.$$




Fig. 5.1 A set of discrete data marked by *small circles* and a linear function $p = p(t)$ represented by the *solid line*

Aproximación por una función cuadrática

En este caso buscamos una función de la forma $p(t) = \alpha + \beta t + \gamma t^2$ que minimice la suma de los errores cuadrados:

$$\min_{\alpha, \beta, \gamma} \sum_{i=1}^n (\alpha + \beta t_i + \gamma t_i^2 - y_i)^2$$

La función a minimizar es

$$F(\alpha, \beta, \gamma) = \sum_{i=1}^n (\alpha + \beta t_i + \gamma t_i^2 - y_i)^2.$$

Las ecuaciones normales resultantes son más complejas, pero pueden resolverse usando álgebra lineal.

Como resultado de

$$\frac{\partial F}{\partial \alpha} = \frac{\partial F}{\partial \beta} = \frac{\partial F}{\partial \gamma} = 0.$$

Obtenemos el sistema

$$\begin{pmatrix} n & \sum t_i & \sum t_i^2 \\ \sum t_i & \sum t_i^2 & \sum t_i^3 \\ \sum t_i^2 & \sum t_i^3 & \sum t_i^4 \end{pmatrix} \begin{pmatrix} \alpha \\ \beta \\ \gamma \end{pmatrix} = \begin{pmatrix} \sum y_i \\ \sum y_i t_i \\ \sum y_i t_i^2 \end{pmatrix}$$

Entonces, los coeficientes de la **función cuadrática** buscada son

$$\begin{pmatrix} \alpha \\ \beta \\ \gamma \end{pmatrix} = \begin{pmatrix} n & \sum t_i & \sum t_i^2 \\ \sum t_i & \sum t_i^2 & \sum t_i^3 \\ \sum t_i^2 & \sum t_i^3 & \sum t_i^4 \end{pmatrix}^{-1} \begin{pmatrix} \sum y_i \\ \sum y_i t_i \\ \sum y_i t_i^2 \end{pmatrix}$$

Así, regresando a los datos de nuestro ejemplo inicial

$$\begin{pmatrix} \alpha \\ \beta \\ \gamma \end{pmatrix} = \begin{pmatrix} 10 & 55 & 385 \\ 55 & 385 & 3025 \\ 385 & 3025 & 25330 \end{pmatrix}^{-1} \begin{pmatrix} 3.12 \\ 20 \\ 138.7 \end{pmatrix} \approx \begin{pmatrix} -0.4078 \\ 0.2997 \\ -0.0241 \end{pmatrix}$$

Así, la función cuadrática buscada es

$$p(t) = -0.4078 + 0.2997 t - 0.0241 t^2.$$




Fig. 5.2 A set of discrete data marked by *small circles* and a quadratic function $p = p(t)$ represented by the *solid curve*