

Materia: Matemáticas para la Ciencia de Datos

Docente: Briceyda B. Delgado

Tarea 2.

Lea el archivo **Formato de tareas** que se encuentra en la siguiente liga <https://drive.google.com/drive/u/0/folders/1F-FI1J5PviBc-EPhfLbnE8PSvWnkgeHj>. En la siguiente lista de ejercicios NO se admite ningún tipo de código en la solución de los ejercicios, cada uno de ellos se puede resolver de forma analítica. La única excepción es el ejercicio 5, donde se indica sea resuelto usando el paquete R. Párrafos que contengan código en la entrega no se van a considerar en la calificación.

1. (15 puntos) La función de densidad de una variable aleatoria está dada por

$$f(x) = \begin{cases} a + bx^2, & 0 \leq x \leq 1, \\ 0, & \text{en otro caso.} \end{cases}$$

Si la esperanza es $E(X) = \frac{3}{5}$. Encuentre a y b .

2. (10 puntos) La estatura de las mujeres adultas en Estados Unidos se distribuye normalmente con media de $\mu = 64.5$ pulgadas y desviación estándar de $\sigma = 2.4$ pulgadas. Hallar la probabilidad de que una mujer elegida al azar mida
 - (a) mida menos de 63 pulgadas;
 - (b) mida entre 63 y 70 pulgadas.
 - (c) Alice mide 72 pulgadas. ¿Qué porcentaje de mujeres mide menos que Alicia?
3. (25 puntos) Realice un análisis de las temperaturas promedio de uno de los 32 estados de México de los años 1993 al 2023 aproximando a través del método de mínimos cuadrados para el caso lineal, cuadrático y cúbico. El caso lineal y cuadrático se explicaron en clase, para en caso cúbico es necesario utilizar el mismo razonamiento y deducir las fórmulas resultantes. Explicar paso a paso el método.

Los estados y el periodo se asignarán de forma personalizada, veáse el final del archivo. Los datos provienen del Servicio Meteorológico Nacional

<https://smn.conagua.gob.mx/es/8-smn-general>

De click en la pestaña Climatología, seguido de Temperaturas y Lluvia, luego selecciones la opción Resúmenes mensuales de Temperaturas y Lluvia.

4. (10 puntos) El cáncer de próstata es el más frecuente entre los varones. Como indicador de si un varón padece cáncer de próstata, los médicos suelen realizar una prueba que mide el nivel de la proteína PSA (antígeno prostático específico) que sólo produce la glándula prostática. Aunque unos niveles más altos de PSA son indicativos de cáncer, la prueba es muy poco fiable. De hecho, la probabilidad de que un hombre no canceroso tenga un nivel elevado de PSA es de aproximadamente 0,135, probabilidad que aumenta a aproximadamente 0,268 si el hombre tiene cáncer. Si, basándose en otros factores, un médico está seguro en un 65 % de que un varón tiene cáncer de próstata, ¿cuál es la probabilidad condicional de que tenga cáncer si
- (a) la prueba indica un nivel elevado de PSA?,
 - (b) la prueba no indica un nivel elevado de PSA?

Sugerencia: Aplique el Teorema de Bayes.

5. (25 puntos) Realice un análisis de componentes principales (PCA por sus siglas en inglés) aplicado a la base de datos **USArrests** del paquete básico de R que contiene el porcentaje de asaltos (Assault), asesinatos (Murder) y secuestros (Rape) por cada 100,000 habitantes para cada uno de los 50 estados de USA (1973). Además, también incluye el porcentaje de la población de cada estado que vive en zonas rurales (UrbanPoP). En este caso, el número de variables es $p = 4$ y el número de observaciones es $n = 50$.
- (a) Centralice las variables para que estas tengan media cero. Muestre los resultados en una tabla.
 - (b) Calcule la matriz de covarianza. En caso de obtener una variabilidad muy alta, primero estandarice para tener una desviación estándar igual a 1.
 - (c) Encuentre los eigenvalores y los eigenvectores de la matriz de covarianza.
 - (d) Tomando la mayor cantidad de componentes principales $\min(n - 1, p) = \min(49, 4) = 4$. Calcule los componentes principales y

grafique de forma bidimensional a las primeras dos componentes principales.

(e) Interprete la información que representa cada componente principal.

6. (15 puntos) Lea el artículo Genes mirror geography within Europe, que se encuentra en la carpeta de referencias compartida de Drive. <https://drive.google.com/drive/u/0/folders/1F-FI1J5PviBc-EPhfLbnE8PSvWnkgeHj>

Explique de forma resumida de qué se trata el artículo y realice un conclusión de cómo el algoritmo de componentes principales es de gran utilidad en la reducción de la dimensionalidad.

Asignación de los estados:

1. Jovanna del Rocio Aguilar López — — — — — >Aguascalientes
2. Gonzalo Emmanuel Collada Felix — — — — — > Baja California
3. Mario Duran Bustamante — — — — — >Baja California Sur
4. Yoshua Espinoza Palacios — — — — — >Campeche
5. Mario Galvan Rosales — — — — — >Chiapas
6. Luis Angel Garcia Amos — — — — — >Chihuahua
7. Lael Gutiérrez Flores — — — — — >Ciudad de México
8. Javier López Rojas — — — — — >Coahuila
9. Bruno Santiago Mendoza Flores — — — — — >Colima
10. Andrés Rangel García — — — — — >Durango
11. Bryan Rodriguez Abarca — — — — — > Estado de México
12. David Alejandro Rodriguez Rios — — — — — >Guanajuato
13. Rodrigo Romero Gregorio — — — — — >Guerrero
14. Carlos Enrique Romero Martínez — — — — — >Hidalgo
15. Claudia Lizbeth Romero Villalpando — — — — — >Jalisco
16. Maria Vanessa Santos Arroyo — — — — — > Michoacán
17. Luis Fernando Talavera Rivera — — — — — >Morelos
18. Giovanni Vargas Palacios — — — — — >Nayarit
19. Carlos Enrique Vázquez Juárez — — — — — > Nuevo León
20. Axel Vázquez Sánchez — — — — — > Oaxaca