Maestría en Ciencia de Datos e Información

Tarea 3

Matemáticas

Alumno: Eduardo Alanís García
Profesora: Dra. Briceyda B. Delgado López
Entrega: 29 de octubre de 2026

INFOTEC

Instrucciones

Los procedimientos se desarrollan de forma analítica y ordenada. El código se utiliza únicamente en el ejercicio 6, donde está permitido.

Herramientas utilizadas

Todos los ejercicios se desarrollaron de manera analítica y el documento se elaboró con LaTeX. El único apartado en el que se permitió el uso de código, el Ejercicio 6, se realizó con **R**.

Ejercicios

Ejercicio 1 (15 puntos). Considere la función $f(x, y) = x^4 + y^4 - 4xy + 2x^2 + 2y^2$.

(a) Calcule el gradiente de f.

Solución. Derivando parcialmente con respecto a x y a y se obtiene

$$\nabla f(x, y) = \begin{pmatrix} 4x^3 - 4y + 4x \\ 4y^3 - 4x + 4y \end{pmatrix}.$$

[1, diapositiva 5; 2, Secciones 14.3 y 14.6].

(b) Calcule la matriz Hessiana de f.

Solución. Las segundas derivadas parciales son

$$f_{xx} = 12x^2 + 4, \qquad f_{xy} = f_{yx} = -4, \qquad f_{yy} = 12y^2 + 4,$$

por lo tanto, la matriz Hessiana es

$$H_f(x, y) = \begin{pmatrix} 12x^2 + 4 & -4 \\ -4 & 12y^2 + 4 \end{pmatrix}.$$

[1, diapositiva 6; 2, Sección 14.7].

(c) Determine los puntos críticos de f.

Solución. Para encontrar los puntos críticos igualamos el gradiente a cero [1, diapositiva 5]:

$$\begin{cases} 4x^3 - 4y + 4x = 0, \\ 4y^3 - 4x + 4y = 0. \end{cases} \iff \begin{cases} y = x^3 + x, \\ x = y^3 + y. \end{cases}$$

Al sumar las ecuaciones $x^3 = y - x$ y $y^3 = x - y$, obtenemos

$$x^3 + y^3 = 0 \iff (x + y)(x^2 - xy + y^2) = 0.$$

Si $x^2 - xy + y^2 = 0$, entonces $x = y = 0$. En el otro caso, $y = -x$ y, usando $y = x^3 + x$,

$$-x = x^3 + x \quad \Longleftrightarrow \quad x(x^2 + 2) = 0.$$

Como $x^2 + 2 > 0 \; \forall x \in \mathbb{R}$, se obtiene $x = 0$ y, por consiguiente, $y = 0$. El único punto crítico es $(0, 0)$.

(d) Analice cada punto crítico utilizando la matriz Hessiana y clasifíquelo como mínimo, máximo o punto de silla.

Solución. El único punto crítico es $(0, 0)$, en ese punto la Hessiana vale

$$H_f(0,0) = \begin{pmatrix} 4 & -4 \\ -4 & 4 \end{pmatrix}, \qquad \det H_f(0,0) = 0.$$

Sus valores propios son 0 y 8, por lo que la Hessiana es semidefinida positiva, pero el criterio de la Hessiana no permite clasificar el punto porque su determinante es cero. Para concluir, reescribimos la función:

$$f(x,y) = x^4 + y^4 - 4xy + 2x^2 + 2y^2 = x^4 + y^4 + 2(x-y)^2 \geq 0.$$

La igualdad se cumple únicamente cuando $x = y = 0$. Por lo tanto, $(0, 0)$ es un mínimo estricto global [1, diapositivas 7–10; 2, Sección 14.7].

Ejercicio 2 (20 puntos)**.** Considere la función

$$f(x,y) = x^2 + xy + y^2 + 3x$$

(a) Encuentra el mínimo (o mínimos) analíticamente. ¿Son mínimos globales o relativos?

Solución. El gradiente y la Hessiana son

$$\nabla f(x,y) = \begin{pmatrix} 2x + y + 3 \\ x + 2y \end{pmatrix}, \qquad H_f(x,y) = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

Al resolver $\nabla f = \vec{0}$, de $x + 2y = 0$ obtenemos $x = -2y$. Sustituyendo en $2x + y + 3 = 0$,

$$-4y + y + 3 = 0 \quad \Longrightarrow \quad y = 1, \qquad x = -2.$$

Los valores propios de la Hessiana son 1 y 3, ambos positivos [1, diapositivas 7–10]. Como la Hessiana es constante, es definida positiva en todo $\mathbb{R}^2$ y, por lo tanto, f es estrictamente convexa [3, Capítulo 2]. Así, el único punto crítico $(-2, 1)$ es un mínimo global, y su valor es

$$f(-2,1) = 4 - 2 + 1 - 6 = -3.$$

Otra forma de verificar que se trata de un mínimo global es expresar la función de la siguiente manera:

$$\begin{aligned}
f(x,y) &= x^2 + xy + y^2 + 3x \\
&= x^2 + x(y+3) + y^2 \\
&= \left(x + \frac{y+3}{2}\right)^2 - \frac{(y+3)^2}{4} + y^2 \\
&= \left(x + \frac{y+3}{2}\right)^2 + \frac{4y^2 - (y+3)^2}{4} \\
&= \left(x + \frac{y+3}{2}\right)^2 + \frac{3}{4}(y^2 - 2y - 3) \\
&= \left(x + \frac{y+3}{2}\right)^2 + \frac{3}{4}(y^2 - 2y + 1 - 4) \\
&= \left(x + \frac{y+3}{2}\right)^2 + \frac{3}{4}\left[(y-1)^2 - 4\right] \\
&= \left(x + \frac{y+3}{2}\right)^2 + \frac{3}{4}(y-1)^2 - 3 \\
&= -3 + \left(x + \frac{y+3}{2}\right)^2 + \frac{3}{4}(y-1)^2.
\end{aligned}$$

Como los términos cuadrados son no negativos, se cumple que

$$f(x,y) \geq -3 \qquad \text{para todo } (x,y) \in \mathbb{R}^2.$$

Por lo tanto, la función tiene un mínimo global único en el punto $(-2,1)$, cuyo valor mínimo es $f(-2,1) = -3$.

(b) Construye cuatro curvas de nivel de $f(x,y)$ [líneas de valor constante de $f(x,y)$].

Solución. Utilizando la expresión obtenida en el inciso anterior, podemos escribir

$$\begin{aligned}
f(x,y) &= -3 + \left(x + 2 + \frac{y-1}{2}\right)^2 + \frac{3}{4}(y-1)^2 \\
&= -3 + (x+2)^2 + (x+2)(y-1) + \frac{(y-1)^2}{4} + \frac{3}{4}(y-1)^2 \\
&= -3 + (x+2)^2 + (x+2)(y-1) + (y-1)^2.
\end{aligned}$$

Por lo tanto, la función puede expresarse de la siguiente manera:

$$f(x,y) = x^2 + xy + y^2 + 3x = -3 + (x+2)^2 + (x+2)(y-1) + (y-1)^2.$$

Las curvas de nivel de la función están dadas por la ecuación [2, Sección 14.1] $f(x,y) = c$. Al sustituir la expresión anterior, obtenemos

$$(x+2)^2 + (x+2)(y-1) + (y-1)^2 = c + 3.$$

Como el valor mínimo de la función es $f(-2,1) = -3$, para obtener curvas de nivel debemos elegir valores de $c > -3$. En particular, si tomamos $c = -2, -1, 0, 4$, obtenemos las siguientes ecuaciones:

$$\begin{aligned}(x+2)^2 + (x+2)(y-1) + (y-1)^2 &= 1,\\ (x+2)^2 + (x+2)(y-1) + (y-1)^2 &= 2,\\ (x+2)^2 + (x+2)(y-1) + (y-1)^2 &= 3,\\ (x+2)^2 + (x+2)(y-1) + (y-1)^2 &= 7.\end{aligned}$$

(c) ¿Es la búsqueda univariante un buen método numérico para encontrar el óptimo de $f(x,y)$? Justifique su respuesta.

Solución. Sí, es un buen método, porque f es cuadrática y está bien escalada: su Hessiana $H_f = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$ tiene valores propios 1 y 3, cuyo cociente es 3, un valor pequeño, por lo que las curvas de nivel son elipses poco alargadas. Lo importante es elegir bien las direcciones de búsqueda [4, Secciones 5.2–5.3].

(d) Supongamos que la dirección de búsqueda viene dada por $\vec{s} = [1,0]$. Si inicializamos en el punto $(0,0)$, encuentra el punto óptimo P_1 en esa dirección de búsqueda analíticamente, no numéricamente.

Solución. La recta de búsqueda que pasa por $(0,0)$ con dirección $\vec{s} = [1,0]$ es $(x,y) = (\lambda, 0)$ con $\lambda \in \mathbb{R}$, pues el óptimo se busca sobre toda la recta [4, Sección 5.2]:

$$f(\lambda, 0) = \lambda^2 + 3\lambda.$$

Derivando e igualando a cero,

$$2\lambda + 3 = 0 \quad \Longrightarrow \quad \lambda = -\frac{3}{2}.$$

Por lo tanto, $P_1 = (-\frac{3}{2}, 0)$.

(e) Repita el ejercicio para un punto de partida de $(0,4)$ para encontrar P_2.

Solución. La recta de búsqueda es $(x,y) = (\lambda, 4)$. En ella,

$$f(\lambda, 4) = \lambda^2 + 7\lambda + 16.$$

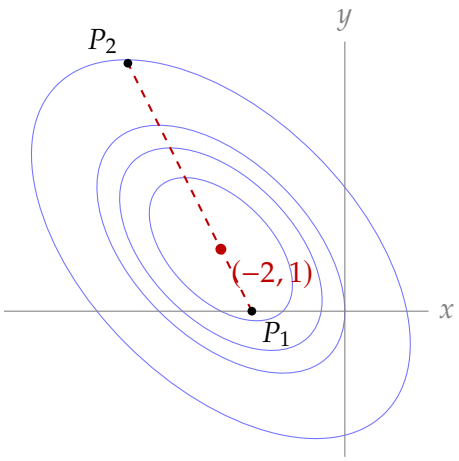
De $2\lambda + 7 = 0$ resulta $\lambda = -\frac{7}{2}$; por tanto, $P_2 = (-\frac{7}{2}, 4)$.

(f) Demuestre gráficamente que una recta que une P_1 y P_2, pasa por el óptimo.

Solución. La pendiente de la recta que pasa por $P_1 = (-\frac{3}{2}, 0)$ y $P_2 = (-\frac{7}{2}, 4)$ es

$$m = \frac{4-0}{-\frac{7}{2}+\frac{3}{2}} = -2,$$

así que su ecuación es $y = -2x - 3$. El óptimo $(-2, 1)$ satisface esta ecuación. La figura muestra las cuatro curvas de nivel, los puntos P_1 y P_2, la recta que los une y el mínimo.



Ejercicio 3 (15 puntos). Dada la función $h(x, y, z) = x^2 + y^2 + z^2$ sujeta a la restricción $x + y + z = 1$:

(a) Encuentre los puntos estacionarios utilizando el método de multiplicadores de Lagrange.

Solución. Definimos el Lagrangiano

$$L(x, y, z, \lambda) = x^2 + y^2 + z^2 - \lambda(x + y + z - 1).$$

Las derivadas parciales son

$$\begin{cases} \frac{\partial L}{\partial x} = 2x - \lambda = 0, \\ \frac{\partial L}{\partial y} = 2y - \lambda = 0, \\ \frac{\partial L}{\partial z} = 2z - \lambda = 0, \\ \frac{\partial L}{\partial \lambda} = -(x + y + z - 1) = 0. \end{cases}$$

De las primeras tres ecuaciones se obtiene $x = y = z = \lambda/2$. Sustituyendo en la restricción,

$$3\frac{\lambda}{2} = 1 \quad \Longrightarrow \quad \lambda = \frac{2}{3}, \qquad x = y = z = \frac{1}{3}.$$

El único punto estacionario es $(\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$, con $\lambda = \frac{2}{3}$ [1, diapositivas 11–13; 2, Sección 14.8].

(b) Verifique si los puntos encontrados son máximos o mínimos utilizando la Hessiana del Lagrangiano.

Solución. La Hessiana del Lagrangiano respecto de (x, y, z) es

$$H_L = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 2 \end{pmatrix},$$

y el gradiente de la restricción es $\nabla g = (1, 1, 1)$. La matriz Hessiana orlada es

$$B = \begin{pmatrix} 0 & \nabla g \\ \nabla g^\top & H_L \end{pmatrix} = \begin{pmatrix} 0 & 1 & 1 & 1 \\ 1 & 2 & 0 & 0 \\ 1 & 0 & 2 & 0 \\ 1 & 0 & 0 & 2 \end{pmatrix}.$$

Sea Δ_2^B el determinante del bloque formado por las tres primeras filas y columnas, y $\Delta_3^B = \det B$:

$$\Delta_2^B = \begin{vmatrix} 0 & 1 & 1 \\ 1 & 2 & 0 \\ 1 & 0 & 2 \end{vmatrix} = -4 < 0, \qquad \Delta_3^B = \begin{vmatrix} 0 & 1 & 1 & 1 \\ 1 & 2 & 0 & 0 \\ 1 & 0 & 2 & 0 \\ 1 & 0 & 0 & 2 \end{vmatrix} = -12 < 0.$$

El criterio establece que si $\Delta_k^B < 0$ para todo k, es decir, si todos los menores orlados son negativos, el punto es un *mínimo local restringido* [1, diapositivas 14–16]. Como $\Delta_2^B < 0$ y $\Delta_3^B < 0$, concluimos que

$$P = \left(\tfrac{1}{3}, \tfrac{1}{3}, \tfrac{1}{3}\right)$$

es un mínimo local restringido, con valor $h(P) = 3 \cdot \frac{1}{9} = \frac{1}{3}$. Además, como f es convexa y la restricción es lineal, este minimo es *global* [1, diapositiva 22].

Ejercicio 4 (10 puntos)**.** Aplique el método de gradiente descendente para minimizar la función

$$f(x, y) = x^2 + 2y^2 - xy - 6x - 8y$$

partiendo del punto inicial $(x_0, y_0) = (0, 0)$.

(a) Use un tamaño de paso constante $\alpha = 0.1$.

Solución. El gradiente de la función es

$$\nabla f(x, y) = \begin{pmatrix} 2x - y - 6 \\ 4y - x - 8 \end{pmatrix}.$$

La actualización del gradiente descendente es

$$\begin{aligned} x_{k+1} &= x_k - 0.1(2x_k - y_k - 6) = 0.8x_k + 0.1y_k + 0.6, \\ y_{k+1} &= y_k - 0.1(4y_k - x_k - 8) = 0.1x_k + 0.6y_k + 0.8. \end{aligned}$$

(b) Realice al menos 5 iteraciones y analice la convergencia.

Solución. Aplicando estas expresiones desde $(0,0)$, se obtienen las siguientes iteraciones:

k	x_k	y_k	$f(x_k, y_k)$
0	0.00000	0.00000	0.000000
1	0.60000	0.80000	−8.840000
2	1.16000	1.34000	−14.297600
3	1.66200	1.72000	−17.911596
4	2.10160	1.99820	−20.392288
5	2.48110	2.20908	−22.124262

Para identificar el punto al que converge el método, igualamos el gradiente a cero:

$$\begin{cases} 2x - y - 6 = 0, \\ 4y - x - 8 = 0. \end{cases} \quad \Longrightarrow \quad (x^*, y^*) = \left(\frac{32}{7}, \frac{22}{7}\right), \qquad f(x^*, y^*) = -\frac{184}{7} \approx -26.2857$$

La Hessiana constante es

$$H_f = \begin{pmatrix} 2 & -1 \\ -1 & 4 \end{pmatrix},$$

con valores propios $3 - \sqrt{2}$ y $3 + \sqrt{2}$. Como ambos son positivos, la Hessiana es definida positiva y f es estrictamente convexa; en consecuencia, $z^* = (x^*, y^*) = (32/7, 22/7)$ es el mínimo global.

Para una función cuadrática estrictamente convexa, el gradiente descendente con paso constante converge si $0 < \alpha < 2/\lambda_{\max}$ [4, Sección 5.13]. Aquí

$$0.1 < \frac{2}{3 + \sqrt{2}} \approx 0.453,$$

así que las iteraciones convergen al mínimo global. Esto es consistente con la tabla, donde $f(x_k, y_k)$ disminuye en cada iteración.

Ejercicio 5 (15 puntos). Verifique que la matriz Hessiana de la siguiente función

$$f(x, y) = (1.5 - x(1 - y))^2 + (2.25 - x(1 - y^2))^2 + (2.625 - x(1 - y^3))^2,$$

no es positiva definida en una vecindad del punto $(0, 1)$.

Solución. Para abreviar las operaciones, consideramos

$$\begin{aligned} r_1(x, y) &= 1.5 - x(1 - y), \\ r_2(x, y) &= 2.25 - x(1 - y^2), \\ r_3(x, y) &= 2.625 - x(1 - y^3). \end{aligned}$$

Así,

$$f(x, y) = r_1^2 + r_2^2 + r_3^2 = \sum_{i=1}^{3} r_i^2.$$

Derivando r_1, r_2, r_3 respecto a x y a y:

$$\begin{aligned}
\frac{\partial r_1}{\partial x} &= y - 1, & \frac{\partial r_1}{\partial y} &= x, \\
\frac{\partial r_2}{\partial x} &= y^2 - 1, & \frac{\partial r_2}{\partial y} &= 2xy, \\
\frac{\partial r_3}{\partial x} &= y^3 - 1, & \frac{\partial r_3}{\partial y} &= 3xy^2.
\end{aligned}$$

Por la regla de la cadena, $\frac{\partial}{\partial x}(r_i^2) = 2r_i \frac{\partial r_i}{\partial x}$, y lo mismo para y. Entonces

$$f_x(x, y) = 2r_1(y - 1) + 2r_2(y^2 - 1) + 2r_3(y^3 - 1).$$

Para f_y:

$$f_y(x, y) = 2r_1\, x + 2r_2\,(2xy) + 2r_3\,(3xy^2) = 2x\left(r_1 + 2y\, r_2 + 3y^2\, r_3\right).$$

Sustituyendo $x = 0$, $y = 1$:

$$\begin{aligned}
r_1(0, 1) &= 1.5, \\
r_2(0, 1) &= 2.25, \\
r_3(0, 1) &= 2.625.
\end{aligned}$$

Además, $y - 1 = y^2 - 1 = y^3 - 1 = 0$ y $x = 2xy = 3xy^2 = 0$; es decir, todas las derivadas parciales de r_1, r_2, r_3 se anulan en $(0, 1)$. En consecuencia, $f_x(0, 1) = 0$ y $f_y(0, 1) = 0$, o sea,

$$\nabla f(0, 1) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Por lo tanto, $(0, 1)$ es un punto estacionario.

Derivada f_{xx}. Los factores $(y - 1)$, $(y^2 - 1)$ y $(y^3 - 1)$ no dependen de x, y $\frac{\partial r_i}{\partial x}$ es justamente cada uno de ellos:

$$\begin{aligned}
f_{xx}(x, y) &= 2(y - 1)(y - 1) + 2(y^2 - 1)(y^2 - 1) + 2(y^3 - 1)(y^3 - 1) \\
&= 2\left[(y - 1)^2 + (y^2 - 1)^2 + (y^3 - 1)^2\right].
\end{aligned}$$

Derivada f_{yy}. Sea $g = r_1 + 2y\, r_2 + 3y^2\, r_3$, de modo que $f_y = 2x\, g$. Como $2x$ no depende de y, se tiene $f_{yy} = 2x\, g_y$. Al derivar g respecto a y hay que usar la regla del producto en los términos $2y\, r_2$ y $3y^2\, r_3$:

$$g_y = x + 2r_2 + 2y(2xy) + 6y\, r_3 + 3y^2(3xy^2).$$

Por lo tanto,

$$f_{yy}(x, y) = 2x\left[x + 2r_2 + 2y(2xy) + 6y\, r_3 + 3y^2(3xy^2)\right].$$

Derivada f_{xy}. Derivamos f_x respecto a y con la regla del producto:

$$\begin{aligned} f_{xy}(x,y) &= 2\big[x(y-1)+r_1\big] + 2\big[2xy(y^2-1)+2y\,r_2\big] + 2\big[3xy^2(y^3-1)+3y^2\,r_3\big] \\ &= 2\left(r_1 + 2y\,r_2 + 3y^2\,r_3\right) + 2x\left[(y-1)+2y(y^2-1)+3y^2(y^3-1)\right]. \end{aligned}$$

Evaluar en $(0,1)$.

$$\begin{aligned} &f_{xx}(0,1) = 2[0+0+0] = 0, \\ &f_{yy}(0,1) = 0 \qquad \text{(pues el factor } 2x \text{ vale } 0), \\ &f_{xy}(0,1) = 2\,(1\cdot 1.5 + 2\cdot 2.25 + 3\cdot 2.625) = 2(1.5+4.5+7.875) = 2(13.875) = \frac{111}{4}. \end{aligned}$$

En f_{xy}, el segundo sumando se anula porque $x = 0$. Con estos valores,

$$H_f(0,1) = \begin{pmatrix} 0 & \frac{111}{4} \\ \frac{111}{4} & 0 \end{pmatrix}, \qquad \det H_f(0,1) = 0\cdot 0 - \left(\frac{111}{4}\right)^2 = -\left(\frac{111}{4}\right)^2 < 0.$$

Los valores propios cumplen $\lambda^2 - \left(\frac{111}{4}\right)^2 = 0$, es decir, $\lambda = \pm\frac{111}{4}$. Hay uno positivo y otro negativo, así que $H_f(0,1)$ es indefinida y el punto $(0,1)$ es un punto silla [1, diapositivas 7–10].

La función $\det H_f(x,y) = f_{xx}f_{yy} - f_{xy}^2$ es un polinomio en x, y, por lo que es continua. Como es negativa en $(0,1)$, la continuidad garantiza que conserva ese signo cerca de $(0,1)$. Es decir, existe una vecindad de $(0,1)$ en la que el determinante permanece negativo. Lo que implica, la Hessiana no es positiva definida en esa vecindad.

(a) ¿Qué pasará con el método de Newton si lo tomamos como punto inicial?

Solución. El método de Newton para optimización consiste en aplicar la iteración de Newton para sistemas de ecuaciones $F(x) = 0$ a $F(x) = \nabla f(x)$, tomando como Jacobiano a la Hessiana H_f. Newton genera una sucesión de puntos mediante

$$\mathbf{x}_{k+1} = \mathbf{x}_k - H_f(\mathbf{x}_k)^{-1}\nabla f(\mathbf{x}_k),$$

siempre que la matriz Hessiana sea invertible [5; 3, Capítulo 7].

Si tomamos como punto inicial $\mathbf{x}_0 = (0,1)^T$, entonces

$$\nabla f(0,1) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \qquad H_f(0,1) = \begin{pmatrix} 0 & \frac{111}{4} \\ \frac{111}{4} & 0 \end{pmatrix}.$$

Aunque la Hessiana es invertible, no es positiva definida, pues sus valores propios son $\lambda_1 = \frac{111}{4}$ y $\lambda_2 = -\frac{111}{4}$. Esto indica que el punto estacionario no es un mínimo local, sino un punto de silla.

Al sustituir en la iteración de Newton obtenemos

$$\mathbf{x}_1 = \mathbf{x}_0 - H_f(\mathbf{x}_0)^{-1} \begin{pmatrix} 0 \\ 0 \end{pmatrix} = \mathbf{x}_0.$$

Por tanto, las iteraciones posteriores permanecen en el mismo punto:

$$\mathbf{x}_k = (0,1)^T, \qquad k \geq 0.$$

En consecuencia, el método de Newton se estanca en un punto estacionario que no es óptimo.

(b) Por otro lado, si iniciamos en el punto $(0,1)$, ¿qué procedimiento se puede llevar a cabo para que el método Newton o de quasi-Newton continúe con sus búsquedas hasta alcanzar el óptimo?

Solución. En el punto exacto $(0,1)$, una búsqueda lineal no genera movimiento porque el gradiente es cero. Primero se puede salir del punto de silla perturbando la iteración en la dirección de curvatura negativa, que para esta Hessiana es $\vec{v} = (1,-1)$. En efecto, para ε suficientemente pequeño,

$$f(\varepsilon, 1-\varepsilon) = f(0,1) - \frac{111}{4}\varepsilon^2 + O(\varepsilon^3) < f(0,1).$$

Desde ese punto se puede continuar con Newton modificado o quasi-Newton, usando una búsqueda lineal con retroceso y modificando la Hessiana o su aproximación para obtener una dirección de descenso. Así se evita aceptar pasos que aumenten la función y se puede seguir iterando hasta satisfacer el criterio de convergencia [3, Capítulos 4, 7 y 9].

(c) Mencione algunas de las principales desventajas y limitantes del método de Newton.

Solución. Entre sus principales limitantes se encuentran las siguientes [3, Capítulo 7]:

- Requiere calcular la Hessiana y resolver un sistema lineal en cada iteración, lo que puede ser costoso en problemas de muchas variables.
- La Hessiana puede ser singular o indefinida, de modo que el paso de Newton no exista o no sea una dirección de descenso.
- La convergencia es local y depende del punto inicial; si este se encuentra lejos del óptimo, el método puede divergir o converger a un punto estacionario que no sea mínimo.

Ejercicio 6 (20 puntos)**.** Sólo en este ejercicio se admite código, aún así es necesario desarrollar analíticamente todo el procedimiento. El costo del petróleo refinado enviado a Japón a través del Estrecho de Malaca en dólares por kilolitro se representa como la suma del costo del petróleo crudo, el seguro, las aduanas, el costo del flete del petróleo, el costo de carga y descarga, el costo del muelle, el costo de la tubería submarina, el costo de almacenamiento, el costo de la zona de tanques, el costo

de refinado y el costo de flete de los productos. Más precisamente, la función a minimizar está dada por

$$c(q,t) = c_c + c_i + c_x + \frac{2.09\times10^4\, t^{-0.3017}}{360} + \frac{1.064\times10^6\, t^{0.4925}}{52.47\, q\,(360)} + \frac{4.242\times10^4\, a\, t^{0.7952} + 1.813\, i\, p\,(nt+1.2q)^{0.861}}{52.47\, q\,(360)} + \frac{4.25\times10^3\, a\,(nt+1.2q)}{52.47\, q\,(360)} + \frac{5.042\times10^3\, q^{-0.1899}}{360} + \frac{0.1049\, q^{0.671}}{360},$$

donde

$a = 0.20$	gastos fijos anuales,
$c_c = 12.5$	precio del crudo, \$/kL,
$c_i = 0.50$	costo del seguro, \$/kL,
$c_x = 0.90$	costo de aduana, \$/kL,
$i = 0.10$	tipo de interés,
$n = 2$	número de puertos,
$p = 7000$	precio del terreno, \$/m^2,
$q =$	capacidad de la refinería, bbl/día,
$t =$	tamaño del petrolero, kL.

Calcule el costo mínimo del petróleo y el tamaño óptimo del petrolero t y de la refinería q usando los métodos de Newton y el método quasi-Newton. Utilice la conversión 1 kL = 6,29 bbl.

Solución.

El codigo completo de la solución explicado de manera detallada se encuentra en: Ejercicio 6, Tarea 3. Eduardo Alanís García.

Sustituimos los valores constantes y escribimos la función en una forma más compacta. Sea $S = nt + 1.2q$ y

$$c_0 = c_c + c_i + c_x = 13.9, \quad r = -0.3017, \quad s = 0.4925, \quad u = 0.7952, \quad v = 0.861, \quad w = -0.1899, \quad m = 0.671,$$

junto con

$$A = \frac{2.09\times10^4}{360}, \quad B = \frac{1.064\times10^6}{52.47(360)}, \quad C = \frac{4.242\times10^4 a}{52.47(360)}, \quad D = \frac{1.813ip}{52.47(360)}, \quad E = \frac{4.25\times10^3 a}{52.47(360)}, \quad F = \frac{5.042\times10^3}{360}, \quad G = \frac{0.1049}{360}.$$

Entonces

$$c(t,q) = c_0 + At^r + B\frac{t^s}{q} + C\frac{t^u}{q} + D\frac{S^v}{q} + E\frac{S}{q} + Fq^w + Gq^m.$$

Se buscan los puntos estacionarios resolviendo $c_t = 0$ y $c_q = 0$. Aplicando las reglas de potencias y cociente,

$$\begin{aligned} c_t &= Art^{r-1} + Bs\frac{t^{s-1}}{q} + Cu\frac{t^{u-1}}{q} + Dvn\frac{S^{v-1}}{q} + E\frac{n}{q} = 0, \\ c_q &= -B\frac{t^s}{q^2} - C\frac{t^u}{q^2} + D\left(-\frac{S^v}{q^2} + 1.2v\frac{S^{v-1}}{q}\right) \\ &\quad + E\left(-\frac{S}{q^2} + \frac{1.2}{q}\right) + Fwq^{w-1} + Gmq^{m-1} = 0. \end{aligned}$$

Para aplicar Newton se requiere la Hessiana. Sus entradas, obtenidas derivando nuevamente, son

$$\begin{aligned} c_{tt} &= Ar(r-1)t^{r-2} + Bs(s-1)\frac{t^{s-2}}{q} + Cu(u-1)\frac{t^{u-2}}{q} + Dv(v-1)n^2\frac{S^{v-2}}{q}, \\ c_{tq} &= -Bs\frac{t^{s-1}}{q^2} - Cu\frac{t^{u-1}}{q^2} + Dvn\left(-\frac{S^{v-1}}{q^2} + 1.2(v-1)\frac{S^{v-2}}{q}\right) - E\frac{n}{q^2}, \\ c_{qq} &= 2B\frac{t^s}{q^3} + 2C\frac{t^u}{q^3} \\ &\quad + D\left(2\frac{S^v}{q^3} - 2.4v\frac{S^{v-1}}{q^2} + 1.44v(v-1)\frac{S^{v-2}}{q}\right) \\ &\quad + E\left(2\frac{S}{q^3} - \frac{2.4}{q^2}\right) + Fw(w-1)q^{w-2} + Gm(m-1)q^{m-2}. \end{aligned}$$

El paso de Newton es

$$\begin{pmatrix} t_{k+1} \\ q_{k+1} \end{pmatrix} = \begin{pmatrix} t_k \\ q_k \end{pmatrix} - H_c(t_k, q_k)^{-1}\nabla c(t_k, q_k), \qquad H_c = \begin{pmatrix} c_{tt} & c_{tq} \\ c_{tq} & c_{qq} \end{pmatrix}.$$

[3, Capítulo 7]. Para el método quasi-Newton BFGS se actualiza la aproximación inversa de la Hessiana mediante

$$H_{k+1}^{-1} = (I - \rho_k s_k y_k^T)H_k^{-1}(I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T, \quad s_k = z_{k+1} - z_k, \quad y_k = \nabla c(z_{k+1}) - \nabla c(z_k), \quad \rho_k = \frac{1}{y_k^T s_k}.$$

[3, Capítulo 9]. En ambos métodos se utilizó una búsqueda lineal de Armijo para conservar $t, q > 0$ y disminuir el costo en cada paso [3, Capítulo 4]. Para el cálculo numérico definimos las coordenadas escaladas

$$\tau = \frac{t}{10^5\,\text{kL}}, \qquad \kappa = \frac{q}{10^5\,\text{bbl/día}}.$$

Así, $t = 10^5\tau$ kL y $q = 10^5\kappa$ bbl/día. Esta elección se debe a que los tamaños relevantes de t y q son del orden de 10^5 en sus unidades respectivas; al escalarlos, las coordenadas toman valores moderados: el punto inicial $(\tau_0, \kappa_0) = (0.5, 1)$ corresponde a $(t_0, q_0) = (50\,000$ kL, $100\,000$ bbl/día), y el óptimo queda cerca de $(4.22, 2.05)$. Las iteraciones dieron:

Método	t (kL)	q (bbl/día)	c (\$/kL)
Newton	421 572.2112	204 504.6473	18.02506914
BFGS	421 572.2065	204 504.6467	18.02506914

Newton convergió en 9 iteraciones y BFGS en 15; en ambos casos la norma del gradiente escalado fue menor que 10^{-9}. En la solución, los valores propios de la Hessiana escalada son aproximadamente 0.0151 y 0.2429, ambos positivos, lo que confirma que se trata de un mínimo local estricto. Este análisis local no demuestra por sí solo que el mínimo sea global.

Usando 1 kL = 6.29 bbl, el tamaño óptimo del petrolero también puede expresarse como

$$t^* = 421\,572.21 \text{ kL} \times 6.29 = 2\,651\,689.21 \text{ bbl}.$$

La capacidad óptima de la refinería, convertida a kilolitros por día, es

$$q^* = \frac{204\,504.65}{6.29} = 32\,512.66 \text{ kL/día}.$$

Por lo tanto, el costo mínimo calculado con la función tal como está escrita en el enunciado es aproximadamente 18.0251 dólares por kL, con petrolero de 421 572.21 kL y refinería de 204 504.65 bbl/día.

Recordemos que el codigo se encuentra de manera detallada en: Ejercicio 6, Tarea 3. Eduardo Alanís García. Pero el codigo en general fue el siguiente:

```
options(scipen = 999)

# Parámetros del modelo
a = 0.20
c_c = 12.5
c_i = 0.50
c_x = 0.90
i_rate = 0.10
n_ports = 2
p_land = 7000
conversion_bbl_per_kL = 6.29

# Exponentes
r_exp = -0.3017
s_exp = 0.4925
u_exp = 0.7952
v_exp = 0.861
w_exp = -0.1899
m_exp = 0.671

# Coeficientes de la función compacta
c0 = c_c + c_i + c_x
A = 2.09e4 / 360
B = 1.064e6 / (52.47 * 360)
C = 4.242e4 * a / (52.47 * 360)
D = 1.813 * i_rate * p_land / (52.47 * 360)
E = 4.25e3 * a / (52.47 * 360)
F = 5.042e3 / 360
G = 0.1049 / 360
```

```r

# Escalas de las variables
scale_t = 1e5 # kL
scale_q = 1e5 # bbl/día

# Función de costo c(t,q), en dólares por kL.
oil_cost = function(t, q) {
  if (length(t) != 1L || length(q) != 1L ||
      !is.finite(t) || !is.finite(q) || t <= 0 || q <= 0) {
    return(Inf)
  }

  S = n_ports * t + 1.2 * q
  c0 +
    A * t^r_exp +
    B * t^s_exp / q +
    C * t^u_exp / q +
    D * S^v_exp / q +
    E * S / q +
    F * q^w_exp +
    G * q^m_exp
}

# Gradiente analítico respecto de (t,q).
oil_gradient = function(t, q) {
  S = n_ports * t + 1.2 * q

  c_t = A * r_exp * t^(r_exp - 1) +
    B * s_exp * t^(s_exp - 1) / q +
    C * u_exp * t^(u_exp - 1) / q +
    D * v_exp * n_ports * S^(v_exp - 1) / q +
    E * n_ports / q

  c_q = -B * t^s_exp / q^2 -
    C * t^u_exp / q^2 +
    D * (-S^v_exp / q^2 + 1.2 * v_exp * S^(v_exp - 1) / q) +
    E * (-S / q^2 + 1.2 / q) +
    F * w_exp * q^(w_exp - 1) +
    G * m_exp * q^(m_exp - 1)

  c(c_t = c_t, c_q = c_q)
}

# Hessiana analítica respecto de (t,q).
oil_hessian = function(t, q) {
  S = n_ports * t + 1.2 * q

  c_tt = A * r_exp * (r_exp - 1) * t^(r_exp - 2) +
```

```
    B * s_exp * (s_exp - 1) * t^(s_exp - 2) / q +
    C * u_exp * (u_exp - 1) * t^(u_exp - 2) / q +
    D * v_exp * (v_exp - 1) * n_ports^2 * S^(v_exp - 2) / q

  c_tq = -B * s_exp * t^(s_exp - 1) / q^2 -
    C * u_exp * t^(u_exp - 1) / q^2 +
    D * v_exp * n_ports *
      (-S^(v_exp - 1) / q^2 +
         1.2 * (v_exp - 1) * S^(v_exp - 2) / q) -
    E * n_ports / q^2

  c_qq = 2 * B * t^s_exp / q^3 +
    2 * C * t^u_exp / q^3 +
    D * (2 * S^v_exp / q^3 -
           2.4 * v_exp * S^(v_exp - 1) / q^2 +
           1.44 * v_exp * (v_exp - 1) * S^(v_exp - 2) / q) +
    E * (2 * S / q^3 - 2.4 / q^2) +
    F * w_exp * (w_exp - 1) * q^(w_exp - 2) +
    G * m_exp * (m_exp - 1) * q^(m_exp - 2)

  matrix(c(c_tt, c_tq, c_tq, c_qq), nrow = 2L, byrow = TRUE,
         dimnames = list(c("t", "q"), c("t", "q")))
}

# Transformaciones entre variables físicas (t,q) y escaladas (tau,kappa).

to_physical = function(z) {
  c(t = scale_t * z[1], q = scale_q * z[2])
}

scaled_cost = function(z) {
  physical = to_physical(z)
  oil_cost(physical["t"], physical["q"])
}

scaled_gradient = function(z) {
  physical = to_physical(z)
  c(scale_t, scale_q) *
    oil_gradient(physical["t"], physical["q"])
}

scaled_hessian = function(z) {
  physical = to_physical(z)
  scale_matrix = diag(c(scale_t, scale_q))
  scale_matrix %*%
    oil_hessian(physical["t"], physical["q"]) %*%
    scale_matrix
}
```

```
126
127 # Búsqueda lineal de Armijo; descarta puntos fuera del dominio t,q > 0.
128 armijo_search = function(z, direction, gradient, value,
129                           c1 = 1e-4, contraction = 0.5,
130                           min_step = 2^-50) {
131   slope = sum(gradient * direction)
132   if (!is.finite(slope) || slope >= 0) {
133     return(NULL)
134   }
135
136   step = 1
137   while (step >= min_step) {
138     candidate = z + step * direction
139     if (all(is.finite(candidate)) && all(candidate > 0)) {
140       candidate_value = scaled_cost(candidate)
141       if (is.finite(candidate_value) &&
142           candidate_value <= value + c1 * step * slope) {
143         return(list(z = candidate, value = candidate_value, step = step))
144       }
145     }
146     step = contraction * step
147   }
148
149   NULL
150 }
151
152 newton_method = function(z0 = c(tau = 0.5, kappa = 1),
153                          tolerance = 1e-9, max_iterations = 100L) {
154   z = as.numeric(z0)
155
156   for (iteration in 0:max_iterations) {
157     value = scaled_cost(z)
158     gradient = scaled_gradient(z)
159     gradient_norm = sqrt(sum(gradient^2))
160
161     if (gradient_norm < tolerance) {
162       return(list(z = z, value = value, iterations = iteration,
163                   gradient_norm = gradient_norm, converged = TRUE))
164     }
165     if (iteration == max_iterations) {
166       break
167     }
168
169     hessian = scaled_hessian(z)
170     newton_step = tryCatch(
171       as.vector(solve(hessian, gradient)),
172       error = function(e) rep(NA_real_, 2L)
173     )
```

```
    direction = -newton_step

    # Si la Hessiana no produce descenso, usar -gradiente como respaldo.
    if (any(!is.finite(direction)) || sum(gradient * direction) >= 0) {
      direction = -gradient
    }

    search = armijo_search(z, direction, gradient, value)
    if (is.null(search)) {
      stop("Newton: la búsqueda de Armijo no encontró un paso aceptable.")
    }
    z = search$z
  }

  list(z = z, value = scaled_cost(z), iterations = max_iterations,
       gradient_norm = sqrt(sum(scaled_gradient(z)^2)), converged = FALSE)
}

bfgs_method = function(z0 = c(tau = 0.5, kappa = 1),
                       tolerance = 1e-9, max_iterations = 200L) {
  z = as.numeric(z0)
  inverse_hessian = diag(2L)

  for (iteration in 0:max_iterations) {
    value = scaled_cost(z)
    gradient = scaled_gradient(z)
    gradient_norm = sqrt(sum(gradient^2))

    if (gradient_norm < tolerance) {
      return(list(z = z, value = value, iterations = iteration,
                  gradient_norm = gradient_norm, converged = TRUE))
    }
    if (iteration == max_iterations) {
      break
    }

    direction = -as.vector(inverse_hessian %*% gradient)
    if (any(!is.finite(direction)) || sum(gradient * direction) >= 0) {
      inverse_hessian = diag(2L)
      direction = -gradient
    }

    search = armijo_search(z, direction, gradient, value)
    if (is.null(search)) {
      stop("BFGS: la búsqueda de Armijo no encontró un paso aceptable.")
    }

    z_next = search$z
```

```
    gradient_next = scaled_gradient(z_next)
    s = z_next - z
    y = gradient_next - gradient
    ys = sum(y * s)

    # Actualización BFGS de la Hessiana inversa aproximada.
    if (is.finite(ys) && ys > 1e-12 * sqrt(sum(s^2) * sum(y^2))) {
      rho = 1 / ys
      identity = diag(2L)
      left = identity - rho * tcrossprod(s, y)
      right = identity - rho * tcrossprod(y, s)
      inverse_hessian = left %*% inverse_hessian %*% right +
        rho * tcrossprod(s, s)
    } else {
      inverse_hessian = diag(2L)
    }

    z = z_next
  }

  list(z = z, value = scaled_cost(z), iterations = max_iterations,
       gradient_norm = sqrt(sum(scaled_gradient(z)^2)), converged = FALSE)
}

report_result = function(method_name, result) {
  if (!result$converged) {
    warning(method_name, " no alcanzó la tolerancia solicitada.")
  }

  physical = to_physical(result$z)
  eigenvalues = eigen(scaled_hessian(result$z),
                      symmetric = TRUE, only.values = TRUE)$values

  cat("\n", method_name, "\n", sep = "")
  cat(sprintf("Iteraciones: %d\n", result$iterations))
  cat(sprintf("tau = %.10f, kappa = %.10f\n", result$z[1], result$z[2]))
  cat(sprintf("t* = %.4f kL (%.4f bbl)\n",
              physical["t"], physical["t"] * conversion_bbl_per_kL))
  cat(sprintf("q* = %.4f bbl/día (%.4f kL/día)\n",
              physical["q"], physical["q"] / conversion_bbl_per_kL))
  cat(sprintf("Costo = %.10f dólares/kL\n", result$value))
  cat(sprintf("Norma del gradiente escalado = %.3e\n",
              result$gradient_norm))
  cat("Valores propios de la Hessiana escalada:",
      paste(sprintf("%.8f", eigenvalues), collapse = ", "), "\n")
  if (all(eigenvalues > 0)) {
    cat("La Hessiana es positiva definida: mínimo local estricto.\n")
  }
```

```
}

# Punto inicial del ejercicio,
z0 = c(tau = 0.5, kappa = 1)
newton_result = newton_method(z0)
bfgs_result = bfgs_method(z0)

report_result("Newton", newton_result)
report_result("BFGS", bfgs_result)
```

Conclusiones

En el Ejercicio 1, $(0, 0)$ es el único punto crítico y es un mínimo estricto global, aun cuando la Hessiana es singular. En el Ejercicio 2, el mínimo global está en $(-2, 1)$ con $f = -3$; la búsqueda univariante converge y la recta que une P_1 y P_2 pasa por el óptimo. En el Ejercicio 3, $(1/3, 1/3, 1/3)$ es el mínimo restringido global, con $h = 1/3$. En el Ejercicio 4, el gradiente descendente con $\alpha = 0.1$ converge a $(32/7, 22/7)$. En el Ejercicio 5, $(0, 1)$ es un punto silla donde Newton se estanca, por lo que se requiere perturbar la iteración o modificar la Hessiana. En el Ejercicio 6, Newton (9 iteraciones) y BFGS (15) coinciden en un mínimo local estricto de aproximadamente 18.0251 dólares por kL, con $t^* \approx 421\,572.21$ kL y $q^* \approx 204\,504.65$ bbl/día. Newton converge en menos iteraciones pero exige calcular la Hessiana, mientras que BFGS la aproxima; no se demostró que el mínimo sea global.

Referencias

[1] Briceyda B. Delgado. Unidad 3: Cálculo multivariable. Material de clase, diapositivas, October 2026. Fecha visible en el documento: 1 de octubre de 2026.

[2] James Stewart. *Multivariable Calculus*. Cengage Learning, 7 edition, 2012. ISBN 9781133384533. URL https://www.cengage.com/c/ebook-multivariable-calculus-7e-stewart/9781133384533/.

[3] Jorge Nocedal and Stephen J. Wright. *Numerical Optimization*. Springer Series in Operations Research and Financial Engineering. Springer, New York, NY, 2 edition, 2006. doi: 10.1007/978-0-387-40065-5. URL https://link.springer.com/book/10.1007/978-0-387-40065-5.

[4] Luke Tierney. Computer intensive statistics stat 7400: Optimization. Notas de curso en línea, Universidad de Iowa, 2023. URL https://homepage.divms.uiowa.edu/~luke/classes/STAT7400-2023/_book/optimization.html#gradient-descent-methods.

[5] Multidimensional-newton. Apunte en PDF del curso 18.06, Massachusetts Institute of Technology, 2017. URL https://web.mit.edu/18.06/www/Spring17/Multidimensional-Newton.pdf. Fecha indicada en el documento: 7 de septiembre de 2017.